

Introdução à Inferência Estatística

10.1 Introdução

Vimos, na Parte 1, como resumir descritivamente variáveis associadas a um ou mais conjuntos de dados. Na Parte 2, construímos modelos teóricos (probabilísticos), identificados por parâmetros, capazes de representar adequadamente o comportamento de algumas variáveis. Nesta terceira parte apresentaremos os argumentos estatísticos para fazer afirmações sobre as características de uma população, com base em informações dadas por amostras.

O uso de informações de uma amostra para concluir sobre o todo faz parte da atividade diária da maioria das pessoas. Basta observar como uma cozinheira verifica se o prato que ela está preparando tem ou não a quantidade adequada de sal. Ou, ainda, quando um comprador, após experimentar um pedaço de laranja numa banca de feira, decide se vai comprar ou não as laranjas. Essas são decisões baseadas em procedimentos amostrais.

Nosso objetivo nos capítulos seguintes é procurar dar a conceituação formal a esses princípios intuitivos do dia-a-dia para que possam ser utilizados cientificamente em situações mais complexas.

10.2 População e Amostra

Nos capítulos anteriores, tomamos conhecimento de alguns modelos probabilísticos que procuram medir a variabilidade de fenômenos casuais de acordo com suas ocorrências: as distribuições de probabilidades de variáveis aleatórias (qualitativas ou quantitativas). Na prática, freqüentemente o pesquisador tem alguma idéia sobre a forma da distribuição, mas não dos valores exatos dos parâmetros que a especificam.

Por exemplo, parece razoável supor que a distribuição das alturas dos brasileiros adultos possa ser representada por um modelo normal (embora as alturas não possam assumir valores negativos). Mas essa afirmação não é suficiente para determinar qual a distribuição normal correspondente; precisaríamos conhecer os parâmetros (média e variância) dessa normal para que ela ficasse completamente especificada. O propósito do pesquisador seria, então, descobrir (estimar) os parâmetros da distribuição para sua posterior utilização.

Se pudéssemos medir as alturas de todos os brasileiros adultos, teríamos meios de obter sua distribuição exata e, daí, produzir os correspondentes parâmetros. Mas nessa situação não teríamos necessidade de usar a inferência estatística!

Raramente se consegue obter a distribuição exata de alguma variável, ou porque isso é muito dispendioso, ou muito demorado ou às vezes porque consiste num processo destrutivo. Por exemplo, se estivéssemos observando a durabilidade de lâmpadas e testássemos todas até queimarem, não restaria nenhuma para ser vendida. Assim, a solução é selecionar parte dos elementos (amostra), analisá-la e *inferir* propriedades para o todo (população).

Outras vezes estamos interessados em explorar relações entre variáveis envolvendo experimentos mais complexos, para a obtenção dos dados. Por exemplo, gostaríamos de obter resposta para a seguinte indagação: a altura que um produto é colocado na gôndola de um supermercado afeta a sua venda? Observe que para responder a questão precisamos obter dados de vendas com o produto oferecido em diferentes alturas, e que essas vendas sejam controladas para evitar interferências de outros fatores que não a altura. Nesse caso não existe claramente um conjunto de *todos* os elementos para os quais pudéssemos encontrar os parâmetros populacionais. Recorrer a modelos para descrever o todo (população) facilita a identificação e solução do problema. Nesse exemplo, supondo que as vendas V_h do produto oferecido na altura h ($h = 1$ representando *baixo*, $h = 2$ representando *meio* e $h = 3$ representando *alto*) segue uma distribuição próxima a normal, ou seja, $V_h \sim N(\mu_h, \sigma^2)$, o nosso problema passa a ser o de verificar, por meio de dados coletados do experimento (amostra), se existe evidência de igualdade das médias μ_1 , μ_2 e μ_3 . Note que, em nossa formulação do problema, supusemos que as três situações de alturas resultam observações com a mesma variância σ^2 . Essa suposição poderia ser modificada.

Soluções de questões como as apresentadas acima são o objeto da *inferência estatística*.

Dois conceitos básicos são, portanto, necessários para o desenvolvimento da Inferência Estatística: população e amostra.

Definição. *População* é o conjunto de todos os elementos ou resultados sob investigação. *Amostra* é qualquer subconjunto da população.

Vejamos outros exemplos para melhor entender essas definições.

Exemplo 10.1. Consideremos uma pesquisa para estudar os salários dos 500 funcionários da Companhia MB. Seleciona-se uma amostra de 36 indivíduos, e anotam-se os seus salários. A variável aleatória a ser observada é “salário”. A população é formada pelos 500 funcionários da companhia. A amostra é constituída pelos 36 indivíduos selecionados. Na realidade, estamos interessados nos salários, portanto, para sermos mais precisos, devemos considerar como a população os 500 salários correspondentes aos 500 funcionários. Conseqüentemente, a amostra será formada pelos 36 salários dos indivíduos selecionados. Podemos estudar a distribuição dos

salários na amostra, e esperamos que esta reflita a distribuição de todos os salários, desde que a amostra tenha sido escolhida com cuidado.

Exemplo 10.2. Queremos estudar a proporção de indivíduos na cidade A que são favoráveis a certo projeto governamental. Uma amostra de 200 pessoas é sorteada, e a opinião de cada uma é registrada como sendo a favor ou contra o projeto. A população consiste de todos os moradores da cidade, e a amostra é formada pelas 200 pessoas selecionadas. Podemos, como foi visto no Capítulo 5, definir a variável X , que toma o valor 1, se a resposta de um morador for favorável, e o valor 0, se a resposta for contrária ao projeto. Assim, nossa população pode ser reduzida à distribuição de X , e a amostra será constituída de uma seqüência de 200 zeros e uns.

Exemplo 10.3. O interesse é investigar a duração de vida de um novo tipo de lâmpada, pois acreditamos que ela tenha uma duração maior do que as fabricadas atualmente. Então, 100 lâmpadas do novo tipo são deixadas acesas até queimarem. A duração em horas de cada lâmpada é registrada. Aqui, a variável é a duração em horas de cada lâmpada. A população é formada por todas as lâmpadas fabricadas ou que venham a ser fabricadas por essa empresa, com o mesmo processo. A amostra é formada pelas 100 lâmpadas selecionadas. Note-se que nesse caso não podemos observar a população, ou seja, a distribuição da duração de vida das lâmpadas na população, pois isso corresponderia a queimar todas as lâmpadas. Assim, em alguns casos, não podemos observar a população toda, pois isso significaria danificar (ou destruir) todos os elementos da população. Esse problema geralmente é contornado atribuindo-se um modelo teórico para a distribuição da variável populacional.

Exemplo 10.4. Em alguns casos, fazemos suposições mais precisas sobre a população (ou sobre a variável definida para os elementos da população). Digamos que X represente o peso real de pacotes de café, enchidos automaticamente por uma máquina. Sabe-se que a distribuição de X pode ser representada por uma normal, com parâmetros μ e σ^2 desconhecidos. Sorteamos 100 pacotes e medimos seus pesos. A população será o conjunto de todos os pacotes enchidos ou que virão a ser enchidos pela máquina, e que pode ser suposta como normal. A amostra será formada pelas 100 medidas obtidas dos pacotes selecionados, que pode ser pensada como constituída de 100 observações feitas de uma distribuição normal. Veremos mais adiante como tal amostra pode ser obtida.

Exemplo 10.5. Para investigar a “honestidade” de uma moeda, nós a lançamos 50 vezes e contamos o número de caras observadas. A população, como no caso do Exemplo 10.2, pode ser considerada como tendo a distribuição da variável X , assumindo o valor 1, com probabilidade p , se ocorrer cara, e assumindo o valor 0, com probabilidade $1 - p$, se ocorrer coroa. Ou seja, a população pode ser considerada como tendo distribuição de Bernoulli com parâmetro p . A variável ficará completamente especificada quando conhecermos p . A amostra será uma seqüência de 50 números zeros ou uns.

Exemplo 10.6. Há razões para supor que o tempo Y de reação a certo estímulo visual dependa da idade do indivíduo (esse exemplo será usado nos Capítulos 15 e 16). Suponha, ainda, que essa *dependência seja linear*. Para verificarmos se essa suposição é verdadeira, obtiveram-se 20 dados da seguinte maneira: 20 pessoas foram selecionadas, sendo 10 homens e 10 mulheres. Dentro de cada grupo de homens e mulheres foram selecionadas duas pessoas das seguintes faixas de idade: 20, 25, 30, 35 e 40 anos. Cada pessoa foi submetida ao teste e seu tempo de reação y foi medido. A população poderia ser considerada como formada por todas aquelas pessoas que viessem a ser submetidas ao teste, segundo o sexo e a idade. A amostra é formada pelas 20 medidas, que estão apresentadas na Tabela 15.1.

Observações:

- (i) Os três últimos exemplos mostram uma ampliação do conceito definido de população, ou seja, designamos agora a população como sendo a função probabilidade ou função densidade de probabilidade de uma v.a. X , modelando a característica de interesse. Esse artifício simplifica substancialmente o problema estatístico, exigindo no entanto uma proposta de modelo para a variável X . Nesses casos simplificaremos a linguagem, dizendo: “seja a população $f(x)$ ”. Por exemplo, “considere a população das alturas $X \sim N(\mu, \sigma^2)$ ”.
- (ii) Essa abordagem, por meio da distribuição de probabilidades, utiliza muitas vezes o conceito de população infinita contínua, exigindo um tratamento matemático mais cuidadoso. É mais fácil apresentar os problemas e soluções por meio de populações finitas. É o que faremos muitas vezes. Entretanto, é importante que o estudante aprenda a trabalhar com o conceito de modelo, explorando o caso de “população $f(x)$ ”.

10.3 Problemas de Inferência

Como já dissemos anteriormente, o objetivo da Inferência Estatística é produzir afirmações sobre dada característica da população, na qual estamos interessados, a partir de informações colhidas de uma parte dessa população. Essa característica na população pode ser representada por uma variável aleatória. Se tivéssemos informação completa sobre a função de probabilidade, no caso discreto, ou sobre a função densidade de probabilidade, no caso contínuo, da variável em questão, não teríamos necessidade de escolher uma amostra. Toda a informação desejada seria obtida por meio da distribuição da variável, usando-se a teoria estudada anteriormente.

Mas isso raramente acontece. Ou não temos qualquer informação a respeito da variável, ou ela é apenas parcial. Podemos admitir, como no exemplo das alturas de brasileiros adultos, que ela siga uma distribuição normal, mas desconhecemos os parâmetros que a caracterizam (média, variância). Em outros casos, podemos ter uma idéia desses parâmetros, mas desconhecemos a forma da curva. Ou ainda, o que é muito freqüente, não possuímos informações nem sobre os parâmetros, nem sobre a forma da curva. Em todos os casos, o uso de uma amostra nos ajudaria a formar uma opinião sobre o comportamento da variável (população).

Embora a identificação e a descrição da população sejam fundamentais no processo inferencial, é comum os pesquisadores dedicarem mais atenção em descrever a amostra do que a população para a qual serão feitas as afirmações. É imprescindível que se explicita claramente a população investigada.

Neste livro estaremos mais preocupados em trabalhar com populações descritas por modelos do que com populações finitas identificadas por elementos portadores de uma característica de interesse. Portanto, na maioria das vezes, iremos nos referir à “população X ”, significando que a variável de interesse X , definida sobre a população-alvo, segue uma distribuição $f(x)$. Nosso problema de interesse passaria a ser o de fazer afirmações sobre a forma da curva e seus parâmetros.

Alguns exemplos simples nos darão uma noção dos tipos de formulações e problemas que a inferência estatística pode nos ajudar a resolver.

Exemplo 10.5. (continuação) Voltemos ao exemplo da moeda. Indicando por X o número de caras obtidas depois de lançar a moeda 50 vezes, sabemos que, se tomados alguns cuidados quando do lançamento, X segue uma distribuição binomial, ou seja, $X \sim b(50, p)$. Esse modelo é válido, admitindo-se ou não a “honestidade” da moeda, isto é, sendo ou não $p = 1/2$. Lançada a moeda, vamos supor que tenham ocorrido 36 caras. Esse resultado traz evidência de que a moeda seja “honesta”? Para tomarmos uma decisão, podemos partir do princípio de que a moeda não favorece nem cara nem coroa, isto é, $p = 1/2$. Com essa informação e com o modelo binomial, podemos encontrar qual a probabilidade de se obterem 36 caras ou mais, e esse resultado nos ajudaria a tomar uma decisão. Suponha que a decisão foi rejeitar a “honestidade” da moeda: qual é a melhor estimativa para p , baseando-se no resultado observado?

Descrevemos aí os dois problemas básicos da Inferência Estatística: o primeiro é chamado *teste de hipóteses*, e o segundo, *estimação*. Nos capítulos seguintes, esses problemas serão abordados com mais detalhes.

Exemplo 10.4. (continuação) Às vezes, o modelo teórico associado ao problema não é tão evidente. No caso da máquina de encher pacotes de café automaticamente, digamos que ela esteja regulada para enchê-los segundo uma distribuição normal com média 500 gramas e desvio padrão de 100 gramas, isto é, $X \sim N(500, 20^2)$. Sabemos também que, às vezes, a máquina desregula-se e, quando isso acontece, o único parâmetro que se altera é a média, permanecendo a mesma variância. Para manter a produção sob controle, iremos colher uma amostra de 100 pacotes e pesá-los. Como essa amostra nos ajudará a tomar uma decisão? Parece razoável, nesse caso, usarmos a média $\bar{x}$ da amostra como informação pertinente para uma decisão. Mesmo que a máquina esteja regulada, dificilmente $\bar{x}$ será igual a 500 gramas, dado que os pacotes apresentam certa variabilidade no peso. Mas se $\bar{x}$ não se afastar muito de 500 gramas, não existirão razões para suspeitarmos da qualidade do procedimento de produção. Só iremos pedir uma revisão se $\bar{x} - 500$, em valor absoluto, for “muito grande”.

O problema que se apresenta agora é o de decidir o que é próximo ou distante de 500 gramas. Se o mesmo procedimento de colher a amostra de 100 pacotes fosse repetido um número muito grande de vezes, sob a condição de a máquina estar regulada, teríamos idéia do comportamento da v.a. $\bar{x}$, e saberíamos dizer se aquele valor observado é ou não um evento raro de ocorrer. Caso o seja, é mais fácil suspeitar da regulagem da máquina do que do acaso.

Vemos, então, a importância nesse caso de se conhecer as propriedades da distribuição da variável $\bar{x}$.

Exemplo 10.6. (continuação) A descrição matemática da v.a. Y : tempo de reação ao estímulo é um pouco mais complexa. Podemos supor que esse tempo, para uma dada idade x , seja uma v.a. com distribuição normal, com média dependendo da idade x , ou seja, podemos escrever

$$Y \sim N(\mu(x), \sigma^2).$$

A *linearidade* expressa no problema pode ser incluída na média $\mu(x)$ da seguinte maneira:

$$\mu(x) = \alpha + \beta x.$$

Voltaremos a esse modelo no Capítulo 16. Outra maneira de escrever as duas relações anteriores é

$$Y | x \sim N(\alpha + \beta x; \sigma^2).$$

Leia-se “ Y dado x ”.

Podemos, por exemplo, estimar os parâmetros α e β , baseados na amostra de 20 dados. Ou podemos querer investigar a possibilidade de β ser igual a zero, significando que a idade não afeta o tempo de reação. Novamente, os dois principais problemas de inferência aparecem aqui: estimação e teste de uma hipótese. Um outro problema importante em inferência é o de *previsão*. Por exemplo, considerando um grupo de pessoas de 40 anos, poderemos prever com o modelo acima qual será o respectivo tempo de reação.

Repetir um mesmo experimento muitas vezes, sob as mesmas condições, nem sempre é possível, mas em determinadas condições é possível determinar teoricamente o comportamento de algumas medidas feitas na amostra, como por exemplo a média. Mas isso depende, em grande parte, do procedimento (plano) adotado para selecionar a amostra. Assim, em problemas envolvendo amostras, antes de tomarmos uma decisão, teríamos de responder a quatro perguntas:

- (a) Qual a população a ser amostrada?
- (b) Como obter os dados (a amostra)?
- (c) Que informações pertinentes (estatísticas) serão retiradas da amostra?
- (d) Como se comporta(m) a(s) estatística(s) quando o mesmo procedimento de escolher a amostra é usado numa população conhecida?

Nas seções e capítulos subseqüentes tentaremos responder a essas perguntas.

10.4 Como Selecionar uma Amostra

As observações contidas em uma amostra são tanto mais informativas sobre a população quanto mais conhecimento explícito ou implícito tivermos dessa mesma população. Por exemplo, a análise da quantidade de glóbulos brancos obtida de algumas gotas de sangue da ponta do dedo de um paciente dará uma idéia geral da quantidade dos glóbulos brancos no corpo todo, pois sabe-se que a distribuição dos glóbulos brancos é homogênea, e de qualquer lugar que se tivesse retirado a amostra ela seria “representativa”. Mas nem sempre a escolha de uma amostra adequada é imediata. Por exemplo, voltando ao Exemplo 10.2, para o qual queríamos obter uma amostra de habitantes para saber a opinião sobre um projeto governamental, escolhendo intencionalmente uma amostra de 200 indivíduos moradores de certa região beneficiada pelo projeto, saberemos de antemão que o resultado conterá um *viés de seleção*. Isto é, na amostra, a proporção de pessoas favoráveis ao projeto deverá ser maior do que no todo, donde a importância da adoção de procedimentos científicos que permitam fazer inferências adequadas sobre a população.

A maneira de se obter a amostra é tão importante, e existem tantos modos de fazê-lo, que esses procedimentos constituem especialidades dentro da Estatística, sendo *Amostragem* e *Planejamento de Experimentos* as duas mais conhecidas. Poderíamos dividir os procedimentos científicos de obtenção de dados amostrais em três grandes grupos:

- (a) *Levantamentos Amostrais*, nos quais a amostra é obtida de uma população bem definida, por meio de processos bem protocolados e controlados pelo pesquisador. Podemos, ainda, subdividi-los em dois subgrupos: levantamentos probabilísticos e não-probabilísticos. O primeiro reúne todas aquelas técnicas que usam mecanismos aleatórios de seleção dos elementos de uma amostra, atribuindo a cada um deles uma probabilidade, conhecida *a priori*, de pertencer à amostra. No segundo grupo estão os demais procedimentos, tais como: amostras intencionais, nas quais os elementos são selecionados com o auxílio de especialistas, e amostras de voluntários, como ocorre em alguns testes sobre novos medicamentos e vacinas. Ambos os procedimentos têm suas vantagens e desvantagens. A grande vantagem das amostras probabilísticas é medir a precisão da amostra obtida, baseando-se no resultado contido na própria amostra. Tais medidas já são bem mais difíceis para os procedimentos do segundo grupo.

Estão nessa situação os Exemplos 10.1 (conhecer os salários da Cia. MB), 10.2 (identificar a proporção de indivíduos favoráveis ao projeto), 10.4 (pesos dos pacotes de café) etc.

- (b) *Planejamento de Experimentos*, cujo principal objetivo é o de analisar o efeito de uma variável sobre outra. Requer, portanto, interferências do pesquisador sobre o ambiente em estudo (população), bem como o controle de fatores externos, com o intuito de medir o efeito desejado. Podemos citar como exemplos aquele já citado sobre a altura de um produto na gôndola de um supermercado afetar as vendas e o Exemplo 10.6. Em ensaios clínicos em medicina, esse tipo de estudo é bastante usado, como por exemplo para testar se um novo medicamento é eficaz ou não para curar certa doença.
- (c) *Levantamentos Observacionais*: aqui, os dados são coletados sem que o pesquisador tenha controle sobre as informações obtidas, exceto eventualmente sobre possíveis

erros grosseiros. As séries de dados temporais são exemplos típicos desses levantamentos. Por exemplo, queremos prever as vendas de uma empresa em função de vendas passadas. O pesquisador não pode selecionar dados, esses são as vendas efetivamente ocorridas. Nesses casos, a especificação de um modelo desempenha um papel crucial na ligação entre dados e população.

No caso de uma série temporal, o modelo subjacente é o de *processo estocástico*; podemos pensar que a série efetivamente observada é uma das *infinitas possíveis realizações* desse processo. A população hipotética aqui seria o conjunto de todas essas realizações, e a série observada seria a amostra. Veja Morettin e Toloi (2006) para mais informações.

Neste livro iremos nos concentrar principalmente em levantamentos amostrais e, mais ainda, num caso simples de amostragem probabilística, a *amostragem aleatória simples, com reposição*, a ser designada por AAS. O leitor poderá consultar Bussab e Bolfarine (2005) para obter mais detalhes sobre outros procedimentos amostrais. Um breve resumo sobre alguns planos é dado no Problema 37. Noções sobre planejamento de experimentos podem ser vistas em Peres e Saldiva (1982).

Problemas

1. Dê sua opinião sobre os tipos de problemas que surgiriam nos seguintes planos amostrais:
 - (a) Para investigar a proporção dos operários de uma fábrica favoráveis à mudança do início das atividades das 7h para as 7h30, decidiu-se entrevistar os 30 primeiros operários que chegassem à fábrica na quarta-feira.
 - (b) Mesmo procedimento, só que o objetivo é estimar a altura média dos operários.
 - (c) Para estimar a porcentagem média da receita municipal investida em lazer, enviaram-se questionários a todas as prefeituras, e a amostra foi formada pelas prefeituras que enviaram as respostas.
 - (d) Para verificar o fato de oferecer brindes nas vendas de sabão em pó, tomaram-se quatro supermercados na zona sul e quatro na zona norte de uma cidade. Nas quatro lojas da zona sul, o produto era vendido com brinde, enquanto nas outras quatro era vendido sem brinde. No fim do mês, compararam-se as vendas da zona sul com as da zona norte.
2. Refazer o Problema 7 do Capítulo 8.

10.5 Amostragem Aleatória Simples

A amostragem aleatória simples é a maneira mais fácil para selecionarmos uma amostra probabilística de uma população. Além disso, o conhecimento adquirido com esse procedimento servirá de base para o aprendizado e desenvolvimento de outros procedimentos amostrais, planejamento de experimentos, estudos observacionais etc. Começamos introduzindo o conceito de AAS de uma população finita, para a qual temos uma listagem de todas as N unidades elementares. Podemos obter uma amostra nessas condições, escrevendo cada elemento da população num cartão, misturando-os numa urna e sorteando tantos cartões quantos desejarmos na amostra. Esse procedimento torna-se inviável quando a população é muito grande. Nesse caso, usa-se um processo alternativo,

no qual os elementos são numerados e em seguida sorteados por meio de uma tabela de números aleatórios (veja a sua utilização em Problemas e Complementos) ou por meio do uso de computadores, que podem gerar números aleatórios (veja o Capítulo 9).

Utilizando-se um procedimento aleatório, sorteia-se um elemento da população, sendo que todos os elementos têm a mesma probabilidade de ser selecionados. Repete-se o procedimento até que sejam sorteadas as n unidades da amostra.

Podemos ter uma AAS *com reposição*, se for permitido que uma unidade possa ser sorteada mais de uma vez, e *sem reposição*, se a unidade sorteada for removida da população.

Do ponto de vista da quantidade de informação contida na amostra, amostrar sem reposição é mais adequado. Contudo, a amostragem com reposição conduz a um tratamento teórico mais simples, pois ela implica que tenhamos *independência* entre as unidades selecionadas. Essa independência facilita o desenvolvimento das propriedades dos estimadores que serão considerados.

Portanto, para o restante do livro, o plano amostral considerado será o de *amostragem aleatória simples com reposição*, que denotaremos simplesmente por AAS.

Vejamos com algum detalhe o significado mais preciso de uma amostra.

Exemplo 10.7. Considere o Problema 2 acima, em que colhemos todas as amostras possíveis de tamanho 2, com reposição, da população $\{1, 3, 5, 5, 7\}$. Defina a variável X : valor assumido pelo elemento na população. Então, a distribuição de X é dada pela Tabela 10.1.

Tabela 10.1: Distribuição da v.a. X para o Problema 2.

x	1	3	5	7
$P(X = x)$	1/5	1/5	2/5	1/5

Indicando por X_1 o número selecionado na primeira extração e por X_2 o número selecionado na segunda extração, vimos que era possível escrever a distribuição conjunta do par (X_1, X_2) . Veja também a Tabela 10.2. Além disso, as distribuições marginais de X_1 e X_2 são independentes e iguais à distribuição de X . Desse modo, cada uma das 25 possíveis amostras de tamanho 2 que podemos extrair dessa população corresponde a observar uma particular realização da v.a. (X_1, X_2) , com X_1 e X_2 independentes e $P(X_1 = x) = P(X_2 = x) = P(X = x)$, para todo x . Essa é a caracterização de amostra casual simples que iremos usar neste livro.

Definição. Uma amostra aleatória simples de tamanho n de uma variável aleatória X , com dada distribuição, é o conjunto de n variáveis aleatórias independentes $X_1, X_2, \dots, X_n$, cada uma com a mesma distribuição de X .

Ou seja, a amostra será a n -upla ordenada $(X_1, X_2, \dots, X_n)$, onde X_i indica a observação do i -ésimo elemento sorteado.

Quando a população é caracterizada por uma distribuição de probabilidades, o modo mais simples para sortear uma AAS é usar os procedimentos de simulação estudados no Capítulo 9. O processo de simular uma observação de uma distribuição especificada por seus parâmetros nada mais é do que retirar uma AAS de tamanho um da população. Desse modo, para retirar uma AAS (com reposição) de n indivíduos da população X , basta gerar n números aleatórios independentes dessa distribuição.

Exemplo 10.8. Vamos retirar uma AAS de 5 alturas (em cm) de uma população de mulheres cujas alturas X seguem a distribuição $N(167; 25)$.

Usando-se, por exemplo, o gerador de números aleatórios do Excel, fornecendo os parâmetros $\mu = 167$ e $\sigma = 5$, além do tamanho da amostra $n = 5$, obtemos os valores:

$$x_1 = 165, \quad x_2 = 161, \quad x_3 = 168, \quad x_4 = 173, \quad x_5 = 173.$$

Note que, se você for gerar uma tal amostra, poderá obter valores diferentes desses. Observe, também, que o primeiro elemento a ser observado pode ser qualquer valor da população simulada $N(167; 25)$. Desse modo, indicando por X_1 o valor observado na primeira extração, concluímos que $X_1 \sim N(167; 25)$. Como a geração do segundo número aleatório é feita independentemente do segundo, resulta que a v.a. X_2 , valor observado na segunda extração, também segue uma distribuição $N(167; 25)$, e assim por diante.

Diante do exposto, vemos que continua válida a definição de AAS dada acima, quando a amostra é retirada de uma população referenciada pela sua distribuição de probabilidades.

No caso de uma população X contínua, com f.d.p. $f(x)$, a f.d.p. conjunta da amostra $(X_1, X_2, \dots, X_n)$, segundo o que vimos no Capítulo 8, será dada por

$$f(x_1, x_2, \dots, x_n) = f_1(x_1)f_2(x_2) \dots f_n(x_n),$$

onde $f_i(x_i)$ denota a distribuição (marginal) de X_i , $i = 1, \dots, n$.

Antes de prosseguirmos, seria interessante fazer uma comparação da inferência estatística com o processo de simulação da população.

Podemos imaginar que qualquer característica X de interesse seja produzida por um “programa” (modelo) de gerador de números aleatórios, e que somente o “proprietário” (natureza) desse programa é que conhece a forma da distribuição de X , os valores dos parâmetros etc. relacionados ao programa. Quando “obtemos” a amostra, estamos apenas observando o resultado da simulação, não conhecemos nada do processo gerador dos dados. O objetivo da inferência estatística é fornecer critérios para nos ajudar a descobrir a forma da distribuição e/ou parâmetros usados pelo “proprietário”. Bons indicadores desses valores nos ajudam a entender melhor os fenômenos e fazer previsões para futuras observações.

Daqui para frente, a menos que esteja especificada de outra maneira, sempre que mencionarmos a palavra amostra, estaremos entendendo a amostra obtida pelo processo probabilístico AAS, ou seja, o vetor aleatório $(X_1, X_2, \dots, X_n)$ definido acima.

Problemas

3. A distribuição do número de filhos, por família, de uma zona rural está no quadro abaixo.

Nº de filhos	Porcentagem
0	10
1	20
2	30
3	25
4	15
Total	100

- Sugira um procedimento para sortear uma observação ao acaso dessa população.
- Dê, na forma de uma tabela de dupla entrada, as possíveis amostras do número de filhos de duas famílias que podem ser sorteadas e as respectivas probabilidades de ocorrência.
- Se fosse escolhida uma amostra de tamanho 4, qual seria a probabilidade de se observar a quádrupla ordenada $(2, 3, 3, 1)$?

10.6 Estatísticas e Parâmetros

Obtida uma amostra, muitas vezes desejamos usá-la para produzir alguma característica específica. Por exemplo, se quisermos calcular a média da amostra $(X_1, X_2, \dots, X_n)$, esta será dada por

$$\bar{X} = \frac{1}{n} \{X_1 + X_2 + \dots + X_n\}.$$

É fácil verificar que $\bar{X}$ é também uma variável aleatória. Podemos também estar interessados em qualquer outra característica da amostra, que será sempre uma função do vetor aleatório $(X_1, \dots, X_n)$.

Definição. Uma *estatística* é uma característica da amostra, ou seja, uma estatística T é uma função de $X_1, X_2, \dots, X_n$.

As estatísticas mais comuns são:

$$\bar{X} = 1/n \sum_{i=1}^n X_i : \text{média da amostra,}$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 : \text{variância da amostra,}$$

$$X_{(1)} = \min (X_1, X_2, \dots, X_n) : \text{o menor valor da amostra,}$$

$X_{(n)} = \max (X_1, X_2, ..., X_n)$: o maior valor da amostra,

$W = X_{(n)} - X_{(1)}$: amplitude amostral,

$X_{(i)}$ = a i -ésima maior observação da amostra.

Em geral, como já vimos no Capítulo 3, podemos considerar as *estatísticas de ordem*,

$$X_{(1)} \leq X_{(2)} \leq ... \leq X_{(n)},$$

ou seja, os elementos da amostra ordenados.

Outras estatísticas importantes são os quantis (empíricos), $q(p)$, $0 < p < 1$, definidos no Capítulo 3, especialmente os três quartis q_1 , q_2 e q_3 .

Para facilitar a linguagem usada em Inferência Estatística, iremos diferenciar as características da amostra e da população.

Definição. Um *parâmetro* é uma medida usada para descrever uma característica da população.

Assim, se estivermos colhendo amostras de uma população, identificada pela v.a. X , seriam parâmetros a média $E(X)$ e sua variância $\text{Var}(X)$.

Os símbolos mais comuns são dados na tabela a seguir.

Denominação	População	Amostra
Média	$\mu = E(X)$	$\bar{X} = \sum X_i/n$
Mediana	$\text{Md} = Q_2$	$\text{md} = q_2$
Variância	$\sigma^2 = \text{Var}(X)$	$S^2 = \sum (X_i - \bar{X})^2/(n - 1)$
Nº de elementos	N	n
Proporção	p	$\hat{p}$
Quantil	$Q(p)$	$q(p)$
Quartis	Q_1, Q_2, Q_3	q_1, q_2, q_3
Intervalo inter-quartil	$d_Q = Q_3 - Q_1$	$d_q = q_3 - q_1$
Função densidade	$f(x)$	histograma
Função de distribuição	$F(x)$	$F_e(x)$

10.7 Distribuições Amostrais


Vimos na seção 10.3 que o problema da inferência estatística é fazer uma afirmação sobre os parâmetros da população através da amostra. Digamos que nossa afirmação deva ser feita sobre um parâmetro θ da população (por exemplo, a média, a variância

ou qualquer outra medida). Decidimos que usaremos uma AAS de n elementos sorteados dessa população. Nossa decisão será baseada na estatística T , que será uma função da amostra $(X_1, X_2, \dots, X_n)$, ou seja, $T = f(X_1, \dots, X_n)$. Colhida essa amostra, teremos observado um particular valor de T , digamos t_0 , e baseados nesse valor é que faremos a afirmação sobre θ , o parâmetro populacional. Veja a Figura 10.1 (a).

A validade da nossa resposta seria melhor compreendida se soubéssemos o que acontece com a estatística T , quando retiramos todas as amostras de uma população conhecida segundo o plano amostral adotado. Isto é, qual a distribuição de T quando $(X_1, \dots, X_n)$ assume todos os valores possíveis. Essa distribuição é chamada *distribuição amostral da estatística T* e desempenha papel fundamental na teoria da inferência estatística. Esquemáticamente, teríamos o procedimento representado na Figura 10.1, onde temos:

- (a) uma população X , com determinado parâmetro de interesse θ ;
- (b) todas as amostras retiradas da população, de acordo com certo procedimento;
- (c) para cada amostra, calculamos o valor t da estatística T ; e
- (d) os valores t formam uma nova população, cuja distribuição recebe o nome de distribuição amostral de T .

Figura 10.1: (a) Esquema de inferência sobre θ .
(b) Distribuição amostral da estatística T .



Vejamos alguns exemplos simples para aclarar um pouco mais o conceito de distribuição amostral de uma estatística. Nosso principal objetivo é identificar um modelo que explique bem a distribuição amostral de T . É evidente que a distribuição de T irá depender da distribuição de X e do plano amostral, em nosso caso reduzido a AAS.

Exemplo 10.9. Voltemos ao Exemplo 10.7, no qual selecionamos todas as amostras de tamanho 2, com reposição, da população $\{1, 3, 5, 5, 7\}$. A distribuição conjunta da variável bidimensional (X_1, X_2) é dada na Tabela 10.2.

Vejamos qual é a distribuição da estatística

$$\bar{X} = \frac{X_1 + X_2}{2} . \tag{10.1}$$

Essa distribuição é obtida por meio da Tabela 10.2. Por exemplo, quando a amostra selecionada é o par $(1, 1)$, a média será 1; então, temos que $P(\bar{X} = 1) = 1/25$. Obteremos a média igual a 3 quando ocorrer o evento $A = \{(1, 5), (3, 3), (5, 1)\}$, logo

$$P(\bar{X} = 3) = P(A) = \frac{2}{25} + \frac{1}{25} + \frac{2}{25} + \frac{5}{25} = \frac{1}{5} .$$

Tabela 10.2: Distribuição das probabilidades das possíveis amostras de tamanho 2 que podem ser selecionadas com reposição da população $\{1, 3, 5, 5, 7\}$.


$X_2 \backslash X_1$	1	3	5	7	Total
1	1/25	1/25	2/25	1/25	1/5
3	1/25	1/25	2/25	1/25	1/5
5	2/25	2/25	4/25	2/25	2/5
7	1/25	1/25	2/25	1/25	1/5
Total	1/5	1/5	2/5	1/5	1

Procedendo de maneira análoga para os demais valores que $\bar{X}$ pode assumir, obtemos a Tabela 10.3, que dá a distribuição da v.a. $\bar{X}$. Na Figura 10.2 temos as distribuições de X e de $\bar{X}$.

Tabela 10.3: Distribuição amostral da estatística $\bar{X}$.

$\bar{x}$	1	2	3	4	5	6	7	Total
$P(\bar{X} = \bar{x})$	1/25	2/25	5/25	6/25	6/25	4/25	1/25	1,00

Figura 10.2: Distribuição de X (---) e $\bar{X}$ (—), obtida de 25 amostras de tamanho 2 de $\{1, 3, 5, 7\}$.



Com um procedimento análogo podemos obter as distribuições amostrais de outras estatísticas de interesse. As Tabelas 10.4 e 10.5 trazem as distribuições amostrais das estatísticas $W = \text{amplitude total}$ e $S^2 = \sum (X_i - \bar{X})^2 / (n - 1)$, respectivamente.

Tabela 10.4: Distribuição amostral de W .

w	0	2	4	6	Total
$P(W = w)$	$7/25$	$10/25$	$6/25$	$2/25$	1,00

Tabela 10.5: Distribuição amostral de S^2 .

s^2	0	2	8	18	Total
$P(S^2 = s^2)$	$7/25$	$10/25$	$6/25$	$2/25$	1,00

Exemplo 10.5. (continuação) No caso do lançamento de uma moeda 50 vezes, usando como estatística $X = \text{número de caras obtidas}$, a obtenção da distribuição amostral, que já foi vista, é feita por meio do modelo binomial $b(50, p)$, qualquer que seja $p = \text{probabilidade de ocorrência de cara num lançamento}$, $0 < p < 1$. Se estivermos interessados em julgar a “honestidade” da moeda, estaremos verificando se $p = 0,5$. Nessas condições, a $P(X \geq 36 | n = 50, p = 0,5) = 0,0013 = 0,13\%$.

Portanto, caso a moeda seja honesta, em 50 lançamentos, a probabilidade de se obterem 36 ou mais caras é da ordem de 1 por 1.000. Ou seja, se a moeda fosse honesta, o resultado observado (36 caras) seria muito pouco provável, evidenciando que $p > 0,5$.

Comparando os dois últimos exemplos, vemos que nos interessa determinar propriedades das distribuições amostrais que possam ser aplicadas em situações mais gerais (como no caso binomial) e não em situações muito particulares (como no Exemplo 10.7). Iremos, agora, estudar as distribuições amostrais de algumas estatísticas importantes. Nos capítulos seguintes essas distribuições serão usadas para fazer inferências sobre populações.

Quando estivermos trabalhando com populações identificadas pela distribuição de probabilidades, não poderemos gerar *todas as amostras possíveis*. Devemos contentar-nos em simular um número “grande” de amostras e ter uma idéia do que acontece com a estatística de interesse.

Exemplo 10.8. (continuação) Qual seria a distribuição amostral da mediana das alturas de amostras de 5 mulheres retiradas da população $X \sim N(167; 25)$? Como não podemos gerar todas as possíveis amostras de tamanho 5 dessa população, simulamos, via Excel, 200 amostras de tamanho 5 e obtivemos os seguintes resultados:


$$E(md) = 166,88, \quad \text{Var}(md) = 7,4289, \quad dp(md) = 2,72,$$

$$x_{(1)} = \min(X_1, \dots, X_{200}) = 160, \quad x_{(200)} = \max(X_1, \dots, X_{200}) = 173.$$

Observando os resultados somos levados a pensar que a distribuição amostral de md deve ser próxima de uma normal, com média próxima de $\mu = 167$ e desvio padrão menor do que $\sigma = 5$. Veja a Figura 10.3.

Voltaremos a falar na distribuição da mediana amostral em seções futuras.

Figura 10.3: Distribuição amostral da mediana, obtida de 200 amostras de tamanho 5 de $X \sim N(167; 25)$.



Problemas

4. Usando os dados da Tabela 10.2, construa a distribuição amostral da estatística

$$\hat{\sigma}^2 = \frac{\sum (X_i - \bar{X})^2}{n}.$$

5. No Problema 3, se X indicar o número de filhos na população, X_1 o número de filhos observados na primeira extração e X_2 na segunda:
- calcule a média e a variância de X ;
 - calcule $E(X_i)$ e $\text{Var}(X_i)$, $i = 1, 2$;
 - construa a distribuição amostral de $\bar{X} = \frac{(X_1 + X_2)}{2}$;
 - calcule $E(\bar{X})$ e $\text{Var}(\bar{X})$;
 - faça num mesmo gráfico os histogramas de X e de $\bar{X}$;
 - construa as distribuições amostrais de $S^2 = \sum_{i=1}^2 (X_i - \bar{X})^2$ e $\hat{\sigma}^2 = \sum_{i=1}^2 (X_i - \bar{X})^2/2$;
 - baseado no resultado de (f), qual dos dois estimadores você usaria para estimar a variância de X ? Por quê?
 - calcule $P(|\bar{X} - \mu| > 1)$.
6. Ainda com os dados do Problema 3, e para amostras de tamanho 3:
- determine a distribuição amostral de $\bar{X}$ e faça o histograma;
 - calcule a média e variância de $\bar{X}$;
 - calcule $P(|\bar{X} - \mu| > 1)$.
 - se as amostras fossem de tamanho 4, a $P(|\bar{X} - \mu| > 1)$ seria maior ou menor do que a probabilidade encontrada em (c)? Por quê?

10.8 Distribuição Amostral da Média

Vamos estudar agora a distribuição amostral da estatística $\bar{X}$, a média da amostra. Consideremos uma população identificada pela variável X , cujos parâmetros média populacional $\mu = E(X)$ e variância populacional $\sigma^2 = \text{Var}(X)$ são supostos conhecidos. Vamos retirar todas as possíveis AAS de tamanho n dessa população, e para cada uma calcular a média $\bar{X}$. Em seguida, consideremos a distribuição amostral e estudemos suas propriedades. Voltemos a considerar, a título de ilustração, o Exemplo 10.7.

Exemplo 10.10. A população $\{1, 3, 5, 5, 7\}$ tem média $\mu = 4,2$ e variância $\sigma^2 = 4,16$. A distribuição amostral de $\bar{X}$ está na Tabela 10.3, da qual obtemos

$$\begin{aligned} E(\bar{X}) &= \sum_i \bar{x}_i p_i = 1 \times \frac{1}{25} + 2 \times \frac{2}{25} + 3 \times \frac{5}{25} + 4 \times \frac{6}{25} + 5 \times \frac{6}{25} \\ &\quad + 6 \times \frac{4}{25} + 7 \times \frac{1}{25} = 4,2. \end{aligned}$$

De modo análogo, encontramos

$$\text{Var}(\bar{X}) = 2,08.$$

Verificamos, aqui, dois fatos: primeiro, a média das médias amostrais coincide com a média populacional; segundo, a variância de $\bar{X}$ é igual à variância de X , dividida por $n = 2$. Estes dois fatos não são casos isolados. Na realidade, temos o seguinte resultado.

Teorema 10.1. Seja X uma v.a. com média μ e variância σ^2 , e seja $(X_1, \dots, X_n)$ uma AAS de X . Então,

$$E(\bar{X}) = \mu \quad \text{e} \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Prova. Pelas propriedades vistas no Capítulo 8, temos:

$$\begin{aligned} E(\bar{X}) &= (1/n) \{E(X_1) + \dots + E(X_n)\} \\ &= (1/n) \{\mu + \mu + \dots + \mu\} = n\mu/n = \mu. \end{aligned}$$

De modo análogo, e pelo fato de $X_1, \dots, X_n$ serem independentes, temos


$$\begin{aligned} \text{Var}(\bar{X}) &= (1/n^2) \{\text{Var}(X_1) + \dots + \text{Var}(X_n)\} \\ &= (1/n^2) \{\sigma^2 + \dots + \sigma^2\} = n\sigma^2/n^2 = \sigma^2/n. \end{aligned}$$

Determinamos, então, a média e a variância da distribuição amostral de $\bar{X}$. Vejamos, agora, como obter informação sobre a forma da distribuição dessa estatística.

Exemplo 10.10. (continuação) Para a população $\{1, 3, 5, 5, 7\}$, vamos construir os histogramas das distribuições de $\bar{X}$ para $n = 1, 2$ e 3 .

- (i) Para $n = 1$, vemos que a distribuição de $\bar{X}$ coincide com a distribuição de X , com $E(\bar{X}) = E(X) = 4,2$ e $\text{Var}(\bar{X}) = \text{Var}(X) = 4,16$ (Figura 10.4(a)).

Figura 10.4: Distribuição de $\bar{X}$ para amostras de $\{1, 3, 5, 5, 7\}$.




- (ii) Para $n = 2$, baseados na Tabela 10.3, temos a distribuição de $\bar{X}$ dada na Figura 10.4(b), com $E(\bar{X}) = 4,2$ e $\text{Var}(\bar{X}) = 2,08$.
- (iii) Finalmente, para $n = 3$, com os dados da Tabela 10.6, temos a distribuição de $\bar{X}$ na Figura 10.4 (c), com $E(\bar{X}) = 4,2$ e $\text{Var}(\bar{X}) = 1,39$.

Observe que, conforme n vai aumentando, o histograma tende a se concentrar cada vez mais em torno de $E(\bar{X}) = E(X) = 4,2$, já que a variância vai diminuindo. Os casos extremos passam a ter pequena probabilidade de ocorrência. Quando n for suficientemente grande, o histograma alisado aproxima-se de uma distribuição normal. Essa aproximação pode ser verificada analisando-se os gráficos da Figura 10.5, que mostram o comportamento do histograma de $\bar{X}$ para várias formas da distribuição da população e vários valores do tamanho da amostra n .

Esses exemplos sugerem que, quando o tamanho da amostra aumenta, independentemente da forma da distribuição da população, a distribuição amostral de $\bar{X}$ aproxima-se cada vez mais de uma distribuição normal. Esse resultado, fundamental na teoria da Inferência Estatística, é conhecido como *Teorema Limite Central (TLC)*.

Figura 10.5: Histogramas correspondentes às distribuições amostrais de $\bar{X}$ para amostras extraídas de algumas populações.



Teorema 10.2. (TLC) Para amostras aleatórias simples $(X_1, \dots, X_n)$, retiradas de uma população com média μ e variância σ^2 finita, a distribuição amostral da média $\bar{X}$ aproxima-se, para n grande, de uma distribuição normal, com média μ e variância σ^2/n .

A demonstração completa desse teorema exigiria recursos dos quais não dispomos, portanto não será dada, mas o importante é sabermos como esse resultado pode ser usado.

Observemos que, se a população for normal, então $\bar{X}$ terá distribuição *exata* normal. Esse resultado segue do fato de que a distribuição de uma combinação linear de **v.a.'s normais independentes** tem ainda distribuição normal. No caso da $\bar{X}$, a média e variância dessa normal serão dadas pelo Teorema 10.1. A prova dessa propriedade depende do conceito de função geradora de momentos, que não será objeto deste livro. O leitor interessado pode consultar Meyer (1965), por exemplo.

Exemplo 10.11. Voltemos ao Exemplo 10.4, onde uma máquina enchia pacotes cujos pesos seguiam uma distribuição $N(500, 100)$. Colhendo-se uma amostra de $n = 100$ pacotes e pesando-os, pelo que foi dito acima, $\bar{X}$ terá uma distribuição normal com média 500 e variância $100/100 = 1$. Logo, se a máquina estiver regulada, a probabilidade de encontrarmos a média de 100 pacotes diferindo de 500 g de menos de 2 gramas será

$$P(|\bar{X} - 500| < 2) = P(498 < \bar{X} < 502) = P(-2 < Z < 2) \approx 95\%.$$

Ou seja, dificilmente 100 pacotes terão uma média fora do intervalo (498, 502). Caso 100 pacotes apresentem uma média fora desse intervalo, podemos considerar como um evento raro, e será razoável supor que a máquina esteja desregulada.

Outra maneira de apresentar o TLC é por meio do

Corolário 10.1. Se $(X_1, \dots, X_n)$ for uma amostra aleatória simples da população X , com média μ e variância σ^2 finita, e $\bar{X} = (X_1 + \dots + X_n)/n$, então

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1). \quad (10.2)$$

Basta notar que se usou a transformação usual de reduzir a distribuição de $\bar{X}$ a uma normal padrão. Observe, também, que (10.2) pode ser escrita como

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1). \quad (10.3)$$

Chamemos de e a v.a. que mede a diferença entre a estatística $\bar{X}$ e o parâmetro μ , isto é, $e = \bar{X} - \mu$; e é chamado o *erro amostral da média*. Então, temos o

Corolário 10.2. A distribuição de e aproxima-se de uma distribuição normal com média 0 e variância σ^2/n , isto é,

$$\frac{\sqrt{n} e}{\sigma} \sim N(0, 1). \quad (10.4)$$

O TLC afirma que $\bar{X}$ aproxima-se de uma normal quando n tende para o infinito, e a rapidez dessa convergência (veja a Figura 10.5) depende da distribuição da popula-

ção da qual a amostra é retirada. Se a população original tem uma distribuição próxima da normal, a convergência é rápida; se a população original se afasta muito de uma normal, a convergência é mais lenta, ou seja, necessitamos de uma amostra maior para que $\bar{X}$ tenha uma distribuição aproximadamente normal. Para amostras da ordem de 30 ou 50 elementos, a aproximação pode ser considerada boa.

Problemas

7. Uma v.a. X tem distribuição normal, com média 100 e desvio padrão 10.
 - (a) Qual a $P(90 < X < 110)$?
 - (b) Se $\bar{X}$ for a média de uma amostra de 16 elementos retirados dessa população, calcule $P(90 < \bar{X} < 110)$.
 - (c) Represente, num único gráfico, as distribuições de X e $\bar{X}$.
 - (d) Que tamanho deveria ter a amostra para que $P(90 < \bar{X} < 110) = 0,95$?
8. A máquina de empacotar um determinado produto o faz segundo uma distribuição normal, com média μ e desvio padrão 10 g.
 - (a) Em quanto deve ser regulado o peso médio μ para que apenas 10% dos pacotes tenham menos do que 500 g?
 - (b) Com a máquina assim regulada, qual a probabilidade de que o peso total de 4 pacotes escolhidos ao acaso seja inferior a 2 kg?
9. No exemplo anterior, e após a máquina estar regulada, programou-se uma carta de controle de qualidade. De hora em hora, será retirada uma amostra de quatro pacotes e esses serão pesados. Se a média da amostra for inferior a 495 g ou superior a 520 g, encerra-se a produção para reajustar a máquina, isto é, reajustar o peso médio.
 - (a) Qual é a probabilidade de ser feita uma parada desnecessária?
 - (b) Se o peso médio da máquina desregulou-se para 500 g, qual é a probabilidade de continuar a produção fora dos padrões desejados?
10. A capacidade máxima de um elevador é de 500 kg. Se a distribuição X dos pesos dos usuários for suposta $N(70, 100)$:
 - (a) Qual é a probabilidade de sete passageiros ultrapassarem esse limite?
 - (b) E seis passageiros?

10.9 Distribuição Amostral de uma Proporção

Vamos considerar uma população em que a proporção de elementos portadores de certa característica é p . Logo, podemos definir uma v.a. X , da seguinte maneira:

$$X = \begin{cases} 1, & \text{se o indivíduo for portador da característica} \\ 0, & \text{se o indivíduo não for portador da característica,} \end{cases}$$

logo,

$$\mu = E(X) = p, \quad \sigma^2 = \text{Var}(X) = p(1 - p).$$

Retirada uma AAS dessa população, e indicando por Y_n o total de indivíduos portadores da característica na amostra, já vimos que

$$Y_n \sim b(n, p).$$

Vamos definir por $\hat{p}$ a proporção de indivíduos portadores da característica na amostra, isto é,

$$\hat{p} = \frac{Y_n}{n}.$$

Então,

$$P(Y_n = k) = P(Y_n/n = k/n) = P(\hat{p} = k/n),$$

ou seja, a distribuição amostral de $\hat{p}$ é obtida da distribuição de Y_n .

Vimos na seção 7.5 que a distribuição binomial pode ser aproximada pela distribuição normal. Vamos mostrar que a justificativa desse fato está no TLC. Inicialmente, observe que

$$Y_n = X_1 + X_2 + \dots + X_n,$$

onde cada X_i tem distribuição de Bernoulli, com média $\mu = p$ e variância $\sigma^2 = p(1 - p)$, e são duas a duas independentes. Podemos escrever que

$$Y_n = n\bar{X},$$

mas pelo TLC, $\bar{X}$ terá distribuição aproximadamente normal, com média p e variância $\frac{p(1-p)}{n}$, ou seja,

$$\bar{X} \sim N\left(p, \frac{p(1-p)}{n}\right).$$

Logo, a transformação $Y_n = n\bar{X}$ terá a distribuição

$$Y_n \sim N(np, np(1-p)),$$

que foi a aproximação adotada na seção 7.5.

Observe que $\bar{X}$, na expressão acima, é a própria variável $\hat{p}$ e, desse modo, para n grande podemos considerar a distribuição amostral de p como aproximadamente normal:

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right).$$

Exemplo 10.12. Suponha que $p = 30\%$ dos estudantes de uma escola sejam mulheres. Colhemos uma AAS de $n = 10$ estudantes e calculamos $\hat{p}$ = proporção de mulheres na amostra. Qual a probabilidade de que $\hat{p}$ difira de p em menos de 0,01? Temos que essa probabilidade é dada por

$$P(|\hat{p} - p| < 0,01) = P(-0,01 < \hat{p} - p < 0,01).$$

Mas, $\hat{p} - p \sim N\left(0, \frac{p(1-p)}{n}\right)$, e como $p = 0,3$, temos que

$$\text{Var}(\hat{p}) = (0,3)(0,7)/10 = 0,021,$$

e, portanto, a probabilidade pedida é igual a

$$P\left(\frac{-0,01}{\sqrt{0,021}} < Z < \frac{0,01}{\sqrt{0,021}}\right) = P(-0,07 < Z < 0,07) = 0,056.$$

Problemas

11. Sabe-se que 20% das peças de um lote são defeituosas. Sorteiam-se oito peças, com reposição, e calcula-se a proporção $\hat{p}$ de peças defeituosas na amostra.
 - (a) Construa a distribuição exata de $\hat{p}$ (use a tábua da distribuição binomial).
 - (b) Construa a aproximação normal à binomial.
 - (c) Você pensa que a segunda distribuição é uma boa aproximação da primeira?
 - (d) Já sabemos que, para dado p fixo, a aproximação melhora à medida que n aumenta. Agora, se n for fixo, para qual valor de p a aproximação é melhor?
12. Um procedimento de controle de qualidade foi planejado para garantir um máximo de 10% de itens defeituosos na produção. A cada 6 horas sorteia-se uma amostra de 20 peças e, havendo mais de 15% de defeituosas, encerra-se a produção para verificação do processo. Qual a probabilidade de uma parada desnecessária?
13. Supondo que a produção do exemplo anterior esteja sob controle, isto é, $p = 10\%$, e que os itens sejam vendidos em caixas com 100 unidades, qual a probabilidade de que uma caixa:
 - (a) tenha mais do que 10% de defeituosos?
 - (b) não tenha itens defeituosos?

10.10 Outras Distribuições Amostrais

Do mesmo modo que estudamos a distribuição amostral de $\bar{X}$, podemos, em princípio, estudar a distribuição amostral de qualquer estatística $T = f(X_1, \dots, X_n)$. Mas, quanto mais complexa for essa relação f , mais difícil será a derivação matemática das propriedades dessa estatística. Vejamos alguns exemplos.

Exemplo 10.13. Na Tabela 10.6 apresentamos a distribuição de três outras estatísticas; a variância da amostra,

$$S^2 = \frac{1}{(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2,$$

a mediana amostral, md , e o estimador

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2,$$

que difere de S^2 apenas no denominador, e que foi estudado no Capítulo 3. Desta tabela, obtemos as distribuições amostrais apresentadas nas Tabelas 10.7, 10.8 e 10.9.

Tabela 10.6: Distribuição amostral de algumas estatísticas obtidas de amostra de tamanho $n = 3$, retiradas da população $\{1, 3, 5, 7\}$ ($\mu = 4,2$, $\sigma^2 = 4,16$ e $Md = 5$).

Tipo de amostra	Frequência (prob. $\times 125$)	Soma	Soma dos quadrados	Média $\bar{x}$	Mediana md	Variância	
						s^2	$\hat{\sigma}^2$
111	1	3	3	1,00	1	0	0
113	3	5	11	1,67	1	4/3	8/9
115	6	7	27	2,33	1	16/3	32/9
117	3	9	51	3,00	1	12	8
133	3	7	19	2,33	3	4/3	8/9
135	12	9	35	3,00	3	4	8/3
137	6	11	59	3,67	3	28/3	56/9
155	12	11	51	3,67	5	16/3	32/9
157	12	13	75	4,33	5	28/3	56/9
177	3	15	99	5,00	7	12	8
333	1	9	27	3,00	3	0	0
335	6	11	43	3,67	3	4/3	8/9
337	3	13	67	4,33	3	16/3	32/9
355	12	13	59	4,33	5	4/3	8/9
357	12	15	83	5,00	5	4	8/3
377	3	17	107	5,67	7	16/3	32/9
555	8	15	75	5,00	5	0	0
557	12	17	99	5,67	5	4/3	8/9
577	6	19	123	6,33	7	4/3	8/9
777	1	21	147	7,00	7	0	0
Total	125						

Tabela 10.7: Distribuição amostral da variância S^2 , para amostras de tamanho 3, retiradas da população $\{1, 3, 5, 7\}$.

s^2	0,00	1,33	4,00	5,33	9,33	12,00
$P(S^2 = s^2)$	11/125	42/125	24/125	24/125	18/125	6/125

$E(S^2) = 4,16, \quad \text{Var}(S^2) = 11,28.$

Tabela 10.8: Distribuição amostral da mediana da amostra md para amostras de tamanho 3, retiradas da população $\{1, 3, 5, 7\}$.

md	1	3	5	7
Prob.	13/125	31/125	68/125	13/125

$E(md) = 4,30, \quad \text{Var}(md) = 2,54.$

Tabela 10.9: Distribuição amostral da variância $\hat{\sigma}^2$, para amostras de tamanho 3, retiradas da população $\{1, 3, 5, 5, 7\}$.

$\hat{\sigma}^2$	0,00	0,89	2,67	3,56	6,22	8,00
Prob.	11/125	42/125	24/125	24/125	18/125	6/125

$$E(\hat{\sigma}^2) = 2,77, \quad \text{Var}(\hat{\sigma}^2) = 5,04.$$

Os gráficos das funções de probabilidade estão nas Figuras 10.6, 10.7 e 10.8. A obtenção das propriedades dessas estatísticas, de modo geral, não é uma tarefa fácil, e os modelos de probabilidade resultantes correspondem a distribuições mais complexas.

Figura 10.6: Distribuição amostral de S^2 para amostras de tamanho $n = 3$ extraídas de $\{1, 3, 5, 5, 7\}$.




Figura 10.7: Distribuição amostral de md para amostras de tamanho $n = 3$ de $\{1, 3, 5, 5, 7\}$.





Figura 10.8: Distribuição amostral de $\hat{\sigma}^2$ para amostras de tamanho $n = 3$ extraídas de $\{1, 3, 5, 5, 7\}$.



Por exemplo, note que $E(S^2) = 4,16 = \sigma^2$, logo S^2 satisfaz uma propriedade análoga a $E(\bar{X}) = \mu$; dizemos que $\bar{X}$ e S^2 são estimadores *não-viesados* dos respectivos parâmetros μ e σ^2 . Esta propriedade já não vale para md e $\hat{\sigma}^2$, pois $E(md) = 4,3$, enquanto $Md = 5,0$ e $E(\hat{\sigma}^2) = 2,77$ e não 4,16. Vemos que $\hat{\sigma}^2$ sub-estima a verdadeira variância.

Também pode-se demonstrar que S^2 segue uma distribuição que é um múltiplo de uma distribuição qui-quadrado (χ^2), quando a população tem distribuição normal. Ver a seção 11.9. Já a mediana md , obtida de amostras de uma população simétrica, com média μ e variância σ^2 , segue aproximadamente uma distribuição normal, com média $E(md) = \mu$ e $\text{Var}(md) = (\pi\sigma^2)/(2n)$. Note que se exigem mais suposições do que aquelas mencionada no TLC. Nos Capítulos 11 e 12 voltaremos a discutir algumas distribuições amostrais e suas aplicações.

Problemas

14. Usando os dados da Tabela 10.2:

- construa a distribuição amostral de $\hat{\sigma}^2$ e compare com a distribuição amostral de S^2 (Tabela 10.5). Você notou alguma propriedade de S^2 que seja “melhor” do que de $\hat{\sigma}^2$?
- seja U a média de elementos distintos de amostras de tamanho $n = 3$. Por exemplo, se a amostra observada for $(1, 1, 3)$, então $u = (1 + 3)/2 = 2$. Construa a distribuição amostral de U ;
- compare as distribuições amostrais de U e $\bar{X}$.

15. Na tabela abaixo tem-se a distribuição dos salários da Secretaria A.

Classes de salários	Frequência relativa
4,5– 7,5	0,10
7,5– 10,5	0,20
10,5– 13,5	0,40
13,5– 16,5	0,20
16,5– 19,5	0,10

- (a) Calcule a média, a variância e a mediana dos salários nessa população.
- (b) Construa a distribuição amostral da média e da mediana para amostras de tamanho 2, retiradas dessa população.
- (c) Mostre que a média $\bar{X}$ e a mediana md da amostra são estimadores não-viesados da mediana Md da população, no sentido que $E(\bar{X}) = E(md) = Md$.
- (d) Qual dos dois estimadores não-viesados você usaria para estimar Md nesse caso? Por quê?
- (e) Baseado na distribuição amostral da média, encontre a distribuição amostral da estatística

$$Z = \frac{\bar{X} - \mu}{\sigma} \sqrt{n},$$

para $n = 2$.

- (f) Quais são os valores de $E(Z)$ e $\text{Var}(Z)$?
- (g) Construa a distribuição amostral da estatística

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

e faça o seu histograma.

- (h) Calcule a média e variância de S^2 .
- (i) Baseando-se nas distribuições amostrais anteriores, determine a distribuição amostral da estatística

$$t = \frac{\bar{X} - \mu}{S} \sqrt{n},$$

e construa seu histograma. Qual o problema encontrado?

- (j) Calcule a média e variância de t , quando possível.
 - (k) Calcule a $P(|t| < 2)$ e $P(|t| < 4,30)$.
16. Tente esboçar como ficariam os histogramas das estatísticas abaixo, para amostras de tamanho grande.
- (a) S^2 (faça o histograma da distribuição da Tabela 10.5)
 - (b) $Z = \frac{\bar{X} - \mu}{\sigma} \sqrt{n}$ (Veja o Teorema Limite Central)
 - (c) $t = \frac{\bar{X} - \mu}{S} \sqrt{n}$, definida no problema anterior (compare com a expressão e o resultado obtido em (b)).

10.11 Determinação do Tamanho de uma Amostra

Em nossas considerações anteriores fizemos a suposição que o tamanho da amostra, n , era conhecido e fixo. Podemos, em certas ocasiões, querer determinar o tamanho da amostra a ser escolhida de uma população, de modo a obter um erro de estimação previamente estipulado, com determinado grau de confiança.

Por exemplo, suponha que estejamos estimando a média μ populacional e para tanto usaremos a média amostral, $\bar{X}$, baseada numa amostra de tamanho n . Suponha que se queira determinar o valor de n de modo que

$$P(|\bar{X} - \mu| \leq \mathcal{E}) \geq \gamma, \quad (10.5)$$

com $0 < \gamma < 1$ e $\mathcal{E}$ é o *erro amostral* máximo que podemos suportar, ambos valores fixados.

Sabemos que $\bar{X} \sim N(\mu, \sigma^2/n)$, logo $\bar{X} - \mu \sim N(0, \sigma^2/n)$ e portanto (10.5) pode ser escrita

$$P(-\mathcal{E} \leq \bar{X} - \mu \leq \mathcal{E}) = P\left(\frac{-\sqrt{n}\mathcal{E}}{\sigma} \leq Z \leq \frac{\sqrt{n}\mathcal{E}}{\sigma}\right) \approx \gamma,$$

com $Z = (\bar{X} - \mu) \sqrt{n}/\sigma$. Dado γ , podemos obter z_γ da $N(0,1)$, tal que $P(-z_\gamma < Z < z_\gamma) = \gamma$, de modo que

$$\frac{\sqrt{n}\mathcal{E}}{\sigma} = z_\gamma,$$

do que obtemos finalmente

$$n = \frac{\sigma^2 z_\gamma^2}{\mathcal{E}^2}. \quad (10.6)$$

Note que em (10.6) conhecemos z_γ e $\mathcal{E}$, mas σ^2 é a variância desconhecida da população. Para podermos ter uma idéia sobre n devemos ter alguma informação prévia sobre σ^2 ou, então, usar uma pequena amostra piloto para estimar σ^2 .

Exemplo 10.13. (continuação) Suponha que uma pequena amostra piloto de $n = 10$, extraída de uma população, forneceu os valores $\bar{X} = 15$ e $S^2 = 16$. Fixando-se $\mathcal{E} = 0,5$ e $\gamma = 0,95$, temos

$$n = \frac{16 \times (1,96)^2}{(0,5)^2} \approx 245.$$

No caso de proporções, usando a aproximação normal da seção 10.9 para $\hat{p}$, é fácil ver que (10.6) resulta

$$n = \frac{z_\gamma^2 p(1-p)}{\mathcal{E}^2}. \quad (10.7)$$

Como não conhecemos p , a verdadeira proporção populacional, podemos usar o fato de que $p(1-p) \leq 1/4$, para todo p , e (10.7) fica

$$n \approx \frac{z_\gamma^2}{4\mathcal{E}^2}. \quad (10.8)$$

Por outro lado, se tivermos alguma informação sobre p ou pudermos estimá-lo usando uma amostra piloto, basta substituir esse valor estimado em (10.7).

Exemplo 10.14. Suponha que numa pesquisa de mercado estima-se que no mínimo 60% das pessoas entrevistadas preferirão a marca A de um produto. Essa informação é baseada em pesquisas anteriores. Se quisermos que o erro amostral de $\hat{p}$ seja menor do que $\varepsilon = 0,03$, com probabilidade $\gamma = 0,95$, teremos

$$n \approx \frac{(1,96)^2(0,6)(0,4)}{(0,03)^2} = 1.024,$$

na qual usamos o fato de que $p \geq 0,60$. Veja também os Problemas 19, 20 e 41.

Problemas

17. Suponha que uma indústria farmacêutica deseja saber a quantos voluntários se deva aplicar uma vacina, de modo que a proporção de indivíduos imunizados na amostra difira de menos de 2% da proporção verdadeira de imunizados na população, com probabilidade 90%. Qual o tamanho da amostra a escolher? Use (10.8).
18. No problema anterior, suponha que a indústria tenha a informação de que a proporção de imunizados pela vacina seja $p \geq 0,80$. Qual o novo tamanho de amostra a escolher? Houve redução?
19. Seja o tamanho de amostra dado por (10.7) e n_0 dado por (10.8). Prove que, para todo p , temos $n \leq n_0$. (Use a função $f(p) = p(1-p)$ para sua resposta.)
20. Suponha que haja a informação $p \leq p_0 < 0,5$, com p_0 conhecida. Se $n_1 = z_\gamma^2 p_0(1-p_0)/\varepsilon^2$, mostre que $n \leq n_1 < n_0$. Mostre que essa mesma relação vale se soubermos que $p \geq p_0 > 0,5$.
[Sugestão: note que $f(p) = p(1-p)$ é crescente em $[0; 0,5]$, atinge o máximo em 0,5 e depois é decrescente em $[0,5; 1]$.]

10.12 Exemplos Computacionais

Vimos, no Exemplo 10.7, como escolher todas as possíveis amostras de tamanho $n = 2$, com reposição, da população $\{1, 3, 5, 5, 7\}$. Obtemos $5^2 = 25$ amostras. Como já salientamos em seções anteriores, ao escolher uma amostra de uma população, estamos na realidade gerando valores de uma v.a. com determinada distribuição de probabilidades, supostamente conhecida. No exemplo, podemos pensar na v.a. X , assumindo os valores $x_1 = 1, x_2 = 3, x_3 = 5, x_4 = 5, x_5 = 7$, com probabilidades todas iguais a 0,2. Portanto, para escolher uma amostra de tamanho $n = 2$, basta gerar dois valores dessa distribuição, como aprendemos no Capítulo 9.

Os programas Excel, SPlus e Minitab têm comandos apropriados para gerar amostras de uma população especificada.

Exemplo 10.15. O Excel usa a opção *Amostragem*, dentro de “Análise de Dados” do menu “Ferramentas”. Na coluna G do quadro do Exemplo 9.5, temos uma amostra aleatória simples (com reposição), de tamanho $n = 5$ da população $\mathcal{P} = \{1, 2, \dots, 10\}$, que está na coluna F.

Exemplo 10.16. O SPlus usa o comando $\text{sample}(x, n)$ para gerar uma amostra *sem* reposição de tamanho n do conjunto x e o comando $\text{sample}(x, n, \text{replace}=\text{T})$ para gerar uma amostra *com* reposição. O Quadro 10.1 mostra como obter amostras de tamanho $n = 7$ do conjunto $x = \{1, 2, 3, \dots, 15\}$, sem e com reposição.

Quadro 10.1: Geração de amostras. SPlus.

```
> x<-c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15)
>
>
> sample(x, 7)
[1] 6 7 4 2 3 10 5
>
>
> sample(x, 7, replace=T)
[1] 12 14 11 10 15 4 11
```

Exemplo 10.17. O Minitab usa os comandos Sample e Replace para obter amostras. Temos, no Quadro 10.2, amostras de tamanho $n = 5$ obtidas do conjunto $\{1, 2, \dots, 10\}$ (na coluna C1). Na coluna C2 temos uma amostra sem reposição e na coluna C3 uma amostra com reposição.

Quadro 10.2: Geração de amostras. Minitab.

	C1	C2	C3	
1	1	10	8	
2	2	1	3	
3	3	8	8	MTB > Sample 5 C1 C2.
4	4	2	6	MTB >
5	5	7	4	MTB > Sample 5 C1 C3;
6	6			SUBC> Replace.
7	7			MTB >
8	8			
9	9			
10	10			

10.13 Problemas e Complementos

21. Uma v.a. X tem distribuição normal com média 10 e desvio padrão 4. Aos participantes de um jogo é permitido observar uma amostra de qualquer tamanho e calcular a média amostral. Ganha um prêmio aquele cuja média amostral for maior que 12.
 - (a) Se um participante escolher uma amostra de tamanho 16, qual é a probabilidade de ele ganhar um prêmio?
 - (b) Escolha um tamanho de amostra diferente de 16 para participar do jogo. Qual é a probabilidade de você ganhar um prêmio?
 - (c) Baseado nos resultados acima, qual o melhor tamanho de amostra para participar do jogo?

22. Se uma amostra com 36 observações for tomada de uma população, qual deve ser o tamanho de uma outra amostra para que o desvio padrão dessa amostra seja $2/3$ do desvio padrão da média da primeira?
23. Definimos a variável $e = \bar{X} - \mu$ como sendo o erro amostral de média. Suponha que a variância dos salários de uma certa região seja 400 reais².
- (a) Determine a média e a variância de e .
 - (b) Que proporção das amostras de tamanho 25 terão erro amostral absoluto maior do que 2 reais?
 - (c) E qual a proporção das amostras de tamanho 100?
 - (d) Nesse último caso, qual o valor de d , tal que $P(|e| > d) = 1\%$?
 - (e) Qual deve ser o tamanho da amostra para que 95% dos erros amostrais absolutos sejam inferiores a um real?
24. A distribuição dos comprimentos dos elos da corrente de bicicleta é normal, com média 2 cm e variância 0,01 cm². Para que uma corrente se ajuste à bicicleta, deve ter comprimento total entre 58 e 61 cm.
- (a) Qual é a probabilidade de uma corrente com 30 elos não se ajustar à bicicleta?
 - (b) E para uma corrente com 29 elos?
- [Observação: suponha que os elos sejam selecionados ao acaso para compor a corrente, de modo que se tenha independência.]
25. Cada seção usada para a construção de um oleoduto tem um comprimento médio de 5 m e desvio padrão de 20 cm. O comprimento total do oleoduto será de 8 km.
- (a) Se a firma construtora do oleoduto encomendar 1.600 seções, qual é a probabilidade de ela ter de comprar mais do que uma seção adicional (isto é, de as 1.600 seções somarem menos do que 7.995 m)?
 - (b) Qual é a probabilidade do uso exato de 1.599 seções, isto é, a soma das 1.599 seções estar entre 8.000 m e 8.005 m?
26. Um professor dá um teste rápido, constante de 20 questões do tipo certo-errado. Para testar a hipótese de o estudante estar adivinhando a resposta, ele adota a seguinte regra de decisão: "Se 13 ou mais questões estiverem corretas, ele não está adivinhando". Qual é a probabilidade de rejeitarmos a hipótese, sendo que na realidade ela é verdadeira?
27. Um distribuidor de sementes determina, por meio de testes, que 5% das sementes não germinam. Ele vende pacotes com 200 sementes com garantia de 90% de germinação. Qual é a probabilidade de que um pacote não satisfaça à garantia?
28. Uma empresa fabrica cilindros com 50 mm de diâmetro, sendo o desvio padrão 2,5 mm. Os diâmetros de uma amostra de quatro cilindros são medidos a cada hora. A média da amostra é usada para decidir se o processo de fabricação está operando satisfatoriamente. Aplica-se a seguinte regra de decisão: "Se o diâmetro médio de amostra de quatro cilindros for maior ou igual a 53,7 mm, ou menor ou igual a 46,3 mm, deve-se parar o processo. Se o diâmetro médio estiver entre 46,3 e 53,7 mm, o processo continua.
- (a) Qual é a probabilidade de se parar o processo se a média dos diâmetros permanecer em 50 mm?
 - (b) Qual é a probabilidade de o processo continuar se a média dos diâmetros se deslocar para 53,7 mm?

29. O CD-Veículos traz os preços de 30 carros nacionais e importados, extraídos da população de todos os carros vendidos no mercado. Supondo que o desvio padrão dessa amostra seja um bom representante do verdadeiro desvio padrão da população, qual será o tamanho de uma outra amostra a ser escolhida, de modo que, com probabilidade 90%, a média amostral difira da verdadeira média de menos de 0,02?
30. **Tabela de Números Aleatórios.** Para sortear AAS, costuma-se usar tabelas de números aleatórios, que são coleções de dígitos construídos aleatoriamente e que simulam o processo de sorteio. Na Tabela VII, apresentamos um pequeno conjunto de números aleatórios. Podem ser usados do seguinte modo: se quisermos selecionar dez nomes de uma lista de 90 pessoas, devemos começar numerando-os 01, 02, ..., 90. Em seguida, escolhemos duas colunas, digamos as duas primeiras, e tomamos os dez primeiros números; no caso, serão: 61, 94, 50, 51, 25, 63, 12, 38, 22, 07, 61.
Observe que o 94 foi eliminado, pois não existe esse número na população, e o 61 deverá aparecer repetido. Para outras explicações e tabelas maiores, consultar Pereira e Bussab (1974).
31. Como você usaria uma tabela (ou um gerador) de números aleatórios para sortear uma amostra nas seguintes situações:
- (a) 5 alunos de sua classe;
 - (b) 10 alunos de sua escola;
 - (c) 15 domicílios de seu bairro;
 - (d) 20 ações negociadas na Bolsa de São Paulo;
 - (e) 5 números de uma população cujos elementos são numerados de 1 a 115. Existe algum modo de "apressar" o sorteio?
 - (f) 5 números de uma população de 115 nomes, cujos números vão de 612 a 726;
 - (g) 5 números de uma população de 115 nomes, cuja numeração não é seqüencial, mas está compreendida entre os números 300 e 599.
32. **Distribuição amostral da diferença de duas médias.** Consideremos duas populações X com parâmetros μ_1 e σ_1^2 e Y com parâmetros μ^2 e σ_2^2 . Sorteiam-se duas amostras independentes: a da primeira população de tamanho n e a da segunda de tamanho m . Calculam-se as médias amostrais $\bar{X}$ e $\bar{Y}$.
- (a) Qual a distribuição amostral de $\bar{X}$? E de $\bar{Y}$?
 - (b) Defina $D = \bar{X} - \bar{Y}$. O que você entende por distribuição amostral de D ?
 - (c) Calcule $E(D)$ e $\text{Var}(D)$.
 - (d) Como você acha que será a distribuição de D ? Por quê?
33. A distribuição dos salários (em salários mínimos) de operários do sexo masculino de uma grande fábrica é $N(5,4; 1,69)$, e a de operários do sexo feminino é $N(5,4; 2,25)$. Sorteiam-se duas amostras, uma com 16 homens e outra com 16 mulheres. Se D for a diferença entre o salário médio dos homens e das mulheres:
- (a) Calcule $P(|D| > 0,5)$.
 - (b) Qual o valor de d tal que $P(|D| > d) = 0,05$?
 - (c) Que tamanho comum deveriam ter ambas as amostras para que $P(|D| > 0,4) = 0,05$?

34. Numa escola A , os alunos submetidos a um teste obtiveram média 70, com desvio padrão 10. Em outra escola B , os alunos submetidos ao mesmo teste obtiveram média 65 e desvio padrão 15. Se colhemos na escola A uma amostra de 36 alunos e na B , uma de 49 alunos, qual é a probabilidade de que a diferença entre as médias seja superior a 6 unidades?
35. **Distribuição amostral da diferença de duas proporções.** Usando os resultados do Problema 32, qual seria a distribuição de $\hat{p}_1 - \hat{p}_2$, a diferença entre as proporções de amostras independentes retiradas de populações com parâmetros p_1 e p_2 ?
36. **Amostras sem reposição de populações finitas.** Suponha uma população com N elementos. Vimos que se extrairmos uma amostra de tamanho n , com reposição, e calcularmos a média amostral $\bar{X}$, então $E(\bar{X}) = \mu$ e $\text{Var}(\bar{X}) = \sigma^2/n$, onde μ e σ^2 são a média e a variância da população, respectivamente. No entanto, se a amostragem for feita sem reposição, então $E(\bar{X}) = \mu$ continua a valer, mas

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \frac{N-n}{N-1}.$$

O fator $(N-n)/(N-1)$ é chamado *fator de correção para populações finitas*. Note que se n for muito menor que N , então esse fator é aproximadamente igual a um, e amostras com ou sem reposição são praticamente equivalentes.

Considere, agora, uma população $\mathcal{P} = \{1, 3, 5, 5, 7\}$, logo $N = 5$. Retire amostras de tamanho $n = 2$, sem reposição, e construa a distribuição amostral de $\bar{X} = (X_1 + X_2)/2$. Obtenha $E(\bar{X})$ e $\text{Var}(\bar{X})$ e verifique que esta é dada pela fórmula acima.

37. **Planos probabilísticos.** Existem vários planos probabilísticos que são utilizados em situações práticas. Vamos descrever brevemente alguns deles.
- (a) **Amostragem Aleatória Simples (AAS).** Nesse plano as n unidades que compõem a amostra são selecionadas de tal forma que todas as possíveis amostras têm a mesma probabilidade de serem escolhidas. Podemos ter AAS com e sem reposição. No Exemplo 9.6 cada amostra com reposição tem probabilidade $1/25$ de ser escolhida.
- (b) **Amostragem Aleatória Estratificada.** Nesse procedimento, a população é dividida em subpopulações ou estratos, usualmente de acordo com os valores (ou categorias) de uma variável, e depois AAS é utilizada na seleção de uma amostra de cada estrato. Por exemplo, considere uma população de $N = 10$ estudantes, para os quais definimos as variáveis renda familiar (X_1) e classe social (X_2), categorizada como A, B ou C. Então, $\mathcal{P} = \{1, 2, \dots, 10\}$ e suponha que a matriz de dados seja

$$\mathbf{D} = \begin{bmatrix} 10 & 8 & 15 & 6 & 22 & 12 & 7 & 16 & 13 & 11 \\ B & C & A & C & A & B & C & A & B & B \end{bmatrix}.$$

Podemos considerar três estratos, determinados pela variável X_2 :

$$\mathcal{P}_A = \{3, 5, 8\}, \quad \mathcal{P}_B = \{1, 6, 9, 10\}, \quad \mathcal{P}_C = \{2, 4, 7\}.$$

Um dos objetivos da estratificação é homogeneizar a variância dentro de cada estrato, relativamente à principal variável de interesse.

- (c) **Amostragem Aleatória por Conglomerados.** Como no item (b), a população é dividida em grupos (subpopulações) distintos, chamados conglomerados. Por exemplo, podemos dividir uma

cidade em bairros ou quadras. Usamos AAS para selecionar uma amostra de conglomerados e depois todos os indivíduos dos conglomerados selecionados são analisados.

- (d) *Amostragem em Dois Estágios*. A população é dividida em grupos, como em (c). Num primeiro estágio, através de AAS, selecionamos algumas subpopulações. Num segundo estágio, usando novamente AAS, retiramos amostras das subpopulações selecionadas na primeiro estágio.
- (e) *Amostragem Sistemática*. Nesse plano, supõe-se que temos uma listagem das unidades populacionais. Para k fixado, sorteamos um elemento entre os k primeiros da listagem. Depois observamos, sistematicamente, indivíduos separados por k unidades. Por exemplo, se $k = 10$ e sorteamos o oitavo elemento, observamos depois o décimo oitavo, vigésimo oitavo etc.

38. *Distribuição do máximo de uma amostra*. Considere M o máximo de uma AAS $X_1, \dots, X_n$, escolhida de uma população com densidade $f(x)$ e f.d.a. $F(x)$. Seja $F_M(m)$ a f.d.a. de M . Então, $F_M(m) = P(M \leq m)$. Agora, o evento $\{M \leq m\}$ é equivalente ao evento $\{X_i \leq m, \text{ para todo } 1 \leq i \leq n\}$. Como as v.a. X_i são independentes, teremos

$$F_M(m) = P(M \leq m) = P(X_1 \leq m, \dots, X_n \leq m) = P(X_1 \leq m) \dots P(X_n \leq m) = [F(m)]^n.$$

Portanto, a densidade de M é dada por

$$f_M(m) = F'_M(m) = n[F(m)]^{n-1}f(m).$$

39. Obtenha a densidade de M para o caso de uma amostra de uma distribuição uniforme no intervalo $(0, \theta)$.
40. Suponha que temos a população $X \sim N(167; 25)$. Gere 100 amostras de tamanho 5 dessa população, usando algum programa de geração de valores de uma distribuição normal, como o Excel ou Minitab.
- (a) Esboce a distribuição amostral de $\bar{X}$ (histograma) e calcule as principais medidas-resumo; faça *box plots* e ramos-e-folhas.
- (b) Mesma questão para *md* = mediana da amostra.
- (c) Compare as duas distribuições, ressaltando as principais diferenças.
- (d) Estude a distribuição da estatística “variância da amostra”.

41. *Tamanho de uma amostra*. Na prática, não conhecemos a distribuição de v.a. X e retiramos uma amostra a fim de estimar algum parâmetro dessa distribuição. Suponha, agora, que nosso interesse esteja na média $\mu = E(X)$. Para estimá-la, colhemos uma amostra $X_1, X_2, \dots, X_n$ de X . Logo, as v.a. X_i são independentes, cada uma delas tem a mesma distribuição que X e $E(X_i) = \mu, \forall i = 1, \dots, n$. Para estimar μ consideramos a média amostral $\bar{X}$.

Um problema que se apresenta é determinar o tamanho da amostra a colher. Isso pode ser feito usando a TLC, como vimos na seção 10.11.

Agora, vamos ver um procedimento diferente, também baseado no TLC, mas que envolve uma *regra de parada* para determinar o número de dados a colher. Esse procedimento foi sugerido por Ross (1997). Pelo TLC podemos escrever

$$P(|\bar{X} - \mu| > c \sigma / \sqrt{n}) \approx P(|Z| > c) = 2[1 - \Phi(c)], \quad (10.9)$$

para qualquer constante $c > 0$, onde $Z \sim N(0, 1)$ e $\Phi(\cdot)$ denota a f.d.a. de Z . Por exemplo, se $c = 1,96$, a probabilidade acima é 0,05.

Suponha que, em vez de colher uma pequena amostra piloto para estimar σ , tenhamos informação suficiente para escolher um valor aceitável, digamos d , para o desvio padrão de $\bar{X}$, que é dado por $\sigma/\sqrt{n}$.

Por (10.9), podemos escrever, por exemplo,

$$P(|\bar{X} - \mu| \leq 1,96d) \approx 0,95.$$

Segue-se que podemos amostrar seqüencialmente de X até que $S/\sqrt{n} < d$, em que calculamos S com os valores até então escolhidos.

O seguinte algoritmo pode, então, ser adotado:

- (1) Escolha um valor aceitável d para $\sigma/\sqrt{n}$.
- (2) Gere pelo menos 30 dados (para obter uma estimativa razoável de σ).
- (3) Continue a gerar dados, parando quando, com n dados, $S/\sqrt{n} < d$, com

$$S^2 = \sum (X_i - \bar{X})^2 / (n - 1).$$

- (4) Estime μ por $\bar{X} = \sum X_i / n$.

Esse método implica podermos calcular $\bar{X}$ e S^2 recursivamente. Isso pode ser feito por meio das seguintes fórmulas, facilmente verificáveis:

$$\bar{X}_j = \frac{1}{j} \sum_{i=1}^j X_i, \quad S_j^2 = \frac{1}{j-1} \sum_{i=1}^j (X_i - \bar{X}_j)^2, \quad j \geq 2,$$

$$S_1^2 = 0,$$

$$\bar{X}_0 = 0,$$

$$\bar{X}_{j+1} = \bar{X}_j + \frac{X_{j+1} - \bar{X}_j}{j+1},$$

$$S_{j+1}^2 = \left(1 - \frac{1}{j}\right) S_j^2 + (j+1)(\bar{X}_{j+1} - \bar{X}_j)^2.$$

Suponha $x_1 = 3$, $x_2 = 5$, $x_3 = 2$, $x_4 = 6$, $x_5 = 4$. Então, usando as fórmulas acima, obtenha, recursivamente, $\bar{X}_i$, S_i^2 , $i = 1, 2, 3, 4, 5$.

42. Suponha uma população $\mathcal{P} = \{1, 2, \dots, N\}$ e a v.a. X definida sobre $\mathcal{P}$. Então, $T = \sum_{i=1}^N X_i$ é chamado *total populacional*. A média populacional é $\mu = T/N$ e a variância populacional é $\sigma^2 = \sum_{i=1}^N (X_i - \mu)^2 / N$. Considere uma AAS de tamanho n extraída de $\mathcal{P}$ e $\bar{X}$ a média amostral. Considere o estimador $\hat{T} = N\bar{X}$. Mostre que $E(\hat{T}) = T$ e $\text{Var}(\hat{T}) = N^2 \sigma^2 / n$.
43. Suponha que queiramos retirar uma amostra de uma distribuição de Bernoulli com parâmetro p . Escolhidos k dados $x_1, x_2, \dots, x_k$, temos que $\bar{x}_k = \sum x_i / k$ é um estimador de p . Então um estimador natural da variância $\sigma^2 = p(1-p)$ da população é $\bar{x}_k(1 - \bar{x}_k)$. Como ficaria o algoritmo descrito no Problema 41 para essa situação?

Estimação

11.1 Primeiras Idéias

Vimos que a Inferência Estatística tem por objetivo fazer generalizações sobre uma população, com base nos dados de uma amostra. Salientamos que dois problemas básicos nesse processo são:

- (a) estimação de parâmetros; e
- (b) teste de hipóteses sobre parâmetros.

Lembremos que *parâmetros* são funções de valores populacionais, enquanto *estatísticas* são funções de valores amostrais.

O problema do teste de hipóteses sobre parâmetros de uma população será tratado no Capítulo 12. Neste capítulo iremos discutir as idéias básicas sobre estimação. Para ilustrar, consideremos o exemplo seguinte.

Exemplo 11.1. Uma amostra de $n = 500$ pessoas de uma cidade é escolhida, e a cada pessoa da amostra é feita uma pergunta a respeito de um problema municipal, para o qual foi apresentada uma solução pela prefeitura. A resposta à pergunta poderá ser SIM (favorável à solução) ou NÃO (contrária à solução). Deseja-se estimar a proporção de pessoas na cidade favoráveis à solução apresentada.

Se 300 pessoas responderam SIM à pergunta, então uma estimativa natural para essa proporção seria $300/500$ ou 60%. Nossa resposta é baseada na suposição de que a amostra é representativa da população. Sabemos, também, que outra amostra poderia levar a outra estimativa. Conhecer as propriedades desses *estimadores* é um dos propósitos mais importantes da Inferência Estatística. Vejamos o que pode ser feito nesse caso particular.

Definamos as v.a. $X_1, \dots, X_n$, tais que:

$$X_i = \begin{cases} 1, & \text{se a } i\text{-ésima pessoa na amostra responder SIM,} \\ 0, & \text{se a } i\text{-ésima pessoa na amostra responder NÃO,} \end{cases}$$

e seja $p = P$ (sucesso), onde aqui *sucesso* significa resposta SIM à questão formulada.

Portanto, se $Y_n = \sum_{i=1}^n X_i$, sabemos que Y_n tem distribuição binomial com parâmetros n e p , e o problema consiste em estimar p . É claro que Y_n representa o número de pessoas na amostra que responderam SIM; portanto, um possível *estimador* de p é

$$\hat{p} = \frac{Y_n}{n} = \frac{\sum_{i=1}^n X_i}{n} = \frac{\text{número de SIM}}{\text{número de indivíduos}}. \quad (11.1)$$

Então, se $Y_n = k$, isto é, observarmos o valor k da variável Y_n , obteremos $\hat{p} = k/n$ como uma *estimativa* de p . Observe que $\hat{p}$, dado por (11.1), é uma v.a., ao passo que k/n é um número, ou seja, um valor da v.a. No exemplo acima, uma estimativa é 0,6 ou 60%.

O estimador $\hat{p}$ teve sua distribuição amostral estudada na seção 10.9. De lá podemos concluir que $\hat{p}$ tem distribuição aproximadamente normal, com parâmetros:

$$E(\hat{p}) = p, \quad (11.2)$$

$$\text{Var}(\hat{p}) = p(1 - p)/n. \quad (11.3)$$


Esses resultados nos ajudam a avaliar as qualidades desse estimador. Por exemplo, o resultado (11.2) indica que o estimador $\hat{p}$, em média, “acerta” p . Dizemos que $\hat{p}$ é um estimador *não-viesado* (ou não-viciado) de p . Ou ainda, o resultado (11.3) indica que para amostras grandes, a diferença entre $\hat{p}$ e p tende a ser pequena, pois para $n \rightarrow \infty$, $\text{Var}(\hat{p}) \rightarrow 0$. Nesse caso, dizemos que $\hat{p}$ é um estimador *consistente* de p . Observe que essas propriedades são válidas para o estimador no conjunto de todas as amostras que poderiam ser extraídas da população. Para uma particular amostra, $\hat{p}$ pode estar distante de p .

Em algumas situações, podemos ter mais de um estimador para um mesmo parâmetro, e desejamos saber qual deles é “melhor”. O julgamento pode ser feito analisando as propriedades desses estimadores. Vejamos um exemplo.

Exemplo 11.2. Desejamos comprar um rifle e, após algumas seleções, restaram quatro alternativas, que chamaremos de rifles A, B, C e D. Foi feito um teste com cada rifle, que consistiu em fixá-lo num cavalete, mirar o centro de um alvo e disparar 15 tiros. Os resultados estão ilustrados na Figura 11.1.

Para analisar qual a melhor arma, podemos fixar critérios. Por exemplo, segundo o critério de “em média acertar o alvo”, escolheríamos as armas A e C. Segundo o critério de “não ser muito dispersivo” (variância pequena), a escolha recairia nas armas C e D. A arma C é aquela que reúne as duas propriedades e, segundo esses critérios, seria a melhor arma. Mas, se outro critério fosse introduzido (por exemplo, menor preço), talvez não fosse a arma escolhida. Muitas vezes, a solução deve ser um compromisso entre as propriedades.

Esse exemplo também nos permite introduzir os conceitos de acurácia e precisão. A *acurácia* mede a proximidade de cada observação do valor alvo que se procura atingir. A *precisão* mede a proximidade de cada observação da média de todas as observações.

Figura 11.1: Resultados de 15 tiros dados por 4 rifles.

Desse modo, podemos descrever cada arma da seguinte maneira:

Arma A: não-viesada, pouco acurada e baixa precisão.

Arma B: viesada, pouco acurada e baixa precisão.

Arma C: não-viesada, muito acurada e boa precisão.

Arma D: viesada, pouco acurada e alta precisão.

Do exposto acima, notamos a importância de se definir propriedades desejáveis para estimadores. Trataremos desse assunto na próxima seção. Outro problema que aparece em inferência é como obter um estimador de determinado parâmetro. Nem sempre temos uma sugestão para um estimador, como no caso da proporção, no Exemplo 11.1. Nas seções 11.3, 11.4 e 11.5 trataremos de três desses métodos.

11.2 Propriedades de Estimadores

Inicialmente vejamos a questão da estimação de um modo mais geral. Considere-mos uma amostra $(X_1, X_2, \dots, X_n)$ de uma v.a. que descreve uma característica de interesse de uma população. Seja θ um parâmetro que desejamos estimar, como por exemplo a média $\mu = E(X)$ ou a variância $\sigma^2 = \text{Var}(X)$.

Definição. Um *estimador* T do parâmetro θ é qualquer função das observações da amostra, ou seja, $T = g(X_1, \dots, X_n)$.

Notemos que, segundo essa definição, um estimador é o que chamamos antes de *estatística*, porém associando-o a um parâmetro populacional.

O problema da estimação é, então, determinar uma função $T = g(X_1, X_2, \dots, X_n)$ que seja “próxima” de θ , segundo algum critério. O primeiro critério que iremos abordar é dado a seguir.

Definição. O estimador T é *não-viesado* para θ se

$$E(T) = \theta, \quad (11.4)$$

para todo θ .

Se (11.4) não valer T diz-se *viesado* e a diferença $V(T) = E(T) - \theta$ é chamado o *viés* de T .

Notemos que a esperança de T em (11.4) é calculada sobre a distribuição amostral de T , como tratada no capítulo anterior.

Definição. *Estimativa* é o valor assumido pelo estimador em uma particular amostra.

Assim, no Exemplo 11.1, $\hat{p}$ é um estimador de p , enquanto 60% é uma estimativa de p .

Exemplo 11.3. Vimos que a média amostral $\bar{X}$ é um estimador não-viesado de $\mu = E(X)$, colhida uma amostra $(X_1, \dots, X_n)$ da v.a. X . Do mesmo modo, como vimos na seção 10.9, a proporção amostral $\hat{p}$ é um estimador não-viesado da proporção p de indivíduos de uma população que tem certa característica comum.

Exemplo 11.4. Considere uma população com N elementos e a variância populacional

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2, \quad (11.5)$$

onde $\mu = \frac{1}{N} \sum_{i=1}^N X_i$ é a média populacional. Um possível estimador para σ^2 , baseado numa AAS de tamanho n extraída dessa população, é

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (11.6)$$

Mostremos que esse estimador é viesado. Pela fórmula (3.11), temos que

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2,$$

logo

$$E(\hat{\sigma}^2) = \frac{1}{n} \sum_{i=1}^n E(X_i^2) - E(\bar{X}^2).$$

Mas, pela definição de AAS e definição de variância de uma v.a., $E(X_i^2) = \text{Var}(X_i) + [E(X_i)]^2 = \sigma^2 + \mu^2$. Também, usando o Teorema 10.1, temos que $E(\bar{X}^2) = \text{Var}(\bar{X}) + [E(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2$.

Seque-se que

$$E(\hat{\sigma}^2) = \frac{1}{n} \sum_{i=1}^n (\sigma^2 + \mu^2) - \left(\frac{\sigma^2}{n} + \mu^2 \right),$$

ou seja,

$$E(\hat{\sigma}^2) = \frac{1}{n} (n(\sigma^2 + \mu^2)) - \frac{\sigma^2}{n} - \mu^2 = \sigma^2 - \frac{\sigma^2}{n} = \sigma^2 \left(1 - \frac{1}{n} \right).$$

Finalmente,

$$E(\hat{\sigma}^2) = \left(\frac{n-1}{n} \right) \sigma^2. \quad (11.7)$$

De (11.7) vemos que $\hat{\sigma}^2$ é viesado para σ^2 e o viés é dado por

$$V = V(\hat{\sigma}^2) = E(\hat{\sigma}^2) - \sigma^2 = -\frac{\sigma^2}{n}. \quad (11.8)$$

Como esse viés é negativo, o estimador $\hat{\sigma}^2$ em geral subestima o verdadeiro parâmetro σ^2 . Por outro lado, por (11.8), o viés diminui com n , ou seja, formalmente, para $n \rightarrow \infty$, o viés de $\hat{\sigma}^2$ tende a zero. Note também que o viés de $\hat{\sigma}^2$ é uma função de σ^2 . Uma estimativa do viés seria dada por

$$\hat{V} = -\frac{\hat{\sigma}^2}{n},$$

ou seja, substituímos o valor desconhecido de σ^2 por uma estimativa, como por exemplo $\hat{\sigma}^2$.

É fácil ver que para obter um estimador não-viesado de σ^2 basta considerar $(n/(n-1))\hat{\sigma}^2$, pois de (11.7) segue-se que

$$E\left(\frac{n}{n-1} \hat{\sigma}^2\right) = \sigma^2.$$

Logo, se definirmos

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad (11.9)$$

então $E(S^2) = \sigma^2$ e S^2 é um estimador não-viesado para σ^2 . Essa é a razão para se usar $n-1$, em vez de n , como denominador da variância da amostra. No Capítulo 3 usamos sempre n como denominador, porque não havia preocupação em saber se estávamos trabalhando com uma população ou uma amostra. Daqui por diante, será feita essa distinção.

Vimos que o estimador $\hat{p}$ é não-viesado e tem variância que tende a zero, quando $n \rightarrow \infty$. Ver (11.2) e (11.3). Dizemos que $\hat{p}$ é consistente. Esse conceito de consistência é um pouco mais difícil de se definir. Vejamos um exemplo para motivar a definição que será dada.

Considere a média $\bar{X}$ calculada para diversos tamanhos de amostras; obtemos, na realidade, uma sequência de estimadores $\{\bar{X}_n, n = 1, 2, \dots\}$. À medida que n cresce, a distribuição de $\bar{X}_n$ torna-se mais concentrada ao redor da verdadeira média μ . Veja, por exemplo, a Figura 10.4 do Capítulo 10. Dizemos que $\{\bar{X}_n\}$ é uma sequência *consistente* de estimadores de μ .

Definição. Uma sequência $\{T_n\}$ de estimadores de um parâmetro θ é *consistente* se, para todo $\varepsilon > 0$,

$$P\{|T_n - \theta| > \varepsilon\} \rightarrow 0, \quad n \rightarrow \infty. \quad (11.10)$$

Não é muito difícil ver que essa condição está satisfeita para $\{\bar{X}_n\}$. Veja o Problema 34.

Em vez de usar (11.10) para verificar se uma sequência de estimadores é consistente, podemos usar o seguinte resultado.

Proposição. Uma sequência $\{T_n\}$ de estimadores de θ é consistente se

$$\lim_{n \rightarrow \infty} E(T_n) = \theta \quad (11.11)$$

e

$$\lim_{n \rightarrow \infty} \text{Var}(T_n) = 0. \quad (11.12)$$

Se T_n for não-viesado, a primeira condição estará, obviamente, satisfeita. Usando esse resultado, vemos que $\hat{p}$ e $\bar{X}_n$ são estimadores consistentes de p e μ , respectivamente, nos Exemplos 11.1 e 11.3.

Exemplo 11.5. Vimos que S^2 , dado por (11.9), é não-viesado para σ^2 . É possível demonstrar, no caso que $X_1, \dots, X_n$ são observações de uma distribuição $N(\mu, \sigma^2)$, que

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}. \quad (11.13)$$

Como $E(S^2) = \sigma^2$, e $\lim_{n \rightarrow \infty} \text{Var}(S^2) = 0$, segue-se que S^2 é um estimador consistente para σ^2 . Dado o que foi dito acima, talvez fosse melhor escrever S_n^2 .

Exemplo 11.6. Vimos que $E(\hat{\sigma}^2) = \sigma^2(1 - 1/n)$, de modo que $\lim_{n \rightarrow \infty} E(\hat{\sigma}^2) = \sigma^2$. Também, de (11.6) e (11.13) e supondo que as observações são de uma distribuição normal $N(\mu, \sigma^2)$, temos que

$$\text{Var}(\hat{\sigma}^2) = \left(\frac{n-1}{n}\right)^2 \text{Var}(S^2) = \frac{n-1}{n^2} (2\sigma^4), \quad (11.14)$$

o que mostra que $\text{Var}(\hat{\sigma}^2) \rightarrow 0$, quando $n \rightarrow \infty$, logo $\hat{\sigma}^2 = \hat{\sigma}_n^2$ também é consistente para σ^2 .

De (11.14) obtemos, também, que

$$\text{Var}(\hat{\sigma}^2) < \frac{2\sigma^4}{n-1} = \text{Var}(S^2). \quad (11.15)$$

Portanto, usando-se somente o critério de “ter menor variância”, $\hat{\sigma}^2$ seria um “melhor” estimador de σ^2 . Mas observe que estamos nos referindo a amostras de uma distribuição normal.

Vejamos agora um critério que nos permite escolher entre dois estimadores do mesmo parâmetro.

Definição. Se T e T' são dois estimadores não-viesados de um mesmo parâmetro θ , e ainda

$$\text{Var}(T) < \text{Var}(T'), \quad (11.16)$$

então T diz-se mais *eficiente* do que T' .

Exemplo 11.7. Consideremos uma população normal X , com parâmetros μ e σ^2 . Queremos estimar a mediana dessa população. Por ser uma distribuição simétrica, sabemos que $\mu = \text{Md}(X)$. Definindo como $\bar{X}$ a média e como md a mediana de uma amostra de tamanho n dessa população, qual dos dois estimadores é o melhor para estimar a mediana populacional?

Pelo que vimos no capítulo anterior,

$$\bar{X} \sim N(\mu, \sigma^2/n). \quad (11.17)$$

Pode-se demonstrar que a distribuição da mediana amostral pode ser aproximada por uma normal, especificamente,

$$\text{md} \sim N(\text{Md}(X), \pi\sigma^2/2n). \quad (11.18)$$

Vemos, portanto, que os dois estimadores são não-viesados, mas $\bar{X}$ é mais eficiente, pois

$$\text{Var}(\text{md})/\text{Var}(\bar{X}) = \pi/2 > 1.$$

Conclui-se que, para estimar a mediana dessa população, é preferível usar a média da amostra como estimador, o que contraria um pouco a nossa intuição.

Para precisar o conceito de estimador acurado, discutido na seção anterior, vamos agora introduzir o conceito de erro quadrático médio.

Chamemos de

$$e = T - \theta,$$

o *erro amostral* que cometemos ao estimar o parâmetro θ da distribuição da v.a. X pelo estimador $T = g(X_1, \dots, X_n)$, baseado na amostra $(X_1, \dots, X_n)$.

Definição. Chama-se *erro quadrático médio* (EQM) do estimador T ao valor

$$EQM(T; \theta) = E(e^2) = E(T - \theta)^2. \quad (11.19)$$

De (11.19) temos

$$\begin{aligned} EQM(T; \theta) &= E(T - E(T) + E(T) - \theta)^2 \\ &= E(T - E(T))^2 + 2E[(T - E(T))(E(T) - \theta)] + E(E(T) - \theta)^2 \\ &= E(T - E(T))^2 + E(E(T) - \theta)^2, \end{aligned}$$


já que $E(T) - \theta$ é uma constante e $E(T - E(T)) = 0$. Podemos, pois, escrever,

$$EQM(T; \theta) = \text{Var}(T) + V^2, \quad (11.20)$$

onde $V = V(T) = E(T) - \theta$ indica, como vimos, o viés de T . A Figura 11.2 ilustra essas duas medidas, usando o caso das armas discutido no Exemplo 11.2.

Vemos, portanto, que um estimador preciso tem variância pequena, mas pode ter EQM grande.

Figura 11.2: Representação gráfica para o EQM.



Problemas

1. Obtenha a distribuição de $\hat{p}$ quando $p = 0,2$ e $n = 5$. Depois calcule $E(\hat{p})$ e $\text{Var}(\hat{p})$.
2. Encontre um limite superior para $\text{Var}(\hat{p})$ quando $n = 10, 25, 100$ e 400 . Faça o gráfico em cada caso.
3. Suponha um experimento consistindo de n provas de Bernoulli, com probabilidade de sucesso p . Seja X o número de sucessos, e considere os estimadores

$$(a) \hat{p}_1 = X/n; \quad (b) \hat{p}_2 = \begin{cases} 1, & \text{se a primeira prova resultar sucesso,} \\ 0, & \text{caso contrário.} \end{cases}$$

Determine a esperança e a variância de cada estimador. Por que $\hat{p}_2$ não é um “bom” estimador?

4. Verifique se $\hat{p}_1$ e $\hat{p}_2$ do Problema 3 são consistentes.
5. Tem-se duas fórmulas distintas para estimar um parâmetro populacional θ . Para ajudar a escolher o melhor, simulou-se uma situação onde $\theta = 100$. Dessa população retiraram-se 1.000 amostras de dez unidades cada uma, e aplicaram-se ambas as fórmulas às dez unidades de cada amostra. Desse modo obtêm-se 1.000 valores para a primeira fórmula t_1 e outros 1.000 valores para a segunda fórmula t_2 , cujos estudos descritivos estão resumidos abaixo. Qual das duas fórmulas você acha mais conveniente para estimar θ . Por quê?

Fórmula 1	Fórmula 2
$\bar{t}_1 = 102$	$\bar{t}_2 = 100$
$\text{Var}(t_1) = 5$	$\text{Var}(t_2) = 10$
Mediana = 100	Mediana = 100
Moda = 98	Moda = 100

11.3 Estimadores de Momentos

Neste capítulo e em anteriores, temos usado certos estimadores de parâmetros populacionais, como a média e a variância, simplesmente tentando “imitar” na amostra o que acontece na população. Foi assim que construímos $\bar{X}$, por exemplo.

A média populacional é um caso particular daquilo que chamamos de momento. Na realidade, ela é o *primeiro momento*. Se X for uma v.a. contínua, com densidade $f(x; \theta_1, \dots, \theta_r)$, dependendo de r parâmetros, então

$$\mu_1 = E(X) = \int_{-\infty}^{\infty} x f(x; \theta_1, \dots, \theta_r) dx. \quad (11.21)$$

Essa média dependerá, genericamente, dos parâmetros desconhecidos $\theta_1, \dots, \theta_r$. Por exemplo, suponha que X tenha distribuição normal, com parâmetros μ e σ^2 . Aqui, $\theta_1 = \mu$, $\theta_2 = \sigma^2$ e $r = 2$. Temos, nesse caso, que $E(X) = \mu$.

Podemos, em geral, definir o k -ésimo momento de X por

$$\mu_k = E(X^k) = \int_{-\infty}^{\infty} x^k f(x; \theta_1, \dots, \theta_r) dx, \quad k = 1, 2, \dots \quad (11.22)$$

Assim, para $k = 2$, obtemos o segundo momento

$$E(X^2) = \int_{-\infty}^{\infty} x^2 f(x; \theta_1, \dots, \theta_r) dx.$$

No caso acima da normal, temos que $E(X^2) = \text{Var}(X) + [E(X)]^2 = \sigma^2 + \mu^2$. Suponha, agora, que colhemos uma amostra de tamanho n da população $(X_1, \dots, X_n)$. Definimos o chamado k -ésimo momento amostral por

$$m_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots \quad (11.23)$$

Temos, portanto, que $m_1 = \bar{X}$ e $m_2 = \sum_{i=1}^n X_i^2 / n$.

Definição. Dizemos que $\hat{\theta}_1, \dots, \hat{\theta}_r$ são estimadores obtidos pelo método dos momentos se eles forem soluções das equações

$$m_k = \mu_k, \quad k = 1, 2, \dots, r. \quad (11.24)$$

O procedimento consiste em substituir os momentos teóricos pelos respectivos momentos amostrais.

Exemplo 11.8. Se $X \sim N(\mu, \sigma^2)$, teremos as seguintes relações válidas para os dois primeiros momentos populacionais:

$$E(X) = \mu, \quad E(X^2) = \sigma^2 + \mu^2,$$

do que obtemos

$$\mu = E(X), \quad \sigma^2 = E(X^2) - E^2(X).$$

Temos, também, os dois primeiros momentos amostrais:

$$m_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X},$$

$$m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

Os estimadores obtidos pelo método dos momentos serão

$$\hat{\mu}_M = m_1 = \bar{X},$$

$$\hat{\sigma}_M^2 = m_2 - m_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \hat{\sigma}^2.$$

Ou seja, obtemos os já mencionados estimadores $\bar{X}$ e $\hat{\sigma}^2$.

Na realidade, podemos ter, às vezes, mais de um estimador de momentos. Suponha, por exemplo, que a v.a. Y tenha uma distribuição de Poisson com parâmetro $\lambda > 0$. Vimos que $E(Y) = \text{Var}(Y) = \lambda$, de modo que λ pode ser estimado por $\bar{Y}$ ou por $\sum_{i=1}^n (Y_i - \bar{Y})^2/n$, ou seja, $\hat{\lambda}_M = \bar{X}$ ou $\hat{\lambda}_M = \hat{\sigma}^2$, que podem resultar em valores muito diferentes. Veja o Problema 46.

11.4 Estimadores de Mínimos Quadrados

Um dos procedimentos mais usados para obter estimadores é aquele que se baseia no princípio dos mínimos quadrados, introduzido por Gauss em 1794, mas que primeiro apareceu com esse nome no apêndice do tratado de Legendre, *Nouvelles Méthodes pour la Détermination des Orbites des Comètes*, publicado em Paris em 1806. Gauss somente viria a publicar seus resultados em 1809, em Hamburgo. Ambos utilizaram o princípio em conexão com problemas de Astronomia e Física.

Vejamos o procedimento por meio de um exemplo simples.

Exemplo 11.9. Um engenheiro está estudando a resistência Y de uma fibra em função de seu diâmetro X e notou que as variáveis são aproximadamente proporcionais, isto é, elas obedecem à relação

$$Y \approx \theta X, \quad (11.25)$$

onde θ é o coeficiente de proporcionalidade. Agora ele deseja estimar o parâmetro θ , baseado numa amostra de cinco unidades, que, submetidas a mensuração e testes, produziram os resultados:

$$X : 1,2 \quad 1,5 \quad 1,7 \quad 2,0 \quad 2,6, \quad \bar{X} = 1,8;$$

$$Y : 3,9 \quad 4,7 \quad 5,6 \quad 5,8 \quad 7,0, \quad \bar{Y} = 5,4.$$

Inspecionando os resultados, conclui-se que $\hat{\theta} = 3$ parece ser um valor razoável. Como verificar a qualidade dessa estimativa? Podemos utilizar o modelo $\hat{Y} = 3X$ e ver como esse prevê os valores de Y , para os dados valores de X , e como são as discrepâncias entre os valores observados e os estimados pelo modelo. Essa análise está resumida na Tabela 11.1.

Os valores da coluna $(Y - 3X)$ medem a inadequação do modelo para cada observação da amostra, enquanto o valor $\sum_{i=1}^5 (Y_i - 3X_i)^2 = 1,06$ é uma tentativa de medir “o erro quadrático total da amostra”. Como em situações anteriores, elevou-se ao quadrado para evitar o problema do sinal. Quanto menor for o erro quadrático total, melhor será a estimativa. Isso nos sugere procurar a estimativa que torne mínima essa soma de quadrados. Matematicamente, o problema passa a ser o de encontrar o valor de θ que minimize a função

$$S(\theta) = \sum_{i=1}^5 (Y_i - \theta X_i)^2. \quad (11.26)$$

Tabela 11.1: Análise do modelo $\hat{Y} = 3X$.

X	Y	$3X$	$Y - 3X$	$(Y - 3X)^2$
1,2	3,9	3,6	0,3	0,09
1,5	4,7	4,5	0,2	0,04
1,7	5,6	5,1	0,5	0,25
2,0	5,8	6,0	-0,2	0,04
2,6	7,0	7,8	0,8	0,64
Total			0	1,06

O mínimo da função é obtido derivando-a em relação a θ , e igualando o resultado a zero (Ver Morettin et al., 2005), o que resulta

$$\frac{dS(\theta)}{d\theta} = \sum_{i=1}^5 (Y_i - \hat{\theta} X_i)(-2X_i) = 0.$$

Resolvendo essa equação, obtemos

$$\hat{\theta}_{MQ} = \frac{\sum_{i=1}^5 X_i Y_i}{\sum_{i=1}^5 X_i^2}.$$

Usando os dados acima encontramos $\hat{\theta}_{MQ} = 2,94$, que conduz a um valor mínimo para $S(\theta)$ de 0,94. Observe que esse valor é realmente menor do que o observado para $\theta = 3$, ou seja, 1,06.

Como foi dito, não esperávamos uma relação perfeita entre as duas variáveis, já que o diâmetro da fibra não é o único responsável pela resistência; outros fatores não controlados afetam o resultado. Desse modo, duas amostras obtidas do mesmo diâmetro X não teriam obrigatoriamente que apresentar o mesmo resultado Y , mas valores em torno de um valor esperado θX .

Em outras palavras, estamos supondo que, para um dado valor da variável explicativa X , os valores da variável resposta Y seguem uma distribuição de probabilidade $f_Y(y)$, centrada em θX . Isso equivale a afirmar que, para cada X , o desvio $\mathcal{E} = Y - \theta X$ segue uma distribuição centrada no zero. Para melhor entendimento dessa proposição, veja o Capítulo 16. Podemos, então, escrever

$$E(Y | x) = \theta x, \quad \text{para todo valor } x.$$

É comum supor que $\mathcal{E}$ tem a mesma distribuição, para todo valor x da variável explicativa X . Desse modo, é comum escrever

$$Y = \theta x + \mathcal{E},$$

com $\mathcal{E}$ seguindo a distribuição $f_{\mathcal{E}}(\cdot)$, com média zero. Como ilustração, poderíamos supor que $\mathcal{E} \sim N(0, \sigma^2)$, para todo x . Quanto menor for a variância σ^2 , melhor será a “previsão” de Y como função de x . Assim, parece razoável escolher θ que torna mínima a soma dos quadrados dos erros:

$$\sum_{i=1}^5 \mathcal{E}_i^2 = \sum_{i=1}^5 (Y_i - \theta X_i)^2.$$

O modelo acima pode ser generalizado, de modo a envolver outras funções do parâmetro θ , resultando no modelo

$$Y = g(X; \theta) + \mathcal{E}, \quad (11.27)$$

e devemos procurar o valor de θ que minimize a função

$$S(\theta) = \sum_{i=1}^n \mathcal{E}_i^2 = \sum_{i=1}^n (Y_i - g(X_i; \theta))^2, \quad (11.28)$$

para uma amostra $(X_1, Y_1), \dots, (X_n, Y_n)$ das variáveis X e Y . A solução $\hat{\theta}_{MQ}$ é chamada de estimador de mínimos quadrados (EMQ) de θ .

Nos Capítulos 15 e 16 voltaremos a esse tópico e trataremos com mais detalhes os chamados modelos lineares.

Problemas

6. Estamos estudando o modelo $y_t = \mu + \mathcal{E}_t$, para o qual uma amostra de cinco elementos produziu os seguintes valores para y_t : 3, 5, 6, 8, 16.
 - (a) Calcule os valores de $S(\mu) = \sum_t (y_t - \mu)^2$, para $\mu = 6, 7, 8, 9, 10$, e faça o gráfico de $S(\mu)$ em relação a μ . Qual o valor de μ que parece tornar mínimo $S(\mu)$?
 - (b) Derivando $S(\mu)$ em relação a μ , e igualando o resultado a zero, você encontrará o EMQ de μ . Usando os dados acima, encontre a estimativa para μ e compare com o resultado do item anterior.
7. Os dados abaixo referem-se ao índice de inflação (y_t) de 1967 a 1979.

Ano (t)	1967	1969	1971	1973	1975	1977	1979
Inflação (y_t)	128	192	277	373	613	1.236	2.639

- (a) Faça o gráfico de y_t contra t .
- (b) Considere ajustar o modelo $y_t = \alpha + \beta t + \mathcal{E}_t$ aos dados. Encontre as estimativas de mínimos quadrados de α e β .
- (c) Qual seria a inflação em 1981?
- (d) Você teria alguma restrição em adotar o modelo linear nesse caso?

8. No Problema 7, determinamos os estimadores de mínimos quadrados para o modelo $y_t = f(t) + \epsilon_t$, no qual $f(t) = \alpha + \beta t$. Suponha agora que

$$f(t) = \alpha + \beta x_t, \quad t = 1, \dots, n,$$

ou seja, temos n valores fixos $x_1, \dots, x_n$ de uma variável fixa (não-aleatória) x . Obtenha os EMQ de α e β para esse modelo.

9. Aplique os resultados do Problema 8 para os dados a seguir:

t	1	2	3	4	5	6	7	8	9	10
x_t	1,5	1,8	1,6	2,5	4,0	3,8	4,5	5,1	6,5	6,0
y_t	66,8	67,0	66,9	67,6	68,9	68,7	69,3	69,8	71,0	70,6

11.5 Estimadores de Máxima Verossimilhança

O Novo Dicionário Aurélio da Língua Portuguesa (2ª edição, 1986) define *verossímil* (ou verossimilhante) aquilo que é semelhante à verdade, provável, e *verossimilhança* (ou verossimilitude, ou ainda verossimilitude), à qualidade ou caráter de verossímil. O que seria uma amostra verossímil? Seria uma amostra que fornecesse a melhor informação possível sobre um parâmetro de interesse da população, desconhecido, e que desejamos estimar.

O princípio da verossimilhança afirma que devemos escolher aquele valor do parâmetro desconhecido que maximiza a probabilidade de obter a amostra particular observada, ou seja, o valor que torna aquela amostra a “mais provável”. O uso desse princípio conduz a um método de estimação pelo qual se obtêm os chamados estimadores de máxima verossimilhança que, em geral, têm propriedades muito boas. Esse princípio foi enunciado por Fisher pela primeira vez em 1912 e, em 1922, deu-lhe forma mais completa, introduzindo a expressão “likelihood” (verossimilhança). Veja Fisher (1935) para mais detalhes. Vamos começar com um exemplo.

Exemplo 11.10. Suponha que temos n provas de Bernoulli com P (sucesso) = p , $0 < p < 1$ e X = número de sucessos. Devemos tomar como estimador aquele valor de p que torna a amostra observada a mais provável de ocorrer.

Suponha, por exemplo, que $n = 3$ e obtemos dois sucessos e um fracasso. A função de verossimilhança é

$$L(p) = P(2 \text{ sucessos e } 1 \text{ fracasso}) = p^2(1 - p).$$

Maximizando essa função em relação a p , obtemos

$$L'(p) = 2p(1 - p) - p^2 = 0 \Rightarrow p(2 - 3p) = 0,$$

do que seguem $p = 0$ ou $p = 2/3$. É fácil ver que o ponto máximo é $\hat{p} = 2/3$, que é o estimador de máxima verossimilhança (EMV) de p .

De modo geral, o EMV do parâmetro p de uma distribuição binomial é

$$\hat{p}_{MV} = \frac{X}{n}, \quad (11.29)$$

que é o estimador usado anteriormente no Exemplo 11.1.

Para chegar a (11.29), observe que a função de verossimilhança nesse caso é

$$L(p) = p^x (1 - p)^{n-x},$$

que é a probabilidade de se obter x sucessos e $n - x$ fracassos. O máximo dessa função ocorre no mesmo ponto que $\ell(p) = \log_e L(p)$. Denotando o logaritmo natural simplesmente por $\log$, temos

$$\ell(p) = x \log p + (n - x) \log(1 - p).$$

Derivando e igualando a zero obtemos $\hat{p}_{MV} = x/n$.

O procedimento, pois, é obter a função de verossimilhança, que depende dos parâmetros desconhecidos e dos valores amostrais, e depois maximizar essa função ou o logaritmo dela, o que pode ser mais conveniente em determinadas situações. Chamando de $L(\theta; X_1, \dots, X_n)$ a função de verossimilhança, a log-verossimilhança será $\ell(\theta; X_1, \dots, X_n) = \log_e L(\theta; X_1, \dots, X_n)$.

No caso de variáveis contínuas, a função de verossimilhança é definida da seguinte maneira. Suponha que a v.a. X tenha densidade $f(x; \theta)$, onde destacamos a dependência do parâmetro θ desconhecido. Retiramos uma amostra de X , de tamanho n , $(X_1, \dots, X_n)$, e sejam $(x_1, \dots, x_n)$ os valores efetivamente observados.

Definição. A função de verossimilhança é definida por

$$L(\theta; x_1, \dots, x_n) = f(x_1; \theta) \dots f(x_n; \theta), \quad (11.30)$$

que deve ser encarada como uma função de θ . O estimador de máxima verossimilhança de θ é o valor $\hat{\theta}_{MV}$ que maximiza $L(\theta; x_1, \dots, x_n)$.

Se indicarmos por $\mathbf{x} = (x_1, \dots, x_n)'$ o vetor contendo a amostra, é costume denotar a verossimilhança por $L(\theta|\mathbf{x})$ e a log-verossimilhança por $\ell(\theta|\mathbf{x})$. O parâmetro θ pode ser um vetor, como no caso de querermos estimar a média μ e a variância σ^2 de uma normal. Nesse caso, $\theta = (\mu, \sigma^2)'$.

Exemplo 11.11. Suponha que a v.a. X tenha distribuição exponencial, com parâmetro $\alpha > 0$, desconhecido, e queremos obter o EMV desse parâmetro. A densidade de X é dada por (7.26):

$$f(x; \alpha) = \begin{cases} \frac{1}{\alpha} e^{-x/\alpha}, & \text{se } x \geq 0 \\ 0, & \text{se } x < 0. \end{cases}$$

Então, a verossimilhança é dada por

$$L(\alpha|x) = (1/\alpha)^n e^{-\sum x_i/\alpha}$$

e a log-verossimilhança fica

$$\ell(\alpha|x) = -n \log \alpha - \sum_{i=1}^n x_i/\alpha.$$

Derivando e igualando a zero obtemos que o EMV de α é

$$\hat{\alpha}_{MV} = \frac{\sum_{i=1}^n x_i}{n}, \quad (11.31)$$

que nada mais é do que a média amostral. Lembremos que na distribuição exponencial $E(X) = \alpha$, e portanto o estimador obtido é o esperado pelo senso comum.

No caso discreto, a função de verossimilhança pode ser escrita na forma

$$L(\theta; x_1, \dots, x_n) = P(X_1 = x_1|\theta) \dots P(X_n = x_n|\theta).$$

Veja o Problema 37 para o caso de termos mais de um parâmetro.

Problemas

10. Na função de verossimilhança $L(p)$ da binomial, suponha que $n = 5$ e $x = 3$. Construa o gráfico da função para os possíveis valores de $p = 1/5, 2/5, 3/5, 4/5$, e verifique que o máximo ocorre realmente para $p = 3/5$.
11. Observa-se uma seqüência de ensaios de Bernoulli, independentes, com parâmetro p , até a ocorrência do primeiro sucesso. Se X indicar o número de ensaios necessários:
 - (a) Mostre que $P(X = x) = (1-p)^{x-1}p$ (distribuição geométrica).
 - (b) Repetiu-se esse experimento n vezes, e em cada um deles o número de ensaios necessários foram $x_1, x_2, \dots, x_n$. Encontre o EMV para p .
 - (c) Usando uma moeda, repetiu-se esse experimento 5 vezes, e o número de ensaios necessários até a ocorrência da primeira coroa foi 2, 3, 1, 4, 1, respectivamente. Qual a estimativa de MV para p = probabilidade de ocorrência de coroa nessa moeda? Existiria outra maneira de estimar p ?
12. Suponha que X seja uma v.a. com distribuição normal, com média μ e variância 1. Obtenha o EMV de μ , para uma amostra de tamanho n , $(x_1, \dots, x_n)$.
13. Considere Y uma v.a. com distribuição de Poisson, com parâmetro $\lambda > 0$. Obtenha a EMV de λ , baseado numa amostra de tamanho n .

11.6 Intervalos de Confiança

Até agora, todos os estimadores apresentados foram pontuais, isto é, especificam um único valor para o estimador. Esse procedimento não permite julgar qual a possível magnitude do erro que estamos cometendo. Daí, surge a idéia de construir os intervalos de confiança, que são baseados na distribuição amostral do estimador pontual.

Exemplo 11.12. Suponha que queiramos estimar a média μ de uma população qualquer, e para tanto usamos a média $\bar{X}$ de uma amostra de tamanho n . Do TLC,

$$e = (\bar{X} - \mu) \sim N(0, \sigma_{\bar{X}}^2), \quad (11.32)$$

com $\text{Var}(\bar{X}) = \sigma_{\bar{X}}^2 = \sigma^2/n$. Daqui podemos determinar qual a probabilidade de cometermos erros de determinadas magnitudes. Por exemplo,

$$P(|e| < 1,96\sigma_{\bar{X}}) = 0,95$$

ou

$$P(|\bar{X} - \mu| < 1,96\sigma_{\bar{X}}) = 0,95,$$

que é equivalente a


$$P(-1,96\sigma_{\bar{X}} < \bar{X} - \mu < 1,96\sigma_{\bar{X}}) = 0,95,$$

e, finalmente,

$$P(\bar{X} - 1,96\sigma_{\bar{X}} < \mu < \bar{X} + 1,96\sigma_{\bar{X}}) = 0,95. \quad (11.33)$$

Convém lembrar que μ não é uma variável aleatória e sim um parâmetro, e a expressão (11.33) deve ser interpretada da seguinte maneira: se pudéssemos construir uma quantidade grande de intervalos (aleatórios!) da forma $]\bar{X} - 1,96\sigma_{\bar{X}}, \bar{X} + 1,96\sigma_{\bar{X}}[$, todos baseados em amostras de tamanho n , 95% deles conteriam o parâmetro μ . Veja a Figura 11.3. Dizemos que $\gamma = 0,95$ é o *coeficiente de confiança*. Nessa figura estão esquematizados o funcionamento e o significado de um intervalo de confiança (IC) para μ , com $\gamma = 0,95$ e σ^2 conhecido.

Figura 11.3: Significado de um IC para μ , com $\gamma = 0,95$ e σ^2 conhecido.




Escolhida uma amostra e encontrada sua média $\bar{x}_0$, e admitindo-se $\sigma_{\bar{x}}$ conhecido, podemos construir o intervalo

$$]\bar{x}_0 - 1,96\sigma_{\bar{x}}, \bar{x}_0 + 1,96\sigma_{\bar{x}}[. \quad (11.34)$$

Esse intervalo pode ou não conter o parâmetro μ , mas pelo exposto acima temos 95% de confiança de que contenha.

Para ilustrar o que foi dito acima, consideremos o seguinte experimento de simulação. Geramos 20 amostras de tamanho $n = 25$ de uma distribuição normal de média $\mu = 5$ e desvio padrão $\sigma = 3$. Para cada amostra construímos o intervalo de confiança para μ , com coeficiente de confiança $\gamma = 0,95$, que é da forma $\bar{X} \pm 1,176$, usando (11.34). Na Figura 11.4, temos esses intervalos representados e notamos que três deles (amostras de números 5, 14 e 15) não contêm a média $\mu = 5$.

Figura 11.4: Intervalos de confiança para a média de uma $N(5, 9)$, para 20 amostras de tamanho $n = 25$.



Exemplo 11.13. Uma máquina enche pacotes de café com uma variância igual a 100 g^2 . Ela estava regulada para encher os pacotes com 500 g , em média. Agora, ela se desregulou, e queremos saber qual a nova média μ . Uma amostra de 25 pacotes apresentou uma média igual a 485 g . Vamos construir um intervalo de confiança com 95% de confiança para μ . De (11.34), teremos

$$IC(\mu; 0,95) = 485 \pm 1,96 \times 2,$$

ou seja,

$$IC(\mu; 0,95) =]481, 489[,$$

pois $\sigma_{\bar{x}} = \sigma/\sqrt{n} = 10/5 = 2\text{g}$.

Se T for um estimador do parâmetro θ , e conhecida a distribuição amostral de T , sempre será possível achar dois valores t_1 e t_2 , tais que

$$P(t_1 < \theta < t_2) = \gamma, \quad (11.35)$$

a probabilidade interpretada como em (11.33), e γ um valor fixo, $0 < \gamma < 1$. Para uma dada amostra, teremos dois valores fixos para t_1 e t_2 , e o intervalo de confiança para θ , com coeficiente de confiança γ , será indicado do seguinte modo:

$$IC(\theta; \gamma) =]t_1, t_2[. \quad (11.36)$$

Se a variância populacional σ^2 não for conhecida, podemos substituir em (11.34) σ_x por $S/\sqrt{n}$, onde S^2 é a variância amostral dada em (11.9). Para n grande, da ordem de 100, o intervalo (11.34), com essa modificação, pode ainda ser usado. Para n não muito grande, a distribuição normal não pode mais ser usada e terá de ser substituída pela distribuição t de Student, que estudamos no Capítulo 7. Esse assunto voltará a ser abordado no Capítulo 12.

Para um coeficiente de confiança qualquer γ , teremos de usar o valor $z(\gamma)$ tal que $P(-z(\gamma) < Z < z(\gamma)) = \gamma$, com $Z \sim N(0, 1)$. O intervalo fica

$$IC(\mu; \gamma) =]\bar{X} - z(\gamma)\sigma_x, \bar{X} + z(\gamma)\sigma_x[. \quad (11.37)$$

Observe, também, que a amplitude do intervalo (11.37) é $L = 2z(\gamma)\sigma/\sqrt{n}$, que é uma constante, independente de $\bar{X}$. Se construirmos vários intervalos de confiança para o mesmo valor de n , σ e γ , estes terão extremos aleatórios, mas todos terão a mesma amplitude L .

Exemplo 11.14. Vamos obter um intervalo de confiança para o parâmetro p de uma distribuição $b(n, p)$. Sabemos que se X = número de sucessos nas n provas, então X tem distribuição aproximadamente normal, com média $\mu = np$ e variância $\sigma^2 = npq$, com $q = 1 - p$. Logo,

$$Z = \frac{X - np}{\sqrt{npq}} \sim N(0, 1),$$

ou ainda,

$$Z = \frac{X/n - p}{\sqrt{pq/n}} = \frac{\sqrt{n}(\hat{p} - p)}{\sqrt{pq}} \sim N(0, 1). \quad (11.38)$$

Assim, se $\gamma = 0,95$, temos, consultando a Tabela III, que

$$P(-1,96 \leq Z \leq 1,96) = 0,95,$$

ou seja,

$$P\left\{-1,96 \leq \frac{\sqrt{n}(\hat{p} - p)}{\sqrt{pq}} \leq 1,96\right\} = 0,95.$$

Portanto, com probabilidade 0,95, temos que

$$-1,96 \sqrt{pq/n} \leq \hat{p} - p \leq 1,96 \sqrt{pq/n},$$

do que segue

$$\hat{p} - 1,96 \sqrt{pq/n} \leq p \leq \hat{p} + 1,96 \sqrt{pq/n}.$$

Como não conhecemos p , podemos proceder de duas maneiras. Uma é usar o fato que $pq \leq 1/4$, de modo que $\sqrt{pq/n} \leq 1/\sqrt{4n}$, obtendo

$$\hat{p} - \frac{1,96}{\sqrt{4n}} \leq p \leq \hat{p} + \frac{1,96}{\sqrt{4n}}. \quad (11.39)$$

Temos, então, que $]\hat{p} - 1,96/\sqrt{4n}; \hat{p} + 1,96/\sqrt{4n}[$ é um intervalo de confiança para p , com coeficiente de confiança de 95%.

Para um γ qualquer, $0 < \gamma < 1$, (11.39) fica

$$\hat{p} - \frac{z(\gamma)}{\sqrt{4n}} \leq p \leq \hat{p} + \frac{z(\gamma)}{\sqrt{4n}}, \quad (11.40)$$

onde $z(\gamma)$ é definido como em (11.37).

Exemplo 11.15. Numa pesquisa de mercado, $n = 400$ pessoas foram entrevistadas sobre determinado produto, e 60% delas preferiram a marca A. Aqui, $\hat{p} = 0,6$ e um intervalo de confiança para p com coeficiente de confiança $\gamma = 0,95$ será

$$0,6 \pm (1,96) 1/\sqrt{1600} = 0,6 \pm 0,049,$$

ou seja

$$IC(p; 0,95) =]0,551; 0,649[.$$

O intervalo (11.40) é chamado *conservador*, pois se p não for igual a $1/2$ e estiver próximo de zero ou de um, então ele fornece um intervalo desnecessariamente maior, porque substituímos pq pelo seu valor máximo, $1/4$. Uma outra maneira de proceder é substituir pq por $\hat{p}\hat{q}$, com $\hat{q} = 1 - \hat{p}$, sendo $\hat{p}$ o estimador de máxima verossimilhança de p , por exemplo. O intervalo obtido fica

$$\hat{p} - z(\gamma)\sqrt{\hat{p}\hat{q}/n} \leq p \leq \hat{p} + z(\gamma)\sqrt{\hat{p}\hat{q}/n}, \quad (11.41)$$

com $z(\gamma)$ definido como em (11.40).

Exemplo 11.16. Suponha que em $n = 400$ provas obtemos $k = 80$ sucessos. Vamos obter um intervalo de confiança para p com $\gamma = 0,90$. Como $\hat{p} = 80/400 = 0,2$ e $\hat{q} = 1 - \hat{p} = 0,8$, então (11.41) fica

$$0,2 \pm (1,645)\sqrt{(0,2)(0,8)/400} = 0,2 \pm 0,033,$$

ou seja,

$$IC(p; 0,90) =]0,167; 0,233[.$$

Usando (11.40) o intervalo conservador é

$$IC(p; 0,90) =]0,159; 0,241[.$$

Observe que o primeiro intervalo tem amplitude menor que o segundo. Outra observação importante é que por (11.40) e um γ fixo, os intervalos que podemos obter para amostras diferentes (mas de mesmo tamanho n) terão a mesma amplitude, dada por $2z(\gamma)/\sqrt{4n}$. Por outro lado, usando (11.41), a amplitude do intervalo será $2z(\gamma) \frac{\sqrt{\hat{p}\hat{q}}}{n}$, que é variável de amostra para amostra, pois $\hat{p}$ (e, conseqüentemente, $\hat{q}$) variará de amostra para amostra.

Problemas

14. Calcule o intervalo de confiança para a média de uma $N(\mu, \sigma^2)$ em cada um dos casos abaixo.

Média Amostral	Tamanho da Amostra	Desvio Padrão da População	Coefficiente de Confiança
170 cm	100	15 cm	95%
165 cm	184	30 cm	85%
180 cm	225	30 cm	70%

15. De 50.000 válvulas fabricadas por uma companhia retira-se uma amostra de 400 válvulas, e obtém-se a vida média de 800 horas e o desvio padrão de 100 horas.
- Qual o intervalo de confiança de 99% para a vida média da população?
 - Com que confiança dir-se-ia que a vida média é $800 \pm 0,98$?
 - Que tamanho deve ter a amostra para que seja de 95% a confiança na estimativa $800 \pm 7,84$?
- (Que suposições você fez para responder às questões acima?)
16. Qual deve ser o tamanho de uma amostra cujo desvio padrão é 10 para que a diferença da média amostral para a média da população, em valor absoluto, seja menor que 1, com coeficiente de confiança igual a:
- 95%
 - 99%
17. Uma população tem desvio padrão igual a 10.
- Que tamanho deve ter uma amostra para que, com probabilidade 8%, o erro em estimar a média seja superior a uma unidade?
 - Supondo-se colhida a amostra no caso anterior, qual o intervalo de confiança, se $\bar{x} = 50$?
18. Uma amostra aleatória de 625 donas de casa revela que 70% delas preferem a marca A de detergente. Construir um intervalo de confiança para p = proporção das donas de casa que preferem A com c.c. $\gamma = 90\%$.
19. Encontre os intervalos de confiança para p se $k/n = 0,3$, com c.c. $\gamma = 0,95$. Utilize os dois enfoques apontados na seção 11.6, com $n = 400$.
20. Antes de uma eleição, um determinado partido está interessado em estimar a proporção p de eleitores favoráveis ao seu candidato. Uma amostra piloto de tamanho 100 revelou que 60% dos eleitores eram favoráveis ao candidato em questão.

- (a) Determine o tamanho da amostra necessário para que o erro cometido na estimação seja de, no máximo, 0,01 com probabilidade de 80%.
- (b) Se na amostra final, com tamanho igual ao obtido em (a), observou-se que 55% dos eleitores eram favoráveis ao candidato em questão, construa um intervalo de confiança para a proporção p . Utilize $\gamma = 0,95$.
21. Suponha que estejamos interessados em estimar a proporção de consumidores de um certo produto. Se a amostra de tamanho 300 forneceu 100 indivíduos que consomem o dado produto, determine:
- (a) o intervalo de confiança para p , com coeficiente de confiança de 95% (interprete o resultado);
- (b) o tamanho da amostra para que o erro da estimativa não exceda a 0,02 unidades com probabilidade de 95% (interprete o resultado).

11.7 Erro Padrão de um Estimador

Vimos que, obtida a distribuição amostral de um estimador, podíamos calcular a sua variância. Se não pudermos obter a distribuição exata, usamos uma aproximação, se essa estiver disponível, como no caso de $\bar{X}$, e a variância do estimador será a variância dessa aproximação. Por exemplo, para a média amostral $\bar{X}$, obtida de uma amostra de tamanho n , temos que

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n},$$

na qual σ^2 é a variância da v.a. X definida sobre a população.

À raiz quadrada dessa variância chamaremos de erro padrão de $\bar{X}$ e o denotaremos por

$$\text{EP}(\bar{X}) = \frac{\sigma}{\sqrt{n}}. \quad (11.42)$$

Definição. Se T for um estimador do parâmetro θ , chamaremos de *erro padrão de T* a quantidade

$$\text{EP}(T) = \sqrt{\text{Var}(T)}. \quad (11.43)$$

A variância de T dependerá dos parâmetros da distribuição de X , o mesmo acontecendo com o erro padrão. Por exemplo, em (11.42), $\text{EP}(\bar{X})$ depende de σ , que em geral é desconhecida. Podemos, então, obter o erro padrão estimado de $\bar{X}$, dado por

$$\widehat{\text{EP}}(\bar{X}) = \widehat{\text{EP}}(\bar{X}) = S/\sqrt{n}, \quad (11.44)$$

na qual S^2 é a variância amostral. Genericamente, o *erro padrão estimado* de T é dado por

$$\widehat{\text{EP}}(T) = \sqrt{\widehat{\text{Var}}(T)}. \quad (11.45)$$

Muitas vezes a quantidade (11.45) é chamada de erro amostral. Mas preferimos chamar de erro amostral à diferença $e = T - \theta$.

Exemplo 11.17. Para o Exemplo 11.15, $\hat{p} = 0,6$, e o erro padrão de $\hat{p}$ será dado por

$$EP(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}. \quad (11.46)$$

Como não conhecemos p usamos no seu lugar o estimador $\hat{p}$, obtendo-se

$$\widehat{EP}(\hat{p}) = \sqrt{(0,6)(0,4)/400} = 0,025.$$

Observe que o intervalo de confiança (11.41) pode ser escrito

$$\hat{p} \pm z(\gamma)(\widehat{EP}(\hat{p})),$$

ao passo que o intervalo para μ dado por (11.37) pode ser escrito

$$\bar{X} \pm (1,96)(EP(\bar{X})).$$

11.8 Inferência Bayesiana

O estabelecimento de uma ponte entre os valores observados na amostra e os modelos postulados para a população, objeto da inferência estatística, exige a adoção de princípios teóricos muito bem especificados. Neste livro usaremos a chamada *teoria freqüentista* (às vezes também chamada de clássica). Seus fundamentos encontram-se em trabalhos de J. Neyman, E. Pearson, R. Fisher e outros.

Consideremos um exemplo para ilustrar esse enfoque. Suponha que tenhamos uma amostra observada $(x_1, \dots, x_n)$ de uma população normal, $N(\mu, \sigma^2)$, e queremos fazer inferências sobre os valores de μ e σ^2 , baseados nas n observações.

Por meio de algum procedimento estudado neste capítulo, selecionamos estimadores $\hat{\mu}(x)$ e $\hat{\sigma}^2(x)$ que sejam funções do vetor de observações $\mathbf{x} = (x_1, \dots, x_n)'$. Considere dados hipotéticos $\mathbf{x}_1, \mathbf{x}_2, \dots$, todas amostras de tamanho n , que poderiam ter sido gerados da população em questão. Obtemos, então, as distribuições amostrais de $\hat{\mu}(\mathbf{x})$ e $\hat{\sigma}^2(\mathbf{x})$, como na seção 10.7. Podemos também obter intervalos de confiança para os parâmetros desconhecidos μ e σ^2 , bem como testar hipóteses sobre esses parâmetros, assunto a ser discutido no Capítulo 12.

Para construir intervalos de confiança e testar hipóteses será necessário conhecer a distribuição amostral dos estimadores. Como só temos um conjunto de dados e não dados hipotéticos, estas distribuições amostrais terão de ser obtidas de outra maneira, e não como no Exemplo 10.7. Usualmente isso é feito usando teoremas como o Teorema Limite Central, discutido na seção 10.8, obtendo-se uma distribuição aproximada para os estimadores, que vale para tamanhos de amostras grandes.

A crítica que se faz à teoria freqüentista é a possibilidade de “replicar dados”, bem como o recurso à teoria assintótica. Uma teoria que não faz uso de tais argumentos é a inferência bayesiana, cujos fundamentos foram estabelecidos por T. Bayes em 1763. Outros expoentes dessa corrente foram Bernoulli (1713), Laplace (1812) e Jeffreys (1939). Aqui, o Teorema de Bayes, estudado no Capítulo 5, tem papel fundamental. A noção de probabilidade prevalente aqui é a subjetiva, discutida brevemente no mesmo capítulo.

Com relação ao nosso exemplo, a Inferência Bayesiana admite que os parâmetros μ e σ^2 , que são quantidades desconhecidas da distribuição de X , podem ser descritos por uma distribuição de probabilidades, $p(\mu, \sigma^2)$, chamada a *distribuição a priori* desses parâmetros. Nessa distribuição são incorporadas todas as informações que temos sobre $\theta = (\mu, \sigma^2)'$, inclusive de natureza subjetiva. Essa distribuição é hipotetizada antes de se colherem os dados.

O que é importante observar é que, tanto na teoria freqüentista como na bayesiana, um parâmetro qualquer, como μ , no exemplo acima, é considerado fixo. O que se faz no enfoque bayesiano é caracterizar a incerteza sobre esse parâmetro por meio de uma distribuição de probabilidades.

Após obtidos os dados, obtemos a função de verossimilhança, que incorpora a informação sobre θ fornecida pelos dados. Finalmente, obtemos a distribuição *a posteriori* de θ , dada a amostra observada. Um estimador de θ pode ser tomado, por exemplo, como a média ou a moda dessa distribuição *a posteriori*.

Vimos no Capítulo 5 que o teorema de Bayes pode ser usado para atualizar probabilidades de um evento. Mas o teorema também pode ser utilizado para obter informação sobre um parâmetro desconhecido de um modelo probabilístico, como o binomial ou normal, por exemplo. Chamemos de θ um tal parâmetro, suposto desconhecido, e para o qual tenhamos alguma informação anterior, consubstanciada numa distribuição de probabilidades $p(\theta)$, chamada distribuição *a priori* de θ . Vamos supor, por ser mais simples, que θ tenha os valores $\theta_1, \theta_2, \dots, \theta_r$, com probabilidades *a priori* $P(\theta = \theta_i) = p(\theta_i)$, $i = 1, 2, \dots, r$. Chamemos de y a nova informação sobre θ , que também é obtida de um modelo discreto. Então o teorema de Bayes pode ser escrito

$$P(\theta_i|y) = \frac{p(\theta_i)P(y|\theta_i)}{\sum_{j=1}^r p(\theta_j)P(y|\theta_j)}, \quad i = 1, 2, \dots, r. \quad (11.47)$$

Aqui, as verossimilhanças são $P(y|\theta_1), \dots, P(y|\theta_r)$, e as probabilidades *a posteriori* determinadas pelo teorema de Bayes são $P(\theta_1|y), \dots, P(\theta_r|y)$. Obtida essa distribuição *a posteriori* de θ , dada a nova informação y , podemos por exemplo estimar θ como sendo a média dessa distribuição ou a moda (o valor que maximiza $P(\theta|y)$).

Exemplo 11.18. Vamos considerar uma aplicação do Teorema de Bayes a um exemplo simples de mercado de ações. Chamemos de y o rendimento do IBOVESPA (Índice da Bolsa de Valores de São Paulo), em porcentagem, por período (mês, por exemplo). Suponha que estejamos interessados somente se o rendimento for positivo ($y > 0$) ou negativo ($y < 0$). Designando por θ o “estado do mercado”, vamos considerar apenas dois estados, mercado em alta (θ_1) ou mercado em baixa (θ_2). Suponha que se tenha a seguinte informação prévia (ou *a priori*) sobre as probabilidades de θ_1 e θ_2 :

priori	θ_1	θ_2
$p(\theta)$	3/5	2/5

Então, as probabilidades *a priori* dos estados são $p(\theta_1) = P(\theta = \theta_1) = 3/5$ e $p(\theta_2) = P(\theta = \theta_2) = 2/5$. As verossimilhanças são dadas aqui por

$$P(y > 0|\theta) \text{ e } P(y < 0|\theta),$$

para $\theta = \theta_1, \theta_2$, que denotaremos genericamente por $p(y|\theta)$. Essas verossimilhanças são supostas conhecidas no Teorema de Bayes e vamos supor que em nosso caso são dadas na tabela abaixo.

$y \backslash \theta$	$p(y \theta)$	
	θ_1	θ_2
$y > 0$	2/3	1/3
$y < 0$	1/3	2/3

Ou seja, temos que

$$P(y > 0|\theta_1) = 2/3, \quad P(y > 0|\theta_2) = 1/3,$$

$$P(y < 0|\theta_1) = 1/3, \quad P(y < 0|\theta_2) = 2/3.$$

Podemos calcular as probabilidades conjuntas $p(y, \theta)$, ou seja,

$$p(y, \theta) = p(\theta)p(y|\theta),$$

obtendo-se a tabela abaixo.

$y \backslash \theta$	$p(y, \theta)$		$p(y)$
	θ_1	θ_2	
$y > 0$	6/15	2/15	8/15
$y < 0$	3/15	4/15	7/15
$p(\theta)$	9/15	6/15	1

Por exemplo,

$$P(y > 0, \theta = \theta_1) = P(\theta = \theta_1) \cdot P(y > 0|\theta = \theta_1) = 3/5 \times 2/3 = 6/15.$$

O Teorema de Bayes, dado pela fórmula (11.47), fornece as probabilidades *a posteriori* de θ_1 e θ_2 , dado o valor observado de y :

$$p(\theta|y) = \frac{p(\theta)p(y|\theta)}{p(y)}. \quad (11.48)$$

Para calcular (11.48) precisamos calcular $p(y)$, que são chamadas probabilidades marginais preditoras ou simplesmente *previsões*. Usando o mesmo argumento que deu origem a (5.14), podemos escrever

$$p(y) = \sum_{\theta} p(y, \theta) = \sum_{\theta} p(\theta)p(y|\theta).$$

Em nosso caso,

$$\begin{aligned} P(y > 0) &= P(\theta_1)P(y > 0|\theta_1) + P(\theta_2)P(y > 0|\theta_2) \\ &= 3/5 \times 2/3 + 2/5 \times 1/3 = 8/15. \end{aligned}$$

Do mesmo modo,

$$P(y < 0) = P(\theta_1)P(y < 0|\theta_1) + P(\theta_2)P(y < 0|\theta_2) = 7/15,$$

e teremos a tabela a seguir:

y	$p(y)$
$y > 0$	$8/15$
$y < 0$	$7/15$

Vemos que essa é a mesma distribuição marginal de y , dada na tabela que mostra a distribuição conjunta de y e θ .

Então, por (11.48),

$$P(\theta = \theta_1 | y > 0) = \frac{P(\theta_1)P(y > 0|\theta_1)}{P(y > 0)} = \frac{3/5 \times 2/3}{8/15} = 3/4,$$

$$P(\theta = \theta_2 | y > 0) = \frac{P(\theta_2)P(y > 0|\theta_2)}{P(y > 0)} = 1/4.$$

De modo análogo, obtemos

$$P(\theta = \theta_1 | y < 0) = 3/7, \quad P(\theta = \theta_2 | y < 0) = 4/7.$$

Temos, então, as probabilidades condicionais de alta e baixa, dada a informação de que o retorno é positivo ou negativo:

$\theta \backslash y$	$p(\theta y)$	
	θ_1	θ_2
$y > 0$	$3/4$	$1/4$
$y < 0$	$3/7$	$4/7$

Podemos, por exemplo, “estimar” θ (alta ou baixa) por θ_1 (mercado em alta) se $y > 0$, já que $P(\theta = \theta_1 | y > 0) = 3/4$ e “estimar” θ por θ_2 (mercado em baixa) se $y < 0$, pois $P(\theta = \theta_2 | y < 0) = 4/7$. Ou seja, tomamos o valor máximo da probabilidade *a posteriori*, dada a informação sobre o rendimento.

Esse é um exemplo do que se chama de modelo estático. Poderíamos considerar um modelo dinâmico, supondo-se que esse muda de período para período (de dia para dia ou de mês para mês etc.).

11.9. Exemplos Computacionais

Simulando Erros Padrões

Na seção 11.7 definimos o que seja o erro padrão de um estimador T de um parâmetro θ , baseado numa AAS de uma população rotulada pela v.a. X . Vimos, em particular, que o erro padrão da média amostral $\bar{X}$ é dado por (11.42) e esse pode ser estimado por (11.44), ou seja,

$$\widehat{EP}(\bar{X}) = \frac{S}{\sqrt{n}}.$$

O erro padrão de um estimador é fundamental para avaliarmos quão bom ele é. Simplesmente calcular T , ou saber que ele é não-viesado, não é suficiente: é necessário calcular sua variabilidade.

Mas, na maioria das situações, não podemos obter uma estimativa do erro padrão de um estimador. Considere, por exemplo, a mediana de uma amostra,

$$md = \text{med}(X_1, \dots, X_n). \quad (11.49)$$

Pode não ser fácil calcular a $\text{Var}(md)$ e, conseqüentemente, o erro padrão de md . Se admitirmos que a aproximação (11.18) é razoável, então teremos

$$\text{EP}(md) \approx \sigma \sqrt{\frac{\pi}{2n}}$$

e poderemos, novamente, estimar σ por S e obter

$$\widehat{\text{EP}}(md) \approx S \sqrt{\frac{\pi}{2n}}.$$

Mas, se tivermos amostras não muito grandes, a aproximação pode não ser adequada.

Felizmente, com o progresso de métodos computacionais usando intensivamente computadores cada vez mais rápidos e com capacidade cada vez maior de lidar com conjuntos grandes de dados, o cálculo de erros padrões, vieses etc., pode ser feito sem recorrer a uma teoria, que muitas vezes pode ser muito complicada ou simplesmente não existir.

Um desses métodos é chamado *bootstrap*, introduzido por B. Efrom, em 1979. Os livros de Efrom e Tibshirani (1993) e Davison e Hinkley (1997) são referências importantes para aqueles que quiserem se aprofundar no assunto.

A idéia básica do método *bootstrap* é re-amostrar o conjunto disponível de dados para estimar o parâmetro θ , com o fim de criar dados replicados. A partir dessas replicações, podemos avaliar a variabilidade de um estimador proposto para θ , sem recorrer a cálculos analíticos.

Vamos ilustrar o método com um exemplo.

Exemplo 11.19. Suponha que temos os dados amostrais $\mathbf{x} = (x_1, x_2, \dots, x_n)$ e queremos estimar a mediana populacional, Md , por meio da mediana amostral $md(\mathbf{x}) = \text{med}(x_1, \dots, x_n)$.

Vamos escolher uma AAS (portanto, com reposição) de tamanho n dos dados. Tal amostra é chamada uma amostra *bootstrap* e denotada por $\mathbf{x}^* = (x_1^*, \dots, x_n^*)$.

Por exemplo, suponha que $\mathbf{x} = (x_1, x_2, x_3, x_4, x_5)$. Poderemos obter, por exemplo, $\mathbf{x}^* = (x_4, x_3, x_3, x_1, x_2)$.

Suponha, agora, que geremos B tais amostras independentes, denotadas $\mathbf{x}_1^*, \dots, \mathbf{x}_B^*$. Para cada amostra *bootstrap*, geramos uma *réplica bootstrap* do estimador proposto, ou seja, de $md(\mathbf{x})$, obtendo-se

$$md(\mathbf{x}_1^*), md(\mathbf{x}_2^*), \dots, md(\mathbf{x}_B^*). \quad (11.50)$$

Definimos o estimador *bootstrap* do erro padrão de $\text{md}(x)$ como

$$\widehat{\text{EP}}_B(\text{md}) = \left[\frac{\sum_{b=1}^B (\text{md}(\mathbf{x}_b^*) - \overline{\text{md}})^2}{B-1} \right]^{1/2}, \quad (11.51)$$

com

$$\overline{\text{md}} = \frac{\sum_{b=1}^B \text{md}(\mathbf{x}_b^*)}{B}. \quad (11.52)$$

Ou seja, o estimador *bootstrap* do erro padrão da mediana amostral é o desvio padrão amostral do conjunto (11.50). Na Figura 11.5 temos representado o esquema do método.

Vamos ilustrar o método com um exemplo numérico simples. Suponha que $n = 5$ e a amostra é $\mathbf{x} = (2, 5, 3, 4, 6)$. Vamos considerar $B = 5$ amostras *bootstrap* de $\mathbf{x}$. Como gerar tais amostras? Primeiramente, geramos cinco números aleatórios $i_1, \dots, i_5$ dentre os cinco números inteiros 1, 2, 3, 4, 5 e consideramos a amostra *bootstrap* $\mathbf{x}^* = (x_{i_1}, \dots, x_{i_5})$. Repetimos esse procedimento cinco vezes. Podemos usar a Tabela VII para gerar esses NA, como já aprendemos. Considere, por exemplo, as cinco primeiras linhas e, começando do canto esquerdo, prossiga em cada linha até obter cinco dígitos entre 1 e 5, inclusive; note que pode haver repetições! Obtemos a Tabela 11.2.

Figura 11.5: Procedimento *bootstrap* para calcular o erro padrão da mediana amostral.




Tabela 11.2: Procedimento *bootstrap*.

NA	Amostra <i>bootstrap</i>	$\text{md}(\mathbf{x}^*)$	$\bar{x}(\mathbf{x}^*)$
1,2,2,5,1	(2,5,5,6,2)	5,0	4,0
4,4,4,3,2	(4,4,4,3,5)	4,0	4,0
5,4,5,5,5	(6,4,6,6,6)	6,0	5,6
5,1,1,5,5	(6,2,2,6,6)	6,0	4,4
2,5,4,5,3	(5,6,4,6,3)	5,0	4,8

Por exemplo, obtidos os NA 1, 2, 2, 5, 1, teremos a amostra *bootstrap* $(x_1, x_2, x_2, x_5, x_1) = (2, 5, 5, 6, 2)$, para a qual a mediana amostral é 5. Segue-se que $\overline{\text{md}} = 26/5 = 5,2$ e

$$\widehat{\text{EP}}_B(\text{md}) = \left[\frac{\sum_{b=1}^5 (\text{md}(\mathbf{x}_b^*) - 5,2)^2}{4} \right]^{1/2} = 0,837.$$

Se usarmos a aproximação (11.18), calculamos a variância da amostra original, obtendo-se $S^2 = 2,5$, donde $\widehat{EP}(\text{md}) \approx 0,886$. Levando-se em conta o tamanho da amostra, a discrepância entre os dois valores não é grande.

Exemplo 11.20. Na Tabela 11.2 calculamos, também, para cada amostra *bootstrap*, a média amostral, $\bar{x}$. Obtemos, usando (11.51),

$$\widehat{EP}_B(\bar{x}) = 0,669,$$

e usando a fórmula (11.44),

$$\widehat{EP}(\bar{x}) = \sqrt{2,5/5} = 0,707,$$

logo o valor obtido pelo método *bootstrap* está bastante próximo do valor calculado pela fórmula obtida de maneira analítica. Obviamente, em situações nas quais há uma fórmula disponível, não há necessidade de se usar *bootstrap*.

A questão que se apresenta é: qual deve ser o valor de B , ou seja, quantas amostras *bootstrap* devemos gerar para estimar erros padrões de estimadores? A experiência indica que um valor razoável é $B = 200$.

No caso geral de um estimador $\hat{\theta} = T(\mathbf{x})$, o algoritmo *bootstrap* para estimar o erro padrão de $\hat{\theta}$ é o seguinte:

- [1] Selecione B amostras *bootstrap* independentes $\mathbf{x}_1^*, \dots, \mathbf{x}_B^*$, cada uma consistindo de n valores selecionados com reposição de $\mathbf{x}$. Tome $B \approx 200$.
- [2] Para cada amostra *bootstrap* $\mathbf{x}_b^*$ calcule a réplica *bootstrap*

$$\hat{\theta}^*(b) = T(\mathbf{x}_b^*), \quad b = 1, 2, \dots, B.$$

- [3] O erro padrão de $\hat{\theta}$ é estimado pelo desvio padrão das B réplicas:

$$\widehat{EP}_B = \left[\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^*(b) - \bar{\theta}^*)^2 \right]^{1/2}, \quad (11.53)$$

com

$$\bar{\theta}^* = \frac{\sum_{i=1}^B \hat{\theta}^*(b)}{B}. \quad (11.54)$$

No exemplo acima, notamos que um intervalo de confiança aproximado para a mediana populacional Md , com coeficiente de confiança 95%, seria

$$5,2 \pm (1,96)(0,837) =]3,56; 6,84[.$$

No exemplo dado, para efeito de ilustração do método *bootstrap*, tomamos uma amostra pequena ($n = 5$) e poucas amostras *bootstrap* ($B = 5$). Para amostras maiores e B na ordem de 200 deveremos fazer um pequeno programa, em alguma linguagem (como o Visual Basic, Pascal, Fortran, C etc.), que gere as amostras *bootstrap*, e calcular o estimador dado por (11.53). Isso implica, em particular, gerar, para cada amostra *bootstrap*, n números aleatórios. Como já vimos, não é prático usar uma tabela de NA nessa situação; devemos usar alguma rotina de computador.

11.10 Problemas e Complementos

22. Um pesquisador está em dúvida sobre duas possíveis estatísticas, t e t' , para serem usadas como estimadores de um parâmetro θ . Assim, ele decidiu usar simulação para uma situação hipotética, procurando encontrar pistas que o ajudassem a decidir qual o melhor estimador. Partindo de uma população fictícia, onde $\theta = 10$, ele retirou 1.000 amostras de 20 elementos, e para cada amostra calculou o valor das estatísticas t e t' . Em seguida, construiu a distribuição de freqüências, segundo o quadro abaixo.

Classes	% de t	% de t'
5–7	10	5
7–9	20	30
9–11	40	35
11–13	20	25
13–15	10	5

- (a) Verifique as propriedades de t e t' como estimadores de θ .
 (b) Qual dos dois você adotaria? Por quê?
23. De experiências passadas, sabe-se que o desvio padrão da altura de crianças de 5ª série do 1º grau é 5 cm.
 (a) Colhendo uma amostra de 36 dessas crianças, observou-se a média de 150 cm. Qual o intervalo de confiança de 95% para a média populacional?
 (b) Que tamanho deve ter uma amostra para que o intervalo $150 \pm 0,98$ tenha 95% de confiança?
24. Um pesquisador está estudando a resistência de um determinado material sob determinadas condições. Ele sabe que essa variável é normalmente distribuída com desvio padrão de duas unidades.
 (a) Utilizando os valores 4,9; 7,0; 8,1; 4,5; 5,6; 6,8; 7,2; 5,7; 6,2 unidades, obtidos de uma amostra de tamanho 9, determine o intervalo de confiança para a resistência média com um coeficiente de confiança $\gamma = 0,90$.
 (b) Qual o tamanho da amostra necessário para que o erro cometido, ao estimarmos a resistência média, não seja superior a 0,01 unidade com probabilidade 0,90?
 (c) Suponha que no item (a) não fosse conhecido o desvio padrão. Como você procederia para determinar o intervalo de confiança, e que suposições você faria para isso? Veja também o Problema 44.
25. Estime o salário médio dos empregados de uma indústria têxtil, sabendo-se que uma amostra de 100 indivíduos apresentou os seguintes resultados:

Salário	Freqüência
150,00–250,00	8
250,00–350,00	22
350,00–450,00	38
450,00–550,00	28
550,00–650,00	2
650,00–750,00	2

Use $\gamma = 0,95$.

26. Suponha que as vendas de um produto satisfaçam ao modelo

$$V_t = \alpha + \beta t + a_t,$$

onde a_t é a variável aleatória satisfazendo as suposições da seção 11.4, e o tempo é dado em meses. Suponha que os valores das vendas nos 10 primeiros meses do ano 1 sejam dados pelos valores da tabela abaixo. Obtenha as previsões para os meses de novembro e dezembro do ano 1 e para julho e agosto do ano 2.

t	1	2	3	4	5	6	7	8	9	10
y_t	5,0	6,7	6,0	8,7	6,2	8,6	11,0	11,9	10,6	10,8

27. Numa pesquisa de mercado para estudar a preferência da população de uma cidade em relação a um determinado produto, colheu-se uma amostra aleatória de 300 indivíduos, dos quais 180 preferiam esse produto.
- Determine um intervalo de confiança para a proporção da população que prefere o produto em estudo; tome $\gamma = 0,90$.
 - Determine a probabilidade de que a estimativa pontual dessa proporção não difira do verdadeiro valor em mais de 0,001.
 - É possível obter uma estimativa pontual dessa proporção que não difira do valor verdadeiro em mais de 0,0005 com probabilidade 0,95? Caso contrário, determine o que deve ser feito.
28. Uma amostra de 10.000 itens de um lote de produção foi inspecionada, e o número de defeitos por item foi registrado na tabela abaixo.

Nº de defeitos	0	1	2	3	4
Quantidade de peças	6.000	3.200	600	150	50

- Determine os limites de confiança para a proporção de itens defeituosos na população, com coeficiente de confiança de 98%. Use (11.40).
 - Mesmo problema, usando (11.41).
29. Antes de uma eleição em que existiam dois candidatos, A e B , foi feita uma pesquisa com 400 eleitores escolhidos ao acaso, e verificou-se que 208 deles pretendiam votar no candidato A . Construa um intervalo de confiança, com c.c. $\gamma = 0,95$, para a porcentagem de eleitores favoráveis ao candidato A na época das eleições.
30. Encontre o c.c. de um intervalo de confiança para p , se $n = 100$, $\hat{p} = 0,6$ e a amplitude do intervalo deve ser igual a 0,090.
31. Usando os resultados do Problema 32 do Capítulo 10, mostre que o intervalo de confiança para a diferença das médias populacionais, com variâncias conhecidas, é dado por

$$IC(\mu_1 - \mu_2 : \gamma) = (\bar{X} - \bar{Y}) \pm z(\gamma) \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}.$$

32. Estão sendo estudados dois processos para conservar alimentos, cuja principal variável de interesse é o tempo de duração destes. No processo A , o tempo X de duração segue a distribuição $N(\mu_A, 100)$, e no processo B o tempo Y obedece à distribuição $N(\mu_B, 100)$. Sorteiam-se duas amostras independentes: a de A , com 16 latas, apresentou tempo médio de duração igual a 50, e a de B , com 25 latas, duração média igual a 60.

- (a) Construa um IC para μ_A e μ_B , separadamente.
- (b) Para verificar se os dois processos podem ter o mesmo desempenho, decidiu-se construir um IC para a diferença $\mu_A - \mu_B$. Caso o zero pertença ao intervalo, pode-se concluir que existe evidência de igualdade dos processos. Qual seria sua resposta?
33. Seja X uma v.a. com $E(X) = \mu$ e $\text{Var}(X) = \sigma^2$ finita. Então, para todo $k > 0$, a seguinte desigualdade (chamada desigualdade de Chebyshev) é válida:

$$P(|X - \mu| \geq k) \leq \text{Var}(X)/k^2. \quad (11.55)$$

Usando (11.55), prove que $\bar{X}$ é um estimador consistente para a média μ de uma população com variância σ^2 .

34. **Lei dos Grandes Números.** Consideremos n provas de Bernoulli com $p = P$ (sucesso), e seja k o número de sucessos nas n provas. A Lei dos Grandes Números (LGN) afirma que, para n grande, a proporção de sucessos k/n estará próxima de $p = P$ (sucesso). Formalmente, para todo $\varepsilon > 0$,

$$P\left\{\left|\frac{k}{n} - p\right| \geq \varepsilon\right\} \leq \frac{p(1-p)}{n\varepsilon^2}. \quad (11.56)$$

Prove (11.56), usando (11.55).

35. A LGN pode ser usada de maneira útil na seguinte situação. Suponha que queiramos saber quantas repetições de um experimento de Bernoulli devemos realizar a fim de que k/n difira de p de menos de ε , com probabilidade maior ou igual a γ . Ou seja, queremos determinar n , tal que

$$P\left\{\left|\frac{k}{n} - p\right| < \varepsilon\right\} \geq \gamma.$$

De (11.56) temos

$$P\left\{\left|\frac{k}{n} - p\right| < \varepsilon\right\} \geq 1 - \frac{p(1-p)}{n\varepsilon^2};$$

logo, comparando, temos que n deve satisfazer

$$1 - \frac{p(1-p)}{n\varepsilon^2} = \gamma \Rightarrow n = \frac{p(1-p)}{\delta\varepsilon^2}, \text{ onde } \delta = 1 - \gamma.$$

Como não conhecemos p , usando o fato de que $p(1-p) \leq 1/4$; logo, basta tomar n tal que $n = 1/4\delta\varepsilon^2$.

Usando esse resultado, resolva este problema: suponha que a proporção de fumantes de uma população é p , desconhecida. Queremos determinar p com um erro de, no máximo, 0,05. Qual deve ser o tamanho da amostra n , a ser escolhida com reposição, se $\gamma = 0,95$?

36. Se a distribuição de X depende de mais de um parâmetro, digamos θ_1 e θ_2 , então $L(\theta_1, \theta_2; X_1, \dots, X_n)$, e para maximizar L basta derivar L em relação a θ_1 e θ_2 (em algumas situações, derivar L não conduz ao EMV; veja o Problema 43). Considere, então, $X \sim N(\mu, \sigma^2)$. Determine os EMV de μ e σ^2 , considerando $\partial\ell/\partial\mu = 0$ e $\partial\ell/\partial\sigma^2 = 0$, onde $\ell = \log L$.

37. **Estimação numa distribuição uniforme.** Suponha que X tenha uma distribuição uniforme no intervalo $(0, \theta)$, onde θ é desconhecido. Uma amostra de n observações $X_1, \dots, X_n$ é escolhida. Sabemos que $E(X) = E(X_i) = \theta/2$, para todo i , e $\text{Var}(X) = \text{Var}(X_i) = \theta^2/12$, para todo i . Logo, se calcularmos a média amostral $\bar{X}$, essa deve estar próxima de $\theta/2$ e podemos estimar θ por $T_1 = 2\bar{X}$.

- (a) Calcule $E(T_1)$.
- (b) Calcule $\text{EQM}(T_1) = E(T_1 - \theta)^2$.
- (c) T_1 é consistente? Por quê?

38. **Continuação do Problema 37.** Outra maneira de estimar θ na uniforme é a seguinte. Considere $M = \max(X_1, \dots, X_n) = x_{(n)}$, ou seja, o maior valor da amostra. Para qualquer valor de θ , $M < \theta$ e M se aproxima de θ quando n aumenta. Tome M como estimador de θ , o que é bastante razoável. Na realidade, veremos, no Problema 42, que $M = \hat{\theta}_{MV}$.

Vimos no Problema 39 do Capítulo 10, que a densidade de M é dada por

$$f_M(x) = \begin{cases} \frac{n}{\theta^n} x^{n-1}, & \text{se } 0 \leq x \leq \theta \\ 0, & \text{caso contrário.} \end{cases} \quad (11.57)$$

- (a) Mostre que $E(M) = \theta \frac{n}{n+1}$, logo M é viesado. Calcule o viés $V_M(\theta)$ de M e mostre que esse viés tende a zero, quando $n \rightarrow \infty$.
 - (b) Considere o estimador $T_2 = \frac{n+1}{n} M$; segue-se que T_2 é não-viesado para θ , ou seja, $E(T_2) = \theta$. Calcule o erro quadrático médio de T_2 , $\text{EQM}(T_2) = E(T_2 - \theta)^2$.
 - (c) T_2 é consistente? Por quê?
39. Para os Problemas 37 e 38, mostre que $\text{Var}(T_2) = [3/(n+2)] \text{Var}(T_1)$. Tome $n = 1, 2, 10, 50, 100$ e verifique qual a relação entre as duas variâncias. Verifique que, para n grande, $T_2 = [(n+1)/n]M$ é um estimador muito melhor do que $T_1 = 2\bar{X}$. Como $T_2 = (1 + 1/n)M$, vemos que, para n grande, $T_2 \approx M$. Portanto, para tamanhos de amostras grandes, o EMV é melhor do que $2\bar{X}$.
40. Considere as situações dos Problemas 37, 38 e 39. Suponha que n seja suficientemente grande para que o TLC se aplique e se possa aproximar a distribuição de X e de M por uma distribuição normal.
- (a) Calcule a média e variância de T_1 , M e T_2 .
 - (b) Obtenha um I.C. $(\theta; 0,90)$ usando T_1 .
 - (c) Idem usando M .
 - (d) Idem usando T_2 .
- [Sugestão: substitua na variância de cada estimador, obtida em (a), o parâmetro θ , desconhecido, pelo seu estimador, para obter a respectiva variância estimada]
41. Foram gerados 1.000 valores de uma distribuição uniforme no intervalo $(0, 5)$, ou seja, $\theta = 5$. As seguintes estatísticas foram obtidas:

$$x_{(1)} = \min(X_1, \dots, X_{1000}) = 0,01132, \quad x_{(1000)} = M = \max(X_1, \dots, X_{1000}) = 4,992;$$

$$q_1 = 1,315, \quad q_2 = 2,572, \quad q_3 = 3,829, \quad \bar{x} = 2,547.$$

Calcule T_1 , T_2 e aplique o resultado do Problema 40 para obter um intervalo de confiança para θ , com c.c. = 90%.


42. EMV na uniforme. Como

$$f(x) = \begin{cases} 1/\theta, & \text{se } 0 \leq x \leq \theta, \\ 0, & \text{caso contrário,} \end{cases}$$

a densidade conjunta da amostra é

$$f(x_1, \dots, x_n; \theta) = \begin{cases} 1/\theta^n, & \text{se } 0 \leq x_i \leq \theta, i = 1, \dots, n \\ 0, & \text{caso contrário.} \end{cases}$$

Segue-se que $\ell(\theta|x_1, \dots, x_n) = -n \log \theta$ e derivando e igualando a zero obteremos $-n/\theta = 0$, ou seja, o EMV de θ seria ∞ ! Evidentemente, essa não é a resposta. Na realidade, não podemos simplesmente derivar a verossimilhança (ou o logaritmo dela) para obter o máximo, pois temos as restrições $0 \leq x_i \leq \theta$, para todo i . Façamos o seguinte. Considere o gráfico da densidade conjunta, ou da verossimilhança, como função de θ . Como devemos ter $0 \leq x_i \leq \theta$, para todo i , o máximo M dos x_i deve ser tal que $0 \leq M \leq \theta$, ou seja, obtemos o gráfico abaixo.



Ou seja, $L(\theta|x_1, \dots, x_n) = 0$, para $\theta \leq M$; logo, o máximo da verossimilhança é obtido para $\theta = M$ e portanto $\hat{\theta}_{MV} = M$.

Esse exemplo mostra que nem sempre obteremos o EMV derivando-se a verossimilhança e igualando-a a zero.

43. Suponha que $X \sim N(\mu, \sigma^2)$, μ e σ^2 desconhecidos. Uma amostra de tamanho $n = 600$ forneceu $\bar{X} = 10,3$ e $S^2 = 1,96$. Supondo que a v.a. $Z = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ seja aproximadamente

normal, obtenha um IC para μ , com c.c. $\gamma = 0,95$ (se n for pequeno, Z não é aproximadamente normal; ver Capítulo 12).

44. Para estimar a média μ desconhecida de uma população, foram propostos dois estimadores não-viesados independentes, $\hat{\mu}_1$ e $\hat{\mu}_2$, de tal sorte que $\text{Var}(\hat{\mu}_1) = \text{Var}(\hat{\mu}_2)/3$. Considere os seguintes estimadores ponderados de μ :
- (a) $T_1 = (\hat{\mu}_1 + \hat{\mu}_2)/2$;
 - (b) $T_2 = (4\hat{\mu}_1 + \hat{\mu}_2)/5$;
 - (c) $T_3 = \hat{\mu}_1$.
- (i) Quais estimadores são não-viesados?
 - (ii) Dispor esses estimadores em ordem crescente de eficiência.
45. Obtenha o estimador de λ na Poisson, pelo método dos momentos.
46. Considere o CD-Notas e retire uma amostra com reposição de tamanho $n = 10$. Determine o erro padrão estimado pelo método *bootstrap* das estatísticas (use $B = 15$, por exemplo):
- (a) md = mediana da amostra;
 - (b) dm = desvio médio da amostra.
 - (c) dam = desvio absoluto mediano.
47. Prove (11.15).
48. Calcule o EQM (erro quadrático médio), dado por (11.20), para os estimadores S^2 e $\hat{\sigma}^2$, no caso de população normal. Compare esses dois EQM. Qual estimador você escolheria, se o critério de escolha é ter o menor EQM?
49. Considere a v.a. discreta X com função de probabilidade dada por:

$$p(x) = P(X = x) = \frac{1}{\theta}, \quad x = 1, 2, \dots, \theta$$

onde $\theta > 0$ é um número inteiro desconhecido. Uma AAS $X_1, \dots, X_n$ de tamanho n é selecionada e considera-se o seguinte estimador de θ :

$$T = 2\bar{X} - 1, \quad \text{onde} \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

- (a) Mostre que T é um estimador não-viesado de θ e obtenha sua variância. T é um estimador consistente de θ ? Por quê?
- (b) Se $n = 6$ e a amostra observada for $x_1 = x_2 = x_3 = x_4 = x_5 = 1$ e $x_6 = 2$, qual é a estimativa de θ ? Esta estimativa é um valor plausível para θ ? Sugira outro estimador para θ que somente conduza a valores plausíveis de θ .

[Observação: $\sum_{i=1}^k i = k(k+1)/2$, $\sum_{i=1}^k i^2 = k(k+1)(2k+1)/6$, $k \geq 1$, k inteiro.]

Testes de Hipóteses

12.1 Introdução

Vimos no Capítulo 10 que um dos problemas a serem resolvidos pela Inferência Estatística é o de testar uma hipótese. Isto é, feita determinada afirmação sobre uma população, usualmente sobre um parâmetro dessa, desejamos saber se os resultados experimentais provenientes de uma amostra contrariam ou não tal afirmação. Muitas vezes, essa afirmação sobre a população é derivada de teorias desenvolvidas no campo substantivo do conhecimento. A adequação ou não dessa teoria ao universo real pode ser verificada ou refutada pela amostra. O objetivo do teste estatístico de hipóteses é, então, fornecer uma metodologia que nos permita verificar se os dados amostrais trazem evidências que apoiem ou não uma hipótese (estatística) formulada.

Neste capítulo iremos introduzir o procedimento básico de teste de hipótese sobre um parâmetro de uma população. A idéia central desse procedimento é a de supor verdadeira a hipótese em questão e verificar se a amostra observada é “verossímil” nessas condições. No capítulo seguinte daremos alguns testes para comparação de parâmetros de duas populações.

12.2 Um Exemplo

Vamos introduzir a idéia de teste de uma hipótese por meio de um exemplo hipotético que, partindo de uma situação simples, será gradualmente ampliado para atender à situação geral do teste de hipóteses.

Exemplo 12.1. Uma indústria usa, como um dos componentes das máquinas que produz, um parafuso importado, que deve satisfazer a algumas exigências. Uma dessas é a resistência à tração. Esses parafusos são fabricados por alguns países, e as especificações técnicas variam de país para país. Por exemplo, o catálogo do país A afirma que a resistência média à tração de seus parafusos é de 145 kg, com desvio padrão de 12 kg. Já para o país B, a média é de 155 kg e desvio padrão 20 kg.

Um lote desses parafusos, de origem desconhecida, será leiloado a um preço muito convidativo. Para que a indústria saiba se faz ou não uma oferta, ela necessita saber qual


país produziu tais parafusos. O edital do leiloeiro afirma que, pouco antes do leilão, será divulgada a resistência média $\bar{x}$ de uma amostra de 25 parafusos do lote. Qual regra de decisão deve ser usada pela indústria para dizer se os parafusos são do país A ou B?

Uma resposta que ocorre imediatamente é a que considera como país produtor aquele para o qual a média da amostra mais se aproximar da média da população. Assim, uma possível regra de decisão seria:

Se $\bar{x} \leq 150$ (o ponto médio entre 145 e 155), diremos que os parafusos são do país A; caso contrário, isto é, $\bar{x} > 150$, são do país B.

Na Figura 12.1 ilustramos essa regra de decisão.

Figura 12.1: Regra de decisão para o Exemplo 12.1.



Suponha que, no dia do leilão, fôssemos informados de que $\bar{x} = 148$; de acordo com nossa regra de decisão, diríamos que os parafusos são de origem A. Podemos estar enganados nessa conclusão? Ou, em outras palavras, é possível que uma amostra de 25 parafusos de origem B apresente média $\bar{x} = 148$? Sim, é possível. Então, para melhor entendermos a regra de decisão adotada, é interessante estudarmos os tipos de erros que podemos cometer e as respectivas probabilidades.

Podemos cometer dois tipos de erros, e vamos numerá-los para facilitar a linguagem:

Erro de tipo I: dizer que os parafusos são de A quando na realidade são de B. Isso ocorre quando uma amostra de 25 parafusos de B apresenta média $\bar{x}$ inferior ou igual a 150 kg.

Erro de tipo II: dizer que os parafusos são de B, quando na realidade eles são de A. Isso ocorre quando uma amostra de 25 parafusos de A apresenta média $\bar{x}$ superior a 150 kg.

Para facilitar ainda mais, vamos definir duas hipóteses também numeradas:

H_0 : os parafusos são de origem B. Isso equivale a dizer que a resistência X de cada parafuso segue uma distribuição com média $\mu = 155$ e desvio padrão $\sigma = 20$.

H_1 : os parafusos são de A, isto é, a média $\mu = 145$ e o desvio padrão $\sigma = 12$.

Finalmente, vamos indicar por RC a região correspondente aos valores menores que 150, ou seja,

$$RC = \{y \in \mathbb{R} | y \leq 150\}.$$

Com as notações indicadas acima, a probabilidade de se cometer cada um dos erros pode ser escrita:

$$P(\text{erro I}) = P(\bar{X} \in RC | H_0 \text{ é verdadeira}) = \alpha$$

e

$$P(\text{erro II}) = P(\bar{X} \notin RC | H_1 \text{ é verdadeira}) = \beta.$$

Quando H_0 for verdadeira, isto é, os parafusos forem de B, sabemos do TLC que $\bar{X}$ terá distribuição aproximadamente normal, com média 155 e desvio padrão igual a $20/\sqrt{25} = 4$, isto é,

$$\bar{X} \sim N(155, 16).$$

Denotando por Z a v.a. com distribuição $N(0, 1)$, temos

$$\begin{aligned} P(\text{erro I}) &= P(\bar{X} \in RC | H_0 \text{ é verdadeira}) \\ &= P(\bar{X} \leq 150 | \bar{X} \sim N(155, 16)) \\ &= P\left(Z \leq \frac{150 - 155}{4}\right) \\ &= P(Z \leq -1,25) = 0,10565 = 10,56\% = \alpha. \end{aligned}$$

De modo análogo, quando H_1 for a alternativa verdadeira, teremos que a v.a. $\bar{X}$ é tal que, aproximadamente,

$$\bar{X} \sim N(145; 5,76).$$

Teremos, então,

$$\begin{aligned} P(\text{erro II}) &= P(\bar{X} \notin RC | H_1 \text{ é verdadeira}) \\ &= P(\bar{X} > 150 | \bar{X} \sim N(145; 5,76)) \\ &= P\left(Z > \frac{150 - 145}{2,4}\right) = P(Z > 2,08) = 0,01876 = 1,88\% = \beta. \end{aligned}$$

Observando esses dois resultados, notamos que, com a regra de decisão adotada, estaremos cometendo o erro de tipo I com maior probabilidade do que o erro de tipo II. De certo modo, essa regra de decisão privilegia a afirmação de que os parafusos são de A. No Quadro 12.1 ilustramos as conseqüências que podem advir da regra de decisão adotada.

Quadro 12.1: Resumo do teste $H_0: \mu = 155$, $H_1: \mu = 145$, com $RC =]-\infty, 150]$.

Origem Real dos Parafusos	Decisão	
A	Sem erro	Erro tipo II $\beta = 1,88\%$
B	Erro tipo I $\alpha = 10,56\%$	Sem erro

Desse quadro, podemos notar que, se os parafusos forem realmente de B (segunda linha) e a amostra tiver média superior a 150 (segunda coluna), diremos que são de B,

e não cometeremos erro algum. Por outro lado, se a média $\bar{x}$ for inferior a 150 (primeira coluna), devemos dizer que são de A, e estaremos cometendo um erro cuja probabilidade nesse caso é de 10,56%. De modo análogo, teremos uma interpretação para o caso de os parafusos serem realmente de A (primeira linha).

Para cada regra de decisão adotada, isto é, se escolhermos um valor $\bar{x}_c$ em vez de 150 no Quadro 12.1, apenas as probabilidades α e β mudarão. Se $\bar{x}_c$ for escolhido menor que 150, notamos que α diminuirá e β aumentará. Logo, deve existir um ponto em que α seja igual a β , ou seja, uma regra de decisão em que a probabilidade de errar contra A seja a mesma que errar contra B. Mostre que esse ponto é $\bar{x}_c = 148,75$, e nesse caso $\alpha = \beta = 5,94\%$.

Do exposto acima constatamos que, escolhido um valor de $\bar{x}_c$, podemos achar as probabilidades α e β de cometer cada tipo de erro. Mas também podemos proceder de modo inverso: fixar um dos erros, digamos α , e encontrar a regra de decisão que irá corresponder à probabilidade de erro de tipo I igual a α .

Por exemplo, fixemos α em 5%, e vejamos qual a regra de decisão correspondente. Temos

$$\begin{aligned} 5\% &= P(\text{erro I}) = P(\bar{X} \leq \bar{x}_c | \bar{X} \sim N(155, 16)) \\ &= P(Z \leq -1,645), \end{aligned}$$

mas da transformação para a normal padrão sabemos que

$$-1,645 = \frac{\bar{x}_c - 155}{4},$$

ou seja, $\bar{x}_c = 148,42$. Então, a regra de decisão será:


Se $\bar{x}$ for inferior a 148,42, dizemos que o lote é de A; caso contrário, dizemos que é de B.

Com essa regra, a probabilidade do erro de tipo II será

$$\begin{aligned} \beta &= P(\text{erro II}) = P(\bar{X} > 148,42 | \bar{X} \sim (145; 5,76)) \\ &= P(Z > 1,425) = 7,93\%. \end{aligned}$$

Veja a ilustração na Figura 12.2.

Figura 12.2: Ilustração dos erros de tipo I e II para o Exemplo 12.1.



Esse segundo tipo de procedimento é bastante utilizado, porque usualmente a decisão que devemos tomar não é apenas entre duas possíveis populações. Os parafusos poderiam ser produzidos por outros países além daqueles citados e, portanto, com outras características quanto à resistência média. Suponha, ainda, que interessa à indústria fazer uma proposta apenas no caso de o parafuso ser de origem B. Qual a regra de decisão que deve adotar?

A hipótese que nos interessa agora é:

H_0 : os parafusos são de origem B ($\mu = 155$ e $\sigma = 20$).

Caso essa não seja a hipótese verdadeira, a alternativa é muito mais ampla e pode ser expressa como:

H_1 : os parafusos não são de origem B (μ e σ desconhecidos).

Aqui não podemos especificar os parâmetros sob a hipótese alternativa H_1 , pois se não forem de origem B, os parafusos podem ser de vários outros países, cada um com suas próprias especificações. Alguns países podem ter técnicas mais sofisticadas de produção e, portanto, produzir com resistência média superior a 155. Outros, como no exemplo dado, com resistência menor. A especificação da hipótese alternativa depende muito do grau de informação que se tem do problema. Por exemplo, vamos admitir que a indústria do país B para esse caso seja a mais desenvolvida, e nenhum outro país possa produzir uma resistência média superior à dela. Então, nossa hipótese alternativa seria mais explícita:


H_1 : os parafusos não são de origem B ($\mu < 155$ e σ qualquer).

Isso significa que só iremos desconfiar de H_0 se $\bar{x}$ for muito menor do que 155. Ou seja, a nossa regra de decisão deverá ser semelhante à vista anteriormente. Como os parâmetros sob a hipótese alternativa são muitos, a melhor solução para construir a regra de decisão é fixar α , a probabilidade do erro de tipo I (rejeitar H_0 quando ela for verdadeira). Se fixarmos novamente $\alpha = 0,5$, e nesse caso a regra de decisão depende apenas das informações de H_0 , a regra de decisão será a mesma anterior:


Se $\bar{x}$ for superior a 148,42, diremos que o lote é de origem B; caso contrário, diremos que não é de origem B.

Com essa regra de decisão e com a hipótese alternativa mais ampla, não podemos encontrar β , pois não temos um único parâmetro μ como alternativa e nada sabemos sobre σ . Então, não podemos controlar o erro de tipo II. As implicações dessa regra de decisão estão resumidas na Figura 12.3 e no Quadro 12.2.

Figura 12.3: Teste $H_0 : \mu = 155$ vs $H_1 : \mu < 155$, com $RC =]-\infty; 148,42]$.



Quadro 12.2: Resumo do teste $H_0: \mu = 155$, $H_1: \mu < 155$, com $RC =]-\infty, 148,42]$.

Origem Real dos Parafusos	Decisão	
		
B	Erro tipo I, $\alpha = 5\%$	Sem erro
não B	Sem erro	Erro tipo II, $\beta = ?$

Podemos reescrever as hipóteses nessa situação da seguinte maneira:

$$H_0: \mu = 155$$

$$H_1: \mu < 155$$

O cálculo de β depende do valor de μ , que não é especificado. Mas podemos considerar a seguinte e importante função.

Definição. A função *característica de operação* (função CO) do teste acima é definida como

$$\beta(\mu) = P(\text{aceitar } H_0 | \mu) = P(\bar{X} > 148,42 | \mu).$$

Ou seja, $\beta(\mu)$ é a probabilidade de aceitar H_0 , considerada como uma função de μ .

Usualmente, considera-se a função $\pi(\mu) = 1 - \beta(\mu)$, que é a probabilidade de se rejeitar H_0 , como função de μ . Essa função é chamada *função poder do teste* e será estudada abaixo com certo detalhe. Nesses casos consideramos que σ é o mesmo para todos os valores de μ .

Admitamos, agora, que não exista razão alguma para acreditarmos que a resistência média dos parafusos de B seja maior ou menor do que a de outros países. Isso irá nos levar a duvidar que os parafusos não são de B, se a média observada for muito maior ou muito menor do que 155. Esta situação corresponde à seguinte hipótese alternativa:

H_1 : os parafusos não são de origem B ($\mu \neq 155$).

Aqui, a regra de decisão deverá indicar dois pontos $\bar{x}_{c_1}$ e $\bar{x}_{c_2}$, tais que:

Se $\bar{x}$ estiver entre $\bar{x}_{c_1}$ e $\bar{x}_{c_2}$, diremos que os parafusos são de origem B; se $\bar{x}$ estiver fora do intervalo, diremos que não são de origem B.

Fixado α , a probabilidade do erro I, existirão muitos valores que satisfazem a essa condição. Daremos preferência àquelas soluções $\bar{x}_{c_1}$ e $\bar{x}_{c_2}$, simétricas em relação à média. Veja a Figura 12.4.

Voltando ao nosso problema, e fixado α em 5%, temos

$$0,05 = P(\text{erro I}) = P(\bar{X} < \bar{x}_{c_1} \text{ ou } \bar{X} > \bar{x}_{c_2} | \bar{X} \sim N(155, 16))$$

$$= P(Z < -1,96 \text{ ou } Z > 1,96),$$

e daqui encontramos

$$-1,96 = (\bar{x}_{c_1} - 155)/4 \Rightarrow \bar{x}_{c_1} = 147,16$$

e

$$1,96 = (\bar{x}_{c_2} - 155)/4 \Rightarrow \bar{x}_{c_2} = 162,84.$$

- (b) Qual deve ser a regra de decisão se quisermos fixar a probabilidade do erro de tipo I em 5%? Qual a probabilidade do erro de tipo II, nesse caso?
- (c) Se $\sigma_A = 5$, como ficariam as respostas de (b)?
- (d) Quais as probabilidades do erro de tipo II, nas condições da questão (b), se a média $\mu_B = 178$? E $\mu_B = 180$? E $\mu_B = 181$? Coloque num gráfico os pares $(\mu_B, P(\text{erro II} | \mu_B))$.

2. Fazendo o teste

$$H_0 : \mu = 1.150 \ (\sigma = 150) \text{ contra } H_1 : \mu = 1.200 \ (\sigma = 200),$$

e $n = 100$, estabeleceu-se a seguinte região crítica:

$$RC = [1.170, +\infty[.$$

- (a) Qual a probabilidade α de rejeitar H_0 quando verdadeira?
 - (b) Qual a probabilidade β de aceitar H_0 quando H_1 é verdadeira?
 - (c) Qual deve ser a região crítica para que $\alpha = \beta$?
3. Nas situações abaixo, escolha como hipótese nula, H_0 , aquela que para você leva a um erro de tipo I mais importante. Descreva quais os dois erros em cada caso.
- (a) O trabalho de um operador de radar é detectar aeronaves inimigas. Quando surge alguma coisa estranha na tela, ele deve decidir entre as hipóteses:
 1. está começando um ataque;
 2. tudo bem, apenas uma leve interferência.
 - (b) Num júri, um indivíduo está sendo julgado por um crime. As hipóteses sujeitas ao júri são:
 1. o acusado é inocente;
 2. o acusado é culpado.
 - (c) Um pesquisador acredita que descobriu uma vacina contra resfriado. Ele irá conduzir uma pesquisa de laboratório para verificar a veracidade da afirmação. De acordo com o resultado, ele lançará ou não a vacina no mercado. As hipóteses que pode testar são:
 1. a vacina é eficaz;
 2. a vacina não é eficaz.
4. Se, ao lançarmos três vezes uma moeda, aparecerem 3 coroas, decidimos rejeitar a hipótese de que a moeda é "honesta". Quais as probabilidades de erro de tipo I e erro de tipo II, se $p = 2/3$?
5. A variável X , custo de manutenção de um tear, pode ser considerada como tendo distribuição normal de média μ e desvio padrão 20 unidades. Os valores possíveis de μ podem ser 200 ou 210. Para verificar qual dos dois valores é o mais provável, usar-se-á uma amostra de 25 teares. Defina:
- (a) Uma hipótese a ser testada.
 - (b) Uma regra de decisão e encontre as probabilidades dos erros de tipo I e II.

12.3 Procedimento Geral do Teste de Hipóteses

A construção de um teste de hipóteses, para um parâmetro populacional, pode ser colocada do seguinte modo. Existe uma variável X associada a dada população e tem-se uma hipótese sobre determinado parâmetro θ dessa população. Por exemplo, afirmamos

que o verdadeiro valor de θ é θ_0 . Colhe-se uma amostra aleatória de elementos dessa população, e com ela deseja-se comprovar ou não tal hipótese.

Como já vimos anteriormente, iniciamos nossa análise explicitando claramente qual a hipótese que estamos colocando à prova e a chamamos de *hipótese nula*, e escrevemos

$$H_0 : \theta = \theta_0.$$

Em seguida, convém explicitar também a hipótese que será considerada aceitável, caso H_0 seja rejeitada. A essa hipótese chamamos de *hipótese alternativa*, e a sua caracterização estatística irá depender do grau de conhecimento que se tem do problema estudado. A alternativa mais geral seria

$$H_1 : \theta \neq \theta_0.$$

Poderíamos, ainda, ter alternativas da forma

$$H_1 : \theta < \theta_0 \quad \text{ou} \quad H_1 : \theta > \theta_0,$$

dependendo das informações que o problema traz.

Qualquer que seja a decisão tomada, vimos que estamos sujeitos a cometer erros. Para facilitar a linguagem, introduzimos as definições:

Erro de tipo I: rejeitar a hipótese nula quando essa é verdadeira. Chamamos de α a probabilidade de cometer esse erro, isto é,

$$\alpha = P(\text{erro do tipo I}) = P(\text{rejeitar } H_0 | H_0 \text{ é verdadeira}).$$

Erro de tipo II: não rejeitar H_0 quando H_0 é falsa. A probabilidade de cometer esse erro é denotada por β , logo

$$\beta = P(\text{erro do tipo II}) = P(\text{não rejeitar } H_0 | H_0 \text{ é falsa}).$$

O objetivo do teste de hipóteses é dizer, usando uma estatística $\hat{\theta}$, se a hipótese H_0 é ou não aceitável. Operacionalmente, essa decisão é tomada através da consideração de uma região crítica RC. Caso o valor observado da estatística pertença a essa região, rejeitamos H_0 ; caso contrário, não rejeitamos H_0 . Esta região é construída de modo que $P(\hat{\theta} \in \text{RC} | H_0 \text{ é verdadeira})$ seja igual a α , fixado *a priori*. RC recebe o nome de *região crítica* ou *região de rejeição* do teste. Um fato importante a ressaltar é que a região crítica é sempre construída sob a hipótese de H_0 ser verdadeira. A determinação do valor de β já é mais difícil, pois usualmente não especificamos valores fixos para o parâmetro sob a hipótese alternativa. Mais adiante trataremos dessa situação, ao considerarmos o poder de um teste.

A probabilidade α de se cometer um erro de tipo I (ou de primeira espécie) é um valor arbitrário e recebe o nome de *nível de significância* do teste. O resultado da amostra é tanto mais significativo para rejeitar H_0 quanto menor for esse nível α . Ou seja, quanto menor for α , menor é a probabilidade de se obter uma amostra com estatística pertencente à região crítica, sendo pouco verossímil a obtenção de uma amostra da população para a qual H_0 seja verdadeira. Usualmente, o valor de α é fixado em 5%, 1% ou 0,1%.

A fixação do valor de α envolve uma questionável arbitrariedade. Neste sentido há um modo alternativo de se proceder, que será considerado na seção 12.8.

12.4 Passos para a Construção de um Teste de Hipóteses

Vimos nas seções anteriores o procedimento que se deve usar para realizar um teste de hipóteses. Daremos abaixo uma seqüência que pode ser usada sistematicamente para qualquer teste de hipóteses.

Passo 1. Fixe qual a hipótese H_0 a ser testada e qual a hipótese alternativa H_1 .

Passo 2. Use a teoria estatística e as informações disponíveis para decidir qual estatística (estimador) será usada para testar a hipótese H_0 . Obter as propriedades dessa estatística (distribuição, média, desvio padrão).

Passo 3. Fixe a probabilidade α de cometer o erro de tipo I e use este valor para construir a região crítica (regra de decisão). Lembre que essa região é construída para a estatística definida no passo 2, usando os valores do parâmetro hipotetizados por H_0 .

Passo 4. Use as observações da amostra para calcular o valor da estatística do teste.

Passo 5. Se o valor da estatística calculado com os dados da amostra não pertencer à região crítica, não rejeite H_0 ; caso contrário, rejeite H_0 .

Procuraremos, sempre que fizermos teste de hipóteses, distinguir bem esses cinco passos. Finalmente um comentário sobre H_0 e o erro de tipo I. Devemos tomar como H_0 aquela hipótese, que, rejeitada, conduza a um erro de tipo I mais importante de evitar. Vejamos um exemplo devido a Neyman (1978). Suponha um experimento para se determinar se um produto A é ou não cancerígeno. Após realizado o teste, podemos concluir: (i) A é cancerígeno ou (ii) A não é cancerígeno. Cada uma dessas conclusões pode estar errada e temos os dois tipos de erro já mencionados, dependendo de qual hipótese seja H_0 . Do ponto de vista do usuário do produto, a hipótese a ser testada deve ser

$$H_0 : A \text{ é cancerígeno,}$$

pois a probabilidade de erro na rejeição dessa hipótese, se ela for verdadeira, deve ser um valor muito pequeno. Outros exemplos estão contidos no Problema 3.

12.5 Testes sobre a Média de uma População com Variância Conhecida

Vejamos, agora, uma aplicação dos cinco passos definidos na seção anterior, para testar a hipótese de que a média de uma população μ seja igual a um número fixado μ_0 , supondo-se a variância σ^2 dessa população conhecida.

Exemplo 12.2. Uma máquina automática para encher pacotes de café enche-os segundo uma distribuição normal, com média μ e variância sempre igual a 400 g². A máquina foi regulada para $\mu = 500$ g. Desejamos, periodicamente, colher uma amostra de 16 pacotes e

verificar se a produção está sob controle, isto é, se $\mu = 500$ g ou não. Se uma dessas amostras apresentasse uma média $\bar{x} = 492$ g, você pararia ou não a produção para regular a máquina?

Vejamos como testar essa hipótese.

Passo 1. Indiquemos por X o peso de cada pacote; então, $X \sim N(\mu, 400)$. E as hipóteses que nos interessam são:

$$H_0 : \mu = 500 \text{ g,}$$


$$H_1 : \mu \neq 500 \text{ g,}$$

pois a máquina pode desregular para mais ou para menos.

Passo 2. Pela afirmação do problema, $\sigma^2 = 400$ será sempre a mesma; logo, para todo μ , a média $\bar{X}$ de 16 pacotes terá distribuição $N(\mu, 400/16)$, de modo que o desvio padrão (ou erro padrão) de $\bar{X}$ é $\sigma_{\bar{x}} = 5$. Em particular, se H_0 for verdadeira, $\bar{X} \sim N(500, 25)$.

Passo 3. Vamos fixar $\alpha = 1\%$; pela hipótese alternativa, vemos que H_0 deve ser rejeitada quando $\bar{X}$ for muito pequena ou muito grande (dizemos que temos um teste bilateral). Portanto, nossa região crítica será como a da Figura 12.5.

Figura 12.5: Região crítica para o teste $H_0 : \mu = 500$ vs $H_1 : \mu \neq 500$ do Exemplo 12.2.



Da tabela da curva normal padronizada obtemos que

$$z_1 = -2,58 = (\bar{x}_{c_1} - 500)/5 \Rightarrow \bar{x}_{c_1} = 487,1,$$

$$z_2 = 2,58 = (\bar{x}_{c_2} - 500)/5 \Rightarrow \bar{x}_{c_2} = 512,9.$$

Segue-se que a região crítica é

$$RC = \{\bar{x} \in \mathbb{R} \mid \bar{x} \leq 487,1 \text{ ou } \bar{x} \geq 512,9\}.$$

Passo 4. A informação pertinente da amostra é sua média, que nesse caso particular é $\bar{x}_0 = 492$.

Passo 5. Como $\bar{x}_0$ não pertence à região crítica, nossa conclusão será não rejeitar H_0 . Ou seja, o desvio da média da amostra para a média proposta por H_0 pode ser considerado como devido apenas ao sorteio aleatório dos pacotes.

A situação analisada não é muito realista: conhecer a variância da população. O caso mais geral, de média e variância desconhecidas, será tratado na seção 12.10.

Problemas

6. Sabe-se que o consumo mensal *per capita* de um determinado produto tem distribuição normal, com desvio padrão 2 kg. A diretoria de uma firma que fabrica esse produto resolveu que retiraria o produto da linha de produção se a média de consumo *per capita* fosse menor que 8 kg. Caso contrário, continuaria a fabricá-lo. Foi realizada uma pesquisa de mercado, tomando-se uma amostra de 25 indivíduos, e verificou-se que $\sum_{i=1}^{25} X_i = 180$ kg, onde X_i representa o consumo mensal do i -ésimo indivíduo da amostra.
 - (a) Construa um teste de hipótese adequado, utilizando $\alpha = 0,05$, e com base na amostra colhida determine a decisão a ser tomada pela diretoria.
 - (b) Qual a probabilidade β de se tomar uma decisão errada se, na realidade, a média populacional for $\mu = 7,8$ kg?
 - (c) Se a diretoria tivesse fixado $\alpha = 0,01$, a decisão seria a mesma? (Justifique sua resposta.)
 - (d) Se o desvio da população fosse 4 kg, qual seria a decisão, com $\alpha = 0,05$? (Justifique sua resposta.)
7. A associação dos proprietários de indústrias metalúrgicas está muito preocupada com o tempo perdido com acidentes de trabalho, cuja média, nos últimos tempos, tem sido da ordem de 60 horas/homem por ano e desvio padrão de 20 horas/homem. Tentou-se um programa de prevenção de acidentes, após o qual foi tomada uma amostra de nove indústrias e medido o número de horas/homens perdidas por acidente, que foi de 50 horas. Você diria, no nível de 5%, que há evidência de melhoria?
8. O salário médio dos empregados das indústrias siderúrgicas de um país é de 2,5 salários mínimos, com um desvio padrão de 0,5 salários mínimos. Uma indústria é escolhida ao acaso e desta é escolhida uma amostra de 49 empregados, resultando um salário médio de 2,3 salários mínimos. Podemos afirmar que esta indústria paga salários inferiores à média nacional, com o nível de 5%?
9. Uma companhia de cigarros anuncia que o índice médio de nicotina dos cigarros que fabrica apresenta-se abaixo de 23 mg por cigarro. Um laboratório realiza 6 análises desse índice, obtendo: 27, 24, 21, 25, 26, 22. Sabe-se que o índice de nicotina se distribui normalmente, com variância igual a 4,86 mg². Pode-se aceitar, no nível de 10%, a afirmação do fabricante?

12.6 Teste para Proporção

Vamos usar os passos descritos na seção 12.4 para mostrar a construção do teste para proporções.

Passo 1. Temos uma população e uma hipótese sobre a proporção p de indivíduos portadores de certa característica. Esta hipótese afirma que essa proporção é igual a certo valor p_0 . Então,

$$H_0 : p = p_0.$$

O problema fornece informações sobre a alternativa, que pode ter uma das três formas abaixo:

- (i) $H_1 : p \neq p_0$ (teste bilateral);
- (ii) $H_1 : p > p_0$ (teste unilateral à direita); e
- (iii) $H_1 : p < p_0$ (teste unilateral à esquerda).

Passo 2. Como vimos na seção 10.9, a estatística $\hat{p}$, a proporção amostral, tem uma distribuição aproximadamente normal, a saber,

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right).$$


Passo 3. Fixado um valor de α , devemos construir a região crítica para p , sob a suposição de que o parâmetro definido por H_0 seja o verdadeiro. Ou seja, podemos escrever

$$\hat{p} \sim N\left(p_0, \frac{p_0(1-p_0)}{n}\right),$$

e, conseqüentemente, teremos a região crítica da Figura 12.6, supondo a alternativa (i) acima; sendo que $d = Z(1 - \alpha/2) \sqrt{p_0(1-p_0)/n}$ e $Z(p)$ é o p -quantil da normal padrão.

O quarto e quinto passos irão depender da amostra, e o procedimento está descrito no exemplo seguinte.

Figura 12.6: Região crítica para o teste $H_0 : p = p_0$ vs $H_1 : p \neq p_0$.



Exemplo 12.3. Uma estação de televisão afirma que 60% dos televisores estavam ligados no seu programa especial da última segunda-feira. Uma rede competidora deseja contestar essa afirmação e decide usar uma amostra de 200 famílias para um teste. Qual deve ser o procedimento adotado para avaliar a veracidade da afirmação da estação? No passo 4 a seguir daremos o resultado da amostra, pois é importante ficar claro que esse resultado não deve influenciar a escolha da alternativa.

Passo 1. Vamos colocar à prova a afirmação da estação, isto é,

$$H_0 : p = 0,60.$$

Sabemos que, se essa hipótese não for verdadeira, espera-se uma proporção menor, nunca maior. A estação divulgaria o máximo possível. Isso nos leva à hipótese alternativa

$$H_1 : p < 0,60.$$

Passo 2. A estatística a ser usada é $\hat{p}$, a proporção de 200 famílias que assistiram ao programa na última segunda-feira, e da teoria sabemos que

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{200}\right).$$


Passo 3. Fixaremos $\alpha = 0,05$ e sob a suposição que H_0 seja verdadeira,

$$\hat{p} \sim N(0,60, 0,24/200),$$

o que irá fornecer a região crítica (veja a Figura 12.7)

$$RC = \{\hat{p} \in \mathbb{R} \mid \hat{p} \leq 0,544\}.$$

Figura 12.7: Região crítica para o teste $H_0 : p = 0,60$ vs $H_1 : p < 0,60$ do Exemplo 12.3.



De fato, devemos achar o valor $\hat{p}_c$ tal que $P(\hat{p} \leq \hat{p}_c) = 0,05$, e usando a aproximação normal acima, teremos

$$P\left(Z \leq \frac{\hat{p}_c - 0,60}{\sqrt{0,24/200}}\right) = 0,05,$$

o que implica

$$\frac{\hat{p}_c - 0,60}{\sqrt{0,24/200}} = -1,645,$$

o valor $-1,645$ sendo obtido da normal padronizada. Segue-se que $\hat{p}_c = 0,544$, correspondendo à região crítica acima.

Passo 4. Admitamos que, da pesquisa feita com as 200 famílias, obtivemos 104 pessoas que estavam assistindo ao programa. A proporção da amostra será $\hat{p} = 104/200 = 0,52$.

Passo 5. Do resultado do passo anterior, vemos que $0,52 \in RC$; portanto, somos levados a rejeitar H_0 . Isto é, há evidências que a audiência do programa de segunda-feira não foi de 60% e sim inferior a esse número.

Problemas

10. Uma pessoa gaba-se de adivinhar qual será o resultado do lance de uma moeda, mas é preciso que os presentes não o perturbem com pensamentos duvidosos. Para testar tal capacidade, lançou-se uma moeda perfeita 6 vezes, e o adivinhador acertou 5. Qual seria sua conclusão?
11. O consumidor de um certo produto acusou o fabricante, dizendo que mais de 20% das unidades fabricadas apresentam defeito. Para confirmar sua acusação, ele usou uma amostra de tamanho 50, onde 27% das peças eram defeituosas. Mostre como o fabricante poderia refutar a acusação. Utilize um nível de significância de 10%.
12. Um fabricante garante que 90% dos equipamentos que fornece a uma fábrica estão de acordo com as especificações exigidas. O exame de uma amostra de 200 peças desse equipamento revelou 25 defeituosas. Teste a afirmativa do fabricante, nos níveis de 5% e 1%.
13. Os produtores de um programa de televisão pretendem modificá-lo se for assistido regularmente por menos de um quarto dos possuidores de televisão. Uma pesquisa encomendada a uma empresa especializada mostrou que, de 400 famílias entrevistadas, 80 assistem ao programa regularmente. Com base nos dados, qual deve ser a decisão dos produtores?

12.7 Poder de um Teste

Vimos que, na construção de um teste de hipóteses, procuramos controlar o erro de tipo I, fixando sua probabilidade de ocorrência, α , e construindo a região crítica de modo que $P(RC|H_0 \text{ verdadeira}) = \alpha$. Ou seja, admitindo que H_0 seja verdadeira, estamos admitindo conhecido(s) o(s) parâmetro(s) que define(m) a distribuição da estatística usada no teste.

Por outro lado, a probabilidade do erro do tipo II, na maioria dos casos, não pode ser calculada, pois a hipótese alternativa usualmente especifica um conjunto de valores para o parâmetro. Voltemos ao exemplo da seção anterior.

Exemplo 12.2. (continuação) No exemplo da máquina de encher pacotes de café, a v.a. X , que descrevia o peso de cada pacote, tinha uma distribuição normal com média μ e variância 400, de modo que a média amostral $\bar{X} \sim N(500, 25)$, sob a hipótese H_0 . Esse fato foi utilizado para determinar a região crítica $RC = \{\bar{x} \in \mathbb{R} \mid \bar{x} < 487,1 \text{ ou } \bar{x} > 512,9\}$ e nossa regra de decisão para verificar se a máquina estava ou não produzindo sob controle foi:

Se $\bar{x} \in RA$, a máquina está sob controle; se $\bar{x} \in RC$, não está,

onde RA é a região de aceitação do teste, isto é, o complementar de RC em relação a $\mathbb{R}$ e, portanto, dada no nosso caso por $RA = \{\bar{x} \in \mathbb{R} \mid 487,1 \leq \bar{x} \leq 512,9\}$.

A probabilidade β do erro de tipo II não pode ser calculada, a menos que se especifique um valor alternativo para μ . Segue-se que a função característica de operação do teste é dada por

$$\begin{aligned}\beta(\mu) &= P(\text{aceitar } H_0 | \mu) = P(\bar{X} \in RA | \mu) \\ &= P(487,1 \leq \bar{X} \leq 512,9 | \mu).\end{aligned}$$

Por exemplo, se a máquina se desregular para $\mu = 505$, teremos

$$\beta(505) = P(\bar{X} \in RA | \mu = 505) = P(-3,58 \leq Z \leq 1,58) = 94,28\%,$$

usando o fato que agora $\bar{X} \sim N(505, 25)$. Lembre-se de que supomos que $\sigma^2 = 400$, sempre!

Para qualquer outro valor do parâmetro μ podemos encontrar o respectivo valor de β , para a regra de decisão adotada. No Quadro 12.4 temos as decisões que podemos tomar e suas respectivas implicações.

Quadro 12.4: Decisões possíveis para o teste $H_0 : \mu = 500$ versus $H_1 : \mu \neq 500$

Decisão	Valor real do parâmetro	
	$H_0 : \mu = 500$	$H_1 : \mu \neq 500$
a máquina está sob controle: $\mu = 500$	$P(RA H_0) = 0,99$	$P(RA H_1) = \beta$ depende de valor alternativo de μ
a máquina não está sob controle: $\mu \neq 500$	$P(RC H_0) = 0,01$	$P(RC H_1) = 1 - \beta$ depende de valor alternativo de μ

Observe, por exemplo, que $1 - \beta(500) = P(\text{rejeitar } H_0 | \mu = 500) = \alpha = 0,01$.

A quantidade $1 - \beta(\mu)$ é usualmente chamada de *poder* ou *potência do teste*, e é a probabilidade de rejeitar a hipótese H_0 , dado um valor qualquer de μ , especificado ou não pela hipótese alternativa, e será denotado por $\pi(\mu)$. No nosso exemplo,

$$\pi(\mu) = P(\text{rejeitar } H_0 | \mu) = P(\bar{X} < 487,1 \text{ ou } \bar{X} > 512,9 | \mu).$$

Na Tabela 12.1 temos alguns valores de $\beta(\mu)$ e de $\pi(\mu)$, para diferentes valores de μ , e na Figura 12.8 a representação gráfica da determinação dessa probabilidade. Observe que quanto maior for a distância entre o valor fixado em $H_0 (\mu = 500)$ e o valor atribuído para a hipótese alternativa, maior será a probabilidade de tomar a decisão correta. Na Figura 12.9 temos o gráfico de $\pi(\mu)$ para os valores de μ da Tabela 12.1.

Tabela 12.1: Valores de $\beta(\mu)$ e $\pi(\mu)$, usando a regra de decisão $RC = \{\bar{x} \in \mathbb{R} | \bar{x} \leq 487,1 \text{ ou } \bar{x} \geq 512,9\}$

Verdadeiro valor de μ		$\pi(\mu)$ (em %)	$\beta(\mu)$ (em %)
À esquerda de 500	À direita de 500		
500	500	1,0	99,0
498	502	1,7	98,3
495	505	5,7	94,3
492	508	16,4	83,6
490	510	28,1	71,9
487	513	49,0	51,0
485	515	66,3	34,7
480	520	92,1	7,9
475	525	99,2	0,8

Figura 12.8: Determinação do poder para o teste do Exemplo 12.2.





Figura 12.9: Curva de poder para o Exemplo 12.2.



As seguintes propriedades de $\pi(\mu)$ são facilmente verificadas:

- (i) $\pi(-\infty) = \pi(+\infty) = 1$;
- (ii) $\pi(500) = \alpha$;
- (iii) π decresce para $\mu < 500$ (isto é, $d\pi/d\mu < 0$ para $\mu < 500$) e π cresce para $\mu > 500$ (isto é, $d\pi/d\mu > 0$, para $\mu > 500$).

Vemos que $\pi(\mu)$ indica a probabilidade de uma decisão correta, para as diversas alternativas do parâmetro e pode ser usada para decidir entre dois testes para uma mesma hipótese.

Exemplo 12.4. Se, no Exemplo 12.2, a amostra colhida fosse de 100 pacotes em vez de 16, e mantivéssemos o mesmo nível de significância $\alpha = 1\%$, a nova região crítica seria

$$RC = \{\bar{x} \in \mathbb{R} \mid \bar{x} \leq 494,8 \text{ ou } \bar{x} \geq 505,2\}.$$

Construindo a função poder para esse teste, obtemos a curva tracejada na Figura 12.9. Verifique essas afirmações.

Observando as duas curvas na Figura 12.9, notamos que para todos os valores sob a hipótese alternativa, a probabilidade de uma decisão correta é maior para amostras de

tamanho 100 do que de tamanho 16. Dizemos, nesse caso, que o teste baseado em amostras de tamanho 100 é *mais poderoso* do que o teste baseado em amostras de tamanho 16. Esse fato está de acordo com a intuição de que um teste com amostras maiores deve levar a melhores resultados.

De modo geral, se quisermos testar

$$\begin{aligned} H_0 : \theta &= \theta_0 \\ H_1 : \theta &\neq \theta_0, \end{aligned}$$

e determinada a RC do teste, baseada na estatística $\hat{\theta}$, podemos dar a seguinte definição geral.

Definição. A função poder (ou potência) do teste de H_0 contra H_1 é definida por


$$\pi(\theta) = P(\hat{\theta} \in RC | \theta),$$

ou seja, é a probabilidade de rejeitar a hipótese nula, como função de θ .

O gráfico dessa função é semelhante àqueles da Figura 12.9, e $\pi(\theta)$ tem as propriedades (i)–(iii) acima, substituindo 500 por θ_0 .

Se tivermos hipóteses alternativas unilaterais, da forma $H_1 : \theta < \theta_0$ ou $H_1 : \theta > \theta_0$, obteremos os gráficos da Figura 12.10.

Figura 12.10: Curvas de poder para alternativas unilaterais.



Nos exemplos anteriores fixamos o tamanho da amostra, n , e o nível de significância, α . Suponha que queiramos determinar o tamanho da amostra e os limites da RC, para alcançarmos dado poder para determinado valor do parâmetro. No Exemplo 12.2 poderíamos, por exemplo, fixar $\pi(510) = 0,80$ e $\pi(500) = 0,05$ (o nível de significância). Dados esses valores, podemos determinar n e a RC. Veja o Problema 33.

Problemas

14. Suponha que estejamos testando $H_0 : p = 0,5$ contra $H_1 : p \neq 0,5$, e que, para uma amostra de tamanho $n = 10$, decidimos pela região crítica $RC = \{0, 1, 2, 8, 9, 10\}$.
 - (a) Determine o nível de significância α .
 - (b) Calcule o poder do teste para $p = 0,2, 0,4, 0,6, 0,8$. Faça um gráfico do poder como função de p .
 - (c) Qual o poder do teste para $p = 0,5$?
15. Sendo X o custo de manutenção de um tear, sabe-se que $X \sim N(\mu, 400)$. Para testar a hipótese $H_0 : \mu = 200$, contra a alternativa $H_1 : \mu > 200$, será usada uma amostra de 25 teares.
 - (a) Fixando-se $\alpha = 5\%$, encontre a correspondente RC.
 - (b) Atribuindo-se valores arbitrários para μ , esboce a função poder do teste.
 - (c) Para que valores de μ o poder será maior do que 50%?

12.8 Valor-p

O método de construção de um teste de hipóteses, descrito nas seções anteriores, parte da fixação do nível de significância α . Pode-se argumentar que esse procedimento pode levar à rejeição da hipótese nula para um valor de α e à não-rejeição para um valor menor. Outra maneira de proceder consiste em apresentar a *probabilidade de significância* ou *nível descritivo* ou ainda *valor-p* do teste. Os passos são muito parecidos aos já apresentados; a principal diferença está em não construir a região crítica. O que se faz é indicar a probabilidade de ocorrer valores da estatística mais extremos do que o observado, sob a hipótese de H_0 ser verdadeira.

Exemplo 12.5. Voltemos ao Exemplo 12.3, onde

$$H_0 : p = 0,60.$$


Como vimos, admitindo essa hipótese verdadeira, $\hat{p} \sim N(0,60; 0,24/200)$. Colhida a amostra obtivemos $\hat{p}_0 = 104/200 = 0,52$. Portanto, podemos calcular qual a probabilidade de ocorrerem valores de $\hat{p}$ mais desfavoráveis para H_0 do que esse. É evidente que quanto menor for $\hat{p}$, maior será a evidência contra $H_0 : p = 0,60$. Assim, calculemos

$$\begin{aligned} P(\hat{p} < 0,52 \mid p = 0,60) &= P\left(Z < \frac{\sqrt{200}(0,52 - 0,60)}{\sqrt{0,24}}\right) \\ &= P(Z < -2,30) = 0,01 = 1\%. \end{aligned}$$

Esse resultado mostra que, se a audiência do programa fosse de 60% realmente, a probabilidade de encontrarmos uma amostra de 200 famílias com 52% ou menos de audiência é de 1%. Isso sugere que, ou estamos diante de uma amostra rara de ocorrer, 1 em 100, ou então a hipótese formulada não é aceitável. Nesse caso, somos levados a essa segunda opção, ou seja, os dados da amostra sugerem que a hipótese H_0 deve ser rejeitada.

O procedimento está ilustrado na Figura 12.11. O valor- p do teste será $\hat{\alpha} = 0,01$.

Figura 12.11: Determinação do valor- p para o Exemplo 12.5.



Exemplo 12.6. Um antibiótico A traz em sua bula a seguinte citação: “Nas broncopneumonias, a ação antiinflamatória de A é colocada em evidência pelo estudo dos parâmetros ventilatórios em duplo-cego contra placebo. Durante o tratamento com A pode-se observar uma melhora significativa em relação ao placebo, da capacidade vital ($p < 0,05$) e o VEMS ($p < 0,001$) e do débito respiratório máximo ($p < 0,001$)”.

Esse exemplo ilustra o uso cada vez mais difundido em muitas áreas aplicadas do conceito de valor- p . As afirmações do tipo “ $p < 0,05$ ” acima referem-se a esse conceito. Vale a pena comentar um pouco sobre “estudos duplo-cego”, mencionados acima. Nesse tipo de estudo, um número n de indivíduos é dividido em dois grupos de tamanhos aproximadamente iguais; a seleção dos indivíduos que vão pertencer a cada grupo é aleatória. Os indivíduos de um grupo recebem o tratamento (o antibiótico A, no caso), e os do outro grupo recebem placebo (uma substância inóqua). Os pesquisadores que acompanham o experimento não sabem quem recebeu tratamento e quem recebeu placebo, o mesmo acontecendo com os pacientes, daí o nome duplo-cego.

Podemos considerar probabilidades de significância bilaterais. Um procedimento é tomar o valor- p bilateral como sendo igual a duas vezes o valor- p unilateral. Esta prática é razoável quando a distribuição da estatística do teste, sob H_0 , for simétrica.

Exemplo 12.7. Uma companhia de serviços de ônibus intermunicipais planejou uma nova rota para servir vários locais situados entre duas cidades importantes. Um estudo preliminar afirma que a duração das viagens pode ser considerada uma v.a. normal, com média igual a 300 minutos e desvio padrão 30 minutos. As dez primeiras viagens realizadas nessa nova rota apresentaram média igual a 314 minutos. Esse resultado comprova ou não o tempo médio determinado nos estudos preliminares?

Passo 1. Indicando por X a duração de cada viagem e por $\mu = E(X)$, queremos testar

$$H_0 : \mu = 300,$$

$$H_1 : \mu \neq 300.$$

Passo 2. Amostras de dez viagens terão média $\bar{X} \sim N(\mu, \sigma^2/10)$.

Passo 3. Sob a hipótese de que H_0 é verdadeira, e pelo fato de σ^2 ser conhecido ($\sigma = 30$), teremos

$$\bar{X} \sim N(300, 900/10).$$

Passo 4. Como o valor observado $\bar{x}_0 = 314$, podemos encontrar a probabilidade de ocorrerem amostras com valores de $\bar{X}$ mais extremos do que esse:

$$P(\bar{X} > 314) = P\left(Z > \frac{314 - 300}{9,49}\right) = P(Z > 1,48) = 0,07.$$

Como a distribuição de $\bar{X}$ é normal, portanto simétrica, tomamos $\hat{\alpha} = 0,14$. Nosso problema consiste em decidir se essa probabilidade corresponde ou não à chance de ocorrer um evento raro. Por ser uma probabilidade não muito pequena, podemos concluir que não existe muita evidência para rejeitar H_0 . Assim, os estudos preliminares parecem estar corretos.

Um problema que pode ocorrer com o procedimento acima, de dobrar a probabilidade, é que o valor de $\hat{\alpha}$ pode ser maior do que um. Por isso, às vezes é preferível anunciar o valor do valor- p unilateral e a direção segundo a qual a observação afasta-se de H_0 . No exemplo, o resultado indica que a chance de ocorrerem amostras com médias iguais ou superiores a 314 é 7%, que é um valor ainda não pequeno. Para outro método, ver o Problema 43.

Se indicarmos genericamente por $\hat{\alpha}$ o valor- p , rejeitaremos H_0 para aqueles níveis de significância α maiores do que $\hat{\alpha}$. No Exemplo 12.7, rejeitaremos H_0 , por exemplo, se $\alpha = 0,10$, mas não a rejeitaremos se $\alpha = 0,05$ ou $\alpha = 0,01$. Ou seja, se o nível descritivo for muito pequeno, como o caso $\hat{\alpha} < 0,01$ do Exemplo 12.6, há evidências de que a hipótese não seja válida. Como vimos nesse exemplo, a probabilidade de significância é muitas vezes denotada por p na literatura (p -value).

Em nosso procedimento de testar uma hipótese estamos usando uma escala de evidências sugerida por Fisher (1954). Suponha que estejamos testando H_0 contra H_1 e, como vimos, rejeitamos H_0 se o valor- p $\hat{\alpha}$ for “bastante pequeno”. A Tabela 12.2, extraída de Efron e Gous (1997), ilustra a escala de Fisher, contra H_0 (ou a favor de H_1).

Tabela 12.2: Escala de significância de Fisher.

valor- p	0,10	0,05	0,025	0,01	0,005	0,001
Natureza da evidência	marginal	moderada	substancial	forte	muito forte	fortíssima

Assim, um valor de $\hat{\alpha} = 0,01$ indica uma evidência forte contra a validade de H_0 , $\hat{\alpha} = 0,05$ indica uma evidência moderada etc. É interessante notar que Fisher tomou como ponto de referência o valor 0,05: valores do valor- p menores do que 0,05 indicam que devemos rejeitar a hipótese nula. As considerações feitas por Fisher referiam-se a testes do qui-quadrado (veja o Capítulo 14).

Problemas

16. Suponha que queiramos testar $H_0: \mu = 50$ contra $H_1: \mu > 50$, onde μ é a média de uma normal $N(\mu, 900)$. Extraída uma amostra de $n = 36$ elementos da população, obtemos $\bar{x} = 52$. Calcule o valor-p $\hat{\alpha}$ do teste.
17. Os novos operários de uma empresa são treinados a operarem uma máquina, cujo tempo X (em horas) de aprendizado é anotado. Observou-se que X segue de perto a distribuição $N(25, 100)$. Uma nova técnica de ensino, que deve melhorar o tempo de aprendizado, foi testada em 16 novos empregados, o quais apresentaram 20,5 horas como tempo médio de aprendizado. Usando o valor- p , você diria que a nova técnica é melhor que a anterior?

12.9 Teste para a Variância de uma Normal

Um teste sobre a variância desconhecida de uma variável, com distribuição normal, irá usar a distribuição qui-quadrado, introduzida na seção 7.6.

Considere a média amostral $\bar{X}$ e a variância amostral S^2 , ambas obtidas de uma amostra de tamanho n , $(X_1, \dots, X_n)$ de $X \sim N(\mu, \sigma^2)$. A soma

$$\left(\frac{X_1 - \mu}{\sigma}\right)^2 + \dots + \left(\frac{X_n - \mu}{\sigma}\right)^2$$

terá distribuição $\chi^2(n)$, pois cada $(X_i - \mu)/\sigma$ terá distribuição $N(0,1)$. Logo, se definirmos

$$\hat{\sigma}_*^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2, \quad (12.1)$$

vemos que

$$Y = \frac{n\hat{\sigma}_*^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \quad (12.2)$$

tem distribuição $\chi^2(n)$. Observe que o estimador $\hat{\sigma}_*^2$ é muito parecido com o estimador $\hat{\sigma}^2$, definido em (11.6), com μ tomando o lugar de $\bar{X}$. É muito importante conhecer a distribuição de $\sum_{i=1}^n (X_i - \bar{X})^2$, para se ter a distribuição de S^2 , que será usada no teste desta seção. Note inicialmente que

$$\begin{aligned} \sum_{i=1}^n (X_i - \mu)^2 &= \sum_{i=1}^n \{(X_i - \bar{X}) + (\bar{X} - \mu)\}^2 \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + 2(\bar{X} - \mu) \sum_{i=1}^n (X_i - \bar{X}) + n(\bar{X} - \mu)^2, \end{aligned}$$

e de $\sum_i (X_i - \bar{X}) = 0$, vem que

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2. \quad (12.3)$$

Dividindo ambos os membros por σ^2 , e reescrevendo (12.3) de forma conveniente, teremos

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 + \left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \right)^2. \quad (12.4)$$

O primeiro membro da expressão (12.4) tem distribuição $\chi^2(n)$, como vimos acima. O último termo de (12.4) tem distribuição $\chi^2(1)$. Seria, então, razoável supor que o primeiro termo do segundo membro tenha distribuição $\chi^2(n-1)$. A comprovação desse fato exige recursos fora do alcance deste livro, mas podemos resumir o resultado da seguinte maneira.

Teorema 12.1. Seja $(Z_1, \dots, Z_n)$ uma amostra aleatória simples retirada de uma população $N(0,1)$. Então:

- (i) $\bar{Z}$ tem distribuição $N(0, 1/n)$;
- (ii) as variáveis $\bar{Z}$ e $\sum_{i=1}^n (Z_i - \bar{Z})^2$ são independentes; e
- (iii) $\sum_{i=1}^n (Z_i - \bar{Z})^2$ tem distribuição $\chi^2(n-1)$.

Corolário 12.1. A variável aleatória $(n-1)S^2/\sigma^2$ tem distribuição $\chi^2(n-1)$.

Prova. De fato,

$$\frac{(n-1)S^2}{\sigma^2} = \frac{n-1}{\sigma^2} \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 = \sum_{i=1}^n (Z_i - \bar{Z})^2,$$

bastando escrever $(X_i - \bar{X})/\sigma = (X_i - \mu)/\sigma - (\bar{X} - \mu)/\sigma$.

A expressão (12.4) e a própria definição de χ^2 garantem uma propriedade muito útil: a soma de duas v.a. independentes, cada uma com distribuição χ^2 , é uma v.a. também com distribuição χ^2 :

$$\chi^2(p) + \chi^2(q) = \chi^2(p+q).$$

Voltemos ao nosso problema original. Queremos testar

$$H_0 : \sigma^2 = \sigma_0^2$$

$$H_1 : \sigma^2 \neq \sigma_0^2.$$

Nossas suposições são que $X_i \sim N(\mu, \sigma^2)$, $i = 1, \dots, n$ e os X_i são independentes. A estatística do teste será, sob H_0 ,

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1). \quad (12.5)$$

Como temos um teste bilateral, a região crítica será da forma $RC = (0, \chi_1^2] \cup [\chi_2^2, +\infty)$, tal que

$$P(\chi^2 \in RC | H_0) = P(0 < \chi^2 < \chi_1^2 \text{ ou } \chi^2 > \chi_2^2) = \alpha,$$

sendo α o nível de significância do teste, fixado *a priori*.

Observado o valor s_0^2 da estatística S^2 , obteremos o valor $\chi_0^2 = \frac{(n-1)s_0^2}{\sigma_0^2}$. Se $\chi_0^2 \in \text{RC}$, rejeitamos H_0 ; caso contrário, aceitamos H_0 .

Exemplo 12.8. Uma das maneiras de manter sob controle a qualidade de um produto é controlar sua variabilidade. Uma máquina de encher pacotes de café está regulada para enchê-los com média de 500 g e desvio padrão de 10 g. O peso de cada pacote X segue uma distribuição $N(\mu, \sigma^2)$. Colheu-se uma amostra de 16 pacotes e observou-se uma variância de $S^2 = 169 \text{ g}^2$. Com esse resultado, você diria que a máquina está desregulada com relação à variância?

Estamos interessados em testar, então,

$$H_0 : \sigma^2 = 100,$$


$$H_1 : \sigma^2 \neq 100.$$

A estatística para realizar o teste é (12.5), com $n = 16$. Fixado o nível de significância α em 5%, teremos da Tabela IV que a região crítica é dada por $\text{RC} = \{\chi^2 : 0 \leq \chi^2 \leq 6,262 \text{ ou } \chi^2 \geq 27,488\}$. Veja a Figura 12.12. O valor observado da estatística é

$$\chi_0^2 = \frac{(n-1)s_0^2}{\sigma_0^2} = \frac{(15)(169)}{100} = 25,35.$$

Como $\chi_0^2 \notin \text{RC}$, somos levados a aceitar H_0 , isto é, a máquina está sob controle quanto à variância.

Figura 12.12: Região crítica para o teste do Exemplo 12.8.



A construção do $\text{IC}(\sigma^2; \gamma)$ é feita a partir da expressão


$$P\left(\chi_1^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_2^2\right) = \gamma \quad (12.6)$$

que permite obter a seguinte desigualdade:

$$\frac{(n-1)S^2}{\chi_2^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_1^2}, \quad (12.7)$$

que será o IC procurado. Veja a Figura 12.13.

Figura 12.13: Valores críticos para a construção de um intervalo de confiança para a variância.



Exemplo 12.9. Os dados abaixo referem-se às vendas diárias, em reais, durante uma semana, de carros de uma revendedora. Construir um IC(σ^2 ; 90%).

Vendas : 253, 187, 96, 450, 320, 105.

Inicialmente, calculamos a variância amostral, que é $s_0^2 = 18.460$; em seguida, os valores χ_1^2 e χ_2^2 que satisfaçam (12.6):

$$P(1,145 \leq \chi^2(5) \leq 11,070) = 0,90.$$

Substituindo em (12.7) obtemos

$$\text{IC}(\sigma^2; 0,90) = [8.338; 80.611].$$

Problemas

18. De uma população $X \sim N(50, 100)$ retira-se uma amostra de dez elementos e calculam-se os valores de $\hat{\sigma}_*^2$ e S^2 . Encontre os valores pedidos abaixo, com a maior precisão possível.
 - (a) Se $P(\hat{\sigma}_*^2 > a) = 10\%$, encontre o valor de a .
 - (b) Sabendo-se que $P(S^2 < a) = 5\%$ e $P(S^2 > b) = 5\%$, encontre a e b .
 - (c) $P(S^2 < 163,16) = \alpha$, encontre α .
 - (d) $P(S^2 > 100) = \alpha$, encontre α .
 - (e) $P(S^2 < 18) = \alpha$, encontre α .
 - (f) Se o valor observado de S^2 foi 180, qual a probabilidade de encontrar uma amostra que produza um S^2 maior do que o observado?
19. Observou-se a produção mensal de uma indústria durante vários anos, verificando-se que ela obedecia a uma distribuição normal, com variância 300. Foi adotada uma nova técnica de produção e, durante 24 meses, observou-se a produção mensal. Após esse período, constatou-se que $\bar{x} = 10.000$ e $s^2 = 400$. Há razões para se acreditar que a variância mudou, ao nível de 20%?
20. Numa linha de produção, é muito importante que o tempo gasto numa determinada operação não varie muito de empregado para empregado.
 - (a) Que parâmetro estatístico poderia ser usado para avaliar esse fato? Por quê?

- (b) Se 11 empregados apresentam os tempos abaixo para realizar essa operação, qual seria a estimativa para a parâmetro acima?

125	135	115	120	150	130
125	145	125	140	130	

12.10 Teste sobre a Média de uma Normal com Variância Desconhecida

Vimos, na seção 12.5, como testar a média de uma normal, supondo que a variância seja conhecida. Comentamos que essa não é uma suposição realista, logo iremos supor agora que temos uma v.a. X , com distribuição normal, com média μ e variância σ^2 desconhecidas.

No Capítulo 7 introduzimos a distribuição t de Student. Veremos, a seguir, como ela pode ser usada para testar hipóteses sobre μ nessa situação.

Consideremos a estatística

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}. \quad (12.8)$$

Inicialmente, dividamos o numerador e denominador pelo desvio padrão σ da população, e teremos

$$\frac{((\sqrt{n}(\bar{X} - \mu))/\sigma)}{(S/\sigma)}$$

O numerador $Z = (\sqrt{n}(\bar{X} - \mu))/\sigma$ tem distribuição $N(0, 1)$, como já foi visto. O quadrado do denominador pode ser escrito como

$$\frac{(n-1)S^2}{\sigma^2} / (n-1) = \frac{Y}{n-1},$$

onde $Y = (n-1)S^2/\sigma^2$. Mas, como foi visto na seção anterior, se os X_i forem normais, Y tem distribuição $\chi^2(n-1)$; logo, a estatística (12.8) é o quociente entre uma v.a. $N(0, 1)$ e a raiz quadrada de uma v.a. $\chi^2(n-1)$, dividida pelo número de graus de liberdade, e pelo Teorema 7.1 temos que

$$\frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n-1). \quad (12.9)$$

Observe que Z e Y são independentes, pois $\bar{X}$ e S^2 são independentes, pelo Teorema 12.1 (ii).

Estamos, agora, em condições de testar as hipóteses

$$\begin{aligned} H_0 : \mu &= \mu_0, \\ H_1 : \mu &\neq \mu_0. \end{aligned}$$


A hipótese alternativa poderia ser $\mu > \mu_0$ ou $\mu < \mu_0$, o que mudaria apenas a região de rejeição de bilateral para unilateral (à direita ou à esquerda, respectivamente).

A estatística a ser usada é

$$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S}, \quad (12.10)$$

que sabemos agora ter uma distribuição t de Student com $(n - 1)$ graus de liberdade. Fixado o valor de α , podemos usar a Tabela V e encontrar o valor t_c , tal que $P(|T| < t_c) = 1 - \alpha$. Veja a Figura 12.14.

Figura 12.14: Valores críticos para o teste t .



Colhida a amostra de n indivíduos, calculamos os valores $\bar{x}_0$ e s_0^2 das estatísticas $\bar{X}$ e S^2 , respectivamente, e depois o valor $t_0 = \sqrt{n}(\bar{x}_0 - \mu_0)/s_0$ de T . Se o valor dessa estatística for inferior a $-t_c$, ou superior a t_c , rejeita-se H_0 . Caso contrário, aceita-se H_0 .

Para a construção de intervalos de confiança, temos que

$$P\left(-t_\gamma < \frac{\sqrt{n}(\bar{X} - \mu)}{S} < t_\gamma\right) = \gamma,$$

da qual segue o intervalo de confiança

$$IC(\mu; \gamma) = \bar{X} \pm t_\gamma \frac{S}{\sqrt{n}}, \quad (12.11)$$

muito parecido com aquele da variância conhecida.

Exemplo 12.10. Um fabricante afirma que seus cigarros contêm não mais que 30 mg de nicotina. Uma amostra de 25 cigarros fornece média de 31,5 mg e desvio padrão de 3 mg. No nível de 5%, os dados refutam ou não a afirmação do fabricante?

Passo 1. As hipóteses aqui são:

$$H_0 : \mu = 30,$$

$$H_1 : \mu > 30.$$

Passo 2. Supondo que X , a quantidade de nicotina por cigarro, tenha distribuição $N(\mu, \sigma^2)$, a estatística

$$T = \frac{\sqrt{25}(\bar{X} - 30)}{S}$$

terá distribuição $t(24)$.

Passo 3. Por ser um teste unilateral, devemos procurar o valor t_c tal que

$$P(T > t_c) = 0,05.$$

Da Tabela V, obtemos $t_c = 1,711$, ou seja, a região crítica para a estatística T é $RC = [1,711; +\infty[$.

Passo 4. O valor observado da estatística é

$$t_0 = \frac{5(31,5 - 30)}{3} = 2,5.$$

Passo 5. Como t_0 pertence à região crítica, rejeitamos H_0 , ou seja, há evidências de que os cigarros contêm mais de 30 g de nicotina.

Outra maneira de proceder é calcular o valor- p , ou seja,

$$\hat{\alpha} = P(T > t_0 | H_0) = P(T > 2,5 | H_0) = 0,01.$$

Esse valor pequeno de $\hat{\alpha}$ leva à rejeição de H_0 .

Para construir um IC(μ ; 0,95), verificamos na Tabela V que o valor $t_\gamma = 2,064$ e, portanto,

$$IC(\mu; 0,95) = 31,5 \pm (2,064) 3/\sqrt{25},$$

ou seja,

$$IC(\mu; 0,95) =]30,26; 32,74[.$$

Antes de encerrar este capítulo cabe uma observação. Quando aceitamos uma hipótese, estamos concluindo que temos algum conhecimento sobre a distribuição da variável de interesse. Já quando rejeitamos a hipótese, a distribuição da variável não fica especificada. A construção de intervalos de confiança desempenha um papel importante nessa situação. Ressaltamos, também, que temos usado a expressão “aceitamos” a hipótese, quando o mais correto talvez fosse “não rejeitamos” a hipótese.

Problemas

21. Da população $X \sim N(50, 100)$ retirou-se uma amostra casual simples de tamanho $n = 10$, calculando-se o valor de $\bar{X}$, S e o respectivo valor de t .
 - (a) Se $P(|\bar{X} - 50| < tS/\sqrt{10}) = 90\%$, encontre o valor de t .
 - (b) Se $\bar{X} = 48$ e $S^2 = 120$, qual a probabilidade de encontrar um valor de t menor que o produzido por essa amostra?
 - (c) Se $S^2 = 120$, calcule a $P(|\bar{X} - 50| < 2)$.
22. O tempo médio, por operário, para executar uma tarefa, tem sido 100 minutos, com um desvio padrão de 15 minutos. Introduziu-se uma modificação para diminuir esse tempo, e, após certo período, sorteou-se uma amostra de 16 operários, medindo-se o tempo de execução de cada um. O tempo médio da amostra foi 85 minutos, e o desvio padrão foi 12 minutos. Estes resultados trazem evidências estatísticas da melhora desejada? Em caso

afirmativo, estime o novo tempo médio de execução. (Apresente as suposições teóricas usadas para resolver o problema.)

23. Estamos desconfiados de que a média das receitas municipais *per capita* das cidades pequenas (0 – 20.000 habitantes) é maior do que a das receitas do estado, que é de 1.229 unidades. Para comprovar ou não essa hipótese, sorteamos dez cidades pequenas, e obtivemos os seguintes resultados: 1.230; 582; 576; 2.093; 2.621; 1.045; 1.439; 717; 1.838; 1.359.

Obs.: Para facilitar os cálculos, informamos que a soma das observações é 13.500, e a soma dos quadrados das observações é 22.335.650 ($13.500^2 = 182.250.000$).

- (a) Mostre que o teste de hipótese usado, com $\alpha = 0,05$, levará à aceitação de que a média das cidades pequenas é igual à do estado.
- (b) Você não acha estranha essa conclusão quando observa que a média da amostra obtida é bem maior do que a média do estado? Como você explicaria isso?
24. Deseja-se estimar qual a porcentagem média da receita familiar gasta com alimentação pelos moradores de uma grande vila industrial. Para isso, selecionou-se uma amostra de 16 famílias, que apresentou os seguintes resultados:

41	44	35	42	34	22	42	42
38	62	29	63	38	45	48	40

- (a) Dê um IC de 95% para a porcentagem média de todas as famílias de moradores da vila.
- (b) Que suposição você fez para responder a pergunta anterior?

12.11 Problemas e Complementos

25. A precipitação pluviométrica anual numa certa região tem desvio padrão $\sigma = 3,1$ e média desconhecida. Para os últimos 9 anos, foram obtidos os seguintes resultados: 30,5; 34,1; 27,9; 35,0; 26,9; 30,2; 28,3; 31,7; 25,8.

- (a) Construa um teste de hipóteses para saber se a média da precipitação pluviométrica anual é maior que 30,0 unidades. Utilize um nível de significância de 5%.
- (b) Discuta o mesmo problema, considerando σ desconhecido.
- (c) Supondo que, na realidade, $\mu = 33,0$, qual a probabilidade de tirarmos uma conclusão errada?

26. Supõe-se que determinado tipo de indústria deva ter, em média, 30 empregados. Para testar tal hipótese, colhe-se uma amostra de 50 indústrias, cujo resultado está abaixo. Caso rejeite a hipótese, dê um intervalo de confiança para a verdadeira média (suponha que $s^2 = \sigma^2$).

Nº de empregados	Freqüência
25 – 35	8
35 – 45	10
45 – 55	13
55 – 65	10
65 – 75	9

27. Uma fábrica de automóveis anuncia que seus carros consomem, em média, 11 litros por 100 km, com desvio padrão de 0,8 litro. Uma revista resolve testar essa afirmação e

- analisa 35 automóveis dessa marca, obtendo 11,3 litros por 100 km como consumo médio (considerar distribuição normal). O que a revista pode concluir sobre o anúncio da fábrica, no nível de 10%?
28. Um dos maiores problemas de uma grande rede de vendas a varejo é a adequação do estoque declarado com o real existente. Decidiu-se fazer a verificação através de procedimentos amostrais. Indicando por X o total em unidades monetárias de cada produto em estoque, verificou-se que $X \sim N(\mu, 400)$. Serão sorteados 4 produtos. O total X de cada um será verificado e calcular-se-á a média $\bar{X}$, que será a estatística de decisão. Numa determinada filial, o valor declarado de μ é 50. Havendo falta, esse parâmetro deve ser 45; no caso de excesso, 58.
- (a) Defina H_0 e H_1 .
 - (b) Descreva os erros do tipo I e II.
 - (c) Fixando $\alpha = 10\%$, qual a regra de decisão para julgar se o estoque está correto ou não?
 - (d) Calcule o erro β .
 - (e) Qual o significado de α e β nesse problema?
29. Seja X uma v.a. com distribuição binomial, com $n = 15$. Considere $H_0 : p \geq 0,5$ contra $H_1 : p < 0,5$, com $RC = \{0, 1, 2\}$.
- (a) Calcule a probabilidade do erro de tipo I.
 - (b) Calcule a probabilidade do erro de tipo II quando $p = 0,3$.
 - (c) Esboce o gráfico do poder do teste.
30. O custo X de manutenção de teares segue uma distribuição normal, $X \sim N(\mu, 400)$. Durante muito tempo, o parâmetro μ tem sido adotado como igual a 200. Suspeita-se que esse parâmetro aumentou, e só nos interessa saber se o novo parâmetro superior a 210. Assim, queremos planejar um teste em que $\alpha = 5\%$ (quando $\mu = 200$) e $\beta = 10\%$ (quando $\mu = 210$).
- (a) Qual deve ser o tamanho da amostra?
 - (b) Qual a RC nesse caso?
31. O número médio diário de clientes de um posto de gasolina tem sido 250, com um desvio padrão de 80 clientes. Durante uma campanha de 25 dias, em que os clientes recebiam um brinde, o número médio de clientes foi 280, com um desvio padrão de 50. Você diria que a campanha modificou a distribuição do número de clientes do posto? Descreva as suposições feitas para a resolução do problema.
32. A receita média, em porcentagem, dos quase 600 municípios de um estado tem sido 7%. O governo pretende melhorar esse índice e, para isso, está estudando alguns incentivos. Para verificar os efeitos desses incentivos, sorteou 10 cidades e estudou quais seriam as porcentagens investidas neles. Os resultados foram, em porcentagem, 8, 10, 9, 11, 8, 12, 16, 9, 12, 13. Admitindo-se que esses números realmente venham a ocorrer, os dados trazem evidência de melhoria? Caso altere a média do estado, dê um intervalo de confiança para a nova média.
33. Para o problema anterior, construa $IC(\sigma^2; 90\%)$ e descreva as suposições consideradas para obtenção da resposta.
34. A prefeitura de uma cidade quer estimar a proporção p dos moradores favoráveis à mudança do horário comercial, com o intuito de economizar combustível. Essa proporção deverá ser estimada com um erro máximo de 5%, a um nível de 90% de confiança.

- (a) Que tamanho deverá ter a amostra se a proporção p esperada deve estar entre 20% e 50%? (Justifique a resposta.)
- (b) Numa amostra de 400 moradores, 160 foram favoráveis à mudança; qual seria o intervalo de confiança para p , nesse caso, com $\gamma = 0,95$?
35. Numa pesquisa realizada com 2.000 proprietários de carros na cidade de São Paulo, 800 responderam que pretendem mudar de carro no decorrer do próximo ano. Dê um IC de 90% para a proporção de todos os proprietários de carros de São Paulo que pretendem mudar de carro no próximo ano.
36. Um fabricante de um certo tipo de aço especial afirma que seu produto tem um severo serviço de controle de qualidade, traduzido pelo desvio padrão da resistência à tensão, que não é maior do que 5 kg por cm^2 . Um comprador, querendo verificar a veracidade da afirmação, tomou uma amostra de 11 cabos e submeteu-a a um teste de tensão. Os resultados foram os seguintes: $\bar{x} = 263$ e $s^2 = 48$. Estes resultados trazem alguma evidência contra a afirmação do fabricante? Use $\alpha = 0,05$.
37. Um escritório de investimento acredita que o rendimento das diversas ações movimentadas por ele foi de 24%. Mais ainda, a nova estratégia definida deve garantir uma maior uniformidade nos rendimentos das diversas ações. No passado, o desvio padrão do rendimento era da ordem de 5%. Para verificar as duas hipóteses, tomaram-se 8 empresas ao acaso, obtendo-se os seguintes rendimentos (dados em %): 23,6; 22,8; 25,7; 24,8; 26,4; 24,3; 23,9 e 25. Quais seriam as conclusões?
38. Sendo X o número de sucessos em $n = 10$ provas de Bernoulli, queremos testar $H_0: p = 0,6$.
- (a) Se o teste for unilateral e rejeitarmos H_0 para valores pequenos de X , determine $\hat{\alpha}$ se o valor observado de X for 3.
- (b) Determine $\hat{\alpha}$ se o teste for bilateral, na situação de (a), isto é, $X = 3$.
39. Considere a situação do problema anterior e suponha que o valor observado seja $X = 6$. O que acontece no caso (b) do problema anterior? O resultado $X = 6$ suporta ou não H_0 ?
40. **Valor-p bilateral.** Vimos no texto um procedimento para determinar $\hat{\alpha}$ no caso bilateral. Outra possibilidade é fazer as probabilidades nas duas caudas complementares em termos da distância à média (ou mediana) da distribuição sob H . Assim, se x for o valor observado de X e m for a média da distribuição, colocamos

$$\hat{\alpha} = P(X \geq x) + P(X \leq m - (x - m)),$$

se x estiver na cauda superior e

$$\hat{\alpha} = P(X \leq x) + P(X \geq m + (m - x)),$$

se x estiver na cauda inferior.

Calcule $\hat{\alpha}$ usando esse critério para os Problemas 41 e 42.

Inferência para Duas Populações


13.1 Introdução

Neste capítulo abordaremos o tópico importante de comparar duas populações P_1 e P_2 , baseados em dados fornecidos por amostras dessas populações. Como vimos, uma grande parte das técnicas usadas em Estatística supõe que as variáveis aleatórias envolvidas tenham distribuição normal. Alguns testes que trataremos envolverão a normal. Contudo, se essa suposição de normalidade for violada, procedimentos mais “robustos” têm de ser utilizados, e veremos exemplos de tal situação.

Uma pergunta que aparece freqüentemente em Ciência é a seguinte: o método A é melhor do que o B? Em termos estatísticos, ela equivale a comparar dois conjuntos de informações, resultantes das medidas obtidas da aplicação dos dois métodos a dois conjuntos de objetos ou indivíduos.

Uma das dificuldades que enfrentamos é a de caracterizar adequadamente a “igualdade” ou “equivalência” de duas populações. Por exemplo, suponha que estamos interessados em saber se alunos de duas regiões, A e B, tiveram desempenhos iguais em um mesmo teste nacional. Mais ainda, suponha que tenhamos os resultados do teste para “todos os alunos” das duas regiões, isto é, conhecemos as duas populações. Suponha que cálculos posteriores revelem que as médias e desvios padrões das duas populações sejam iguais, isto é, $\mu_A = \mu_B$ e $\sigma_A = \sigma_B$. Será que isso equivale a dizer que os desempenhos nas duas regiões são equivalentes? Se uma análise mais cuidadosa não for feita, poderemos ser levados a responder afirmativamente a essa questão. Entretanto, observando a Figura 13.1, vemos que é possível ter duas distribuições com os mesmos parâmetros acima, mas formas bastante distintas.

Figura 13.1: Distribuições das populações A e B, com $\mu_A = \mu_B = 4$, $\sigma_A = \sigma_B = 1,16$.



Esse fato nos remete à necessidade de também mencionarmos a forma da distribuição. Especificada a forma, a igualdade dos parâmetros que identificam a curva implica a igualdade ou coincidência das duas populações. É bem pouco provável que um mesmo fenômeno obedeça a formas de distribuições distintas, como no exemplo da Figura 13.1. Seguir uma mesma distribuição, porém com parâmetros distintos, é mais verossímil. Como a normal é um modelo importante e seguido por muitas variáveis de interesse prático, estaremos admitindo essa forma, a não ser quando uma análise dos dados nos diga o contrário.

Neste capítulo trataremos de várias situações, que passamos a descrever.

1. Inferências para duas médias: amostras independentes.

Aqui temos dados na forma de duas amostras, extraídas independentemente de cada população. É muito comum em experimentos do tipo “controle” *versus* “tratamento”, nos quais o interesse principal é verificar o efeito desse último. O caso típico é aquele de comparar uma nova droga com uma padrão, usadas para o tratamento de uma doença.

Exemplo 13.1.

- (a) Um curso de Estatística é ministrado pela televisão para um grupo de alunos e ao vivo para outro grupo. Queremos testar a hipótese de que o curso ao vivo é mais eficaz que o curso por meio da televisão.
- (b) Queremos comparar o efeito de duas rações, A e B, sobre o crescimento de porcos. Dois grupos de porcos em crescimento foram alimentados com as duas rações e após cinco semanas verificam-se quais foram os ganhos de peso dos porcos dos dois grupos.
- (c) 20 canteiros foram plantados com uma variedade de milho. Em dez deles um novo tipo de fertilizante é aplicado e nos outros um fertilizante padrão. Examinando-se as produções dos dois canteiros, queremos saber se há diferenças significativas entre as produções.

Na maioria das vezes fica claro o que chamamos de controle e tratamento. No exemplo (c) acima, os canteiros tratados com o novo fertilizante seriam o grupo de tratamento, enquanto os demais, tratados com o fertilizante usual, constituiriam o grupo de controle. Mas nos exemplos (a) e (b) essa distinção é apenas convencional.

Formalmente, o *modelo* para o problema das duas amostras é o seguinte: as v.a. $X_1, \dots, X_m$ representam as respostas do grupo de controle e são consideradas v.a. independentes, com a mesma distribuição, P_1 ; $Y_1, \dots, Y_n$ representam as respostas do grupo de tratamento e são v. a. independentes, com a mesma distribuição, P_2 . Além disso, $X_1, \dots, X_m, Y_1, \dots, Y_n$ são independentes entre si.

A hipótese a ser testada é

$$H_0: P_1 = P_2, \quad (13.1)$$

ou seja, queremos testar a homogeneidade das populações de onde as amostras foram extraídas. H_0 é chamada *hipótese de homogeneidade*.


O significado de (13.1) dependerá muito do interesse do pesquisador em considerar qual “tipo” de igualdade implicará a coincidência das duas distribuições. Admitamos que tanto P_1 como P_2 sigam uma distribuição normal, ou seja, $P_1 \sim N(\mu_1, \sigma_1^2)$ e $P_2 \sim N(\mu_2, \sigma_2^2)$. Na Figura 13.2 temos as quatro situações possíveis. Observando os gráficos da Figura 13.2 não temos dúvidas em reconhecer que as duas populações são iguais no caso (a) e diferentes no caso (d). Já nos outros dois casos, podem existir situações em que elas possam ser consideradas iguais ou não. Por exemplo, uma pesquisa para verificar se o salário médio da região P_1 é o mesmo da região P_2 aceita como resposta verdadeira tanto a situação (a) como a (b). Outra pesquisa para verificar se dois processos produzem peças com a mesma qualidade em termos de dispersão aceita como verdadeiras as situações (a) ou (c).

Assim, a estratégia para comparar duas populações, por meio de seus parâmetros, envolve suposições sobre a forma das distribuições, para depois testar médias e variâncias. É comum estarmos interessados em testar apenas que P_1 e P_2 difiram em *localização* (ou posição), isto é, a alternativa a H_0 é que P_1 esteja à direita de P_2 , ou o contrário, mas que ambas tenham a mesma dispersão (caso $\mu_1 \neq \mu_2$ e $\sigma_1 = \sigma_2$ da figura). Nesse caso, H_0 será equivalente a

$$H_0: \Delta = 0, \quad (13.2)$$

com $\Delta = \mu_2 - \mu_1$.

Figura 13.2: (a) $\mu_1 = \mu_2, \sigma_1 = \sigma_2$ (b) $\mu_1 = \mu_2, \sigma_1 \neq \sigma_2$ (c) $\mu_1 \neq \mu_2, \sigma_1 = \sigma_2$ (d) $\mu_1 \neq \mu_2, \sigma_1 \neq \sigma_2$.



Os testes t de Student e de Wilcoxon, descritos a seguir, são apropriados para esse tipo de situação. O teste t é aplicável quando P_1 e P_2 supostas são normais, com médias μ e $\mu + \Delta$, respectivamente, e com a mesma variância. O teste de Wilcoxon aplica-se para P_1 e P_2 quaisquer, mas suponha-se que a escala de medidas seja pelo menos

ordinal. A análise fica mais fácil quando a P_1 e P_2 são atribuídas distribuições de variáveis contínuas. Discutiremos a razão desta suposição adicional.

Outro caso de interesse é aquele em que queremos testar se as duas médias são iguais, mas as variâncias são diferentes. Na Figura 13.1, as duas curvas teriam dispersões diferentes ao redor de suas médias. Então, um teste preliminar de igualdade de variâncias seria necessário. O teste t de Student para o caso de populações normais será apresentado neste capítulo.

A hipótese (13.1) ou (13.2) nos diz que não há efeito do tratamento. A alternativa usual para H_0 é que o efeito do tratamento é o de aumentar as respostas. Isto é, P_2 gera valores maiores que P_1 , com maior freqüência. Mas pode ocorrer o contrário: diminuir as respostas. Por exemplo, o “tratamento” visa a diminuir o tempo para executar determinada tarefa.

2. Inferências para duas médias: amostras dependentes

Quando se comparam as médias de duas populações, pode ocorrer uma diferença significativa por causa de fatores externos não-controlados. Por exemplo, no caso do Exemplo 13.4 abaixo, poderia ocorrer que um dos grupos tivesse vendedores mais experientes e habilidosos do que o outro. Logo, a diferença seria devido a esses fatos, e não ao mérito real da técnica de vendas. Um modo de contornar esse problema é coletar as observações em pares, de modo que os dois elementos de cada par sejam homogêneos em todos os sentidos, exceto no que diz respeito ao fator que queremos comparar.

Por exemplo, no caso do Exemplo 13.1 (a), para testar os dois métodos de ensino, poderíamos usar n pares de gêmeos, sendo que um elemento de cada par recebe aulas pela TV e outro ao vivo. Esse procedimento pretende controlar o maior número possível de fatores externos que possam afetar o aprendizado. Se houver diferença no aprendizado, essa dever-se-á realmente ao método.

Esse procedimento também é usado quando observações das duas amostras são feitas no mesmo indivíduo, por exemplo, medindo uma característica do indivíduo antes e depois de ele ser submetido a um tratamento.

O teste t de Student para observações pareadas (ou emparelhadas), supondo normalidade, é apropriado para essas situações.

3. Inferências para duas variâncias: amostras independentes

Como vimos no item 1, podemos testar se duas amostras independentes provêm de duas populações com variâncias iguais, desconhecidas. Se essas variâncias forem diferentes, o teste tem de ser modificado. Esse teste, sob a suposição de normalidade das duas populações, usa uma estatística que tem uma distribuição especial, chamada F de Snedecor.

Finalizando esta seção, ressaltamos que poderemos ter mais do que duas amostras, e técnicas semelhantes podem ser desenvolvidas. Veja o Capítulo 15.

13.2 Comparação das Variâncias de Duas Populações Normais

A situação que vamos considerar nesta seção envolve a utilização da distribuição F , estudada na seção 7.7. A descrição a seguir é importante.

Uma das distribuições amostrais mais usadas, e que corresponde a uma distribuição F , resulta do seguinte problema. Suponha que temos duas amostras independentes, de tamanhos n_1 e n_2 , retiradas de duas populações normais com a mesma variância σ^2 . Indiquemos os estimadores de σ^2 obtidos das amostras por S_1^2 e S_2^2 , respectivamente. Já vimos que

$$U = \frac{(n_1 - 1)S_1^2}{\sigma^2} \sim \chi^2(n_1 - 1),$$

$$V = \frac{(n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_2 - 1),$$

e portanto a v.a.

$$\frac{S_1^2}{S_2^2} = \frac{\frac{U}{n_1 - 1}}{\frac{V}{n_2 - 1}} \sim F(n_1 - 1, n_2 - 1). \quad (13.3)$$

Essa variável será usada no teste desta seção.

Consideremos, agora, uma amostra $X_1, \dots, X_n$ de uma população com distribuição $N(\mu_1, \sigma_1^2)$ e uma amostra $Y_1, \dots, Y_m$ de uma população com distribuição $N(\mu_2, \sigma_2^2)$. Suponhamos que as duas amostras sejam independentes.

Queremos testar

$$H_0 : \sigma_1^2 = \sigma_2^2 = \sigma^2$$

$$H_1 : \sigma_1^2 \neq \sigma_2^2.$$

Chamemos de S_1^2 e S_2^2 as variâncias amostrais respectivas. De (13.3) e sob a suposição de H_0 ser verdadeira, isto é $\sigma_1^2 = \sigma_2^2$, temos que

$$W = S_1^2/S_2^2 \sim F(n - 1, m - 1). \quad (13.4)$$

Fixado α , encontramos dois números f_1 e f_2 , da Tabela VI, tais que

$$P(W \in \text{RC}) = P(W < f_1 \text{ ou } W > f_2) = \alpha.$$

Os valores f_1 e f_2 são determinados de modo que $P(W < f_1) = \alpha/2 = P(W > f_2)$. Na prática, consideramos o quociente (13.4) de tal sorte que $S_1^2/S_2^2 > 1$.

Colhidas as amostras de n e m indivíduos, respectivamente, das duas populações, calculamos os valores observados s_{10}^2 e s_{20}^2 e o valor observado de W , ou seja, $w_0 = s_{10}^2/s_{20}^2$.

Se w_0 pertencer à região crítica, rejeitamos H_0 ; caso contrário, a aceitamos.

Exemplo 13.2. Queremos verificar se duas máquinas produzem peças com a mesma homogeneidade quanto à resistência à tensão. Para isso, sorteamos duas amostras de seis peças de cada máquina, e obtivemos as seguintes resistências:

Máquina A:	145	127	136	142	141	137
Máquina B:	143	128	132	138	142	132

As hipóteses a serem testadas são:

$$H_0: \sigma_A^2 = \sigma_B^2 = \sigma^2$$

$$H_1: \sigma_A^2 \neq \sigma_B^2.$$

Sob a suposição de normalidade das medidas de resistência à tensão, para as duas máquinas, temos que a v.a. W , definida por (13.4), tem uma distribuição $F(5,5)$. Fixando $\alpha = 0,10$ e consultando a Tabela VI, teremos

$$RC =]0, (5,05)^{-1}[\cup]5,05, +\infty[.$$

Das amostras encontramos $s_A^2 = 40$ e $s_B^2 = 37$, portanto $w_0 = 1,08$. Como esse valor não pertence à região crítica, aceitamos H_0 , ou seja, as máquinas produzem com a mesma homogeneidade quanto à variabilidade.

Caso tivéssemos rejeitado a hipótese de igualdade das variâncias, seria conveniente obter um intervalo de confiança para o quociente das duas variâncias. De (13.3) podemos escrever, quando $\sigma_1^2 \neq \sigma_2^2$,

$$W = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} = \frac{U/(n-1)}{V/(m-1)} \sim F(n-1, m-1),$$

e para um dado γ , $0 < \gamma < 1$, podemos encontrar dois valores f_1 e f_2 , tais que

$$P(f_1 < F(n-1, m-1) < f_2) = \gamma.$$

Dessa igualdade, segue-se que, com probabilidade γ ,

$$f_1 < \frac{S_1^2}{S_2^2} \frac{\sigma_2^2}{\sigma_1^2} < f_2,$$

ou seja, o IC(σ_2^2/σ_1^2 ; γ) será dado por

$$f_1 \frac{S_2^2}{S_1^2} < \frac{\sigma_2^2}{\sigma_1^2} < f_2 \frac{S_2^2}{S_1^2} \quad (13.5)$$

Exemplo 13.3. Suponha que para outras seis medidas para as máquinas A e B do Exemplo 13.2 tivéssemos $S_A^2 = 85$ e $S_B^2 = 8$. Como $w_0 = 85/8 = 10,62$, rejeitaríamos H_0 . Então, o IC dado por (13.5) ficaria, com $\gamma = 0,90$,

$$\frac{1}{5,05} \frac{8}{85} < \frac{\sigma_B^2}{\sigma_A^2} < 5,05 \frac{8}{85},$$

ou seja,

$$0,019 < \frac{\sigma_B^2}{\sigma_A^2} < 0,475.$$

Invertendo-se, obtemos, também,

$$2,10 < \frac{\sigma_A^2}{\sigma_B^2} < 52,6,$$

que indica a variação possível, no nível fixado, da razão entre as duas variâncias. Note que, sob H_0 , temos $\sigma_A^2/\sigma_B^2 = 1$, que não pertence a esse intervalo.

Problemas

- Da população $X \sim N(50, 100)$ retirou-se uma amostra casual simples de $n = 10$ elementos. Da população $Y \sim N(60, 100)$ retirou-se uma amostra casual simples de $m = 6$ indivíduos, independente da primeira. Obtemos as variâncias amostrais S_1^2 e S_2^2 , respectivamente.
 - Encontre o valor de a , tal que $P(S_1^2/S_2^2 < a) = 95\%$.
 - Encontre o valor de b , tal que $P(S_1^2/S_2^2 > b) = 95\%$.
- Por que em (13.3) as v.a. U e V são independentes?
- Uma das maneiras de medir o grau de satisfação dos empregados de uma mesma categoria quanto à política salarial é por meio do desvio padrão de seus salários. A fábrica A diz ser mais coerente na política salarial do que a fábrica B. Para verificar essa afirmação, sorteu-se uma amostra de 10 funcionários não especializados de A, e 15 de B, obtendo-se os desvios padrões $s_A = 1.000$ reais e $s_B = 1.600$ reais. Qual seria a sua conclusão?
- Deseja-se comparar a qualidade de um produto produzido por duas fábricas. Essa qualidade será definida pela uniformidade com que o produto é produzido em cada fábrica. Tomaram-se duas amostras, uma de cada fábrica, medindo-se o comprimento dos produtos (o resumo dos resultados está no quadro abaixo). A qualidade das duas fábricas é a mesma? Caso a sua resposta seja negativa, dê um intervalo de confiança para indicar a intensidade dessa desigualdade.

Estatísticas	Fábrica A	Fábrica B
Amostra	21	17
Média	21,15	21,12
Variância	0,0412	0,1734

13.3 Comparação de Duas Populações: Amostras Independentes

Nesta seção estudaremos o caso onde temos duas amostras independentes, $X_1, \dots, X_n$ e $Y_1, \dots, Y_m$, de duas populações P_1 e P_2 , respectivamente.

Estaremos interessados em comparar as médias dessas populações, verificando se elas podem ser consideradas iguais ou não. No caso de populações normais, teremos, preliminarmente, de usar o que aprendemos na seção anterior, para testar se as variâncias de P_1 e P_2 são iguais.

Consideraremos duas situações: na primeira, iremos supor que as populações sejam normais (veja os Problemas 32, 33 e 34 do Capítulo 10, os Problemas 31 e 32 do Capítulo 11 e o Problema 29 do Capítulo 12); na segunda, essa suposição não é necessária.

13.3.1 Populações Normais

Aqui, $P_1 \sim N(\mu_1, \sigma_1^2)$ e $P_2 \sim N(\mu_2, \sigma_2^2)$.

Queremos testar a hipótese (13.1), que aqui fica escrita na forma

$$H_0: \mu_1 = \mu_2.$$

Na situação da Figura 13.2 (c), a alternativa adequada é

$$H_1: \mu_2 > \mu_1,$$

mas supondo as variâncias iguais. Se estivermos apenas interessados em verificar se existe diferença entre as médias das duas populações, não importando a direção, então a alternativa adequada será

$$H_1: \mu_1 \neq \mu_2.$$

Para cada amostra calculamos os estimadores da média e da variância:

$$\begin{aligned}\bar{X} &= \frac{1}{n} \sum_{i=1}^n X_i, & S_1^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2; \\ \bar{Y} &= \frac{1}{m} \sum_{i=1}^m Y_i, & S_2^2 &= \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2.\end{aligned}$$

Sob a hipótese H_0 , isto é, $\mu_1 = \mu_2$,

$$E(\bar{X} - \bar{Y}) = 0, \tag{13.6}$$

$$\text{Var}(\bar{X} - \bar{Y}) = \text{Var}(\bar{X}) + \text{Var}(\bar{Y}) = \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}. \tag{13.7}$$

Como $\bar{X} - \bar{Y}$ tem distribuição normal, se as variâncias fossem conhecidas, a estatística

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\sigma_1^2/n + \sigma_2^2/m}} \tag{13.8}$$

teria distribuição normal padrão, *sob a hipótese nula H_0* , e poderia ser usada para testar H_0 contra H_1 . Contudo, nas situações de interesse prático, as variâncias não são conhecidas, devendo ser substituídas por estimativas convenientes. Aqui, a distribuição t

de Student desempenha papel importante. Notemos que, da definição da v.a. t de Student, $t = \sqrt{n}(\bar{X} - \mu)/S$, podemos obter

$$t^2 = \frac{\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2}{[(n-1)S^2/\sigma^2]/(n-1)} \sim F(1, n-1), \quad (13.9)$$

o que mostra uma relação entre as distribuições $t(n-1)$ e $F(1, n-1)$. Observe que o numerador de (13.9) é o quadrado de uma $N(0, 1)$ e, portanto, tem uma distribuição $\chi^2(1)$, e o denominador é o quociente de uma v.a. $\chi^2(n-1)$ por $(n-1)$.

Vamos considerar dois casos.

(a) Mesma Variância, Desconhecida

Suponha que, ao testar a hipótese de igualdade de variâncias, esta não seja rejeitada, isto é, $\sigma_1^2 = \sigma_2^2 = \sigma^2$, porém essa variância comum é desconhecida. Como S_1^2 e S_2^2 são dois estimadores não-viesados de σ^2 , podemos combiná-los para obter um estimador comum

$$S_p^2 = \frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 + \sum_{i=1}^m (Y_i - \bar{Y})^2}{n+m-2}, \quad (13.10)$$

que também é um estimador não-viesado de σ^2 . Mais ainda, cada parcela do numerador de (13.10), quando dividida por σ^2 , terá distribuição qui-quadrado, com $(n-1)$ e $(m-1)$ graus de liberdade, respectivamente. Logo, teremos que

$$\frac{(n+m-2)S_p^2}{\sigma^2} \sim \chi^2(n+m-2). \quad (13.11)$$

Pelo Teorema 7.1, a estatística

$$T = \frac{\frac{\bar{X} - \bar{Y}}{\sigma\sqrt{1/n + 1/m}}}{S_p/\sigma} = \frac{\bar{X} - \bar{Y}}{S_p\sqrt{1/n + 1/m}} \quad (13.12)$$

terá uma distribuição t de Student, com $(n+m-2)$ graus de liberdade, sob a hipótese H_0 , isto é, se $\mu_1 = \mu_2$.

Tabela 13.1: Dados para duas técnicas de vendas.

Dados	Vendas	
	Técnica A	Técnica B
Média	68	76
Variância	50	75
Vendedores	12	15

Exemplo 13.4. Duas técnicas de venda são aplicadas por dois grupos de vendedores: a técnica A, por 12 vendedores, e a técnica B, por 15 vendedores. Espera-se que a técnica B produza melhores resultados. No final de um mês, obtiveram-se os resultados da Tabela 13.1.

Vamos testar, para o nível de significância de 5%, se há diferenças significativas entre as vendas resultantes das duas técnicas. Informações adicionais permitem supor que as vendas sejam normalmente distribuídas, com uma variância comum σ^2 , desconhecida.

As hipóteses a serem testadas ficam

$$H_0: \mu_A = \mu_B$$

$$H_1: \mu_A < \mu_B.$$

Pelas suposições acima, podemos usar a estatística (13.12), com $n = 12$, $m = 15$ e $S_p^2 = (11S_A^2 + 14S_B^2)/25$. Da Tabela V obtemos $RC =]1,708, +\infty[$.

Da Tabela 13.1 calculamos

$$s_p^2 = \frac{11(50) + 14(75)}{25} = 64,$$

$$t_0 = \frac{76 - 68}{8\sqrt{1/12 + 1/15}} = 2,56.$$

Como $t_0 \in RC$, rejeitamos H_0 , ou seja, existe evidência de que a técnica B produz melhores resultados do que a técnica A.

Encontrada diferença entre os métodos, a continuação natural é construir um intervalo de confiança para a diferença $\Delta = \mu_B - \mu_A$. Do resultado (13.12) é fácil verificar que

$$IC(\Delta; \gamma) = (\bar{x}_0 - \bar{y}_0) \pm t_{\gamma} s_p \sqrt{1/n + 1/m}.$$

Para o nosso exemplo, com $\gamma = 0,95$, esse intervalo reduz-se a

$$IC(\Delta; 0,95) = 8 \pm (2,06)(8) \sqrt{1/12 + 1/15}$$

$$= 8 \pm 6,38 =]1,62; 14,38[.$$

(b) Variâncias Desiguais, Desconhecidas

Quando a hipótese de igualdade de variâncias for rejeitada, devemos usar a estatística

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{S_1^2/n + S_2^2/m}}. \quad (13.13)$$

Pode-se provar que, sob a veracidade de H_0 , a v.a. T aproxima-se de uma distribuição t de Student, com o número de graus de liberdade dado aproximadamente por

$$v = \frac{(A + B)^2}{A^2/(n - 1) + B^2/(m - 1)} , \quad (13.14)$$

na qual

$$A = s_1^2/n, \quad B = s_2^2/m.$$

Como esse valor é geralmente fracionário, arredonde para o inteiro mais próximo para obter o número de graus de liberdade.

Exemplo 13.5. Queremos testar as resistências de dois tipos de vigas de aço, A e B. Tomando-se $n = 15$ vigas do tipo A e $m = 20$ vigas do tipo B, obtemos os valores na Tabela 13.2. Usando um teste F com nível $\alpha = 10\%$ rejeitamos a hipótese de variâncias iguais.

Tabela 13.2: Médias e variâncias para dois tipos de vigas de aço.

Tipo	Média	Variância
A	70,5	81,6
B	84,3	161,5

Consideremos as hipóteses

$$H_0: \mu_A = \mu_B$$

$$H_1: \mu_A \neq \mu_B.$$

A estatística a ser usada é (13.13), com $v = (182,66)/(2,11 + 3,43) = 32,9$, logo tomamos $v = 33$. Com $\alpha = 0,05$, obtemos da Tabela V que $RA =]-2,0345; 2,0345[$. Com os dados da Tabela 13.2, temos $t_0 = (-13,8)/3,68 = -3,75$.

Como $t_0 \in RC$, rejeitamos H_0 , ou seja, há evidências de que os dois tipos de vigas têm resistências médias diferentes.

Problemas

5. Num estudo comparativo do tempo médio de adaptação, uma amostra aleatória, de 50 homens e 50 mulheres de um grande complexo industrial, produziu os seguintes resultados:

Estatísticas	Homens	Mulheres
Médias	3,2 anos	3,7 anos
Desvios padrões	0,8 anos	0,9 anos

Que conclusões você poderia tirar para a população de homens e mulheres dessa indústria? (Indique as suposições feitas para resolver o problema.)

6. Diversas políticas em relação às filiais de uma rede de supermercados estão associadas ao gasto médio dos clientes em cada compra. Deseja-se comparar esse parâmetro para duas novas filiais, por meio de duas amostras de 50 clientes cada. As médias obtidas

foram 62 e 71, respectivamente. Sabe-se que o desvio padrão, em ambos os casos, deve ser da ordem de 20 unidades. É possível afirmar que o gasto médio nas duas filiais seja o mesmo? Caso contrário, dê um intervalo de confiança para a diferença.

7. Uma fábrica de embalagens para produtos químicos está estudando dois processos para combater a corrosão de suas latas especiais. Para verificar o efeito dos tratamentos, foram usadas amostras cujos resultados estão no quadro abaixo (em porcentagem de corrosão eliminada). Qual seria a conclusão sobre os dois tratamentos?

Método	Amostra	Média	Desvio Padrão
A	15	48	10
B	12	52	15

8. No Problema 4, teste a hipótese de que as médias dos comprimentos do produto produzido pelas duas fábricas são iguais.
9. Para investigar a influência da opção profissional sobre o salário inicial de recém-formados, investigaram-se dois grupos de profissionais: um de liberais em geral e outro de formados em Administração de Empresas. Com os resultados abaixo, expressos em salários mínimos, quais seriam suas conclusões?

Liberais	6,6	10,3	10,8	12,9	9,2	12,3	7,0	
Administradores	8,1	9,8	8,7	10,0	10,2	8,2	8,7	10,1

13.3.2 Populações Não-Normais

Passamos, agora, a descrever um teste que não faz suposições a respeito da forma das distribuições P_1 e P_2 , a não ser que as variáveis envolvidas tenham uma escala de medida pelo menos ordinal. Ou seja, podemos abordar o caso de variáveis qualitativas ordinais e variáveis quantitativas. Esse teste (chamado de Wilcoxon ou de Mann-Whitney) pertence a uma categoria de procedimentos chamados *não-paramétricos* ou *livres de distribuição*.

Teremos para análise amostras *independentes* das duas populações e queremos testar a hipótese (13.1) contra a alternativa de que as distribuições diferem em localização: estaremos interessados em saber se uma população tende a ter valores maiores do que a outra, ou se elas têm a mesma mediana ou média.

O teste de Wilcoxon é baseado nos *postos* dos valores obtidos combinando-se as duas amostras. Isso é feito ordenando-se esses valores, do menor para o maior, independentemente do fato de qual população cada valor provém. A estatística do teste é a *soma* dos postos associados aos valores amostrados de uma população, P_1 , por exemplo. Se essa soma for grande, isso é uma indicação de que os valores dessa população tendem a ser maiores do que os valores de P_2 , e, então, rejeitamos (13.1).

No caso de termos uma v.a. qualitativa ordinal, comumente associamos números às diversas categorias (ou classes, ou atributos), segundo as quais a variável é classi-

ficada. Por exemplo, podemos ter 1 para *bom*, 2 para *muito bom* e 3 para *ótimo*. Vemos, então, que esses valores são os postos, nesse caso, e em outras situações é preferível trabalhar com postos do que com valores arbitrários associados à v.a. qualitativa.

Quando trabalhamos com v.a. quantitativas poderemos ter valores repetidos nas amostras. Veremos como associar postos nesse caso. Para evitar esses *empates*, uma possibilidade é supor que a v.a. seja contínua, de modo que se X for uma tal variável, $P(X = x_0) = 0$. Essa suposição é eventualmente necessária para o desenvolvimento teórico do teste, mas na prática, quer X seja contínua ou discreta, valores repetidos poderão aparecer.

(a) Observações Distintas

Suponha que tenhamos N observações $Z_1, Z_2, \dots, Z_N$. Ordenando-as da menor para a maior obtemos as estatísticas de ordem, $Z_{(1)} \leq Z_{(2)} \leq \dots \leq Z_{(N)}$. Inicialmente, suponha que não haja observações coincidentes, de modo que os sinais de $\leq$ são substituídos por $<$. Então, associamos números (normalmente 1, 2, ..., N), chamados *postos*, que correspondem às posições das observações na ordenação. O posto de Z_i é igual a 1 + (número de $Z_j < Z_i$). Assim, dadas as observações

$$Z_1 = 0,3, Z_2 = 1,5, Z_3 = -0,5, Z_4 = 2,0,$$

os postos de Z_1, Z_2, Z_3 e Z_4 serão, respectivamente,

$$R_1 = 2, R_2 = 3, R_3 = 1, R_4 = 4,$$

já que a ordenação resulta em

$$-0,5 < 0,3 < 1,5 < 2,0, \quad \text{ou} \quad Z_3 < Z_1 < Z_2 < Z_4.$$

Exemplo 13.6. Num estudo sobre um novo método para ensinar Matemática elementar, foram selecionadas cinco crianças. Destas, três são escolhidas ao acaso e ensinadas segundo o novo método, enquanto as outras duas funcionaram como controle e receberam instrução por um método tradicional. Após um período de cinco semanas é feito um teste, e as crianças são ordenadas segundo seu desempenho: a criança que tiver menor nota recebe posto 1, etc., até a criança que tiver maior nota recebe posto 5.

O método de ensino será considerado eficaz se as três crianças que recebem o novo método tiverem postos altos nessa ordenação combinada das cinco crianças. Seja H_0 a hipótese nula que especifica que o tratamento (novo método) não tem efeito, isto é, a nota da criança não é afetada se ela for ou não ensinada pelo novo método. Se H_0 for verdadeira, o posto atribuído a cada criança é determinado somente pela sua inteligência, ou seja, a ordenação das crianças não depende de qual recebe tratamento e qual funciona como controle. A Tabela 13.3 mostra todos os casos possíveis para a ordenação, onde C indica controle e T , tratamento.

Tabela 13.3: Valores de W_s para o Exemplo 13.6.

Postos					W_s
1	2	3	4	5	
C	C	T	T	T	12
C	T	C	T	T	11
T	C	C	T	T	10
C	T	T	C	T	10
T	C	T	C	T	9
C	T	T	T	C	9
T	C	T	T	C	8
T	T	C	T	C	7
T	T	T	C	C	6
T	T	C	C	T	8

Vemos que as crianças e seus postos podem ser divididos em dois grupos (tratados e controles) de $\binom{5}{3} = 10$ maneiras diferentes. A suposição de que as três crianças recebendo o tratamento são selecionadas ao acaso e de que os tratamentos são equivalentes, implica que todas as dez possibilidades têm a mesma probabilidade 1/10.

Consideremos a estatística

$$W_s = S_1 + S_2 + S_3, \tag{13.15}$$

onde S_1 , S_2 e S_3 são os postos das crianças que receberam o tratamento na amostra combinada.

Poderíamos considerar como regra de decisão para rejeitar H_0 a ocorrência de $W_s = 12$, correspondendo à ocorrência de CCTTT, clara superioridade do tratamento. Qual seria a probabilidade de esse evento ocorrer por mero acaso, ou seja, quando os dois métodos são equivalentes? Nesse caso teremos

$$P(W_s = 12 | H_0 \text{ verdadeiro}) = 0,10,$$

que é a probabilidade do erro de tipo I, ou seja, o nível de significância do teste. Mas, como vimos antes, usualmente procedemos de maneira oposta, ou seja, fixamos α e não a regra de decisão.

Como vimos acima, rejeitamos H_0 para valores grandes de W_s , ou seja, $W_s \geq c$, onde c é uma constante determinada a partir do nível de significância do teste, α . Obtemos o teste de Wilcoxon:

“Rejeite H_0 se $W_s \geq c$, onde c é determinada por $P(W_s \geq c | H_0 \text{ é verdadeira}) = \alpha$ ”.


A distribuição nula (isto é, sob H_0) de W_s é obtida da Tabela 13.3 e está na Tabela 13.4.

Tabela 13.4: Distribuição de W_s , observações distintas.

w	6	7	8	9	10	11	12
$P(W_s = w)$	1/10	1/10	2/10	2/10	2/10	1/10	1/10

A distribuição de W_s é simétrica ao redor do valor 9 que, como veremos, representa a média de W_s , dada por $n(N+1)/2$, com $N = n + m$ (Ver Figura 13.3).

Figura 13.3: Distribuição de W_s para o Exemplo 13.6.



Se, por exemplo, $\alpha = 0,05$, não existe valor satisfazendo $P(W_s \geq c) = 0,05$. Podemos encontrar c somente para valores de α iguais a 0,1; 0,2; 0,4 etc. Por exemplo, se $\alpha = 0,1$, então

$$P(W_s \geq 12) = 0,1 \quad \text{e} \quad c = 12.$$

Consideremos, agora, a situação geral. Queremos testar (13.1). Temos duas amostras independentes, $X_1, \dots, X_n$, de P_1 , e $Y_1, \dots, Y_m$, de P_2 . Seja $N = n + m$ e combinamos as duas amostras numa só, ordenamos os N valores no menor para o maior e chamemos $S_1 < S_2 < \dots < S_m$ os postos dos Y_i (tratamentos) e $R_1 < R_2 < \dots < R_n$ os postos dos X_i (controles). Estamos supondo que não haja empates. Seja

$$W_s = S_1 + S_2 + \dots + S_m \quad (13.16)$$

a soma dos postos dos tratamentos. Rejeitamos H_0 se $W_s \geq c$.

No caso bilateral, rejeite H_0 se $W_s < c_1$ ou $W_s > c_2$, para dado α .

Não é difícil verificar que, se a distribuição de P_1 for contínua, então

$$P(S_1 = s_1, \dots, S_m = s_m) = \frac{1}{\binom{N}{m}}, \quad (13.17)$$

onde $s_1 < s_2 < \dots < s_m$ e $s_i \in \{1, 2, \dots, N\}$, $N = n + m$.

Observação. Por (13.17) vemos que a distribuição dos postos e portanto de W_s não depende de P_1 . Isso não ocorrerá se P_1 não for contínua. Se as distribuições P_1 e P_2 forem contínuas, há ausência de empates (isto é, coincidência entre valores de X e de Y). Isso significa que poderíamos considerar nossas medidas de X e Y de tal sorte que coincidências seriam evitadas. Na prática, contudo, as medidas são feitas em geral com o mesmo número de casas decimais, de modo que empates podem ocorrer. Essa situação é analisada abaixo.

A distribuição sob H_0 de W_s pode ser encontrada como no Exemplo 13.6. Para dado valor de w , verificamos quantas amostras de tamanho m , retiradas de $P = \{1, 2, \dots, N\}$ fornecem o valor de w . Se $\#(w; n, m)$ indicar esse número, então, por (13.17),

$$P(W_s = w | H_0 \text{ é verdadeira}) = \frac{\#(w; n, m)}{\binom{N}{m}}. \quad (13.18)$$

Pode-se provar o seguinte resultado (veja, por exemplo, Lehmann, 1975):

Teorema 13.1. Para a estatística W_s temos:

$$E(W_s) = \frac{m(N+1)}{2}, \quad (13.19)$$

$$\text{Var}(W_s) = \frac{nm(N+1)}{12}. \quad (13.20)$$

Além disso, a distribuição de W_s pode ser aproximada pela distribuição normal; quando $n, m \rightarrow \infty$, a v.a.

$$Z = \frac{W_s - E(W_s)}{\sqrt{\text{Var}(W_s)}} \quad (13.21)$$

tem uma distribuição aproximada $N(0, 1)$.

Uma estatística equivalente a W_s é

$$U_s = W_s - \frac{1}{2}m(m+1), \quad (13.22)$$

chamada *estatística de Mann-Whitney*. Há duas vantagens em se usar U_s :

- (a) a distribuição de U_s para $n = n_1$ e $m = m_1$ é a mesma que a distribuição de U_s quando os tamanhos são invertidos, isto é, para $n = m_1$ e $m = n_1$. Isso não acontece com W_s ;
- (b) o valor mínimo de W_s é obtido quando os postos dos m tratamentos são 1, 2, ..., m e $1 + 2 + \dots + m = m(m+1)/2$; logo, o valor mínimo de U_s é zero, para quaisquer valores de n e m , simplificando a construção de tabelas. A Tabela VIII do Apêndice dá os valores de $P(U_s \leq u)$.

Para essa estatística temos o resultado seguinte.

Teorema 13.2. A média e variância de U_s são dadas por

$$E(U_s) = \frac{nm}{2} \quad (13.23)$$

e

$$\text{Var}(U_s) = \frac{nm(N+1)}{12}, \quad (13.24)$$

respectivamente. Além disso, a distribuição de U_s pode também ser aproximada por uma normal.

Exemplo 13.7. Suponha que $m = n = 10$ e queremos calcular $P(W_s \leq 87)$. O valor tabelado é 0,0952, que é encontrado na Tabela VIII com $n = m = 10$, e levando-se em conta que $U_s = 87 - 10 \times 11/2 = 32$ e, portanto, $P(U_s \leq 32) = 0,0952$.

Por outro lado, usando a aproximação normal, $E(W_s) = 105$, $\text{Var}(W_s) = 175$, temos

$$P(W_s \leq 87) = P\left(\frac{W_s - 105}{\sqrt{175}} \leq \frac{87 - 105}{\sqrt{175}}\right) = P(Z \leq -1,36) \approx 0,087,$$

que está bem próxima do valor encontrado usando-se a tabela.

A aproximação pode ser melhorada usando-se a correção de continuidade discutida na seção 7.5, pois aqui também estamos aproximando a distribuição de uma v.a. discreta (W_s) por uma distribuição de variável contínua (normal). Verifique que, usando essa correção, obtemos $P(W_s \leq 87) \approx 0,0934$.

(b) Observações Não Todas Distintas

Consideremos, agora, a situação em que haja observações coincidentes, ou empates.

Suponha, por exemplo, que $n = 3$, $m = 2$ e as observações são

$$1,3; 1,5; 1,5; 2,1; 2,5.$$

Nesse caso, usamos *postos médios*. Associamos o posto 1 à observação 1,3; às duas observações empatadas 1,5 associamos a média dos postos 2 e 3, que seriam atribuídas se as observações fossem distintas, ou seja, atribuímos o posto $(2 + 3)/2 = 2,5$; à observação 2,1 atribuímos o posto 4 e à observação 2,5 atribuímos o posto 5.

Embora a atribuição de postos seja diferente nesse caso, continuaremos a usar a mesma notação anterior para os postos das observações X_i e Y_i . A distribuição da estatística W_s não é mais dada por (13.17), pois os valores de $S_1, \dots, S_m$ não são mais os anteriores. Retomemos o exemplo dado. Temos que a distribuição conjunta dos postos S_1 e S_2 será:

$$\begin{aligned} P(S_1 = 1, S_2 = 2,5) &= 2/10, & P(S_1 = 1, S_2 = 4) &= 1/10, \\ P(S_1 = 1, S_2 = 5) &= 1/10, & P(S_1 = S_2 = 2,5) &= 1/10, \\ P(S_1 = 2,5, S_2 = 4) &= 2/10, & P(S_1 = 2,5, S_2 = 5) &= 2/10, \\ P(S_1 = 4, S_2 = 5) &= 1/10, \end{aligned}$$

pois ainda cada uma das $\binom{5}{2} = 10$ escolhas de dois dos postos médios como S_1 e S_2 são igualmente prováveis. Portanto a distribuição de $W_s = S_1 + S_2$ é dada pela Tabela 13.5.

Tabela 13.5: Distribuição de W_s , observações não-distintas.

w	3,5	5,0	6,0	6,5	7,5	9,0
$P(W_s = w)$	2/10	2/10	1/10	2/10	2/10	1/10

Observe que a distribuição da v.a. W_s nesse caso não é simétrica; será simétrica ao redor de $m(N + 1)/2$ se $n = m$.

Genericamente, o teste de Wilcoxon, no caso de observações empatadas, rejeita H_0 usando a mesma regra de decisão que no caso de observações não empatadas, exceto que a distribuição de W_s vai depender de n , m e dos números de observações empatadas em cada valor, ao contrário da situação de não empates, para a qual a distribuição de W_s depende somente de n e m .

Exemplo 13.8. Supondo $n = 3$, $m = 2$, as observações dos controles são 1,3, 1,5 e 2,1, e as observações dos tratamentos são 1,5 e 2,5. Então,

$$S_1 = 2,5, \quad S_2 = 5, \quad R_1 = 1, \quad R_2 = 2,5, \quad R_3 = 4 \quad \text{e} \quad W_s = S_1 + S_2 = 7,5.$$

Pelo que vimos acima, o valor- p será

$$\hat{\alpha} = P(W_s \geq 7,5) = 2/10 + 1/10 = 0,3,$$

logo não rejeitaremos H_0 nos níveis usuais.

Suponha que temos d_1 observações empatadas no menor valor, d_2 observações empatadas no segundo menor valor etc. até d_e observações empatadas no maior valor, onde e é o número de valores distintos. Denominamos (e ; $d_1, \dots, d_e$) de *configuração de empates*, e a distribuição de W_s dependerá dessa configuração. Assim sendo, tabelas teriam de ser construídas para cada configuração de empates, o que não é prático. O que se faz é o seguinte: se o número de empates for pequeno, continue a usar a Tabela VIII. Caso contrário, use a aproximação normal. Nesse caso, a média de W_s é a mesma anterior, mas a variância é igual à anterior menos uma correção devida aos empates:

$$\text{Var}(W_s) = \frac{mn(N+1)}{12} - \frac{mn}{12N(N-1)} \sum_{i=1}^e (d_i^3 - d_i). \quad (13.25)$$

A aproximação normal será adequada se m e n forem relativamente grandes, e as proporções d_i/N não forem próximas de 1.

Exemplo 13.9. Em aparelhos dentários são usados grampos de dois tipos: um modelo em T e outro circunferencial, C . O objetivo é verificar se a resistência à remoção de grampos em T é a mesma do modelo C . Foram usados 40 corpos de provas (dente-grampo), sendo 20 para o modelo T e 20 para o modelo C , com cinco leituras para cada corpo de prova, num total de 100 observações para cada modelo. As Figuras 13.4 e 13.5 mostram os histogramas para os dois modelos, a resistência sendo medida em kg.

Figura 13.4: Resistência à remoção, em kg, para o modelo *C*.





Figura 13.5: Resistência à remoção, em kg, para o modelo *T*.



Vemos que há assimetrias nos histogramas, sugerindo que a aplicação do teste *t* de Student não é adequada nessa situação. A Tabela 13.6 mostra as médias das 5 leituras para cada corpo de prova, para o modelo *T* e para o modelo *C* (em ordem crescente).

Admitamos que o grupo de controle seja aquele em que os grampos sejam do tipo *T*, e grampos do tipo *C* constituam o tratamento. Ordenando as médias da Tabela 13.6 e atribuindo postos obtemos a Tabela 13.7.

Tabela 13.6: Valores de resistência à remoção para os dois modelos.

T	C	T	C
0,60	0,52	1,19	1,19
0,63	0,77	1,20	1,20
0,83	0,79	1,26	1,34
0,85	0,79	1,28	1,36
0,91	0,81	1,30	1,38
0,95	0,81	1,37	1,43
1,01	0,89	1,45	1,64
1,03	0,98	1,54	1,71
1,03	1,01	1,68	2,16
1,16	1,18	2,20	2,25

Tabela 13.7: Postos para o Exemplo 13.9.

Média	0,52	0,60	0,63	0,77	0,79	0,79	0,81	0,81	0,83	0,85
Tipo	C	T	T	C	C	C	C	C	T	T
Posto	1	2	3	4	5,5	5,5	7,5	7,5	9	10
Média	0,89	0,91	0,95	0,98	1,01	1,01	1,03	1,03	1,16	1,18
Tipo	C	T	T	C	C	T	T	T	T	C
Posto	11	12	13	14	15,5	15,5	17,5	17,5	19	20
Média	1,19	1,19	1,20	1,20	1,26	1,28	1,30	1,34	1,36	1,37
Tipo	C	T	T	C	T	T	T	C	C	T
Posto	21,5	21,5	23,5	23,5	25	26	27	28	29	30
Média	1,38	1,43	1,45	1,54	1,64	1,68	1,71	2,16	2,20	2,25
Tipo	C	C	T	T	C	T	C	C	T	C
Posto	31	32	33	34	35	36	37	38	39	40

Aqui $n = m = 20$ e queremos testar

H_0 : a resistência à remoção é a mesma para os dois tipos de grampos;

H_1 : o tipo C apresenta menor resistência à remoção do que o do tipo T.

A soma dos postos dos tratamentos é

$$W_S = S_1 + S_2 + \dots + S_{20} = 406,5.$$

Usando a aproximação normal, a v.a.

$$Z = \frac{W_S - E(W_S)}{\sqrt{\text{Var}(W_S)}}, \quad (13.26)$$

onde $\text{Var}(W_S)$ é dada por (13.25), e terá distribuição aproximadamente $N(0, 1)$. Consultando a Tabela 13.7, temos

$$d_1 = d_2 = d_3 = d_4 = 1, \quad d_5 = 2, \quad d_6 = 2, \quad d_7 = \dots = d_{12} = 1,$$

$$d_{13} = 2, \quad d_{14} = 2, \quad d_{15} = d_{16} = 1, \quad d_{17} = 2, \quad d_{18} = 2,$$

$$d_{19} = \dots = d_{34} = 1.$$

Aqui, temos $e = 34$ valores distintos e

$$E(W_S) = (20 \times 41)/2 = 410,$$

$$\begin{aligned} \text{Var}(W_S) &= (20 \times 20 \times 41)/12 - (20 \times 20)/(12 \times 40 \times 39) [(8 - 2) \times 6] \\ &= 1.366,667 - 2,857 = 1.363,810. \end{aligned}$$

O valor de (13.26) é

$$Z = (406,5 - 410)/36,93 = -0,095.$$

Como rejeitaremos H_0 se $W_S \leq c$, no nível $\alpha = 0,05$, devemos comparar esse valor com o valor $-1,64$ da normal padrão, portanto não rejeitamos H_0 .

Vemos que o valor- p do teste é

$$\hat{\alpha} = P(W_s \leq 406,5) \approx P(Z \leq -0,095) = 0,46,$$

que é uma indicação de que a hipótese H_0 deve ser aceita.

Observação. Comparação entre o Teste t e o Teste de Wilcoxon.

O teste t baseia-se na suposição de que as populações P_1 e P_2 sejam normais. Uma violação dessa suposição altera a distribuição da estatística usada no teste e muda as probabilidades dos erros de tipo I e II. Dizemos que um teste é *robusto* contra a violação de uma suposição se suas probabilidades de erro de tipo I e II não são afetadas de forma apreciável pela violação.

Pode-se mostrar que o teste t é pouco sensível à heterogeneidade de variâncias se $m = n$, mas ele será mais afetado se as variâncias forem diferentes e $m \neq n$.

Os testes t e de Wilcoxon são comparados através de seus poderes em termos de uma quantidade chamada *eficiência relativa assintótica*, mas não entraremos em detalhes aqui sobre esse assunto. Mas podemos resumir a situação da seguinte maneira:

- (a) O teste t é mais poderoso quando temos populações normais, mas a perda de eficiência do teste de Wilcoxon é pequena (menos de 5%) nesse caso;
- (b) haverá pouca diferença entre os dois testes para distribuições próximas da normal;
- (c) o teste de Wilcoxon é mais eficiente para distribuições que têm caudas “mais pesadas” do que a normal.

Para se ter uma idéia do que significa mais pesada, observamos que as distribuições t e Cauchy têm distribuições com caudas mais pesadas que a normal. Se P_1 e P_2 forem ambas uniformes, pode-se provar que os dois testes são igualmente eficientes e se P_1 e P_2 forem ambas exponenciais, o teste de Wilcoxon é três vezes mais eficiente.

Problemas

10. Vinte canteiros foram plantados com milho. Em dez deles um novo tipo de fertilizante foi aplicado, obtendo-se as produções abaixo. Há diferenças significativas entre as produções? A alternativa é que o novo fertilizante tende a produzir valores maiores. Tome $\alpha = 0,05$. Calcule $\hat{\alpha}$.

Controle	7,1	6,0	8,0	7,0	6,6	7,4	7,0	7,0	6,9	6,8
Tratamento	6,9	6,8	7,5	6,8	6,9	6,8	6,8	6,8	6,7	6,6

11. Obtenha a distribuição nula de W_s para os casos:
- (a) $m = 2, n = 2$; (b) $m = 2, n = 4$; (c) $m = n = 3$.
12. Calcule as seguintes probabilidades, usando a Tabela VIII e a aproximação normal.
- (a) $m = 6, n = 7, P(W_s \leq 48)$
 - (b) $m = 8, n = 10, P(W_s \leq 65)$
 - (c) $m = 10, n = 10, P(W_s \geq 63)$
13. Encontre a distribuição nula de W_s no caso de empates, para os casos:

- (a) $m = n = 3, d_1 = d_2 = 1, d_3 = 2, d_4 = d_5 = 1$
 (b) $m = n = 3, d_1 = d_2 = d_3 = 2$
 (c) $m = 2, n = 3, d_1 = d_2 = 1, d_3 = 3$

14. Faça os histogramas para W_5 nos Problemas 11 e 13.

15. Suponha que as observações dos tratamentos sejam 3, 3, 5 e 7, e as observações dos controles sejam 1, 4 e 8, e que o teste de Wilcoxon rejeite para valores grandes de W_5 . Calcule $\hat{\alpha} = P(W_5 \geq w)$, onde w é o valor observado de W_5 .

13.4 Comparação de Duas Populações: Amostras Dependentes

Na seção 13.1 já discutimos essa situação. Aqui, temos duas amostras $X_1, \dots, X_n$ e $Y_1, \dots, Y_n$, só que agora as observações são pareadas, isto é, podemos considerar que temos na realidade uma amostra de pares $(X_1, Y_1), \dots, (X_n, Y_n)$. Se definirmos a v.a. $D = X - Y$, teremos a amostra $D_1, D_2, \dots, D_n$, resultante das diferenças entre os valores de cada par. Observe que reduzimos a um problema com uma única população, conforme estudado nos capítulos anteriores.

Consideraremos dois casos: no primeiro, supomos que a população das diferenças é normal; no segundo, supomos que essa população é simétrica.

13.4.1 População Normal

Nessa situação, faremos a seguinte suposição: a v.a. D tem distribuição normal $N(\mu_D, \sigma_D^2)$. Podemos deduzir daqui que

$$\bar{D} = \frac{1}{n} \sum_{i=1}^n D_i = \frac{1}{n} \sum_{i=1}^n (X_i - Y_i) = \bar{X} - \bar{Y} \quad (13.27)$$

terá distribuição $N(\mu_D, \sigma_D^2/n)$.

Considere

$$S_D^2 = \frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})^2. \quad (13.28)$$

Pelo Teorema 7.1, a estatística

$$T = \frac{\sqrt{n}(\bar{D} - \mu_D)}{S_D} \quad (13.29)$$

terá distribuição t de Student, com $(n-1)$ graus de liberdade.

Como

$$\mu_D = E(D) = E(X - Y) = E(X) - E(Y) = \mu_1 - \mu_2,$$

qualquer afirmação sobre o $\mu_1 - \mu_2$ corresponde a uma afirmação sobre μ_D .

Exemplo 13.10. Cinco operadores de certo tipo de máquina são treinados em máquinas de duas marcas diferentes, A e B. Mediu-se o tempo que cada um deles gasta na realização de uma mesma tarefa, e os resultados estão na Tabela 13.8.

Tabela 13.8: Tempos para realização de tarefa para cinco operadores.

Operador	Marca A	Marca B
1	80	75
2	72	70
3	65	60
4	78	72
5	85	78

Com o nível de significância de 10%, poderíamos afirmar que a tarefa realizada na máquina A demora mais do que na máquina B?

Estamos interessados em testar

$$H_0 : \mu_A = \mu_B$$

$$H_1 : \mu_A > \mu_B.$$

Essas hipóteses são equivalentes a

$$H_0 : \mu_D = 0$$

$$H_1 : \mu_D > 0.$$

Como é o mesmo operador que realiza a tarefa nas duas máquinas, estamos diante do caso em que se pode usar variáveis emparelhadas. Vamos admitir que, sob H_0 , a diferença de tempo segue uma distribuição normal $N(0, \sigma_D^2)$. Logo, usamos a estatística (13.29).

Para determinar a região crítica, note que, devido à forma de H_1 , devemos encontrar t_c tal que $P(T > t_c) = 0,10$, sendo que T tem distribuição $t(4)$. Usando a Tabela V, obtemos

$$RC =]1,54; +\infty[.$$

Da Tabela 13.8 obtemos os valores de D :

$$d_i : 5, 2, 5, 6, 7$$

e, portanto,

$$\bar{d} = 5 \quad \text{e} \quad s_D^2 = 3,5.$$

O valor observado da estatística T é $t_0 = (5/1,87)(\sqrt{5}) = 5,98$. Segue-se que rejeitamos H_0 , ou seja, demora-se mais para realizar a tarefa com a máquina A.

Podemos construir um intervalo de confiança para μ_D ; para $\gamma = 0,90$,

$$IC(\mu_A - \mu_B; 0,90) = IC(\mu_D; 0,90) = 5 \pm (2,13)(1,87)/\sqrt{5},$$

ou seja,

$$IC(\mu_D; 0,90) =]3,22; 6,78[.$$

13.4.2 População Não-Normal

Vamos considerar, agora, um teste baseado nos postos das diferenças D_i ; o chamado *teste dos postos sinalizados de Wilcoxon*. Para esse teste, supomos que a escala das diferenças seja pelo menos intervalar e que os pares (X_i, Y_i) constituam uma AAS.

Isso implica, em particular, que os D_i são independentes, com a mesma mediana. Suponha, ainda, que cada D_i tenha uma distribuição simétrica. Ou seja, as médias e medianas coincidem.

Exemplo 13.11. Suponha que se possa simular um modelo por meio de duas linguagens computacionais, que chamaremos A e B. Supostamente, o tempo usando B é menor que o tempo usando A. Cinco pares de alunos são selecionados para o teste, de modo que cada membro de um par tenha a mesma habilidade computacional nas duas linguagens do que o outro. Um membro de cada par é escolhido ao acaso e este vai usar a linguagem B; o outro usará A. O tempo de simulação (em segundos) de cada linguagem é anotado, obtendo-se a Tabela 13.9.

Tabela 13.9: Tempos de simulação (em segundos) para as linguagens A e B.

Par	1	2	3	4	5
tempo de B(X)	300	410	420	410	400
tempo de A(Y)	350	390	490	435	440
$D = X - Y$	-50	20	-70	-25	-40
Posto de $ D $	4	1	5	2	3
Posto sinalizado	-4	+1	-5	-2	-3

Queremos testar a hipótese de que os tempos são semelhantes contra a hipótese de que os tempos de B são menores. Ou, ainda,

$$H_0 : \mu_B - \mu_A = \mu_D = 0,$$

$$H_1 : \mu_B - \mu_A = \mu_D < 0.$$

Na quarta linha da Tabela 13.9 estão apresentadas as diferenças D_i , e os postos são calculados a partir das variáveis $|D_i|$, ou seja, os módulos (ou valores absolutos) dos D_i (quinta linha). A sexta linha, “posto sinalizado”, é obtida atribuindo-se ao posto de $|D_i|$ o sinal correspondente de D_i . Por exemplo, para a primeira observação, $D_1 = 300 - 350 = -50$, com $|D_1| = 50$, que tem posto 4 e, portanto, posto sinalizado -4 .

Notamos que só há um posto positivo, $+1$. Se indicarmos por T^+ a soma dos postos positivos, rejeitaremos H_0 se T^+ for “pequeno”. É claro que podemos trabalhar com os postos negativos também, e considerar $T^- = -$ (soma dos postos negativos). No exemplo, $T^+ = 1$ e $T^- = 14$. Usando T^- , rejeitaremos H_0 se esta for “grande”. Note que $T^+ + T^- = 15$, que é a soma de todos os postos dos $|D_i|$, que, por sua vez, é $n(n + 1)/2$, sendo $n = 5$ o número de pares. Em geral, devemos usar a menor soma.

Trabalhemos com T^+ . Para conduzir o teste, devemos obter a distribuição dessa estatística, sob a hipótese nula H_0 . Para isso, note que, se H_0 for verdadeira, cada

posto tem a mesma probabilidade de ser associado com um sinal + ou com um sinal -. Logo, a seqüência de postos sinalizados é uma de todas as possíveis combinações de $\pm 1, \pm 2, \dots, \pm 5$. Há $2^5 = 32$ tais combinações, todas equiprováveis sob H_0 , ou seja, com probabilidade $1/32$.

Na Tabela 13.10 temos todas as possibilidades juntamente com o valor de T^+ . Na Tabela 13.11 temos a distribuição de T^+ . Note que a distribuição de T^+ é simétrica, com média e mediana iguais a 7,5.

Tabela 13.10: Sinais possíveis para os postos, Exemplo 13.10.

1	2	3	4	5	T^+	1	2	3	4	5	T^+
+	+	+	+	+	15	+	+	-	+	-	7
-	+	+	+	+	14	-	+	-	-	+	7
+	-	+	+	+	13	-	-	+	+	-	7
+	+	-	+	+	12	+	-	-	-	+	6
-	-	+	+	+	12	+	+	+	-	-	6
+	+	+	-	+	11	-	+	-	+	-	6
-	+	-	+	+	11	+	-	-	+	-	5
+	+	+	+	-	10	-	+	+	-	-	5
-	+	+	-	+	10	-	-	-	-	+	5
+	-	-	+	+	10	+	-	+	-	-	4
-	+	+	+	-	9	-	-	-	+	-	4
-	-	-	+	+	9	+	+	-	-	-	3
+	-	+	-	+	9	-	-	+	-	-	3
+	+	-	-	+	8	-	+	-	-	-	2
+	-	+	+	-	8	+	-	-	-	-	1
-	-	+	-	+	8	-	-	-	-	-	0

Tabela 13.11: Distribuição de T^+ sob H_0 .

T^+	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Frequência	1	1	1	2	2	3	3	3	3	3	3	2	2	1	1	1

O valor- p do teste é $P(T^+ \leq 1 | H_0) = 2/32 = 0,06$, usando a Tabela 13.11. Ou seja, há indicação de que o tempo de simulação usando a linguagem B é menor do que o tempo de A. Observe que temos poucos pares, e o valor $\hat{\alpha} = 0,06$ não é tão pequeno (veja a Tabela 12.2). Mas como temos somente um posto positivo dentre cinco, somos levados a duvidar da validade de H_0 .

Vejam, agora, o caso geral. Tomemos os valores absolutos das diferenças, ou seja,

$$|D_i| = |X_i - Y_i|, i = 1, \dots, m.$$

Quando $X_i = Y_i$ omitir a diferença correspondente e seja n o número de diferenças estritamente diferentes de zero. Associemos a cada par (X_i, Y_i) o posto do módulo de D_i correspondente. Use postos médios, se houver D_i coincidentes.

A hipótese a ser testada é que a média (ou a mediana) das diferenças seja igual a zero contra a alternativa que não seja. Testes unilaterais podem, também, ser considerados. Ou seja, dada a simetria da distribuição dos D_i , iremos testar

$$H_0 : \mu_D = 0,$$

$$H_1 : \mu_D \neq 0,$$

onde μ_D representa, como antes, a média das diferenças.

Considere

$$R_i = \begin{cases} R(X_i, Y_i), & \text{se } D_i > 0, \\ -R(X_i, Y_i), & \text{se } D_i < 0, \end{cases} \quad (13.30)$$

onde $R(X_i, Y_i)$ é o posto associado a (X_i, Y_i) .

Temos dois casos a tratar:

(A) Se não houver empates, use a estatística

$$T^+ = \sum (R_i \text{ com } D_i > 0), \quad (13.31)$$

ou seja, a soma dos postos positivos. Use a Tabela IX, pág. 506, para obter os quantis w_p da estatística, ou seja, o valor, tal que $P(T^+ < w_p) \leq p$ e $P(T^+ > w_p) \leq 1 - p$, se H_0 for verdadeira. Para $n > 50$ use a aproximação normal, com média e variância dados no teorema abaixo. Para $p > 0,5$ o quantil é dado por

$$w_p = \frac{n(n+1)}{2} - w_{1-p}.$$

(B) Se houver empates, use a estatística

$$V = \frac{\sum_{i=1}^N R_i}{\sqrt{\sum_{i=1}^N R_i^2}}, \quad (13.32)$$

que tem uma distribuição aproximadamente $N(0,1)$, sob a hipótese nula.

Teorema 13.3. A média e variância de T^+ são dadas por

$$E(T^+) = \frac{n(n+1)}{4} \quad (13.33)$$

e

$$\text{Var}(T^+) = \frac{n(n+1)(2n+1)}{24}, \quad (13.34)$$

respectivamente.

Exemplo 13.11. (continuação) Obtivemos aqui $T^+ = 1$. A região crítica é unilateral à esquerda, logo rejeitamos H_0 se $T^+ < w_\alpha$, onde w_α é o quantil dado pela Tabela IX. Se fixarmos $\alpha = 0,025$ ou $\alpha = 0,01$, obteremos $w_\alpha = 0$, com $n = 5$, e, portanto, aceitaremos

H_0 . Se $\alpha = 0,05$, então $w_\alpha = 1$, e o valor observado estará na fronteira da região crítica e teremos dúvidas em aceitar ou rejeitar H_0 . Como salientamos antes, a decisão, nesse caso, dependerá de uma análise cuidadosa dos resultados, dado o pequeno valor de n .

13.5 Comparação de Proporções em Duas Populações

Nosso objetivo agora é a comparação das proporções de duas populações P_1 e P_2 . Sendo mais explícitos, queremos comparar as proporções populacionais p_1 e p_2 , por meio dos estimadores $\hat{p}_1$ e $\hat{p}_2$ obtidos de amostras independentes de tamanhos n_1 e n_2 respectivamente. Das seções 10.9 e 12.6 temos

$$\hat{p}_1 \sim N\left(p_1, \frac{p_1(1-p_1)}{n_1}\right), \hat{p}_2 \sim N\left(p_2, \frac{p_2(1-p_2)}{n_2}\right).$$

Comparando com o resultado da seção 13.3.1, e também do Problema 10.32, obtemos

$$\hat{p}_1 - \hat{p}_2 \sim N\left(p_1 - p_2, \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}\right),$$

e portanto, a estatística de decisão, tanto para a construção de intervalos de confiança como para testes de hipóteses, será

$$z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} \sim N(0, 1).$$

Mas como os valores dos parâmetros são desconhecidos, substituem-se as variâncias pelas seus estimadores, obtendo-se, como visto em 13.3.1(b), uma distribuição aproximadamente t de Student. Entretanto, estudos envolvendo proporções utilizam amostras grandes e os valores da distribuição t aproximam-se de valores da normal padronizada. Desse modo, para comparação de duas proporções recomenda-se sempre o uso da estatística:

$$z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}} \sim N(0, 1). \quad (13.35)$$

Exemplo 13.12: Para lançamento da nova embalagem do sabonete SEBO a divisão de criação estuda duas propostas:

A: amarela com letras vermelhas, ou

B: preta com letras douradas.

Eles acreditam que a proposta A chama a atenção em pelo menos 5% a mais do que a proposta B. Para verificar a validade de tal informação conduziu-se o seguinte experimento: em cada um de dois supermercados “semelhantes” foram colocados sabonetes com cada tipo de embalagem, e a clientes selecionados aleatoriamente foi perguntado se tinham notado o sabonete e que descrevessem qual a embalagem. Abaixo estão os resultados.

Proposta	Notaram?		Total
	Sim	Não	
A	168	232	400
B	180	420	600
Total	348	652	1000

Os resultados da pesquisa justificam ou não as suposições da divisão de criação? Aqui, consideramos

$$H_0: p_A - p_B = 0,05, \quad H_1: p_A - p_B > 0,05.$$

Da tabela obtemos: $\hat{p}_1 = 0,42$ e $\hat{p}_2 = 0,30$, e aplicando a fórmula (13.35) obtemos:

$$Z = \frac{(0,42 - 0,30) - 0,05}{\sqrt{\frac{(0,42)(0,58)}{400} + \frac{(0,30)(0,70)}{600}}} = 2,26.$$

Consultando a Tabela III, encontramos o valor- p $\hat{\alpha} = 1,19\%$, o que leva a rejeição de H_0 . O passo seguinte seria a construção de um Intervalo de Confiança, e novamente aplicado a expressão (13.35), obtém-se:

$$IC(p_A - p_B: 95\%) = (0,42 - 0,30) \pm 1,96 \sqrt{\frac{(0,42)(0,58)}{400} + \frac{(0,30)(0,70)}{600}},$$

$$IC(p_A - p_B: 95\%) = 0,12 \pm 0,036 = [0,084; 0,156].$$

Para testar a hipótese de igualdade de proporções, $p_1 = p_2$, e usando as mesmas argumentações apresentadas na seção 13.3.1(a), deve-se usar uma estimativa comum das variâncias dada por $\hat{p}_c(1 - \hat{p}_c)$, onde $\hat{p}_c = (n_1 p_1 + n_2 p_2) / (n_1 + n_2)$, resultando no teste:

$$Z = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\hat{p}_c(1 - \hat{p}_c) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim N(0, 1) \quad (13.36)$$

Exemplo 13.12 (continuação). Voltando ao problema do sabonete SEBO, suponha que eles não sabem se uma embalagem é ou não mais atraente do que outra, e a pesquisa foi feita para responder a essa questão. Portanto o teste agora será:

$$H_0: p_A = p_B, \quad H_1: p_A \neq p_B.$$

Da tabela obtemos $\hat{p}_c = (348/1000) = 0,348$, substituindo em (13.36), obtemos:

$$Z = \frac{0,42 - 0,30}{\sqrt{0,348(0,652)\left(\frac{1}{400} + \frac{1}{600}\right)}} = 3,90.$$

Consultando a Tabela III, encontramos valor- p próximo de zero, o que leva a rejeição de H_0 . Como esse resultado mostra que as variâncias também são diferentes, a construção do Intervalo de Confiança é obtida do mesmo modo acima.

Problemas

16. Para investigar a lealdade de consumidores a um determinado produto, sorteou-se uma amostra de 200 homens e 200 mulheres. Foram classificados como tendo alto grau de fidelidade 100 homens e 120 mulheres. Os dados trazem evidências de diferença de grau de fidelidade entre os sexos? Em caso afirmativo construa um intervalo de confiança para a diferença.
17. Em uma amostra de 500 famílias da cidade A, constatou-se que 298 haviam comprado, durante os últimos 30 dias, o refrigerante Meca-Mela em sua nova versão incolor. Na cidade B esse número foi de 147 em 300 famílias entrevistadas. Na cidade A foi feita uma campanha publicitária através da rádio local, e não na cidade B. Os resultados trazem evidências de que as campanhas locais aumentam as vendas?
18. Um partido afirma que a porcentagem de votos masculinos a seu favor será 10% a mais que a de votos femininos. Em uma pesquisa feita entre 400 homens, 170 votariam no partido, enquanto que entre 625 mulheres, 194 lhe seriam favoráveis. A afirmação do partido é verdadeira ou não? Caso rejeite a igualdade, dê um IC para a diferença.
19. Para investigar os resultados do segundo turno de uma eleição estadual tomaram-se duas amostras de 600 eleitores cada: uma da capital e outra do interior. Da primeira, 276 disseram que votariam no candidato A, enquanto que 312 eleitores do interior também o fariam.
 - (a) Estime a proporção de eleitores da capital que votariam em A. Dê um IC.
 - (b) Existe diferença nas proporções entre capital e interior?
 - (c) Que tamanho igual deveriam ter ambas as amostras para que a diferença entre as proporções fosse estimada com erro inferior a 2%?
 - (d) Qual a proporção esperada de votos que irá receber o candidato A no estado?
 - (e) De uma amostra de 120 indivíduos da classe A e B, 69 são favoráveis a eleição em dois turnos, enquanto que em uma amostra de 100 indivíduos da classe C, 48 é que são favoráveis. Existe evidência e diferenças de opiniões em relação à classe social?
20. Para verificar a importância de um cartaz nas compras de certo produto, procedeu-se do seguinte modo:
 - (a) formaram-se sete pares de lojas;
 - (b) os pares foram formados de modo que tivessem as mesmas características quanto à localização, ao tamanho e ao volume de vendas;
 - (c) num dos elementos do par, colocou-se o cartaz; no outro, não;
 - (d) as vendas semanais foram registradas, e os resultados estão a seguir.
 Qual seria a sua conclusão sobre a eficiência do cartaz? Use o teste t , fazendo as suposições necessárias.

Pares	Vendas	
	Sem cartaz	Com cartaz
1	13	16
2	18	24
3	14	18
4	16	14
5	19	26
6	12	17
7	22	29

- 21. Resolva o problema anterior, usando o teste dos postos sinalizados de Wilcoxon.
- 22. Aplique o teste de Wilcoxon para os dados do Exemplo 13.10.
- 23. Os dados abaixo referem-se a medidas de determinada variável em 19 pessoas antes e depois de uma cirurgia. Verifique se as medidas pré e pós-operatórias apresentam a mesma média. Que suposições você faria para resolver o problema? Faça gráficos apropriados para verificar suas suposições.

Pessoas	Pré	Pós	Pessoas	Pré	Pós
1	50,0	42,0	10	40,0	50,0
2	50,0	42,0	11	50,0	48,0
3	50,0	78,0	12	75,0	52,0
4	87,5	33,0	13	92,5	74,0
5	32,5	96,0	14	38,0	47,5
6	35,0	82,0	15	46,5	49,0
7	40,0	44,0	16	50,0	58,0
8	45,0	31,0	17	30,0	42,0
9	62,5	87,0	18	35,0	60,0
			19	39,4	28,0

13.6 Exemplo Computacional

Consideremos as medidas de um índice de placa bacteriana obtidas de 26 crianças em idade pré-escolar, antes e depois do uso de uma escova experimental (Hugger). Veja o CD-Placa, no final do livro.

Como temos medidas feitas num mesmo indivíduo, as duas amostras são dependentes. Se quisermos testar se os índices médios de placa bacteriana antes e depois da escovação são iguais, teremos de usar a metodologia da seção anterior. Usando a notação dessa seção, teremos que testar

$$H_0 : \mu_1 = \mu_2$$
$$H_1 : \mu_1 > \mu_2,$$

ou, o que é equivalente,


$$H_0 : \mu_D = 0$$
$$H_1 : \mu_D > 0.$$

Na Tabela 13.12 temos os dados e as diferenças $d_i = x_i - y_i$, $i = 1, 2, \dots, 26$. Na Figura 13.6 temos os *box plots* dos dois conjuntos de dados, que sugerem distribuições bem diferentes.

Tabela 13.12: Índices de placa bacteriana.

Sujeito	Antes (x_i)	Depois (y_i)	$d_i = x_i - y_i$	Postos de $ d_i $
1	2,18	0,43	1,75	18
2	2,05	0,08	1,97	20
3	1,05	0,18	0,87	7
4	1,95	0,78	1,17	13
5	0,28	0,03	0,25	2
6	2,63	0,23	2,40	23,5
7	1,50	0,20	1,30	16
8	0,45	0,00	0,45	3
9	0,70	0,05	0,65	5
10	1,30	0,30	1,00	10
11	1,25	0,33	0,92	8
12	0,18	0,00	0,18	1
13	3,30	0,90	2,40	23,5
14	1,40	0,24	1,16	12
15	0,90	0,15	0,75	6
16	0,58	0,10	0,48	4
17	2,50	0,33	2,17	21
18	2,25	0,33	1,92	19
19	1,53	0,53	1,00	10
20	1,43	0,43	1,00	10
21	3,48	0,65	2,83	26
22	1,80	0,20	1,60	17
23	1,50	0,25	1,25	14,5
24	2,55	0,15	2,40	23,5
25	1,30	0,05	1,25	14,5
26	2,65	0,25	2,40	23,5
Total			35,52	351,0

Figura 13.6: *Box plot* para x_i (antes) e y_i (depois). SPPlus.



Temos que $\bar{d} = 1,366$ e $S_D^2 = 0,5631$, donde o desvio padrão $S_D = 0,75$.

A estatística do teste é

$$t = \frac{\sqrt{n}(\bar{d} - 0)}{S_D} = \frac{\sqrt{26}(1,366)}{0,75} = 9,2864.$$

Fixando-se $\alpha = 0,01$, o valor crítico da estatística t com 25 graus de liberdade é 2,485, que deve ser comparado com o valor obtido acima. Logo, rejeitamos H_0 , de modo que a nova escova é eficaz em remover a placa bacteriana.

O valor- p do teste é

$$\hat{\alpha} = P(t(25) > 9,2864) \approx 0,$$

o que confirma que a hipótese nula deve ser rejeitada. Um intervalo de confiança para μ_D é dado por $[1,063; 1,669]$. A saída do programa Minitab para efetuar esse teste está no Quadro 13.1. Uma breve explicação dos comandos segue abaixo:

- (a) O comando “Paired C1, C2” significa que estamos solicitando que seja feito um teste com observações pareadas, que estão nas colunas C1 e C2;
- (b) o comando “Test 0.0” significa que queremos um teste para igualdade de médias;
- (c) o comando “Alternative 1” significa que a hipótese alternativa é aquela estabelecida acima, isto é, $\mu_1 > \mu_2$;
- (d) o comando “Confidence 95.0” estabelece que o intervalo de confiança a ser construído tem coeficiente de confiança $\gamma = 0,95$;
- (e) finalmente, os comandos “GDotplot;” e “GBBoxplot.” pedem para fazer um gráfico de dispersão unidimensional e um *box plot*, respectivamente.

A saída do programa mostra:

- (a) as médias das duas amostras e a diferença das médias (“Mean”);
- (b) os desvios padrões das duas amostras e das diferenças (“StDev”); por exemplo, $S_D = 0,75$, como encontramos acima.
- (c) os erros padrões estimados dos estimadores (“SE Mean”); por exemplo, o erro padrão estimado de $\bar{X} - \bar{Y}$ é $S_D/\sqrt{n} = 0,147$; esse valor é usado para construir o intervalo de confiança para $\mu_1 - \mu_2$;
- (d) o intervalo de confiança com c.c. = 0,95 para $\mu_1 - \mu_2$, dado por $[1,063; 1,669]$;
- (e) o valor observado da estatística t (“T-value”), no caso $t = 9,29$, e o valor- p (“P-value”), que é zero nesse caso.

Além dessa saída, podemos pedir gráficos ilustrativos. Por exemplo, o *dotplot* com o intervalo de confiança da Figura 13.7. Neste, vemos destacado o valor estipulado por H_0 , que, no exemplo, é zero, e não pertence ao intervalo. Na Figura 13.8 temos o *box plot* das diferenças, com o mesmo intervalo de confiança e H_0 .

Quadro 13.1: Test t pareado. Minitab.

```
MTB > Paired c1 c2;
```

```
SUBC> Confidence 95.0;
```

```
SUBC> Test 0.0;
```

```
SUBC> Alternative 1;
```

```
SUBC> GDotplot;
```

```
SUBC> GBoxplot.
```

Paired T-Test and Confidence Interval

Paired T for C1 – C2

	N	Mean	StDev	SE Mean
C1	26	1.642	0.883	0.173
C2	26	0.276	0.232	0.046
Difference	26	1.366	0.750	0.147

95% CI for mean difference: (1.063, 1.669)

T-Test of mean difference = 0 (vs not = 0): T-Value = 9.29 P-Value = 0.000

Figura 13.7: Dotplot das diferenças d_i , com o intervalo de confiança para μ_D ; também mostrados $H_0: \mu_D = 0$ e $\bar{d} = 1,366$.





Figura 13.8: Box plot para as diferenças d_i , com o intervalo de confiança para μ_D ; também mostrados $H_0 : \mu_D = 0$ e $\bar{d} = 1,366$.



13.7 Problemas e Complementos

24. Uma empresa deseja estudar o efeito de uma pausa de dez minutos para um cafezinho sobre a produtividade de seus trabalhadores. Para isso, sorteou seis operários, e contou o número de peças produzidas durante uma semana sem intervalo e uma semana com intervalo. Os resultados sugerem se há ou não melhora na produtividade? Caso haja melhora, qual deve ser o acréscimo médio de produção para todos os trabalhadores da fábrica?

Operário	1	2	3	4	5	6
Sem Intervalo	23	35	29	33	43	32
Com Intervalo	28	38	29	37	42	30

25. Numa indústria deseja-se testar se a produtividade média dos operários do período diurno é igual à produtividade média dos operários do período noturno. Para isso, colheram-se duas amostras, uma de cada período, observando-se a produção de cada operário. Os resultados obtidos foram os seguintes:

	n	$\sum x_i$	$\sum x_i^2$
Diurno	15	180	2.660
Noturno	15	150	2.980

De acordo com esses resultados, quais seriam suas conclusões?

26. Num levantamento feito com os operários da indústria mecânica, chegou-se aos seguintes números: salário médio = 3,64 salários mínimos e desvio padrão = 0,85 salário mínimo. Suspeita-se que os salários da subclasse formada pelos torneiros mecânicos são diferentes dos salários do conjunto todo, tanto na média como na variância. Que

conclusões você obteria se uma amostra de 25 torneiros apresentasse salário médio igual a 4,22 salários mínimos e desvio padrão igual a 1,25 salário mínimo?

27. Os dados abaixo representam a porcentagem do orçamento gasto com pessoal para 50 pequenos municípios de uma certa região.

69,5	71,6	73,0	68,9	68,9	70,0
72,6	66,2	68,1	72,4	67,6	73,2
67,6	69,7	71,0	69,4	71,5	73,8
69,6	69,6	68,2	69,9	71,4	70,7
69,7	71,0	66,0	70,3	71,7	69,2
69,8	68,4	69,5	68,2	72,1	70,8
72,2	69,2	71,7	65,6	69,6	70,1
69,9	70,5	68,0	70,2	69,0	66,3
69,4	67,1				

- (a) Analise estatisticamente os dados.
- (b) Com base na sua análise, e sabendo que na região considerada existem, ao todo, 200 municípios, em quantos deles você acha que o gasto com pessoal é maior que 70% do orçamento?
- (c) Em outra região, sabe-se que o gasto médio com pessoal é de 65%, e o desvio padrão é de 20%. Qual das duas regiões é mais homogênea em relação a essa variável? Por quê?
28. Uma amostra de 100 trabalhadores de uma fábrica grande demora, em média, 12 minutos para completar uma tarefa, com um desvio padrão de dois minutos. Uma amostra de 50 trabalhadores de uma outra fábrica demora, em média, 11 minutos para completar a mesma tarefa, com desvio padrão igual a três minutos.
- (a) Construa um IC de 95% para a diferença entre as duas médias populacionais.
- (b) Deixe bem claro quais as suposições feitas para a solução apresentada.
29. Deseja-se testar se dois tipos de ensino profissional são igualmente eficazes. Para isso, sortearam-se duas amostras de operários; a cada uma, deu-se um dos tipos de treinamento e, no final, submeteram-se os dois grupos a um mesmo teste. Que tipo de conclusão você poderia tirar, baseando-se nos resultados abaixo?

Amostra	Nº de elementos	Média	Desvio padrão
Tipo I	12	75	5
Tipo II	10	74	10

30. Numa discussão sobre reajuste salarial, entre empresários e o sindicato dos empregados, chegou-se a um impasse. Os empresários dizem que o salário médio da categoria é 7,6 salários mínimos (SM), e os empregados dizem que é 6,5 SM. Para eliminar dúvidas, cada um dos grupos resolveu colher uma amostra independente. Os empresários, com uma amostra de 90 operários, observaram um salário médio de 7,0 SM, com um desvio padrão igual a 2,9 SM. Já a amostra do sindicato, com 60 operários, apresentou média igual a 7,10 SM e desvio padrão de 2,4 SM.
- (a) As amostras colhidas servem para justificar as respectivas afirmações dos dois grupos?
- (b) De posse dos dois resultados, qual é o seu parecer?

31. A Torrefação Guarany está querendo comprar uma nova ensacadora de café. Após consultar o mercado, ficou indecisa entre comprar a de marca A ou a de marca B. Quanto ao custo, facilidade de pagamento, tamanho etc. elas são equivalentes. O fator que decidirá a compra será a precisão em encher os pacotes (medido pela variância). Deseja-se, na realidade, testar hipótese $\sigma_A^2 = \sigma_B^2$, através da estatística $F = S_A^2/S_B^2$. Podem-se construir regiões críticas bilaterais, unilaterais à direita ou à esquerda, dependendo do objetivo. Indique qual seria a região crítica mais favorável às seguintes pessoas: (Justifique.)
- proprietário da torrefação;
 - fabricante de A; e
 - fabricante de B.

32. Um médico deseja saber se uma certa droga reduz a pressão arterial média. Para isso, mediu a pressão arterial em cinco voluntários, antes e depois da ingestão da droga, obtendo os dados do quadro abaixo. Você acha que existe evidência estatística de que a droga realmente reduz a pressão arterial média? Que suposições você fez para resolver o problema?

Voluntário	A	B	C	D	E
Antes	68	80	90	72	80
Depois	60	71	88	74	76

33. Uma amostra de 100 lâmpadas elétricas produzidas pela fábrica A indica uma vida média de 1.190 horas, com desvio padrão de 90 horas. Uma amostra de 75 lâmpadas produzidas pela fábrica B indica uma vida média de 1.230 horas, com desvio padrão de 120 horas. Admitindo que as variâncias populacionais sejam diferentes, você acha que existe diferença entre as vidas médias populacionais das lâmpadas produzidas pelas fábricas A e B?
34. Queremos comparar dois métodos de ensino A e B. Dispomos de 40 crianças. Podemos proceder de duas maneiras:
- Sorteamos 20 crianças para compor uma classe, e as restantes formam outra classe. Aplicamos um método a cada classe e, depois, fazemos uma avaliação para todas as crianças a respeito do assunto ensinado.
 - Aplicamos inicialmente um teste de inteligência às 40 crianças. Numeramos as crianças de 1 a 40, segundo o resultado do teste. Consideramos os 20 pares (1, 2), (3, 4), ..., (39, 40), e de cada par sorteamos uma criança para cada classe.

Obtemos, assim, duas classes de 20 crianças, homogêneas quanto à inteligência. Aplicamos um método a cada classe e depois avaliamos todas as crianças.

- Qual a variável de observação em cada procedimento?
 - Quais as hipóteses estatísticas adequadas?
 - Qual o teste estatístico de decisão em cada caso?
 - Qual dos dois procedimentos você preferiria? Por quê?
35. De 400 moradores sorteados de uma grande cidade industrial, 300 são favoráveis a um projeto governamental, e de uma amostra de 160 moradores de uma cidade cuja principal atividade é o turismo, 120 são contra.
- Você diria que a diferença de opiniões nas duas cidades é estatisticamente significativa?

- (b) Qual seria um IC de 90% para a proporção de favoráveis ao projeto nas duas cidades? (Suponha que o número de pessoas nas duas cidades seja aproximadamente igual.)
36. Para verificar o grau de adesão de uma nova cola para vidros, preparam-se dois tipos de montagem: cruzado (A), onde a cola é posta em forma de X, e quadrado (B), onde a cola é posta apenas nas quatro bordas. Os resultados da resistência para duas amostras de 10 cada estão abaixo. Que tipo de conclusão poderia ser tirada?

Método A	16	14	19	18	19	20	15	18	17	18
Método B	13	19	14	17	21	24	10	14	13	15

37. Em um estudo para comparar os efeitos de duas dietas, A e B, sobre o crescimento, 6 ratos foram submetidos à dieta A, e 9 ratos à dieta B. Após 5 semanas, os ganhos em peso foram:

A	15	18	12	11	14	15			
B	11	11	12	16	12	13	8	10	13

- (a) Admitindo que temos duas amostras independentes de populações normais, teste a hipótese de que não há diferença entre as duas dietas, contra a alternativa que a dieta A é mais eficaz, usando o teste t de Student, no nível de $\alpha = 0,01$. Calcule $\hat{\alpha}$.
- (b) Efetue o teste usando a estatística de Wilcoxon, com $\alpha = 0,01$. Calcule $\hat{\alpha}$.
38. As amostras $(X_1, \dots, X_{10})$ e $(Y_1, \dots, Y_{10})$ de duas populações normais com médias μ_1 e μ_2 e mesma variância σ^2 forneceram as estatísticas:

$$\bar{X} = 80, S_1^2 = 16; \quad \bar{Y} = 83, S_2^2 = 18.$$

Teste, com o nível $\alpha = 0,05$, a hipótese $H_0: \mu_1 = \mu_2$ contra a alternativa $H_1: \mu_1 < \mu_2$.

39. Em um estudo sobre um novo método para ensinar Matemática a alunos do primeiro grau, dez crianças foram selecionadas ao acaso de um grupo de 20 e ensinadas pelo novo método, enquanto as outras dez serviram como controle e ensinadas pelo método tradicional. Após dez semanas o desempenho dos alunos em um teste foi avaliado e obtiveram-se as seguintes notas:

Novo método	8,5	7,5	9,0	9,5	10,0	7,0	6,5	8,0	8,5	7,0
Controle	7,5	10,0	6,5	5,0	8,0	7,5	4,5	9,5	6,5	7,5

Teste, com nível $\alpha = 0,05$, a hipótese de que o novo método é mais eficaz, utilizando o teste t e o teste Wilcoxon. Obtenha $\hat{\alpha}$ em cada caso.

40. Seja $W_R = R_1 + \dots + R_n$ a soma dos postos dos controles. Qual o valor de $W_R + W_S$?
41. Se $n = 4$ e $m = 6$, prove que $P(W_S \geq 35) = P(W_S \leq 31)$, usando o fato que W_S é simétrica em torno de $m(N+1)/2$.
42. Se $n = 4$ e $m = 6$, prove que $P(W_S \geq 35) = P(W_R \leq 20)$.
43. Para o CD-Placa, teste se a escova convencional é eficaz para remover a placa bacteriana. Calcule o valor- p do teste.

44. Para o CD-Temperaturas, teste se a temperatura média de Cananéia é igual à temperatura média de Ubatuba (suponha que as observações para cada cidade sejam independentes, embora saibamos que elas não são, pois temos dados de séries temporais).
45. Numa pesquisa sobre a opinião dos moradores de duas cidades, *A* e *B*, com relação a um determinado projeto, obteve-se:

Cidade	<i>A</i>	<i>B</i>
Nº de entrevistados	400	600
Nº de favoráveis	180	350

Construa um IC para a diferença de proporções de opiniões nas duas cidades.

46. Duas máquinas *A* e *B*, são usadas para empacotar pó de café. A experiência passada garante que o desvio padrão para ambas é de 10 g. Porém, suspeita-se que elas têm médias diferentes. Para verificar, sortearam-se duas amostras: uma com 25 pacotes da máquina *A* e outra com 16 pacotes da máquina *B*. As médias foram, respectivamente, $\bar{x}_A = 502,74$ g e $\bar{x}_B = 496,60$ g. Com esses números, e com o nível de 5%, qual seria a conclusão do teste $H_0: \mu_A = \mu_B$?
47. Na região sul da cidade, 60 entre 400 pessoas preferem a bebida Meca-Mela entre as demais similares. Na região norte, a proporção é de 40 entre 225 entrevistados. Baseado no resultado dessa amostra, você diria que a proporção de todos os moradores nas duas regiões é a mesma? Use $\alpha = 0,05$.
48. Uma pesquisa mercadológica sobre fidedignidade a um produto foi realizada em dois anos consecutivos, com duas amostras independentes de 400 donas de casa em cada uma delas. A preferência pela marca em questão foi de 33% e 29%, respectivamente. Os resultados trazem alguma evidência de mudança de preferência?

Análise de Aderência e Associação

14.1 Introdução

No Capítulo 4 estudamos como analisar descritivamente dois conjuntos de dados provenientes de duas variáveis aleatórias, resumidas na forma de tabelas de dupla entrada. Essas variáveis podem ser qualitativas ou quantitativas, e a idéia era que podíamos classificar os elementos da amostra de cada variável em categorias, ou classes ou ainda atributos. Na Tabela 4.11 temos a situação geral, em que duas v.a. qualitativas X e Y foram classificadas em r categorias para X e s categorias para Y . Usaremos a notação dada naquele capítulo (ver seção 4.4). Lá, estávamos interessados em analisar a possível associação entre X e Y , e, para isso, propusemos o uso da estatística qui-quadrado de Pearson, dada por (4.4), e que repetimos aqui:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}, \quad (14.1)$$

onde n_{ij}^* denota o valor esperado sob a hipótese de que as duas v.a. não são associadas. Naquele capítulo apenas notamos que essa estatística deveria ser “pequena”, se a hipótese H_0 de não-associação fosse verdadeira, e “grande”, caso contrário. Lá também estudamos como medir, por meio do coeficiente de correlação, a associação entre duas variáveis quantitativas. Neste capítulo vamos precisar esses conceitos. Além do teste mencionado no Capítulo 4, iremos estudar outros testes que utilizam muito a estatística (14.1), bem como outras distribuições já estudadas. Faremos, agora, uma breve resenha sobre esses testes.

1. Testes de Aderência

Temos uma população P e queremos verificar se ela segue uma distribuição especificada P_0 , isto é, queremos testar a hipótese $H_0 : P = P_0$. No Capítulo 12 vimos também como testar essa hipótese, empregando testes sobre os parâmetros média e variância.

Aqui, o teste comparará o número de casos ocorridos em caselas especificadas, com o número esperado de casos nelas, quando a hipótese H_0 for verdadeira.

O procedimento consiste em considerar classes, segundo as quais a variável X , característica da população, pode ser classificada. A variável X pode ser qualitativa ou quantitativa. Neste capítulo estudaremos um teste no qual as probabilidades da v.a. X pertencer a cada uma das classes são especificadas. A estatística usada será (14.1).

Exemplo 14.1. Um dado é lançado 300 vezes, com os resultados dados na Tabela 14.1. Por enquanto, considere somente a linha correspondente às frequências observadas. Com os resultados observados, queremos saber se o dado é “honesto”, isto é, se a probabilidade de ocorrência de qualquer face é $1/6$. Ou seja, queremos testar a hipótese

$$H_0 : p_1 = p_2 = \dots = p_6 = 1/6,$$

onde $p_i = P$ (face i), $i = 1, 2, \dots, 6$. Isso equivale a dizer que P_0 segue uma distribuição uniforme discreta.

Tabela 14.1: Resultados do lançamento de um dado 300 vezes.

Ocorrência (i)	1	2	3	4	5	6	Total
Freq. Observada (n_i)	43	49	56	45	66	41	300
Freq. Esperada (n_i^*)	50	50	50	50	50	50	300

2. Testes de Homogeneidade

Considere o seguinte exemplo.

Exemplo 14.2. Uma prova básica de Estatística foi aplicada a 100 alunos de Ciências Humanas e a 100 alunos de Ciências Biológicas. As notas são classificadas segundo os graus A, B, C, D e E (onde D significa que o aluno não recebe créditos e E indica que o aluno foi reprovado). Os resultados estão na Tabela 14.2.

Tabela 14.2: Resultados da aplicação de uma prova de Estatística a 100 alunos de Ciências Humanas e 100 alunos de Biologia.

Aluno de	Grau					Total
	A	B	C	D	E	
C. Humanas	15	20	30	20	15	100
C. Biológicas	8	23	18	34	17	100
Total	23	43	48	54	32	200

Queremos testar se as distribuições das notas, para as diversas classes, são as mesmas para os dois grupos de alunos. Esse teste pode ser estendido para o caso de três ou mais populações.

Testes desse tipo já foram vistos no Capítulo 13, onde queríamos testar a hipótese (13.1). Estudamos lá dois testes, o t de Student e o de Wilcoxon. Para esses testes, supomos ou que as populações sejam normais ou, então, preferencialmente, que tenham distribuições contínuas (não necessariamente normais). Mas, de qualquer modo, testávamos separadamente se as duas populações diferiam em localização ou escala. No caso presente iremos apresentar um teste baseado na estatística (14.1), que contempla alternativas gerais; por exemplo, as populações podem diferir-se em localização e escala.

Novamente, para efetuar o teste, consideramos amostras das duas populações, P_1 e P_2 , e classificamos os seus elementos de acordo com certo número de categorias para as duas variáveis características de P_1 e P_2 .

3. Testes de Independência

Vimos, no Capítulo 4, a importância de quantificar o grau de associação entre duas variáveis, usando a estatística (14.1). Porém, essa quantificação só tem sentido se as variáveis não forem independentes. O teste que apresentaremos aqui supõe a existência de duas v.a.'s X e Y , e os valores de amostras delas são classificados segundo categorias, obtendo-se uma tabela de dupla entrada. Queremos testar a hipótese que X e Y são independentes.

Exemplo 14.3. Uma companhia de seguros analisou a frequência com que 2.000 segurados (1.000 homens e 1.000 mulheres) usaram hospitais. Os resultados estão na Tabela 14.3. A hipótese a testar é que o uso de hospital independe do sexo do segurado (veja o Problema 6 do Capítulo 4).

Tabela 14.3: Frequências com que 2.000 segurados usaram hospital.

	Homens	Mulheres
Usaram hospital	100	150
Não usaram hospital	900	850

4. Teste para o Coeficiente de Correlação

Quando se investiga associação entre duas variáveis quantitativas, o artifício de agrupar os dados em intervalos (classes) reduz a variável quantitativa a um caso particular de variável qualitativa, assim, poderíamos usar as mesmas técnicas da análise desse último tipo de variável. Mas esse procedimento pode não ser o melhor possível, e o uso do coeficiente de correlação como medida de associação entre variáveis quantitativas é o caminho mais apropriado. Na seção 14.5 voltaremos a tratar desse tema agora sob o ponto de vista da inferência.

Para finalizar esta seção, notamos que os testes descritos nos itens (1)-(3) são todos baseados na distribuição qui-quadrado e são parte dos chamados *testes não-paramétricos*. Para essa classe de testes não se supõe que a população (ou populações) siga algum modelo particular, como fizemos para alguns dos testes dos Capítulos 12 e 13. Na seção 14.6

introduzimos, por meio de um exemplo, um outro tipo de teste não-paramétrico de aderência, baseado na comparação da distribuição empírica dos dados com a distribuição hipotetizada para a população.

14.2 Testes de Aderência

Retomemos o Exemplo 14.1.

Exemplo 14.1. (continuação) Para o uso da fórmula (14.1) necessitamos conhecer os valores esperados do lançamento do dado, sob a hipótese de ele ser “honesto”, ou seja, sob a hipótese H_0 formulada anteriormente. Observamos da Tabela 14.1 que o dado foi lançado 300 vezes. Então, se H_0 for verdadeira, esperaremos 50 casos em cada casela, como mostrado na tabela. Na fórmula (14.1) e na tabela denotamos as frequências observadas por n_i e as esperadas por n_i^* . Usando a fórmula podemos calcular o qui-quadrado observado,

$$\chi_{\text{obs}}^2 = \frac{(43 - 50)^2}{50} + \dots + \frac{(41 - 50)^2}{50} = \frac{376}{50} = 8,56.$$

Como veremos a seguir, essa estatística, sob H_0 , segue uma distribuição qui-quadrado, com o número de graus de liberdade apropriado. Imagine que queiramos simular uma amostra de 300 lançamentos de um dado. O problema seria o de preencher as seis caselas correspondentes às frequências n_i , na Tabela 14.1, com a restrição de a soma ser 300. É fácil ver que só podemos preencher “livremente” cinco das caselas, uma delas (qualquer) resultará como a diferença entre 300 e a soma dessas cinco. Temos, então, cinco “graus de liberdade” para preencher as caselas.

Consultando a Tabela IV, com $\alpha = 0,05$ e 5 graus de liberdade, encontramos o valor crítico $\chi_c^2 = 11,070$, que é maior do que $\chi_{\text{obs}}^2 = 8,56$, logo, não rejeitamos H_0 . Ou seja, há evidências de que o dado seja honesto.

O problema aqui pode ser caracterizado da seguinte maneira. Temos uma amostra $X_1, \dots, X_n$ da v.a. X que caracteriza a população P e queremos testar a hipótese

$$H_0 : P = P_0 \quad (14.2)$$

onde P_0 tem uma distribuição de probabilidades especificada. Muitas vezes, como é o caso de variáveis qualitativas e variáveis discretas, a variável X de interesse da população é categorizada em classes $A_1, A_2, \dots, A_s$ e temos as probabilidades $p_i = P(X \in A_i)$, $i = 1, 2, \dots, s$. Então, a hipótese H_0 pode ser formulada de modo equivalente como

$$H_0 : p_1 = p_{10}, p_2 = p_{20}, \dots, p_s = p_{s0},$$

onde p_{i0} são os valores especificados pela hipótese nula, ou seja, são as probabilidades conhecidas que determinam P_0 .

No caso de uma v.a. discreta X , assumindo os valores $i = 0, 1, 2, \dots$, temos que $p_i = P(X = i)$, $i \geq 0$; X pode ser uma v.a. binomial, ou Poisson ou ainda

geométrica, por exemplo. Poderemos querer testar se a amostra observada vem de uma dessas distribuições.

Se X for uma v.a. contínua, poderemos dividir o seu domínio de variação em intervalos (de mesma amplitude, por exemplo) e construir a distribuição de frequências correspondente, como fizemos no Capítulo 2. Por exemplo, poderemos querer testar se nossa amostra foi escolhida de uma população com distribuição normal (média e variância especificadas).

Em todas as situações obtemos uma tabela de contingência $1 \times s$, como aquela formada pela primeira linha (frequências observadas) da Tabela 14.4.

Tabela 14.4: Frequências observadas e esperadas numa tabela $1 \times s$.

Categoria	A_1	A_2	...	A_s	Total
Freq. Observadas	O_1	O_2	...	O_s	n
Freq. Esperadas	E_1	E_2	...	E_s	n

Incidentalmente, o modelo probabilístico apropriado para essa situação é o *modelo multinomial*. Veja o Problema 27.

Vamos escrever a estatística (14.1) na forma

$$\chi^2 = \sum_{i=1}^s \frac{(O_i - E_i)^2}{E_i}, \quad (14.3)$$

onde O_i representa o valor efetivamente observado para a classe A_i , e E_i representa o valor esperado, sob a hipótese H_0 , para a classe A_i . Como temos n observações, os valores esperados sob H_0 são dados por

$$E_i = np_{i0}, \quad i = 1, 2, \dots, s. \quad (14.4)$$

Se a hipótese H_0 for verdadeira, pode-se demonstrar que χ^2 tem uma distribuição qui-quadrado com $(s - 1)$ graus de liberdade.

A hipótese alternativa a H_0 é que pelo menos uma das igualdades não valha, ou seja,

$$H_1 : p_j \neq p_{j0}, \text{ para pelo menos um } j. \quad (14.5)$$

Rejeitaremos H_0 se o valor da estatística (14.3) for grande, no sentido que podemos encontrar um valor c da Tabela IV, tal que $P(\chi^2(s - 1) > c) = \alpha$, para o nível de significância α fixado. Temos, pois, um teste unilateral à direita.

Exemplo 14.4. Um estudo sobre acidentes de trabalho numa indústria revelou que, em 150 acidentes, obtemos a distribuição da Tabela 14.5.

Tabela 14.5: Acidentes de trabalho numa indústria nos dias da semana.

Dia	Seg.	Terça	Quarta	Quinta	Sexta	Total
O_i	32	40	20	25	33	150
E_i	30	30	30	30	30	150
$(O_i - E_i)^2/E_i$	0,1333	3,333	3,333	0,833	0,300	7,932

O objetivo é testar a hipótese que os acidentes ocorrem com igual frequência nos cinco dias da semana. Ou seja, queremos testar

$$\begin{aligned} H_0 : p_1 = p_2 = \dots = p_5 = 1/5, \\ H_1 : p_j \neq 1/5, \text{ para pelo menos um } j. \end{aligned}$$

Sob a hipótese nula, os valores esperados estão na Tabela 14.5. Por exemplo, $E_1 = 150 \times 1/5 = 30$ etc. Obtemos

$$\chi^2_{\text{obs}} = \frac{(32 - 30)^2}{30} + \dots + \frac{(33 - 30)^2}{30} = 7,932.$$

Fixando-se $\alpha = 0,05$, temos que o valor crítico de uma distribuição $\chi^2(4)$ é 9,488, portanto não rejeitamos H_0 . O valor- p do teste é

$$\hat{\alpha} = P(\chi^2(4) > 7,932) \approx 0,09552,$$

o que nos diz a mesma coisa.

Exemplo 14.5. Retomemos o Exemplo 6.17, no qual consideramos o ajuste de uma distribuição de Poisson à desintegração de substâncias radioativas. Na Tabela 6.13 tínhamos as informações necessárias para calcular (14.3), sendo que $n_k = 0_k$ e $np_k = E_k$, $k = 1, 2, \dots, 11$. Temos, então, que $s = 11$ e $v = s - 1 = 10$ graus de liberdade. O valor observado de (14.3) é $\chi^2 = 12,875$, e não rejeitamos H_0 , no nível de significância $\alpha = 0,05$, pois o valor crítico obtido da Tabela IV é 18,307. Verifique que o valor- p aqui é $\hat{\alpha} > 0,23$.

Finalmente, vejamos um exemplo para testar se um conjunto de dados vem de uma população normal especificada.

Exemplo 14.6. Considere os dados abaixo, que supostamente são uma amostra de tamanho $n = 30$ de uma distribuição normal, de média $\mu = 10$ e variância $\sigma^2 = 25$. Os dados já estão ordenados.

1,04	1,73	3,93	4,44	6,37	6,51
7,61	7,64	8,18	8,48	8,57	8,65
9,71	9,87	9,95	10,01	10,52	10,69
11,72	12,17	12,61	12,98	13,03	13,16
14,11	14,60	14,64	14,75	16,68	22,14

Vamos classificar esses dados em quatro intervalos, delimitados pelos quartis teóricos $Q(0,25)$, $Q(0,5)$ e $Q(0,75)$ da $N(10,25)$. Chamando de $Z(p)$ os quantis da $N(0,1)$, temos

$$Q(0,25) = 10 + 5Z(0,25) = 10 + 5(-0,6745) = 6,6275,$$

$$Q(0,5) = 10 + 5Z(0,5) = 10 + 5(0) = 10,$$

$$Q(0,75) = 10 + 5Z(0,75) = 10 + 5(0,6745) = 13,3725.$$

A hipótese nula a ser testada é

$$H_0 : P = N(10,25).$$

Tabela 14.6: Valores observados e esperados para dados, sob suposição de normalidade.

Classes	A_1 $(-\infty; 6,6275]$	A_2 $(6,6275; 10]$	A_3 $(10; 13,3725]$	A_4 $(13,3725; +\infty)$	Total
O_i	4	11	9	6	30
E_i	7,5	7,5	7,5	7,5	30


Na Tabela 14.6 temos os valores observados em cada intervalo e os valores esperados, sob H_0 , ou seja, cada intervalo deve conter um quarto das observações, ou, ainda, as probabilidades das classes são dadas por

$$p_1 = P(X < 6,6275) = 0,25,$$

$$p_2 = P(6,6275 < X < 10) = 0,25 \text{ etc.}$$

O valor da estatística (14.3) é $\chi^2 = 3,87$, que deve ser comparado com o valor crítico de uma $\chi^2(3)$, para dado nível de significância. Se $\alpha = 0,05$, esse valor é 7,815, que nos leva a aceitar H_0 , ou seja, podemos considerar que temos uma amostra de uma normal com média 10 e variância 25. O valor- p do teste é maior do que 0,25. Verifique. Um gráfico dos quantis dos dados contra os quantis de uma normal está na Figura 14.4. Os pontos deveriam estar todos próximos de uma reta. Isso acontece para a maioria dos pontos, mas há pontos distantes da reta e, em particular, um ponto atípico no canto superior direito (o valor 22,14). Um histograma e um *box plot* dos dados estão mostrados na Figura 14.1.

Figura 14.1: Histograma e *box plot* para os dados do Exemplo 14.6. SPlus.



Problemas

- 1. Calcule o valor-p para o Exemplo 14.1.
- 2. Calcule os valores-p para os Exemplos 14.5 e 14.6.
- 3. Um modelo genético especifica que animais de certa população devam estar classificados em quatro categorias, com probabilidades $p_1 = 0,656$, $p_2 = 0,093$, $p_3 = 0,093$, $p_4 = 0,158$. Dentre 197 animais, obtivemos as seguintes frequências observadas: $O_1 = 125$, $O_2 = 18$, $O_3 = 20$, $O_4 = 34$. Teste se esses dados estão de acordo com o modelo genético postulado.
- 4. Teste se os dados abaixo são observações de uma distribuição normal com média 30 e desvio padrão 10.

15,9	16,9	18,3	18,5	19,0
19,5	21,8	23,0	23,8	24,5
26,1	26,9	32,3	35,0	36,1
36,5	37,2	38,5	40,9	44,2

- 5. Um dado foi lançado 1.000 vezes, com os seguintes resultados:

Ocorrência	1	2	3	4	5	6
Frequência	158	186	179	161	141	175

Teste a hipótese que o dado é balanceado.

14.3 Testes de Homogeneidade

Vimos no capítulo anterior como testar a hipótese (13.1) de que as duas populações P_1 e P_2 tinham a mesma distribuição. Os testes utilizados foram baseados na distribuição t de Student, que assume normalidade das populações, ou o teste não-paramétrico de Wilcoxon (Mann-Whitney), que não faz essa suposição, mas fica bem mais fácil se as distribuições forem contínuas.

O teste que apresentaremos agora pode ser usado para dados discretos ou contínuos e serve para testar H_0 dada por (13.1) contra alternativas gerais, e não somente para testar diferenças de localização.

Exemplo 14.2 (continuação) Considerando P_1 como a população de alunos de Ciências Humanas e P_2 a dos alunos de Ciências Biológicas, nosso objetivo é testar a hipótese

$$H_0 : P_1 = P_2,$$

usando os resultados amostrais da Tabela 14.2. Para isso, precisamos encontrar os valores esperados n_{ij}^* , para aplicar a fórmula (14.1).

Inicialmente, observemos que se H_0 for verdadeira, a distribuição de probabilidades nas duas linhas deveria ser a mesma, e equivaleria a ter uma única população P . A última linha (de totais) da Tabela 14.2 representaria uma amostra de 200 alunos dessa única

população. A Tabela 14.7 apresenta as estimativas das proporções, em cada grau, para P_1 , P_2 e P . Sendo H_0 verdadeira, deveríamos esperar para P_1 e P_2 as mesmas proporções observadas para P , ou valores aproximadamente iguais. Ou, ainda, todas as linhas dessa tabela deveriam ser iguais entre si, e iguais à linha de totais, o que aparentemente não ocorre. A partir dessas porcentagens podemos obter as frequências absolutas correspondentes (ou valores esperados) se H_0 for verdadeira. Obtemos, então, a Tabela 14.8.

Tabela 14.7: Porcentagens estimadas das classes para cada população.

Aluno de	Grau					Total
	A	B	C	D	E	
C. Humanas	15	20	30	20	15	100
C. Biológicas	8	23	18	34	17	100
Total	11,5	21,5	24	27	16	100

Tabela 14.8: Frequências absolutas sob H_0 (n_{ij}^*).

Aluno de	Grau					Total
	A	B	C	D	E	
C. Humanas	11,5	21,5	24	27	16	100
C. Biológicas	11,5	21,5	24	27	16	100
Total	23	43	48	54	32	200

Desse modo, encontramos os valores esperados n_{ij}^* , que podem ser substituídos em (14.1), obtendo-se

$$\chi^2_{\text{obs}} = \frac{(15 - 11,5)^2}{11,5} + \dots + \frac{(15 - 16)^2}{16} + \frac{(8 - 11,5)^2}{11,5} + \dots + \frac{(17 - 16)^2}{16} = 9,09.$$

Novamente, para consultar a tabela precisamos determinar os graus de liberdade, e vamos usar o mesmo argumento anterior. Quantas caselas poderíamos preencher livremente em uma simulação, sendo que os totais marginais são conhecidos? Observando a Tabela 14.9, concluímos que basta preencher apenas quatro caselas, as seis restantes são encontradas por diferenças. Como exemplo, preenchamos quatro caselas com círculos; as demais (sinais de “mais”) podem ser obtidas por diferenças a partir dos totais de linhas ou colunas.

Tabela 14.9: Determinação do número de graus de liberdade.

Aluno de	Grau					Total
	A	B	C	D	E	
C. Humanas	o	+	o	+	+	100
C. Biológicas	+	o	+	o	+	100
Total	23	43	48	54	32	200

Da Tabela IV, com $\alpha = 0,05$ e 4 graus de liberdade encontramos $\chi^2_c = 9,488$, o que leva à não-rejeição de H_0 , ou seja, a distribuição das notas é a mesma para as duas populações.

Observe que os valores esperados na Tabela 14.8 podem ser obtidos de $n_{ij}^* = (n_{i.} n_{.j})/n$.

Exemplo 14.7. Consideremos, novamente, o Exemplo 13.9 e verifiquemos quantos elementos de cada amostra caem nas seguintes classes de resistência à remoção: (0,4; 1,0], (1,0; 1,6], (1,6; 2,2], (2,2; 2,8]. Obtemos a Tabela 14.10, com os valores esperados entre parênteses.

Tabela 14.10: Valores observados para amostras do Exemplo 13.12.

Populações	(0,4; 1,0]	(1,0; 1,6]	(1,6; 2,2]	(2,2; 2,8]	Total
$P_1(T)$	29(33)	60(52)	9(11)	2(4)	100
$P_2(C)$	37(33)	44(52)	13(11)	6(4)	100
Total	66	104	22	8	200

Utilizando (14.1) obtemos $\chi^2_{\text{obs}} = 6,1585$. Como temos $s = 4$, rejeitaremos H_0 , se $6,1585 > c$, onde c é o valor de uma v.a. com distribuição $\chi^2(3)$, tal que $P(\chi^2(3) > c) = \alpha$. Com $\alpha = 0,05$, obtemos $c = 7,815$ da Tabela IV, logo não rejeitamos H_0 no nível α .

Esse teste pode ser estendido para o caso de termos r populações $P_1, \dots, P_r$ e queremos testar a hipótese

$$H_0 : P_1 = P_2 = \dots = P_r \quad (14.6)$$

contra a alternativa em que pelo menos duas são distintas. Obteremos uma tabela de dupla entrada $r \times s$. Designando-se os tamanhos das amostras dessas populações por $n_1, \dots, n_r$, com $n_1 + \dots + n_r = N$, e por n_{ij} o número de elementos da amostra de P_i classificados na categoria j , teremos a situação da Tabela 4.11. A hipótese a ser testada aqui é

$$H_0 : p_{11} = p_{21} = \dots = p_{r1} \\ \dots \\ p_{1s} = p_{2s} = \dots = p_{rs}$$

Nesse caso, a estatística (14.1) tem distribuição $\chi^2(v)$, onde o número de graus de liberdade v é dado por $v = (r - 1)(s - 1)$. O argumento para obter esse número é o mesmo usado para o Exemplo 14.2.

Problemas

- Suponha que tenhamos razões para crer que as notas obtidas por estudantes de escolas públicas sejam menores que as notas obtidas por estudantes de escolas particulares, ao tomarem o exame vestibular para uma Universidade. Para testar essa hipótese, foram selecionadas duas amostras de estudantes que prestaram o vestibular, suas médias gerais foram anotadas e obteve-se a tabela a seguir.

Escola	(0; 2,5]	(2,5; 5,0]	(5,0; 7,5]	(7,5; 10,0]	Total
Pública	15	22	18	3	58
Particular	6	10	20	6	42
Total	21	32	38	9	100

Teste a hipótese que as duas populações são homogêneas, para o nível de significância $\alpha = 0,01$. Obtenha o valor- p $\hat{\alpha}$.

7. Cem estudantes foram divididos em duas classes de 50 cada e o objetivo era testar um novo método de ensinar Probabilidades. Uma classe recebeu um método tradicional e a outra, o novo método. Após o curso, foi pedido que os estudantes resolvessem um problema típico de Probabilidades. Os resultados foram os seguintes:

	Exercício correto	Exercício errado
Método convencional	33	17
Método novo	37	13

Há razões para acreditar que o novo método é superior?

8. Duas novas drogas vão ser testadas em 160 pessoas portadoras de rinite alérgica. Metade das pessoas recebe a droga A e a outra metade recebe a droga B. Obtém-se a tabela abaixo. Teste a hipótese de que as duas drogas são igualmente eficazes para tratar a doença.

	Eficaz	Não Eficaz
Droga A	55	25
Droga B	48	32

9. Um produto novo é lançado por uma empresa, e, para verificar a sua aceitação, dois grupos de pessoas de duas cidades são consultados. De 100 pessoas da cidade A, 32 gostaram do produto e, de 50 pessoas da cidade B, 12 gostaram do produto. Há evidências que o produto seja igualmente aceito nas duas cidades?

14.4 Testes de Independência

Retomemos o Exemplo 4.3, para efeito de ilustração.

Exemplo 14.8. Naquele exemplo, o que se queria era verificar se a criação de determinado tipo de cooperativa estava associada ao fator regional. Os dados das Tabelas 4.8 e 4.9 estão reproduzidas na Tabela 14.11.

Como temos três linhas e quatro colunas, o número de graus de liberdade da estatística é $\nu = (3 - 1)(4 - 1) = 6$. Fixando-se $\alpha = 0,05$, devemos procurar um valor c , tal que $P(\chi^2(6) > c) = 0,05$, e da Tabela IV obtemos $c = 12,592$. Portanto a região crítica do teste é $RC = [12,592; +\infty[$.

Vimos na seção 4.3 como construir os valores esperados, sob a hipótese de independência (ver Tabela 4.9), que estão entre parênteses na Tabela 14.11. O valor observado da estatística qui-quadrado encontrado foi $\chi^2_{\text{obs}} = 171,76$. Como esse valor pertence à região crítica, rejeitamos H_0 , ou seja, há uma forte dependência entre os fatores “tipo de cooperativa” e “região de localização”.

O nível descritivo do teste é $\hat{\alpha} = P(\chi^2(6) > 171,76 | H_0 \text{ é verdadeira}) < 0,1\%$, ou seja, temos uma forte indicação que H_0 deve ser rejeitada.

A formalização dos testes de independência passa a ser como segue. Chamemos de p_{ij} a probabilidade de um indivíduo ser classificado nas categorias i , $i = 1, \dots, r$ e j , $j = 1, \dots, s$, simultaneamente; denotemos por $p_{i.}$ e $p_{.j}$ as probabilidades marginais. A hipótese de independência pode ser escrita na forma

$$\begin{aligned} H_0 : p_{ij} &= p_{i.} p_{.j}, \text{ para todo par } (i, j), \\ H_1 : p_{ij} &\neq p_{i.} p_{.j}, \text{ para algum par } (i, j). \end{aligned}$$

Lembremos que $p_{i.} = \sum_{j=1}^s p_{ij}$ e $p_{.j} = \sum_{i=1}^r p_{ij}$.

Tabela 14.11: Valores observados e esperados para o Exemplo 14.9.

Estado	Consumidor	Produtor	Escola	Outras	Total
São Paulo	214(157)	237(269)	78(143)	119(79)	648
Paraná	51(73)	102(124)	126(67)	22(37)	301
Rio G. Sul	111(146)	304(250)	139(133)	48(73)	602
Total	376	643	343	189	1.551

A estatística a usar é novamente (14.1), que terá, sob a hipótese H_0 , uma distribuição qui-quadrado com $v = (r - 1)(s - 1)$ graus de liberdade. Rejeitaremos H_0 se o valor observado da estatística for maior do que um valor crítico, dado pela Tabela IV, fixado um valor do nível de significância α .

Dado que a distribuição de qui-quadrado, nesse caso, é uma distribuição aproximada, precisamos tomar certos cuidados na sua aplicação. Um deles é garantir que todos os valores esperados das caselas não sejam inferiores a cinco.

Problemas

- 10. Para o Problema 16 do Capítulo 4, teste formalmente se a opinião dos habitantes depende do local da residência.
- 11. Teste se o uso de hospital independe do sexo para o Exemplo 14.3.
- 12. Para o Problema 22 do Capítulo 4, teste se existe dependência entre os fatores: tendência dos alunos a prosseguir os estudos e classe social dos entrevistados.
- 13. Investigando a “fidelidade” de consumidores de um produto, obteve-se uma amostra de 200 homens e 200 mulheres. Foram classificados como tendo alto grau de fidelidade 100 homens e 120 mulheres. Os dados fornecem evidência de possíveis diferenças de grau de fidelidade entre sexos?


14. Uma pesquisa sobre a qualidade de certo produto foi realizada enviando-se questionários a donas-de-casa pelo correio. Aventure-se a possibilidade de que os respondentes voluntários tenham um particular viés de respostas, fizeram-se mais duas tentativas com os não-respondentes. Os resultados estão indicados abaixo. Você acha que existe relação entre a resposta e o número de tentativas?

Opinião sobre o produto	Nº de donas-de-casa		
	1ª tentativa	2ª tentativa	3ª tentativa
Excelente	62	36	12
Satisfatório	84	42	14
Insatisfatório	24	22	24

14.5 Teste Para o Coeficiente de Correlação

O teste apresentado na seção anterior é adequado para averiguar a independência de duas variáveis qualitativas. Vimos, na seção 4.5, que para variáveis quantitativas o coeficiente de correlação é uma medida de associação mais adequada. Usualmente, podemos determinar o coeficiente de correlação para uma amostra, pois desconhecemos esse valor na população. Uma população que tenha duas variáveis não-correlacionadas pode produzir uma amostra com coeficiente de correlação diferente de zero. Para testar se a amostra foi colhida de uma população para a qual o coeficiente de correlação entre duas variáveis é nulo, precisamos obter a distribuição amostral da estatística r , definida em (4.7). Esquematicamente, temos a situação da Figura 14.2.

Figura 14.2: Coeficiente de correlação para população e amostra.



Seja $\rho = \rho(X, Y)$ o verdadeiro coeficiente de correlação populacional desconhecido. Vamos apresentar a distribuição amostral de r para duas condições da população: $\rho = 0$ e $\rho \neq 0$. Em ambos os casos, a distribuição amostral exige que a distribuição da v.a. (X, Y) na população seja *normal bidimensional*, como definida no Capítulo 8.

Exemplo 14.8. Teste para $\rho = \rho_0$. Durante muito tempo, o coeficiente de correlação entre a nota final num curso de treinamento de operários e sua produtividade, após seis meses do curso, resultou ser 0,50. Foram introduzidas modificações no curso, com o intuito de aumentar a correlação. Se o coeficiente de correlação de uma amostra de 28 operários submetidos ao novo curso foi 0,65, você diria que os objetivos da modificação foram atingidos?

A. Hipóteses

X : resultado no teste; Y : produtividade;

$$H_0 : \rho(X, Y) = 0,50;$$

$$H_1 : \rho(X, Y) > 0,50;$$

B. Estatística do Teste

R. Fisher sugeriu a seguinte transformação para a estatística r :

$$\xi = \frac{1}{2} \ln \frac{1+r}{1-r}, \quad (14.7)$$

que tem uma distribuição muito próxima de uma normal $N(\mu_\xi, \sigma_\xi^2)$, com

$$\mu_\xi = \frac{1}{2} \ln \frac{1+\rho_0}{1-\rho_0}, \quad \sigma_\xi^2 = \frac{1}{n-3}, \quad (14.8)$$

sendo n o tamanho da amostra $(X_1, Y_1), \dots, (X_n, Y_n)$ e ρ_0 o valor do parâmetro populacional. A aproximação não vale para $\rho = -1$ ou $\rho = 1$. Além disso, para $\rho = 0$, temos um teste exato, que será visto no próximo exemplo. No nosso caso, sob a hipótese H_0 , ξ terá distribuição aproximadamente normal, com

$$\mu_\xi = \frac{1}{2} \ln \frac{1+0,5}{1-0,5} = 0,549, \quad \sigma_\xi^2 = \frac{1}{25} = 0,04.$$

C. Região Crítica

Como a hipótese alternativa sugere uma região crítica unilateral à direita, e como $\xi \sim N(0,549; 0,04)$, vem que a RC para ξ , no nível de significância $\alpha = 0,05$, será

$$RC = \{\xi : \xi > 0,549 + 1,654\sqrt{0,04}\} = \{\xi : \xi > 0,878\}.$$

D. Resultado da Amostra

Como $r = 0,65$, vem que

$$\xi_0 = \frac{1}{2} \ln \frac{1+0,65}{1-0,65} = 0,774.$$

E. Conclusão

Como $\xi_0 \notin RC$, aceitamos H_0 , ou seja, não existe evidência de que o coeficiente de correlação tenha aumentado.

Exemplo 14.9. Teste para $\rho = 0$. Queremos testar se existe ou não correlação entre o número de clientes e os anos de experiência de agentes de seguros. Sorteamos cinco agentes e observamos as duas variáveis. Os dados estão na Tabela 14.12. Qual seria a conclusão, baseando-se nesses dados?

Tabela 14.12: Anos de experiência para cinco agentes de seguros.

Agente	A	B	C	D	E
Anos de Experiência	2	4	5	6	8
Número de Clientes	48	56	64	60	72

A. Hipóteses

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$

B. Estatística do Teste

Para amostras retiradas de uma população para a qual $\rho = 0$, pode-se provar que a estatística

$$T = r \sqrt{\frac{n-2}{1-r^2}} \quad (14.9)$$

tem distribuição t de Student com $n - 2$ graus de liberdade. No nosso exemplo, a estatística terá distribuição $t(3)$.

C. Região Crítica

Por ser um teste bilateral, consultando a Tabela V, teremos para $\alpha = 0,10$,

$$RC = (-\infty, -2,353] \cup [2,353, +\infty).$$

D. Resultado da Amostra

Calculando o coeficiente de correlação para os dados acima, obtemos $r = 0,95$; logo,

$$t_0 = (0,95) \sqrt{\frac{3}{1-(0,95)^2}} = 5,254.$$

E. Conclusão

Como $t_0 \in RC$, rejeitamos H_0 , isto é, existe dependência entre anos de experiência e números de clientes.

Nesse caso seria conveniente construir um intervalo de confiança para ρ . Observe que, se $\rho \neq 0$, devemos usar a estatística ξ de (14.7). Portanto, se tomarmos por exemplo $\gamma = 0,95$, devemos procurar dois números ξ_1 e ξ_2 para ξ , tais que

$$P(\xi_1 < \xi < \xi_2) = 0,95.$$

Como $\xi \sim N(\mu_\xi, 1/2)$, podemos escrever

$$P\left(\frac{\xi_1 - \mu_\xi}{\sqrt{1/2}} < \frac{\xi - \mu_\xi}{\sqrt{1/2}} < \frac{\xi_2 - \mu_\xi}{\sqrt{1/2}}\right) = 0,95,$$

ou seja,

$$P(-1,96 < Z < 1,96) = 0,95,$$

com $Z \sim N(0,1)$. Logo, o intervalo para μ_ξ é

$$IC(\mu_\xi; 0,95) = \xi_0 \pm 1,96\sqrt{1/2}.$$

Mas,

$$\xi_0 = \frac{1}{2} \ln \frac{1+0,95}{1-0,95} = 1,832,$$

logo

$$IC(\mu_{\xi}; 0,95) = 1,832 \pm 1,384 = (0,448; 3,216).$$

Como

$$\mu_{\xi} = \frac{1}{2} \ell n \frac{1 + \rho}{1 - \rho},$$

e uma expressão semelhante vale para os extremos do intervalo, podemos obter as operações inversas para encontrar os extremos do intervalo para ρ . Assim, de

$$0,448 = \frac{1}{2} \ell n \frac{1 + r}{1 - r}$$

obtemos

$$r = \frac{e^{0,896} - 1}{e^{0,896} + 1} = 0,420,$$

e de

$$3,216 = \frac{1}{2} \ell n \frac{1 + r}{1 - r}$$

obtemos

$$r = \frac{e^{6,432} - 1}{e^{6,432} + 1} = 0,997.$$

Finalmente, obtemos

$$IC(\rho; 0,95) = (0,420; 0,997).$$

Problemas

15. Estamos estudando se há ou não correlação entre as notas de diversas disciplinas de um curso de mestrado. Analisando uma amostra de 12 alunos, encontrou-se uma correlação de 0,60 entre as disciplinas de Estatística e Metodologia da Pesquisa. Teste a hipótese de não haver correlação entre as disciplinas. Caso a rejeite, dê um intervalo de confiança para o coeficiente de correlação populacional.
16. Existe relação entre o volume de uma carga e o tempo gasto para acondicioná-la? Para investigar esse fato, sortearam-se nove pedidos de mercadorias, medindo-se as duas variáveis de interesse. Com os dados obtidos abaixo, quais seriam as suas conclusões?

Tempo	84	108	110	133	144	152	180	196	231
Volume	48	72	63	82	88	109	112	123	140

14.6 Outro Teste de Aderência

Na seção 14.2 estudamos, por meio da distribuição qui-quadrado, como testar a hipótese de que um conjunto de dados provém de uma distribuição especificada. Nesta seção vamos introduzir uma outra maneira de testar a hipótese (14.2), por meio de um exemplo.


No Problema 47 do Capítulo 3 vimos que um estimador da verdadeira função densidade de uma população é o histograma. Em particular, foi apresentada uma maneira de obter o intervalo de classe, baseada numa “distância” entre o histograma e a função densidade.

Suponha que tenhamos uma amostra $X_1, \dots, X_n$ de uma população P , sobre a qual estamos considerando uma v.a. X . Designemos por $f(x)$ a *função densidade* e por $F(x)$ a *função de distribuição acumulada* (f.d.a.) de X . Estimar $f(x)$ é equivalente a estimar $F(x)$. Nosso objetivo é testar se a amostra observada veio de uma distribuição de probabilidades especificada, e (14.2) é equivalente a

$$H_0 : F(x) = F_0(x), \text{ para todo } x.$$

Vamos considerar a *função de distribuição empírica* (f.d.e.), $F_e(x)$, definida no problema 17 do Capítulo 2, como um estimador de $F(x)$, para todo valor x real. A situação é a da Figura 14.3.

Figura 14.3: Gráficos da f.d.a. e f.d.e. e distâncias $d_i = F(x_{(i)}) - F_e(x_{(i)})$.



Se $F_e(x)$ for um bom estimador de $F(x)$ as duas curvas devem estar próximas. Como em todo teste de hipóteses, para testar a hipótese acima, teremos que definir o que significa “próximo”. Há várias maneiras de medir a “distância” entre $F(x)$ e $F_e(x)$. Os probabilistas russos Kolmogorov e Smirnov propuseram uma estatística para o teste, obtida tomando o máximo dos valores absolutos das diferenças $F(x_i) - F_e(x_i)$, $i = 1, \dots, n$. Nessas diferenças, calculadas nos valores amostrais, $F(x_i)$ é o valor calculado sob a hipótese nula H_0 , ou seja, é o valor que a f.d.a. hipotetizada toma no ponto x_i . Formalmente, a estatística a ser usada no teste é

$$D = \max_{1 \leq i \leq n} |F(x_i) - F_e(x_i)|. \quad (14.10)$$

O valor encontrado deve ser comparado com um valor crítico, obtido na Tabela X, fixado um nível de significância do teste. Se D for maior que o valor tabelado, rejeitamos H_0 .

Retomemos o Exemplo 14.6, onde queríamos testar se 30 valores observados provinham de uma distribuição normal, com média 10 e desvio padrão 5.

Exemplo 14.6. (continuação) A hipótese a ser testada pode ser escrita na forma

$$H_0 : F(x) = F_0(x), \forall x,$$

$$H_1 : F(x) \neq F_0(x), \text{ para algum } x,$$

onde $F_0(x)$ é a f.d.a. da v.a. $X \sim N(10,25)$.

Lembremos que a f.d.e. $F_e(x)$ é uma função em “escada”, dando um salto igual a $1/30$ em cada valor $x_{(i)}$.

Na Tabela 14.13 temos os cálculos necessários. Vemos, por exemplo:

$$F_0(1,04) = P(X \leq 1,04) = P\left(Z \leq \frac{1,04 - 10}{5}\right) = P(Z \leq -1,792) = 0,0366,$$

$$F_e(1,04) = 1/30 = 0,0333 \text{ etc.}$$

Tabela 14.13: Dados para o Teste de Kolmogorov-Smirnov do Exemplo 14.2.


x_i	$F(x_i)$	$F_e(x_i)$	$ F(x_i) - F_e(x_i) $	x_i	$F(x_i)$	$F_e(x_i)$	$ F(x_i) - F_e(x_i) $
1,04	0,0366	0,0333	0,00323	10,01	0,5008	0,5333	0,03253
1,73	0,0491	0,0667	0,01760	10,52	0,5414	0,5667	0,02525
3,93	0,1124	0,1000	0,01237	10,69	0,5549	0,6000	0,04512
4,44	0,1331	0,1333	0,00026	11,72	0,6346	0,6333	0,00124
6,37	0,2340	0,1667	0,06725	12,17	0,6679	0,6667	0,00119
6,51	0,2426	0,2000	0,04259	12,61	0,6992	0,7000	0,00083
7,61	0,3163	0,2333	0,08299	12,98	0,7244	0,7333	0,00892
7,64	0,3185	0,2667	0,05180	13,03	0,7277	0,7667	0,03892
8,18	0,3579	0,3000	0,05793	13,16	0,7363	0,8000	0,06369
8,48	0,3806	0,3333	0,04723	14,11	0,7945	0,8333	0,03887
8,57	0,3874	0,3667	0,02077	14,60	0,8212	0,8667	0,04545
8,65	0,3936	0,4000	0,00642	14,64	0,8233	0,9000	0,07670
9,71	0,4769	0,4333	0,04354	14,75	0,8289	0,9333	0,10439
9,87	0,4896	0,4667	0,02296	16,68	0,9092	0,9667	0,05744
9,95	0,4960	0,5000	0,00399	22,14	0,9924	1,0000	0,07591

Os valores de $F_0(x)$ podem ser obtidos como na seção 7.8, por exemplo, usando o comando CDF do Minitab.

Da tabela, vemos que o valor máximo dos valores absolutos das diferenças é $D = 0,104$. Da Tabela X, vemos que para $\alpha = 0,05$, o valor crítico é 0,242, logo aceitamos H_0 , ou seja, os dados realmente são uma amostra de uma distribuição normal, com $\mu = 10$ e $\sigma = 5$.

Podemos comparar os quantis (empíricos) dos dados com os quantis da normal, por meio de um gráfico $q \times q$, com o objetivo de verificar que os pontos se distribuem ao redor de uma reta, como na Figura 14.4.

Figura 14.4: Quantis da normal padrão contra quantis dos dados.



14.7 Problemas e Complementos

17. Teste a independência entre o tipo de atividade e o tipo de propriedade de embarcações para o Problema 20 do Capítulo 4.
18. Supõe-se que uma moeda favoreça cara, na proporção de duas caras para três coroas. Para testar tal hipótese, lança-se uma moeda quatro vezes, contando-se o número de caras. Repete-se esse experimento 625 vezes. Os resultados estão na tabela abaixo. Esses dados confirmam ou não a suposição?

Nº de caras	0	1	2	3	4	Total
Freqüências	72	204	228	101	20	625

19. Num laboratório foi realizada uma pesquisa de mercado em que se estudou a preferência com relação a dois adoçantes artificiais, A e B, obtendo-se os resultados seguintes.

Sexo	Preferem A	Preferem B	Indecisos
Feminino	50	110	40
Masculino	150	42	8

A distribuição de preferências pelos dois sexos é a mesma? Calcule o valor-p.

20. Prove que (14.3) pode ser escrita na forma

$$\chi^2 = \sum_{i=1}^s O_i^2/E_i - n.$$

21. Teste, para o nível de 5%, se existe correlação ou não entre o setor primário e o índice de analfabetismo, usando a amostra do Problema 11 do Capítulo 4. Caso a resposta seja afirmativa, construa um IC de 95% de confiança para ρ .
22. No Problema 28 do Capítulo 4, use as sugestões dadas para testar a hipótese $\rho = 0$.
23. Suspeita-se que o coeficiente de correlação entre o salário do marido e o da mulher seja de 0,60 ou mais. Para verificar tal hipótese, colheu-se uma amostra de 10 casais, observando-se o salário de ambos. Veja os resultados no Problema 29 do Capítulo 4. Qual seria sua conclusão?
24. No Problema 26 do Capítulo 4, temos três variáveis, X , Y e Z , e queremos verificar qual é maior, $\rho(X, Y)$ ou $\rho(X, Z)$. Verifique se algum dos coeficientes de correlação pode ser considerado como sendo nulo.
25. **Comparação dos coeficientes de correlação de duas populações.** Vamos supor que ρ_1 e ρ_2 sejam os coeficientes de correlação de duas populações, das quais retiramos duas amostras independentes, de tamanhos n e m , respectivamente. Desse modo, as v.a.

$$Z_1 = \frac{1}{2} \ell n \frac{1+r_1}{1-r_1} \quad \text{e} \quad Z_2 = \frac{1}{2} \ell n \frac{1+r_2}{1-r_2}$$

são independentes e terão, respectivamente, as distribuições

$$Z_1 \sim N\left(\mu_1; \frac{1}{n-3}\right) \quad \text{e} \quad Z_2 \sim N\left(\mu_2; \frac{1}{m-3}\right),$$

com

$$\mu_1 = \frac{1}{2} \ell n \frac{1+\rho_1}{1-\rho_1} \quad \text{e} \quad \mu_2 = \frac{1}{2} \ell n \frac{1+\rho_2}{1-\rho_2}.$$

Segue-se que a v.a. $D = Z_1 - Z_2$ terá distribuição normal, com média

$$\mu_D = \mu_1 - \mu_2 = \frac{1}{2} \ell n \left(\frac{1+\rho_1}{1-\rho_1} - \frac{1+\rho_2}{1-\rho_2} \right)$$

e variância $\sigma_D^2 = 1/(n-3) + 1/(m-3)$. Quando $\rho_1 = \rho_2$, temos que $\mu_D = 0$. Esse resultado permite testar se dois coeficientes de correlação são iguais ou não.

26. Deseja-se verificar se os homens e as mulheres reagem do mesmo modo a um pré-treinamento que visa prepará-los para realizar certa tarefa. Um grupo de 28 mulheres e 52 homens são submetidos ao pré-treinamento e, em seguida, mede-se a correlação entre o resultado no teste do curso e o número de erros cometidos ao realizar a tarefa. Os coeficientes de correlação observados foram: para as mulheres, $-0,82$; para os homens, $-0,52$. Usando os resultados do problema anterior, qual seria sua conclusão? Interprete o significado do coeficiente de correlação negativo.

27. **Distribuição multinomial.** Suponha que, quando realizamos um experimento aleatório, os resultados possíveis são os eventos $A_1, \dots, A_s$, com probabilidades $p_i = P(A_i)$, $i = 1, \dots, s$, $\sum_i p_i = 1$. Suponha que repetimos o experimento n vezes e que p_i permanece constante em todas as repetições. Defina as v.a. $X_1, \dots, X_s$ como:

X_i = número de vezes que A_i ocorre nas n repetições, $i = 1, \dots, s$.

Então, temos que

$$P(X_1 = n_1, X_2 = n_2, \dots, X_s = n_s) = \frac{n!}{n_1! n_2! \dots n_s!} p_1^{n_1} p_2^{n_2} \dots p_s^{n_s},$$

com $n_1 + \dots + n_s = n$. Se $s = 2$ obtemos a distribuição binomial. Observe que $X_1 + \dots + X_s = n$, logo as v.a. $X_1, \dots, X_s$ não são independentes. Como cada $X_i \sim \text{Bin}(n, p_i)$, obtemos $E(X_i) = np_i$, $\text{Var}(X_i) = np_i(1 - p_i)$, $i = 1, \dots, s$.

28. Suponha que uma empresa quer saber o efeito de fumar sobre testes respiratórios para seus trabalhadores. Suponha que os trabalhadores são divididos em três classes: nunca fumou, fumou no passado e fumante, e que dados anteriores mostram que as porcentagens de trabalhadores nessas três classes são, respectivamente: 52%, 12%, 36%. Se dez trabalhadores são selecionados ao acaso, qual a probabilidade de se obter exatamente cinco que nunca fumaram, dois que fumaram no passado e três fumantes atuais?
29. Teste, para o nível $\alpha = 0,05$, que os dados abaixo são de uma amostra de uma distribuição uniforme no intervalo $(0,1)$.

0,145	0,299	0,516	0,901	0,433
0,430	0,932	0,356	0,178	0,248
0,882	0,125	0,517	0,519	0,251
0,191	0,661	0,321	0,504	0,206
0,224	0,960	0,092	0,179	0,974
0,173	0,413	0,372	0,887	0,275
0,561	0,853	0,527	0,239	0,124
0,060	0,968	0,421	0,041	0,775
0,810	0,603	0,229	0,452	0,874
0,785	0,384	0,064	0,990	0,983

30. Teste, para o nível $\alpha = 0,01$, se os dados abaixo provêm de uma distribuição exponencial, com média 0,5.

0,378	0,391	0,458	0,063	0,009
1,007	0,470	0,368	0,831	0,387
0,228	0,389	0,627	0,480	0,093
0,123	0,089	0,646	0,093	0,400

31. Teste se os dados do CD-Notas são normais. Use o teste de aderência e o teste de Kolmogorov-Smirnov.

Inferência para Várias Populações

15.1 Introdução

Como vimos no Capítulo 1, uma das preocupações de um estatístico ao analisar um conjunto de dados é criar modelos que explicitem estruturas do fenômeno sob observação, as quais frequentemente estão misturadas com variações acidentais ou aleatórias. A identificação dessas estruturas permite conhecer melhor o fenômeno, bem como fazer afirmações sobre possíveis comportamentos.

Portanto, uma estratégia conveniente de análise é supor que cada observação seja formada por duas partes, como vimos em (1.1) do Capítulo 1:

$$\text{observação} = \text{previsível} + \text{aleatório}. \quad (15.1)$$

Aqui, a primeira componente incorpora o conhecimento que o pesquisador tem sobre o fenômeno e é usualmente expressa por uma função matemática, com parâmetros desconhecidos. A segunda parte, a aleatória (ou não previsível), representa aquilo que o pesquisador não pode controlar e para a qual são impostas algumas suposições, como, por exemplo, que ela obedeça a algum modelo probabilístico específico, que, por sua vez, também contém parâmetros desconhecidos.

Dentro desse cenário, o trabalho do estatístico passa a ser o de estimar os parâmetros desconhecidos das duas partes do modelo, baseado em amostras observadas.

Neste capítulo iremos investigar um modelo simples, chamado de *análise de variância com um fator*. No capítulo seguinte iremos estudar o modelo de regressão linear simples. As técnicas de análise de variância foram desenvolvidas principalmente pelo estatístico inglês Ronald A. Fisher, a partir de 1918. O leitor interessado pode consultar os trabalhos pioneiros de Fisher (1935, 1954) ou Peres e Saldiva (1982) para mais informações sobre esse assunto.


A situação geral pode ser descrita como segue. Temos uma população P de unidades experimentais (indivíduos, animais, empresas etc.), para a qual temos uma v.a. Y de interesse.

Suponha, agora, que possamos classificar as unidades dessa população segundo *níveis* de um *fator*. Por exemplo, o fator pode ser o sexo, com dois níveis, arbitrariamente denotados por 1: sexo masculino e 2: sexo feminino. A v.a. Y pode ser a altura de cada indivíduo.

Genericamente podemos ter I níveis para esse fator. A população fica, então, dividida em I subpopulações (ou estratos), $P_1, \dots, P_I$, cada uma representada por um nível i do fator, $i = 1, 2, \dots, I$. No exemplo citado teríamos duas subpopulações: a dos indivíduos do sexo masculino e a dos indivíduos do sexo feminino.

Na Figura 15.1 mostramos graficamente as suposições adotadas para o comportamento da população neste modelo. A Figura 15.1 (a) mostra um comportamento mais amplo, com distribuições distintas para cada subpopulação. Na Figura 15.1 (b), aparece a suposição mais comum, em que a parte aleatória segue uma distribuição normal, com a mesma variância σ^2 para todas as subpopulações P_i , $i = 1, 2, \dots, I$.

Figura 15.1: Formas da distribuição de y para os diversos níveis do fator.



Para cada nível i , observamos a v.a. Y em n_i unidades experimentais selecionadas ao acaso da subpopulação correspondente, ou seja, teremos uma amostra $(y_{i1}, \dots, y_{in_i})$ dessa subpopulação. No exemplo citado acima, temos $i = 1, 2$, ou seja, dois níveis para o fator sexo. Extraímos uma amostra de tamanho n_1 de P_1 : pessoas do sexo masculino, $(y_{11}, \dots, y_{1n_1})$, e uma amostra de tamanho n_2 de P_2 : pessoas do sexo feminino, $(y_{21}, \dots, y_{2n_2})$. Essas amostras são independentes.

Suponha que $E(Y) = \mu$ para a população toda, ou seja, a *média global* da v.a. Y para P . Suponha, também, que $E(Y|P_i) = \mu_i$, $i = 1, \dots, I$, ou seja, as médias da v.a. Y para as subpopulações sejam $\mu_1, \dots, \mu_I$. No nosso exemplo, μ é a média das alturas da população de todos os indivíduos, μ_1 é a média das alturas dos homens, e μ_2 é a média das alturas das mulheres.

O objetivo é estimar μ_i , $i = 1, \dots, I$ e testar hipóteses sobre essas médias. Uma hipótese de interesse é

$$H_0: \mu_1 = \mu_2 = \dots = \mu_I = \mu, \quad (15.2)$$

contra a alternativa

$$H_1: \mu_i \neq \mu_j \text{ para algum par } (i, j). \quad (15.3)$$

O teste acima corresponde a verificar se as duas populações estão dispostas como na Figura 15.1 (c), ou seja, os centros das distribuições têm a mesma ordenada e estão sobre uma reta paralela ao eixo do fator. Isso significa que o fator não tem influência sobre a média da variável sob observação.

A análise da variância pode ser pensada como um método para testar a hipótese H_0 acima, por meio da análise das variâncias das diversas amostras. Esse método estende aquele visto no Capítulo 13, onde comparávamos apenas duas médias. A teoria desenvolvida naquele capítulo envolvia situações mais amplas do que as que serão vistas aqui. Sob as mesmas suposições os dois métodos são equivalentes. Porém, não podemos usar os métodos do Capítulo 13 para comparar mais do que duas populações. Poderia ser aventada a possibilidade de testar as hipóteses duas a duas, mas isso traz problemas relacionados no nível de significância do teste global, já que efetuaremos

$\begin{pmatrix} 1 \\ 2 \end{pmatrix}$ testes parciais. Voltaremos a esse assunto na seção 15.4,

Um modelo conveniente para descrever essa situação é

$$y_{ij} = \mu_i + e_{ij} \quad i = 1, \dots, I, \quad j = 1, \dots, n_i, \quad (15.4)$$

para o qual supomos que e_{ij} são v.a. independentes, de média zero e variância σ_e^2 , desconhecida, por exemplo. Podemos adicionar a hipótese de que esses “erros” sejam normais, ou seja,

$$e_{ij} \sim N(0, \sigma_e^2), \quad (15.5)$$

para $i = 1, 2, \dots, I, j = 1, 2, \dots, n_i$.

Logo, além de estimar $\mu_1, \dots, \mu_p$, temos que estimar também σ_e^2 . Se (15.4) e (15.5) valerem, teremos I subpopulações normais $N(\mu_i, \sigma_e^2)$, $i = 1, 2, \dots, I$, que têm médias diferentes e mesma variância. A Figura 15.1 (b) ilustra essa situação, com $I = 4$.

O modelo (15.4) é chamado *modelo com efeitos fixos*, no sentido de que as subpopulações determinadas pelos níveis do fator são aquelas de interesse do pesquisador. Se o experimento fosse repetido, amostras aleatórias das *mesmas* subpopulações seriam extraídas e analisadas. Pode-se considerar, também, modelos com efeitos aleatórios, mas esse caso não será tratado neste livro.

Exemplo 15.1. Um psicólogo está investigando a relação entre o tempo que um indivíduo leva para reagir a um estímulo visual (Y) e alguns fatores, como sexo (W), idade (X) e acuidade visual (Z , medida em porcentagem). Na Tabela 15.1 temos os tempos para $n = 20$ indivíduos (valores da v.a. Y). O fator sexo tem dois níveis: $i = 1$: sexo masculino (H) e $i = 2$: sexo feminino (M), com $n_1 = n_2 = 10$. O fator idade tem cinco níveis: $i = 1$: indivíduos com 20 anos de idade, $i = 2$: indivíduos com 25 anos etc., $i = 5$: indivíduos com 40 anos. Aqui, $n_1 = \dots = n_5 = 4$. A acuidade visual, como porcentagem

Tabela 15.1: Tempos de reação a um estímulo (Y) e acuidade visual (Z) de 20 indivíduos, segundo o sexo (W) e a idade (X).

Indivíduo	Y	W	X	Z
1	96	H	20	90
2	92	M	20	100
3	106	H	20	80
4	100	M	20	90
5	98	M	25	100
6	104	H	25	90
7	110	H	25	80
8	101	M	25	90
9	116	M	30	70
10	106	H	30	90
11	109	H	30	90
12	100	M	30	80
13	112	M	35	90
14	105	M	35	80
15	118	H	35	70
16	108	H	35	90
17	113	M	40	90
18	112	M	40	90
19	127	H	40	60
20	117	H	40	80

da visão completa, também gera cinco níveis: $i = 1$: indivíduos com 100% de visão, $i = 2$: indivíduos com 90% de visão, e assim por diante. Não foi possível controlar essa variável *a priori* como as outras duas, já que ela exige exames oftalmológicos para sua mensuração. Daí o desbalanceamento dos tamanhos observados: $n_1 = 2$, $n_2 = 10$, $n_3 = 5$, $n_4 = 2$ e $n_5 = 1$. Fatores desse tipo são chamados de *co-fatores*.

Assim, para o fator sexo, teremos o modelo (15.4) com $i = 1, 2, j = 1, 2, 3, \dots, 10$, e para o fator idade, o mesmo modelo com $i = 1, 2, \dots, 5, j = 1, 2, 3, 4$.

Exemplo 15.2. Uma escola analisa seu curso por meio de um questionário com 50 questões sobre diversos aspectos de interesse. Cada pergunta tem uma resposta, numa escala de 1 a 5 (v.a. Y), onde a maior nota significa melhor desempenho. Na última avaliação usou-se uma amostra de alunos de cada período, e os resultados estão na Tabela 15.2. Aqui, o fator é período, com três níveis: $i = 1$: manhã, $i = 2$: tarde e $i = 3$: noite; temos $n_1 = 7$, $n_2 = 6$ e $n_3 = 8$.

Tabela 15.2: Avaliação de um curso segundo o período.

Período		
Manhã	Tarde	Noite
4,2	2,7	4,6
4,0	2,4	3,9
3,1	2,4	3,8
2,7	2,2	3,7
2,3	1,9	3,6
3,3	1,8	3,5
4,1		3,4
		2,8

Exemplo 15.3. Num experimento sobre a eficácia de regimes para emagrecer, homens, todos pesando cerca de 100 kg e de biotipos semelhantes, são submetidos a três regimes. Após um mês, verifica-se a perda de peso de cada indivíduo, obtendo-se os valores da Tabela 15.3.

Tabela 15.3: Perdas de peso de indivíduos submetidos a três regimes.

Regime		
1	2	3
11,8	7,4	10,5
10,5	9,7	11,2
12,5	8,2	11,8
12,3	7,2	13,1
15,5	8,6	14,0
11,4	7,1	9,8

Aqui, o fator é regime, com $I = 3$ níveis e cada regime é indexado por; $i = 1, 2, 3$. A v.a. Y é a perda de peso depois de um mês. $E(Y) = \mu$ é a perda de peso global dos 18 homens, μ_i é a perda média de peso para o regime i . As amostras têm todas o mesmo tamanho $n_1 = n_2 = n_3 = 6$.

Problemas

1. O modelo (15.4) pode ser escrito na forma

$$y_{ij} = \mu + \alpha_i + e_{ij},$$

com $i = 1, \dots, I$ e $j = 1, \dots, n_i$. Dizemos que α_i é o efeito diferenciado da subpopulação P_i ou do nível i do fator. Mostre que os estimadores de mínimos quadrados para μ e α_i são dados por

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^I \sum_{j=1}^{n_i} y_{ij} = \bar{y},$$

$$\hat{\alpha}_i = \bar{y}_i - \bar{y}, \quad \text{com} \quad \bar{y}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij},$$

se impusermos a condição $\sum_{i=1}^I n_i \alpha_i = 0$.

2. Obtenha $\hat{\mu}$, $\hat{\alpha}_i$ para os Exemplos 15.2 e 15.3.

15.2 Modelo para Duas Subpopulações

Inicialmente, consideremos o caso em que temos um fator com dois níveis, como no Exemplo 15.1, com o fator sexo. Ou seja, queremos avaliar o efeito do sexo do indivíduo sobre o seu tempo de reação ao estímulo. Temos, então, o modelo

$$y_{ij} = \mu_i + e_{ij}, \quad (15.6)$$

onde

μ_i = efeito comum a todos os elementos do nível $i = 1, 2$;

e_{ij} = efeito aleatório, não-controlado, do j -ésimo indivíduo do nível i ,

y_{ij} = tempo de reação ao estímulo do j -ésimo indivíduo do nível i .

15.2.1 Suposições

É necessário introduzir suposições sobre os erros e_{ij} a fim de fazer inferências sobre μ_1 e μ_2 . Iremos admitir que:

- (i) $e_{ij} \sim N(0, \sigma_e^2)$, para todos $i = 1, 2$ e $j = 1, 2, \dots, n_i$.
- (ii) $E(e_{ij} e_{ik}) = 0$, para $j \neq k$ e $i = 1, 2$, indicando independência entre observações dentro de cada subpopulação.

(iii) $E(e_{1j} e_{2k}) = 0$, para todo j e k , indicando independência entre observações das duas subpopulações.

Com essas suposições, temos duas amostras aleatórias simples, independentes entre si, retiradas das duas subpopulações $N(\mu_1, \sigma_e^2)$ e $N(\mu_2, \sigma_e^2)$.

Queremos testar a hipótese

$$H_0: \mu_1 = \mu_2$$

contra a alternativa

$$H_1: \mu_1 \neq \mu_2.$$

Como já salientamos acima, esse teste pode ser conduzido com os métodos do Capítulo 13, mas o objetivo aqui é introduzir a metodologia da análise de variância, com um caso simples. A extensão para mais de dois níveis será estudada na seção 15.3.

Note que estamos supondo que as variâncias residuais dos níveis 1 e 2 são iguais, ou seja,

$$\text{Var}(e_{1j}) = \text{Var}(e_{2j}) = \sigma_e^2, \text{ para todo } j = 1, \dots, n_i. \quad (15.7)$$

Essa é a propriedade conhecida como *homoscedasticidade*, isto é, estamos admitindo que a variabilidade residual é a mesma para os dois níveis (ou que P_1 e P_2 têm a mesma variabilidade segundo a v.a. Y). Note também que

$$E(y_{ij}) = \mu_i, \quad \text{Var}(y_{ij}) = \text{Var}(e_{ij}) = \sigma_e^2. \quad (15.8)$$

15.2.2 Estimação do Modelo

Nosso objetivo é estimar μ_1 , μ_2 e σ_e^2 no modelo (15.6), para podermos testar H_0 . Usaremos estimadores de mínimos quadrados. Poderíamos usar também estimadores de máxima verossimilhança, pois sabemos que nossas observações têm distribuição normal. Temos que, de (15.6), os *resíduos* são dados por

$$e_{ij} = y_{ij} - \mu_i, \quad (15.9)$$

e a soma dos quadrados dos resíduos é dada por

$$\begin{aligned} SQ(\mu_1, \mu_2) &= \sum_{i=1}^2 \sum_{j=1}^{n_i} e_{ij}^2 = \sum_{i=1}^2 \sum_{j=1}^{n_i} (y_{ij} - \mu_i)^2 \\ &= \sum_{j=1}^{n_1} (y_{1j} - \mu_1)^2 + \sum_{j=1}^{n_2} (y_{2j} - \mu_2)^2, \end{aligned}$$

ou seja,

$$SQ(\mu_1, \mu_2) = \sum_{j=1}^{n_1} e_{1j}^2 + \sum_{j=1}^{n_2} e_{2j}^2. \quad (15.10)$$

Observe que essa soma de quadrados é uma função de μ_1 e μ_2 . Se as variâncias residuais das duas subpopulações não fossem iguais, essa soma seria mais afetada por aquele nível que tivesse maior variância, e isso deveria influenciar a escolha dos estimadores. Nesse caso, uma sugestão seria então minimizarmos a expressão (15.10) com e_{ij}^2 substituída por $(e_{ij}/\sigma_i)^2$, com $\text{Var}(e_{ij}) = \sigma_i^2$, o que conduz a *estimadores de mínimos quadrados ponderados*.

Derivando (15.10) em relação a μ_1 e μ_2 obtemos:

$$\frac{\partial SQ(\mu_1, \mu_2)}{\partial \mu_i} = -2 \sum_{j=1}^{n_i} (y_{ij} - \mu_i) = 0, \quad i = 1, 2,$$

do que segue que os estimadores são dados por

$$\hat{\mu}_1 = \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1j} = \bar{y}_1, \quad (15.11)$$

$$\hat{\mu}_2 = \frac{1}{n_2} \sum_{j=1}^{n_2} y_{2j} = \bar{y}_2, \quad (15.12)$$

que são as médias das observações dos níveis 1 e 2, respectivamente. Logo,

$$SQ(\hat{\mu}_1, \hat{\mu}_2) = \sum_{j=1}^{n_1} (y_{1j} - \bar{y}_1)^2 + \sum_{j=1}^{n_2} (y_{2j} - \bar{y}_2)^2. \quad (15.13)$$

Podemos pensar em (15.13) como a *quantidade total de informação quadrática perdida* pela adoção do modelo (15.6). Essa soma é também denominada *soma dos quadrados dos resíduos*.

Vejamos outra maneira de escrever essa soma. Dentro do grupo dos homens, a variância da subpopulação P_1 pode ser estimada por

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{j=1}^{n_1} (y_{1j} - \bar{y}_1)^2, \quad (15.14)$$

e a variância da subpopulação P_2 das mulheres é estimada por

$$S_2^2 = \frac{1}{n_2 - 1} \sum_{j=1}^{n_2} (y_{2j} - \bar{y}_2)^2. \quad (15.15)$$

Segue-se que

$$SQ(\hat{\mu}_1, \hat{\mu}_2) = (n_1 - 1)S_1^2 + (n_2 - 1)S_2^2. \quad (15.16)$$

Temos, acima, dois estimadores não-viesados do mesmo parâmetro σ_e^2 e, portanto, podemos definir uma variância amostral ponderada

$$S_e^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}, \quad (15.17)$$

e, usando (15.16), podemos escrever

$$S_e^2 = \frac{SQ(\hat{\mu}_1, \hat{\mu}_2)}{n - 2}, \quad (15.18)$$

se $n = n_1 + n_2$. Vemos que S_e^2 é a *quantidade média* de informação quadrática perdida e é um estimador não-viesado de σ_e^2 . Observe que esse é o mesmo estimador definido em (13.10).

Temos, portanto, um primeiro enfoque para estimar a variância desconhecida, σ_e^2 , por meio da *variância devida ao erro* ou *variância dentro de amostras*, dada por S_e^2 , que é baseada nas *variâncias amostrais*, dadas por (15.14) e (15.15). A soma de quadrados (15.16) é também chamada de *soma de quadrados dentro dos grupos*.

Um outro enfoque será visto mais adiante, e que consiste em estimar σ_e^2 , através de uma *variância entre amostras*, baseada na variabilidade *entre as médias amostrais*, também chamada *variação devida ao fator*.

Exemplo 15.1. (continuação) Para os dados da Tabela 15.1, temos:

Grupo dos Homens (nível 1): $\bar{y}_1 = 110,1$, $\sum_{j=1}^{10} (y_{1j} - \bar{y}_1)^2 = 670,9$, $S_1^2 = 74,54$;

Grupo das Mulheres (nível 2): $\bar{y}_2 = 104,9$, $\sum_{j=1}^{10} (y_{2j} - \bar{y}_2)^2 = 566,9$, $S_2^2 = 62,99$.

Segue-se que

$$S_e^2 = \frac{670,9 + 566,9}{18} = \frac{1.237,8}{18} = 68,77, \quad S_e = 8,29.$$

Note que a soma dos quadrados dos resíduos é

$$SQ(\hat{\mu}_1, \hat{\mu}_2) = SQ(\bar{y}_1, \bar{y}_2) = 1.237,8.$$

Observe, também, que $\bar{y}_1$ e $\bar{y}_2$, denotam os tempos médios estimados de reação ao estímulo dos homens e mulheres, respectivamente.

Uma questão de interesse é a seguinte: será que o conhecimento do sexo de um indivíduo ajuda a melhorar a previsão do tempo de reação dele ao estímulo? Para responder a essa questão, devemos ter algum modelo alternativo para poder comparar os ganhos. O modelo usualmente adotado é o mais simples de todos, ou seja, aquele

que considera os dados vindos de uma única população. Suponha que os valores da v.a. Y para todos os $n = 20$ indivíduos sigam o modelo

$$y_i = \mu + e_i, \quad i = 1, 2, \dots, 20. \quad (15.19)$$

Podemos considerar esse modelo como sendo para *uma população*, ou seja, aquela de todos os indivíduos para a qual queremos investigar o tempo de reação ao estímulo, independentemente do sexo, idade e outros fatores.

Para o modelo (15.19) a soma dos quadrados dos resíduos é

$$SQ(\mu) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \mu)^2, \quad (15.20)$$

e o estimador de mínimos quadrados de μ , é obtido derivando-se (15.20) com relação a μ e igualando a zero, chegando-se a

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}, \quad (15.21)$$

ou seja, a média de todas as observações. Como aqui $y_i \sim N(\mu, \sigma_e^2)$, um estimador da variância residual σ_e^2 é

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{SQ(\mu)}{n-1} \quad (15.22)$$

ou seja, a nossa conhecida variância amostral.

Para os dados da Tabela 15.1, encontramos

$$\bar{y} = \frac{2.150}{20} = 107,50,$$

$$S^2 = \frac{1.373}{19} = 72,26, \quad S = 8,5.$$

Assim, sem informação adicional, podemos prever o tempo de reação de um indivíduo como sendo 107,50, com um desvio padrão de 8,5. Os resíduos desse modelo e do modelo (15.6) estão na Tabela 15.4, colunas $e(1)$ e $e(2)$, respectivamente. Comparando esses resíduos, vemos que os segundos melhoram um pouco as previsões, isto é, fazem cair o erro quadrático médio de 8,5 para 8,29. Mas essa queda nos parece pequena para justificar a inclusão do fator *sexo* no modelo, e talvez fosse preferível adotar o modelo mais simples (15.19).

Tabela 15.4: Resíduos para vários modelos ajustados aos dados do Exemplo 15.1.

Variáveis				Resíduos dos Modelos		
				e(1)	e(2)	e(3)
Indivíduo	Tempo de Reação	Sexo	Idade	$y_i - \bar{y}$	$y_{ij} - \bar{y}_i$	$y_{ij} - \bar{y}_i$
1	96	H	20	-11,50	-14,1	-2,50
2	92	M	20	-15,50	-12,9	-6,50
3	106	H	20	-1,50	-4,1	7,50
4	100	M	20	-7,50	-4,9	1,50
5	98	M	25	-9,50	-6,9	-5,25
6	104	H	25	-3,50	-6,1	0,75
7	110	H	25	2,50	-0,1	6,75
8	101	M	25	-6,50	-3,9	-2,25
9	116	M	30	8,50	11,1	8,25
10	106	H	30	-1,50	-4,1	-1,75
11	109	H	30	1,50	-1,1	1,25
12	100	M	30	-7,50	-4,9	-7,75
13	112	M	35	-4,50	7,1	1,25
14	105	M	35	-2,50	0,1	-5,75
15	118	H	35	10,50	7,9	7,25
16	108	H	35	0,50	-2,1	-2,75
17	113	M	40	5,50	8,1	-4,25
18	112	M	40	4,50	7,1	-5,25
19	127	H	40	19,50	16,9	9,75
20	117	H	40	9,50	6,9	-0,25
d.p.				8,50	8,29	6,08
2d.p.				17,00	16,58	12,16

Nota: Nesta tabela estão expressos os resíduos de diversos modelos ajustados aos dados e colocados juntos para comparar os “lucros” na adoção de cada modelo. No texto aparece o significado de cada coluna dos resíduos.

15.2.3 Intervalos de Confiança

Com as suposições feitas sobre os erros, podemos escrever

$$\bar{y}_1 \sim N(\mu_1, \sigma_e^2 / n_1), \bar{y}_2 \sim N(\mu_2, \sigma_e^2 / n_2), \tag{15.23}$$

o que permite construir intervalos de confiança separados para os dois parâmetros μ_1 e μ_2 , como já vimos anteriormente. Esses têm a forma

$$\bar{y}_i \pm t_\gamma \frac{S_e}{\sqrt{n_i}}, \quad i = 1, 2, \tag{15.24}$$

onde t_γ é o valor crítico da distribuição t de Student com $\nu = n - 2$ graus de liberdade, tal que $P(-t_\gamma < t(n-2) < t_\gamma) = \gamma$, $0 < \gamma < 1$. Observe que o número de graus de liberdade é $(n - 2)$ e não $n_i - 1$, porque

$$Z_i = \frac{(\bar{y}_i - \mu_i)\sqrt{n_i}}{\sigma_e} \sim N(0,1),$$

$$W = \frac{(n-2)S_e^2}{\sigma_e^2} \sim \chi^2(n-2)$$

e, portanto, $\frac{Z_i}{\sqrt{W/(n-2)}} = \frac{\sqrt{n_i}(\bar{y}_i - \mu_i)}{S_e}$ tem distribuição $t(n-2)$ pelo Teorema 7.1. Daqui, obtemos (15.24).

Exemplo 15.1. (continuação) Para o Exemplo 15.1, temos:

$$IC(\mu_1; 0,95) = 110,10 \pm (2,101)8,29 / \sqrt{10} =]104,59; 115,61[,$$

$$IC(\mu_2; 0,95) = 104,90 \pm (2,101)8,29 / \sqrt{10} =]99,39; 110,41[,$$

com $t_{0,95} = 2,101$ encontrado na Tabela V, com $\nu = 18$ graus de liberdade.

Ainda, com as suposições feitas, podemos concluir que

$$\bar{y}_1 - \bar{y}_2 \sim N(\mu_1 - \mu_2, \sigma_e^2 / n_1 + \sigma_e^2 / n_2), \quad (15.25)$$

de modo que a estatística

$$T = \frac{(\bar{y}_1 - \bar{y}_2) - (\mu_1 - \mu_2)}{S_e \sqrt{1/n_1 + 1/n_2}} \quad (15.26)$$

tem distribuição t de Student com $\nu = n_1 + n_2 - 2 = n - 2$ graus de liberdade, e um intervalo de confiança para a diferença $\mu_1 - \mu_2$ pode ser construído.

Exemplo 15.1. (continuação) Para o exemplo,

$$\begin{aligned} IC(\mu_1 - \mu_2; 0,95) &= (\bar{y}_1 - \bar{y}_2) \pm t_y S_e \sqrt{1/n_1 + 1/n_2} \\ &= (110,1 - 104,9) \pm (2,101)(8,29)\sqrt{1/10 + 1/10} =]-2,59; 12,99[. \end{aligned}$$

Este resultado implica que a hipótese

$$H_0: \mu_1 = \mu_2 \quad (15.27)$$

não pode ser rejeitada no nível $\alpha = 0,05$, já que o zero pertence ao intervalo. Isso está de acordo com o resultado já apontado de que o conhecimento do sexo de um indivíduo não irá ajudar a prever o tempo de reação ao estímulo.

O teste da hipótese para (15.27), com as suposições adotadas, é feito usando a estatística (15.26), com $n_1 + n_2 - 2$ g.l., obtendo-se o valor observado $t_0 = 1,40$, que, comparado com o valor crítico de 2,101 ($\alpha = 5\%$ e 18 g.l.), leva à não-rejeição da hipótese, como foi visto acima.

15.2.4 Tabela de Análise de Variância

As operações processadas anteriormente podem ser resumidas num quadro, para facilitar a análise. Se (15.27) for válida, o modelo adotado será

$$y_{ij} = \mu + e_{ij},$$

e a quantidade de informação perdida (devida aos resíduos) será dada por

$$SQ(\hat{\mu}) = \sum_{i=1}^2 \sum_{j=1}^{n_i} (y_{ij} - \bar{y})^2, \quad (15.28)$$

que iremos chamar de *soma de quadrados total*, abreviadamente, SQTot.

Analogamente, adotado o modelo (15.4), a quantidade de informação perdida é dada por (15.13) ou (15.16), e que chamamos de *soma de quadrados dos resíduos*, abreviadamente, SQRes, ou *soma de quadrados dentro dos dois grupos*, abreviadamente, SQDen.

A economia obtida ao passarmos de um modelo para outro será

$$SQTot - SQDen = SQEnt, \quad (15.29)$$

que chamaremos de *soma de quadrados entre grupos*. Não é difícil provar que (veja o problema 18)

$$SQEnt = \sum_{i=1}^2 n_i (\bar{y}_i - \bar{y})^2. \quad (15.30)$$

Observando essa expressão, vemos que ela representa a variabilidade *entre as médias amostrais*, ou seja, uma “distância” entre a média de cada grupo e a média global. Donde o nome “soma de quadrados entre grupos”. Quanto mais diferentes forem as médias $\bar{y}_i$, $i = 1, 2$, maior será SQEnt e, conseqüentemente, menor será SQDen.

As quantidades

$$QMTot = \frac{SQTot}{n-1} \quad (15.31)$$

e

$$QMDen = \frac{SQDen}{n - 2} \quad (15.32)$$

são chamadas *quadrado médio total* e *quadrado médio dentro* (ou residual), respectivamente.

Todas essas informações são agrupadas numa única tabela, conhecida pelo nome de ANOVA (abreviação de ANalysis Of VAriance), descrita na Tabela 15.5.

Tabela 15.5: Tabela de Análise de Variância (ANOVA).

F.V.	g.l.	SQ	QM	F
Entre	1	SQEnt	QMENT	QMENT/ S_e^2
Dentro	$n - 2$	SQDen	QMDen (ou S_e^2)	
Total	$n - 1$	SQTot	QMTot (ou S^2)	

Na primeira coluna temos as descrições das diferentes somas de quadrados, tecnicamente indicadas por fontes de variação (F.V.). Os graus de liberdade (g.l.) da segunda coluna estão associados às respectivas somas de quadrados, sendo que o número de g.l. da SQE é obtido por subtração. Falaremos abaixo sobre QMENT e a razão $F = QMENT/QMDen$.

Exemplo 15.1. (continuação) Com os dados obtidos anteriormente para o Exemplo 15.1, podemos construir a tabela ANOVA para o modelo (15.4). O resultado está na Tabela 15.6.

Tabela 15.6: Tabela ANOVA para o Exemplo 15.1.

F.V.	g.l.	SQ	QM	F
Entre	1	135,20	135,20	1,97
Dentro	18	1.237,80	68,77	
Total	19	1.373,00	72,26	

Da ANOVA encontramos os desvios padrões residuais $S_e = \sqrt{68,77} = 8,29$ do “modelo completo” (15.4) e $S = \sqrt{72,26} = 8,50$, do “modelo reduzido” (15.19). A economia propiciada ao passar de um modelo para outro, em termos de soma de quadrados, é 135,20, e em termos de quadrados médios, comparando 72,26 e 68,77. Proporcionalmente, economizamos

$$\frac{135,20}{1.373,00} = 0,0985 \approx 9,85\%,$$

ou seja, aproximadamente 10% na SQ de resíduos. Podemos dizer que essa é a *proporção da variação explicada pelo modelo* (15.9). Essa medida é chamada *coeficiente de explicação* do modelo, denotada por

$$R^2 = \frac{\text{SQEnt}}{\text{SQTot}}. \quad (15.33)$$

Essa medida já foi usada na seção 4.6. Veja o problema 27.

A conveniência ou não do modelo (15.4) está associada ao teste (15.27), já que aceitar essa hipótese implica a adoção do modelo (15.19). Com as suposições feitas, a estatística para o teste é (15.26), que, sob H_0 fica

$$T = \frac{\bar{y}_1 - \bar{y}_2}{S_e \sqrt{1/n_1 + 1/n_2}}, \quad (15.34)$$

que tem distribuição $t(n_1 + n_2 - 2)$. Também sabemos que o quadrado de T tem distribuição $F(1, n_1 + n_2 - 2)$ (ver seção 13.3). Contudo,

$$\text{QMEnt} = \text{SQEnt} = n_1(\bar{y}_1 - \bar{y})^2 + n_2(\bar{y}_2 - \bar{y})^2,$$

e como

$$\bar{y} = \frac{n_1\bar{y}_1 + n_2\bar{y}_2}{n_1 + n_2},$$

podemos escrever

$$\text{QMEnt} = \frac{n_1 n_2}{n_1 + n_2} (\bar{y}_1 - \bar{y}_2)^2 = \frac{(\bar{y}_1 - \bar{y}_2)^2}{1/n_1 + 1/n_2}. \quad (15.35)$$

Logo, concluímos que

$$T^2 = \frac{(\bar{y}_1 - \bar{y}_2)^2}{S_e^2(1/n_1 + 1/n_2)} = \frac{\text{QMEnt}}{S_e^2} = F. \quad (15.36)$$

Essa é a estatística que aparece na última coluna da tabela ANOVA. Portanto, podemos usar F , com $(1, n - 2)$ graus de liberdade para testar a hipótese (15.27). Rejeitaremos H_0 se $F > c$, c determinado pelo nível de significância do teste.

Exemplo 15.4. Da ANOVA da Tabela 15.6, vemos que o valor da estatística F é 1,97. Consultando a Tabela VI, com $(1, 18)$ g.l. e $\alpha = 0,05$, encontramos o valor crítico 4,41. Logo, não rejeitamos H_0 ; $\mu_1 = \mu_2$. Isso significa que não há vantagem em usar o modelo (15.4) no lugar de (15.19).

Problemas

3. Na tabela abaixo estão os dados referentes a uma amostra de 21 alunos do primeiro ano de um curso universitário. As variáveis são:

- Y: nota obtida na primeira prova do curso;
- X: se cursou escola particular (P) ou oficial (O);
- Z: o período em que está matriculado: manhã (M), tarde (T), noite (N).

y	56	68	69	70	70	72	75	77	83	84	84
x	P	O	P	P	O	O	O	P	P	P	O
z	N	M	M	M	T	N	M	M	T	N	N

y	85	90	92	95	95	95	100	100	100	100	
x	O	P	O	P	P	P	P	P	P	P	
z	T	T	M	M	N	T	T	M	M	T	

Considere o modelo $y_i = \mu + e_i, i = 1, 2, \dots, 21, e_i \sim N(0, \sigma^2)$. Obtenha os erros quadráticos médios de $\hat{\mu}$ e $\hat{\sigma}^2$. Construa intervalos de confiança para μ e σ^2 , com coeficiente de confiança 95%. Analise os resíduos do modelo.

- 4. Usando os dados do problema 3, você diria que o fato de a pessoa ter cursado a escola particular ou oficial influi no resultado da primeira prova? Siga todos os passos do Exemplo 15.1 para responder a essa pergunta.
- 5. Usando os dados do Exemplo 15.2, você diria que o fato de estudar durante o dia ou à noite afeta o desempenho dos alunos?
- 6. Numa pesquisa sobre rendimentos por hora, com assalariados segundo o grau de instrução, obtiveram-se os dados da tabela abaixo. Construa a tabela ANOVA e verifique se existe diferença significativa entre os rendimentos das duas categorias.

Escolaridade	n	Σx_i	Σx_i^2
Fundamental	50	111,50	259,93
Médio	20	71,00	258,89

[Observação: rendimentos (x) expressos como porcentagem do salário mínimo.]

- 7. Obtenha a tabela ANOVA para o Exemplo 15.3, usando o fator regime com os níveis I e 2.


15.3 Modelo para Mais de Duas Subpopulações

Para ilustrar essa situação, vamos considerar o fator idade para o Exemplo 15.1. Consideremos o modelo

$$y_{ij} = \mu_i + e_{ij}, \tag{15.37}$$

para $i = 1, 2, 3, 4, 5$ (níveis de idade) e $j = 1, 2, 3, 4$ (quatro indivíduos para cada nível de idade). Na Figura 15.2 temos os *box plots* da variável resposta (tempo de reação estímulo), para cada nível do fator idade. Vemos claramente que o tempo aumenta com a idade.

Figura 15.2: *Box plots* para a variável Y (estímulo) para cada nível de idade.



Agora, queremos minimizar

$$SQ(\mu_1, \dots, \mu_5) = \sum_{i=1}^5 \sum_{j=1}^4 (y_{ij} - \mu_i)^2, \quad (15.38)$$

com as hipóteses $E(e_{ij}) = 0$, para todo i, j e $\text{Var}(e_{ij}) = \sigma_e^2$, para todo i, j . É fácil verificar que os estimadores das médias μ_i são

$$\hat{\mu}_i = \frac{1}{n_i} \sum_{j=1}^4 y_{ij} = \bar{y}_i, \quad i = 1, 2, \dots, 5, \quad (15.39)$$

e que

$$SQ_{\text{Den}} = SQ_{\text{Res}} = SQ(\hat{\mu}_1, \dots, \hat{\mu}_5) = \sum_{i=1}^5 \sum_{j=1}^4 (y_{ij} - \bar{y}_i)^2,$$

ou seja,

$$SQ_{\text{Den}} = \sum_{i=1}^5 (n_i - 1) S_i^2,$$

onde S^2 é variância amostrais do i -ésimo nível (grupo de idade). Todas essas variâncias amostrais são estimadores não-viesados de σ_e^2 , logo pode-se, novamente, considerar o estimador ponderado

$$S_e^2 = \frac{\sum_{i=1}^5 (n_i - 1) S_i^2}{n - 5} = \frac{\text{SQDen}}{n - 5}. \quad (15.40)$$

Para nossos dados, obtemos:

(1) $i = 1$ (20 anos)

$$\bar{y}_1 = 98,5, \quad \sum_{j=1}^4 (y_{1j} - \bar{y}_1)^2 = 107,0, \quad S_1^2 = 35,67$$

(2) $i = 2$ (25 anos)

$$\bar{y}_2 = 103,25, \quad \sum_{j=1}^4 (y_{2j} - \bar{y}_2)^2 = 78,75, \quad S_2^2 = 26,25$$

(3) $i = 3$ (30 anos)

$$\bar{y}_3 = 107,75, \quad \sum_{j=1}^4 (y_{3j} - \bar{y}_3)^2 = 132,75, \quad S_3^2 = 44,25$$

(4) $i = 4$ (35 anos)

$$\bar{y}_4 = 110,75, \quad \sum_{j=1}^4 (y_{4j} - \bar{y}_4)^2 = 94,75, \quad S_4^2 = 31,58$$

(5) $i = 5$ (40 anos)

$$\bar{y}_5 = 117,25, \quad \sum_{j=1}^4 (y_{5j} - \bar{y}_5)^2 = 140,75, \quad S_5^2 = 46,92.$$

Segue-se que

$$S_e^2 = 554/15 = 36,93, \quad S_e = 6,08.$$

A tabela ANOVA para o fator idade está na Tabela 15.7.

Tabela 15.7: Tabela ANOVA para o Exemplo 15.1, com fator idade.

F.V.	g.l.	SQ	QM	F
Entre	4	819,00	204,75	5,54
Dentro	15	554,00	36,93	
Total	19	1.373,00	72,26	

Da tabela concluímos que houve uma redução substancial na soma de quadrados (819 unidades quadradas), ou seja,

$$R^2 = \frac{819}{1.373} = 59,65\%,$$


isto é, aproximadamente 60% da variação total é explicada pelo fator idade, reduzindo o erro quadrático médio de 8,50 para 6,08.

Como antes, podemos construir os intervalos de confiança para os parâmetros μ_i . Por exemplo, para o grupo de idade de 25 anos,

$$IC(\mu_2; 0,95) = 103,25 \pm \frac{(2,131)(6,08)}{2} = [96,77; 109,73].$$

Os resíduos desse modelo encontram-se na Tabela 15.4, coluna $e(3)$, e verificamos que eles diminuíram bastante, indicando a boa capacidade de previsão do modelo. A análise dos resíduos na Figura 15.3 não sugere violação de nenhuma das suposições feitas.

Figura 15.3: Resíduos do modelo $y_{ij} = \mu_i + e_{ij}$ para o fator idade.



A hipótese

$$H_0: \mu_1 = \dots = \mu_5 \quad (15.41)$$

pode ser testada usando-se o valor 5,54 da estatística F . Da Tabela VI encontramos que o valor crítico de $F(4,15)$, com $\alpha = 0,05$, é 3,06, logo rejeitamos H_0 . Ou seja, há evidências de que os tempos médios de reação para os diversos grupos de idade não sejam todos iguais.

Problemas

8. Usando os dados do problema 3, você diria que o período que o aluno está cursando influencia seu desempenho na primeira prova?
9. Continuação do problema 6. Na pesquisa de salário, acrescentou-se uma amostra de universitários.
 - (a) O grau de escolaridade influencia os rendimentos?
 - (b) Qual seria o rendimento médio para pessoas com formação universitária?
 - (c) Existe diferença entre os rendimentos médios daqueles com instrução universitária e assalariados com primeiro grau? Com segundo grau?

Escolaridade	n	Σx_i	Σx_i^2
Fundamental	50	111,50	259,93
Médio	20	71,00	258,89
Superior	10	84,30	717,94

10. Quer-se verificar a durabilidade de duas marcas de tintas que têm preços de custo bem diferenciados. Para isso foram selecionadas dez casas, cinco pintadas com a marca A e as cinco restantes pintadas com a marca B. Após um período de seis meses, foi atribuída a cada casa uma nota, resultante de vários quesitos. Os resultados foram os seguintes:

Marca A	85	87	92	80	84
Marca B	91	91	92	86	90

Com esses dados, você diria que uma das marcas é melhor do que a outra?

15.4 Comparações entre as Médias

A análise de variância é apenas o primeiro passo no estudo de comparação de médias de vários grupos. Quando o modelo que está sendo testado apresenta pouco poder de previsão, ou seja, quando não houver evidências para rejeitar a hipótese de igualdade entre as médias, então a análise é final. O fator que está sendo investigado não produz efeito nenhum sobre a variável resposta.

Entretanto, quando o teste rejeita a hipótese de igualdade (15.2), estamos afirmando que ocorre pelo menos uma desigualdade, e essa conclusão na maioria dos casos não é suficiente para o pesquisador. Ele deseja saber de que modo ocorre essa desigualdade. Como ilustração, suponha que se rejeite a hipótese $H_0: \mu_1 = \mu_2 = \mu_3$. Então, existem as seguintes possibilidades para a alternativa:

(1) $\mu_1 = \mu_2 \neq \mu_3$, (2) $\mu_1 \neq \mu_2 = \mu_3$ (3) $\mu_1 = \mu_3 \neq \mu_2$, e (4) $\mu_1 \neq \mu_2 \neq \mu_3$.

Existem vários métodos para resolver esse problema, e alguns deles podem ser vistos em Peres e Saldiva (1982). Aqui iremos discutir apenas um deles.

Um modo de investigar a causa da rejeição é comparar os grupos dois a dois. Como já foi visto na seção 15.2, isso pode ser feito por meio da construção de intervalos de confiança para a diferença, obtendo-se, por exemplo,

$$IC(\mu_1 - \mu_2; \gamma) = (\bar{y}_1 - \bar{y}_2) \pm t_\gamma S_e \sqrt{1/n_1 + 1/n_2}, \quad (15.42)$$

com t_γ obtido de uma distribuição t de Student com $n - I$ graus de liberdade. Poderíamos, então, construir os intervalos para todos os possíveis pares e, observando-se aqueles que não contêm o valor zero, obter conclusões sobre a razão da rejeição.

Exemplo 15.5. Investigando o efeito da idade, vimos que a hipótese H_0 foi rejeitada. O intervalo de confiança para a diferença de duas médias quaisquer seria dado por

$$\begin{aligned} IC(\mu_i - \mu_j; 0,95) &= (\bar{y}_i - \bar{y}_j) \pm (2,131)(6,08)\sqrt{1/4 + 1/4} \\ &= (\bar{y}_i - \bar{y}_j) \pm 9,16. \end{aligned}$$

Segue-se que grupos de idade cuja diferença de médias seja superior a 9,16 seriam diferentes. Na Tabela 15.8 observa-se que se aceita a igualdade apenas para grupos vizinhos, indicando uma relação mais forte entre as variáveis, fato que será explorado no próximo capítulo.

Tabela 15.8: Médias e diferenças de médias para os diversos grupos de idades para o Exemplo 15.1.

Grupo	20 anos	25 anos	30 anos	35 anos	40 anos
Média	98,50	103,25	107,75	110,75	117,25
Diferença	4,75	4,50	3,00	6,50	

No entanto, com esse procedimento não se pode controlar as probabilidades do erro de tipo I, ou seja, a probabilidade de rejeitar uma hipótese verdadeira. Por exemplo, suponha que todas as médias sejam iguais. No problema acima, com cinco grupos e sob a hipótese nula, teríamos então $\binom{5}{2} = 10$ possíveis comparações duas a duas, cada uma testada no nível de 5%, e a probabilidade de que pelo menos uma das comparações exceda 9,16 é bem maior do que 5% (na realidade, pode ser mostrado que essa probabilidade está em torno de 29%). Essa probabilidade cresce com o número de comparações. Para controlar melhor essa probabilidade global do erro de tipo I, pode ser usada uma correção, baseada na desigualdade de Bonferroni (ver problema 19). Usa-se, então, o intervalo

$$IC(\mu_i - \mu_j; \gamma) = (\bar{y}_i - \bar{y}_j) \pm t_\gamma^* S_e \sqrt{1/n_i + 1/n_j}, \quad (15.43)$$

onde o único valor que muda é o de t_γ^* , que tem o mesmo número de graus de liberdade, mas o nível de significância agora é $\alpha^* = \alpha/m$, onde m é o número de comparações duas a duas que desejamos fazer.

Exemplo 15.6. No Exemplo 15.5, $\alpha^* = 0,05/10 = 0,005$. Da Tabela V, com 15 graus de liberdade, encontramos $t^* = 3,438$ (obtido por interpolação linear) e então

$$IC(\mu_i - \mu_j; 0,95) = (\bar{y}_1 - \bar{y}_2) \pm (3,438)(6,08)\sqrt{1/2} \\ (\bar{y}_1 - \bar{y}_2) \pm 14,78.$$

Rejeitaremos H_0 para diferenças maiores do que 14,78 e vemos que apenas existe diferença entre os grupos de 20 e 40 anos.

Os intervalos de Bonferroni são conservadores, pois o nível α^* real será menor do que aquele nominal, e essa diferença aumenta com m . Portanto, recomenda-se que o seu uso seja restrito a um número pequeno de comparações.

Problemas

11. Queremos verificar o efeito do tipo de impermeabilização em lajes de concreto. As quantidades de água que passaram pela laje, em cada tipo, foram medidas durante um mês, obtendo-se os valores da tabela abaixo. Que conclusão pode obter?

I	II	III	IV
56	64	45	42
55	61	46	39
62	50	45	45
59	55	39	43
60	56	43	41

12. Os dados abaixo vêm de um experimento completamente aleatorizado, onde 5 processos de estocagem foram usados com um produto perecível por absorção de água. 25 exemplares desse produto foram divididos em cinco grupos de cinco elementos, e após uma semana mediu-se a quantidade de água absorvida. Os resultados codificados estão no quadro abaixo. Existem evidências de que os processos de estocagem produzem resultados diferentes?

		Sexo		
A	B	C	D	E
8	4	1	4	10
6	-2	2	6	8
7	0	0	5	7
5	-2	-1	5	4
8	3	-3	4	9

15.5 Teste de Homoscedasticidade

Uma das suposições básicas para a aplicação da técnica de ANOVA é a de homoscedasticidade, ou seja, que a variância seja a mesma em todos os níveis. Muitas

vezes, não podemos garantir *a priori* se essa suposição é adequada, e podemos analisar os dados para obter uma resposta. Podemos fazer uma inspeção visual ou um teste. A seguir apresentaremos o teste de Barlett para testar a igualdade de variâncias (veja Dixon e Massey, 1957):

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_I^2 \quad (15.44)$$

As informações de que dispomos são: os tamanhos amostrais n_i , e variâncias amostrais $S_i^2 = 1, 2, \dots, I$, com $n = n_1 + \dots + n_I$.

O teste é construído do seguinte modo:

(i) calcule a variância comum

$$S_e^2 = \frac{\sum_{i=1}^I (n_i - 1) S_i^2}{n - I} = \frac{SQDen}{n - 1} = QMDen;$$

(ii) calcule

$$M = (n - I) \ell n S_e^2 - \sum_{i=1}^I (n_i - 1) \ell n S_i^2;$$

(iii) calcule

$$C = 1 + \frac{1}{3(I - 1)} \left[\sum_{i=1}^I \left(\frac{1}{n_i - 1} \right) - \left(\frac{1}{n - I} \right) \right];$$

(iv) construa a estatística M/C , que segue uma distribuição aproximada qui-quadrado, com $I - 1$ g.l., para amostras grandes. Esquematicamente,

$$M/C \sim \chi^2 (I - 1).$$

Exemplo 15.7. Voltemos aos dados do tempo de reação ao estímulo como função da idade. Da amostra obtemos os seguintes resultados:

Grupo etário	20	25	30	35	40
Tamanho amostra	4	4	4	4	4
Variância	35,67	26,25	44/25	31,58	46,92

Seguindo os passos (i) – (iv) acima, obtemos:

(i) $S = 36,93$;

(ii) $M = (20 - 5) \ell n(36,93) - 3[\ell n(35,67) + \dots + \ell n(46,92)] = 0,36$;

(iii) $C = 1 + \frac{1}{3(5 - 1)} \left[\frac{5}{3} - \frac{1}{15} \right] = 1,13$;

(iv) $M/C = (0,36)/(1,13) = 0,32$.

Consultando a Tabela IV, com 4 g.l. e $\alpha = 0,05$, encontramos $\chi_c^2 = 11,1$, e portanto não rejeitamos a hipótese H_0 de igualdade de variâncias.

15.6 Exemplo Computacional

Vamos utilizar o Minitab para ilustrar o uso de um pacote para resolver um problema de análise de variância. Retomemos o Exemplo 15.1, como fator idade. O Quadro 15.1 mostra a saída do Minitab, usando a opção ANOVA do menu. Observe que os valores encontrados coincidem com aqueles já obtidos na seção 15.3, Tabela 15.7. O valor- p do teste de igualdade de médias é indicado por $P = 0,006$. A saída mostra também as estimativas das médias dos grupos, os desvios padrões e o desvio padrão ponderado, $S_e = 6,08$. Os intervalos de confiança individuais estão mostrados de forma pictórica, com uma escala anexa, notando-se intersecções que levam à rejeição da hipótese de igualdade de médias.

Quadro 15.1: ANOVA para o Exemplo 15.1. Minitab.

One-way Analysis of Variance					
Analysis of Variance for C1					
Source	DF	SS	MS	F	P
C2	4	819.0	204.8	5.54	0.006
Error	15	554.0	36.9		
Total	19	1373.0			

Individual 95% CIs For Mean					
Based on Pooled StDev					
Level	N	Mean	StDev	-----+-----+-----	
20	4	98.50	5.97	(-----*-----)	
25	4	103.25	5.12	(-----*-----)	
30	4	107.75	6.65	(-----*-----)	
35	4	110.75	5.62	(-----*-----)	
40	4	117.25	6.85	(-----*-----)	
Pooled StDev = 6.08				-----+-----+-----	
				100	110 120

Na Figura 15.3 temos os resíduos para cada nível do fator idade, bem como os resíduos para todas as idades. Na Figura 15.4 vemos os *box plots* desses resíduos, por nível, e na Figura 15.5 o *box plot* dos resíduos para todas as idades.

Figura 15.4: Box plots para os resíduos por nível do fator idade.





Figura 15.5: Boxplot para os resíduos de todas as idades.



15.7 Problemas e Complementos

13. A seção de treinamento de uma empresa quer saber qual de três métodos de ensino é mais eficaz. O encarregado de responder a essa pergunta pode dispor de 24 pessoas para verificar a hipótese. Ele as dividiu em três grupos de oito pessoas, de modo aleatório, e submeteu cada grupo a um dos métodos. Após o treinamento os 24 participantes foram submetidos a um mesmo teste, cujos resultados estão na tabela abaixo (quanto maior a nota, melhor o resultado). Quais seriam as conclusões sobre os métodos de treinamento?

Método 1		Método 2		Método 3	
3	8	4	7	6	7
5	4	4	4	7	9
2	3	3	2	8	10
4	9	8	5	6	9
Σx_i	38	37		62	
Σx_i^2	224	199		496	

14. Quer-se testar o efeito do tipo de embalagem sobre as vendas do sabonete Sebo. As embalagens são as seguintes:
- A: a tradicional embalagem preta B: cartolina vermelha C: papel alumínio rosa
- Escolheram-se três territórios de venda, com potenciais de vendas supostamente idênticos.

Cada tipo de embalagem foi designado aleatoriamente a uma região e as vendas observadas durante 4 semanas, obtendo-se os resultados da tabela abaixo. Quais seriam suas conclusões e críticas a esse experimento?

Réplicas (Semanas)	Embalagens		
	A	B	C
1	15	21	9
2	20	23	13
3	9	19	20
4	12	25	18
Total	56	88	60

15. Um produtor de gelatina em pó está testando um novo lançamento e quer verificar em que condições de preparo o produto seria mais bem aceito. Vinte e quatro donas-de-casa atribuíram notas (0 a 10) para o prato que produziram com o produto. Junto com o produto foram fornecidos quatro tipos de receitas: duas para doces (A e D) e duas para salgados (B e C). Feita a análise estatística, quais recomendações você faria ao produtor? Discuta a validade das suposições feitas para resolver o problema.

Receita			
A	B	C	D
2	4	3	3
5	7	5	6
1	3	1	2
7	9	9	8
2	4	6	1
6	8	8	4

16. Num curso de extensão universitária, entre outras informações, obteve-se informação sobre salário e área de formação acadêmica, com os seguintes resultados:

Formação	n_i	$\bar{x}$	s
Humanas	65	28,75	3,54
Exatas	12	35,21	5,46
Biológicas	8	43,90	4,93

Aqui, n_i indica a frequência, $\bar{x}$ o salário médio, e s o desvio padrão amostral. Teste a hipótese de que os salários médios nessas três áreas é o mesmo.

17. Suspeita-se que quatro livros, escritos sob pseudônimo, são de um único autor. Uma pequena investigação inicial selecionou amostras de páginas de cada um dos livros, contando-se o número de vezes que determinada construção sintática foi usada. Com os resultados abaixo, quais seriam as suas conclusões?

Livros			
1	2	3	4
28	29	26	39
31	33	24	27
17	35	22	35
25	24	19	34
26	28	23	28
22		25	34
24		29	33
		30	

18. Prove que $QMEnt = \sum n_i (\bar{y}_i - \bar{y})^2$.

19. **Contrastes Múltiplos.** Quando consideramos testar a hipótese $\mu_i = \mu_j$ dentre as I médias, a região crítica de nível α será dada por

$$|\bar{y}_i - \bar{y}_j| > t_{\alpha/2} S_e \sqrt{1/n_i + 1/n_j}, \quad (15.45)$$

na qual $t_{\alpha/2}$ encontra-se na Tabela V, com $n - I$ graus de liberdade e tal que $P(|t| > t_{\alpha/2}) = \alpha$. A aplicação desse método apresenta um problema, que tem sido bastante estudado e é conhecido como o problema de *contrastes múltiplos*.

No nosso Exemplo 15.1, com quatro observações por grupo de idade, teremos de aplicar (15.45) para cada uma das $m = \binom{5}{2} = 10$ possíveis comparações de médias duas a duas. Se $\alpha = 0,05$, por exemplo, teremos

$$P(|\bar{y}_i - \bar{y}_j| \leq t_{\alpha/2} S_e \sqrt{1/2}) = 0,95, \quad (15.46)$$

e a probabilidade de que se verifiquem as dez condições (15.46), supondo independência, é $(0,95)^{10} = 0,598$, e não 0,95.

Portanto, aplicando-se o teste várias vezes, é provável que apareçam diferenças entre grupos, mesmo que elas não existam.

Um método que resolve o problema é baseado na desigualdade de Bonferroni. Seja A_ℓ o evento que consiste em rejeitar a hipótese $\mu_i = \mu_j$, sendo que essa hipótese é verdadeira. Suponha que $P(A_\ell) = \alpha$. Se B for o evento tal que rejeitamos pelo menos uma das hipóteses, quando ela é verdadeira, então

$$B = A_1 \cup A_2 \cup \dots \cup A_m.$$

Segue-se da desigualdade de Bonferroni que

$$P(B) = P(A_1 \cup A_2 \cup \dots \cup A_m) \leq \sum_{\ell=1}^m P(A_\ell) = m\alpha.$$

Se indicarmos por α^* a probabilidade do erro do tipo I global para os m contrastes, $P(B) \leq \alpha^*$, logo tomamos o nível de cada contraste como

$$\alpha = \alpha^*/m.$$

Para m grande, α pode ser tão pequeno que não o encontramos em tabelas da distribuição t de Student. Pode-se usar a aproximação

$$t_v(\alpha) \approx z_\alpha \left(1 - \frac{z_\alpha + 1}{4v} \right)^{-1},$$

na qual v é o número de graus de liberdade da distribuição t e Z_α é o valor da $N(0, 1)$ tal que $P(Z > Z_\alpha) = \alpha$.

20. Construa uma ANOVA completa para os Exemplos 15.2 e 15.3.
21. Usando a proposta do problema 19 e os dados do Exemplo 15.3, teste $H_0: \mu_1 = \mu_2 = \mu_3$, com $\alpha = 0,05$.
22. Teste a igualdade de variâncias para o Exemplo 15.3.
23. **Preparação para intervalo de predição, problema 24.** As vendas diárias (Y) de um grande centro de compras seguem uma distribuição normal com média igual a \$100 e desvio padrão igual a \$20.
 - (a) Qual o intervalo que contém 95% das vendas diárias?
 - (b) Se $\bar{X}$ representar a média de amostras de vendas de nove dias, qual intervalo conterá 95% das médias?
 - (c) Compare e interprete os dois intervalos acima.
Suponha, agora, que não se conheça nem a média nem o desvio padrão da população. Sorteou-se uma amostra de nove dias com as seguintes vendas diárias:

157	162	135	136	154	178	180	127	128
-----	-----	-----	-----	-----	-----	-----	-----	-----
 - (d) Qual a melhor estimativa para a média populacional?
 - (e) E para o desvio padrão populacional?
 - (f) Construa um intervalo de confiança (IC) de 95% para a média populacional.
 - (g) Construa um IC para a variância populacional.
 - (h) Explique em poucas palavras o significado dos intervalos obtidos em (f) e (g).
 - (i) Suponha, agora, que baseado nessa amostra você deva responder à pergunta (a). Como você não conhece a média e a variância populacional, você decide “emprestar” os respectivos valores da amostra e calcular o intervalo. Qual seria esse intervalo? Você tem alguma restrição a essa resposta?
 - (j) Consultando um livro de Estatística, você encontrou a seguinte fórmula para prever uma possível observação futura, Y_f :

$$IP(Y_f; \gamma) = \bar{y} \pm t_\gamma S \sqrt{1 + 1/n}.$$

Esse intervalo é chamado *intervalo de predição* (ou *previsão*). Construa o IP e interprete o resultado.

- (k) Compare com a resposta dado em (h), explicando a diferença entre eles.

24. **Intervalo de predição.** Vamos supor adotado o modelo (15.19) para a variável Y e desejamos prever uma observação futura Y_f . Pelo modelo adotado, podemos escrever que

$$Y_f = \mu + E_f$$

que poderá ser estimado por $\hat{Y}_f = \bar{y} + \varepsilon_f$, e por desconhecer ε_f substituímo-lo por seu valor esperado, que é zero. Logo, o estimador (ou predição) da futura observação passa a ser a média da amostra. Admitindo a observação futura como sendo independente das observações anteriores, podemos escrever

$$\text{Var}(\hat{Y}_f) = \text{Var}(\bar{y}) + \text{Var}(\varepsilon_f) = \frac{\sigma_e^2}{n} + \sigma_e^2 = \sigma_e^2 \left(\frac{1}{n} + 1 \right),$$

e que será estimada por

$$\widehat{\text{Var}}(\hat{Y}_f) = S_e^2 \left(\frac{1}{n} + 1 \right).$$

Usando a mesma argumentação para a construção de intervalos de confiança, podemos construir um IC para a futura observação, que chamaremos de intervalo de predição (IP), do seguinte modo:

$$\text{IP}(Y_f; \gamma) = \bar{y} \pm t_\gamma S_e \sqrt{1 + \frac{1}{n}}.$$

25. Mostre que o IP para uma observação futura Y_{if} do i -ésimo grupo, pode ser escrito como:

$$\text{IP}(Y_{if}; \gamma) = \bar{y}_i \pm t_\gamma S_e \sqrt{1 + \frac{1}{n_i}}$$

e calcule o IP para uma pessoa de 40 anos no Exemplo 15.1. Compare com o respectivo IC para a média do mesmo grupo.

26. Conduziu-se um estudo-piloto para determinar qual o intervalo de normalidade para o peso de crianças com dez anos de idade. Usando-se uma amostra de 50 crianças, encontrou-se o peso X de cada uma delas, com os seguintes resultados: $\sum x_i = 1.639,5$ kg e $\sum x_i^2 = 56.950,33$ kg². Com esses dados, quais seriam os limites de um intervalo para que crianças com dez anos de idade fossem consideradas como tendo peso normal?
27. Prove a equivalência das expressões (15.33) e (4.13).

Regressão Linear Simples

16.1 Introdução

No Capítulo 8 introduzimos o conceito de regressão para duas v.a. quantitativas, X e Y . Vimos que a esperança condicional de Y , dado que $X = x$, por exemplo, denotada por $E(Y|x)$, é uma função de x , ou seja,

$$E(Y|x) = \mu(x). \quad (16.1)$$

Em (8.27) definimos precisamente essa função. Uma definição similar vale para $E(X|y)$, que será uma função de y . Estamos considerando aqui o caso em que X e Y são definidas sobre uma mesma população P . Por exemplo, X pode ser a idade e Y o tempo de reação ao estímulo, no Exemplo 15.1. Nesse exemplo, a análise sugeriu a existência de uma relação mais forte entre as duas variáveis, e a modelamos por

$$y_{ij} = \mu_i + e_{ij}, \quad i = 1, \dots, 5, \quad j = 1, \dots, 4, \quad (16.2)$$

onde μ_i é a média do grupo de idade i . Podemos pensar que o fator idade determina cinco subpopulações (ou estratos) em P e de lá escolhemos cinco amostras aleatórias de tamanhos $n_i = 4$, $i = 1, \dots, 5$.

Em (16.1), $\mu(x)$ pode ser qualquer função de x ; veja o Exemplo 8.21. Um caso simples de interesse é aquele em que X e Y têm distribuição conjunta normal bidimensional. Nesse caso, $\mu(x)$ e $\mu(y)$ são, de fato, funções lineares. Veja a seção 8.8.


Continuando com o Exemplo 15.1, tanto X (idade) como Y (tempo de resposta ao estímulo) são v.a. contínuas, e podemos pensar em introduzir um modelo alternativo para y_{ij} , dada a relação entre X e Y . Observando as médias de Y , segundo os grupos de idades, ou seja, $E(Y|x)$, percebemos que estas aumentam conforme as pessoas envelhecem. A Figura 16.1 mostra os dados observados, onde notamos uma tendência crescente, bem como os valores repetidos de Y para cada nível de idade x .

Um modelo razoável para $E(Y|x)$ pode ser

$$E(Y|x) = \mu(x) = \alpha + \beta x, \quad (16.3)$$

ou seja, o tempo médio de reação é uma função linear da idade.

Figura 16.1: Gráfico de dispersão de idade e reação ao estímulo, com reta ajustada.



A forma da função $\mu(x)$ deve ser definida pelo pesquisador, em função do grau de conhecimento teórico que ele tem do fenômeno sob estudo. Um modelo alternativo a (16.2) seria, então,

$$y_{ij} = \mu(x_i) + e_{ij}, \quad (16.4)$$

com $E(Y|x_i) = \mu(x_i) = \alpha + \beta x_i$, $i = 1, 2, \dots, 5$. Entretanto, a forma usual de escrever o modelo é

$$y_i = \mu(x_i) + e_i, \quad (16.5)$$

onde y_i indica o tempo de reação do i -ésimo indivíduo com x_i anos de idade, $i = 1, 2, \dots, n$, e n é o número total de observações. Teremos, então, com essa notação, valores repetidos para X , por exemplo, $x_1 = \dots = x_4 = 20$. Convém reforçar a idéia que estamos propondo um modelo de comportamento para as médias das subpopulações, logo teremos de estimar os parâmetros envolvidos na função $\mu(x)$, baseados numa amostra de $n = 20$ observações, no exemplo.


No caso de (16.3) o modelo pode ser escrito como

$$y_i = E(Y|x_i) + e_i = \alpha + \beta x_i + e_i, \quad i = 1, 2, \dots, n, \quad (16.6)$$

devendo-se encontrar os valores mais prováveis para α e β , segundo algum critério, a partir de n observações de pares de valores de (X, Y) .

Antes de prosseguirmos, seria conveniente interpretar os parâmetros envolvidos no modelo (16.5). Sabemos que α , o intercepto, representa o ponto onde a reta corta o eixo das ordenadas, e β , o coeficiente angular, representa o quanto varia a média de Y para um aumento de uma unidade da variável X . Esses parâmetros estão representados na Figura 16.2.

Figura 16.2: Representação do modelo $E(Y|x) = \alpha + \beta x$.



Voltando ao nosso exemplo, onde X é a idade e Y o tempo de reação, β representa o acréscimo no tempo médio de reação para cada ano de envelhecimento das pessoas. Aqui α representa o tempo de reação para a idade zero (recém-nascido), o que é uma inadequação do modelo.

Observação. Chamamos (16.3) de modelo linear, pois este representa uma reta. Todavia, em casos mais gerais, o termo *linear* refere-se ao modo como os *parâmetros entram no modelo*, ou seja, de forma linear. Por exemplo, o modelo

$$E(Y|x) = \alpha + \beta x + \gamma x^2,$$

embora graficamente represente uma parábola, é *modelo linear em α , β e γ* . Por outro lado,

$$E(Y|x) = \alpha e^{\beta x} \quad (16.7)$$

não é um modelo linear em α e β .

Determinados modelos não-lineares podem ser transformados em lineares, por meio de transformações das variáveis. Assim, tomando-se o logaritmo (de base e) em (16.7) obtemos

$$\ell n E(Y|x) = \ell n(\alpha) + \beta x = \alpha' + \beta x,$$

que é linear em α' e β .

Ao lado de um tratamento formal para estudar o modelo (16.6), devemos usar as técnicas de análise de dados que estudamos na Parte 1 do livro. Em particular, podemos fazer diversos tipos de gráficos *antes* que o modelo seja ajustado, *durante* o processo de ajuste e, finalmente, *depois* que o modelo foi ajustado.

A Figura 16.1 é um exemplo de um gráfico que deve ser feito antes de selecionar o modelo. Ou seja, temos um gráfico de dispersão entre as variáveis X (idade) e Y (tempo de reação ao estímulo). Esse tipo de diagrama permite ver qual o tipo de relação existente entre as variáveis, se há valores atípicos, se há valores repetidos (como no Exemplo 15.1), se a variabilidade de Y está aumentando ou não com X etc. Nesse mesmo exemplo, se decidirmos incluir a variável “acuidade visual” no modelo, teríamos duas variáveis explicativas e poderíamos fazer, por exemplo, gráficos de dispersão entre a resposta e cada variável explicativa e entre as duas variáveis explicativas. Este último nos daria uma idéia do *planejamento* envolvido, ou seja, se os pares de valores das variáveis explicativas estão cobrindo o plano (x_1, x_2) , se há grupos de pontos etc.

Exemplos de gráficos depois do ajuste serão vistos na seção 16.5, quando fizermos uma análise dos resíduos, para avaliar a adequação do modelo aos dados. Gráficos durante o ajuste são utilizados quando estudarmos a possibilidade de considerar vários modelos alternativos para o problema em questão. Esse tópico não será explorado com detalhes no livro.

16.2 Estimação dos Parâmetros

Como no capítulo anterior, iremos encontrar os estimadores de mínimos quadrados para os parâmetros do modelo linear (16.6), mas o mesmo desenvolvimento pode ser aplicado em modelos mais complexos. Será necessário ainda introduzir algumas suposições para as v.a. envolvidas. A primeira delas é que a variável X é por hipótese controlada e não está sujeita a variações aleatórias. Dizemos que X é uma variável fixa (ou sem erro ou determinística). Segundo, para dado valor x de X , os erros distribuem-se ao redor da média $\alpha + \beta x$ com média zero, isto é,

$$E(e_i | x) = 0. \quad (16.8)$$

Em terceiro lugar, e pela mesma razão apresentada no capítulo anterior, devemos supor que os erros tenham a mesma variabilidade em torno dos níveis de X , ou seja,

$$\text{Var}(e_i | x) = \sigma_e^2. \quad (16.9)$$

E em quarto lugar, introduziremos a restrição de que os erros sejam não-correlacionados.

Colhida uma amostra de n indivíduos, teremos n pares de valores (x_i, y_i) , $i = 1, \dots, n$, que devem satisfazer ao modelo (16.6), isto é,

$$y_i = \alpha + \beta x_i + e_i, \quad i = 1, \dots, n. \quad (16.10)$$

Temos, então, n equações e $n + 2$ incógnitas (α , β , e_1 , e_2 , ..., e_n). Precisamos introduzir um critério que permita encontrar α e β . Como no capítulo anterior, vamos adotar o critério que consiste em encontrar os valores de α e β que minimizam a soma dos quadrados dos erros, dados por

$$e_i = y_i - (\alpha + \beta x_i), \quad i = 1, \dots, n. \quad (16.11)$$

Obtemos, então, a quantidade de informação perdida pelo modelo ou soma dos quadrados dos erros (ou desvios)

$$\text{SQ}(\alpha, \beta) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n \{y_i - (\alpha + \beta x_i)\}^2. \quad (16.12)$$

Para cada valor de α e β teremos um resultado para essa soma de quadrados, e a solução de mínimos quadrados (MQ) é aquela que torna essa soma mínima. Temos, então, o problema de encontrar o mínimo de uma função de duas variáveis, α e β , no caso (ver Morettin et al., 2005). Derivando em relação a α e β e igualando a zero, observamos que as soluções $\hat{\alpha}$ e $\hat{\beta}$ devem satisfazer

$$\begin{aligned} n\hat{\alpha} + \hat{\beta} \sum_{i=1}^n x_i &= \sum_{i=1}^n y_i, \\ \hat{\alpha} \sum_{i=1}^n x_i + \hat{\beta} \sum_{i=1}^n x_i^2 &= \sum_{i=1}^n x_i y_i, \end{aligned} \quad (16.13)$$

as quais produzem as soluções

$$\begin{aligned}\hat{\alpha} &= \bar{y} - \hat{\beta}\bar{x}, \\ \hat{\beta} &= \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}.\end{aligned}\quad (16.14)$$

Substituindo em (16.3), teremos o estimador para a média $\mu(x)$, dado por

$$\hat{\mu}(x_i) = \hat{\alpha} + \hat{\beta}x_i, \quad i = 1, \dots, n, \quad (16.15)$$

que iremos indicar por

$$\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i, \quad (16.16)$$

ou, ainda, por

$$\hat{y}_i = \bar{y} - \hat{\beta}\bar{x} + \hat{\beta}x_i = \bar{y} + \hat{\beta}(x_i - \bar{x}). \quad (16.17)$$

Exemplo 16.1. Voltemos ao Exemplo 15.1 e vamos ajustar o modelo (16.10), com:

y_i : tempo de reação do i -ésimo indivíduo,

x_i : idade do i -ésimo indivíduo,

e_i : desvio, $i = 1, 2, \dots, 20$.

Da Tabela 16.1 obtemos as informações:

$$\begin{aligned}n &= 20, \quad \sum y_i = 2.150, \quad \sum x_i = 600, \quad \sum x_i y_i = 65.400, \\ \bar{y} &= 107,50, \quad \bar{x} = 30, \quad \sum x_i^2 = 19.000.\end{aligned}$$

Substituindo em (16.14) obtemos

$$\begin{aligned}\hat{\beta} &= \frac{65.400 - (20)(30)(107,50)}{19.000 - (20)(30)^2} = 0,90, \\ \hat{\alpha} &= 107,50 - (0,90)(30) = 80,50,\end{aligned}$$

o que nos dá o *modelo ajustado*

$$\hat{y}_i = 80,50 + 0,90x_i, \quad i = 1, 2, \dots, 20. \quad (16.18)$$

Com esse modelo podemos prever, por exemplo, o tempo médio de reação para pessoas de 20 anos, que será indicado por $\hat{y}(20)$ e determinado por

$$\hat{y}(20) = 80,50 + (0,90)(20) = 98,50.$$

De modo análogo, os tempos médios para as idades 25, 30, 35 e 40 serão, respectivamente, estimados por: 103,00, 107,50, 112,00, e 116,50. Esses valores são muito próximos daqueles encontrados na seção 15.3, e a vantagem desse modelo sobre aquele é a possibilidade de estimar o tempo de reação médio para um grupo de idades não observado. Suponhamos, por exemplo, que se deseja estimar o tempo médio para o grupo de pessoas com 33 anos; este será dado por

$$\hat{y}(33) = 80,50 + (0,90)(33) = 110,20.$$

Na Figura 16.1 aparecem representados os dados observados, bem como a reta ajustada. Podemos observar que o modelo parece ser adequado, não apresentando nenhum ponto com desvio exagerado.

Problemas

- Usando os dados do Exemplo 15.1:
 - Encontre a reta de mínimos quadrados $\hat{z}_i = \alpha + \beta x_i$, onde z mede a acuidade visual e x , a idade.
 - Interprete o significado de α e β nesse problema.
 - Para cada indivíduo, encontre o desvio $\hat{e}_i = z_i - \hat{z}_i$; existe algum com valor muito exagerado?
- A tabela abaixo indica o valor y do aluguel e a idade x de cinco casas.
 - Encontre a reta de MQ, supondo a relação $E(y|x) = \alpha + \beta x$.
 - Faça o gráfico dos pontos e da reta ajustada. Você acha que o modelo adotado é razoável?
 - Qual o significado do coeficiente angular nesse caso?
 - E do coeficiente linear?

x	10	13	5	7	20
y	4	3	6	5	2

- Um laboratório está interessado em medir o efeito da temperatura sobre a potência de um antibiótico. Dez amostras de 50 gramas cada foram guardadas a diferentes temperaturas, e após 15 dias mediu-se a potência. Os resultados estão no quadro abaixo.
 - Faça a representação gráfica dos dados.
 - Ajuste a reta de MQ, da potência como função da temperatura.
 - O que você acha desse modelo?
 - A que temperatura a potência média seria nula?

Temperatura	30°			50°			70°			90°	
Potência	38	43	32	26	33	19	27	23	14	21	

- Ainda usando os dados do exemplo numérico 15.1, investigue o ajuste da reta de MQ na variável tempo de reação como função da acuidade visual.

16.3 Avaliação do Modelo

Nesta seção e nas seguintes estudaremos várias formas de avaliar se o modelo linear postulado é adequado ou não, dadas as suposições que fizemos sobre ele.

16.3.1 Estimador de σ_e^2

Como no capítulo anterior, para julgar a vantagem da adoção de um modelo mais complexo (linear ou outro qualquer), vamos usar a estratégia de compará-lo com o modelo mais simples, que é aquele discutido na seção 15.2, ou seja,

$$y_i = \mu + e_i. \quad (16.19)$$

A vantagem será sempre medida por meio da diminuição dos erros de previsão, ou ainda, da variância residual S_e^2 . Para o modelo ajustado (16.16), cada *resíduo* é dado por

$$\hat{e}_i = y_i - \hat{y}_i = y_i - \hat{\alpha} - \hat{\beta}x_i. \quad (16.20)$$

Como vimos na seção 16.1, vários gráficos envolvendo esses resíduos podem ser feitos para avaliar se eles são “bons representantes” dos verdadeiros e_i desconhecidos, no sentido de que as suposições feitas sobre estes estão satisfeitas. Esses gráficos serão estudados na seção 16.5.

Quando estes resíduos forem pequenos, temos uma indicação de que o modelo está produzindo bons resultados. Para julgarmos se o resíduo é pequeno ou não, devemos compará-lo com os resíduos do modelo alternativo, dados por $y_i - \bar{y}$. Da dificuldade de compará-los individualmente, preferimos trabalhar com as respectivas somas de resíduos quadráticos, dadas por

$$SQTot = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (16.21)$$

$$e \quad SQRes = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (16.22)$$

Exemplo 16.1. (continuação) Na quinta coluna da Tabela 16.1 aparecem os resíduos

$$\hat{e}_i = y_i - \hat{y}_i = y_i - (80,50 + 0,90x_i)$$

que elevados ao quadrado e somados produzirão

$$SQRes = 563,00.$$

Sabemos que $SQTot = 1.373,00$, o que mostra uma sensível redução de 810 unidades. Mais ainda, a comparação da quinta coluna da Tabela 16.1 com a coluna $e(3)$ da Tabela 15.4 mostra o melhor comportamento dos resíduos do modelo de regressão (16.18).

Tabela 16.1: Resíduos para o modelo (16.18).

i	Variáveis			Resíduos
	Tempo de Reação	Sexo	Idade	$y_i - \hat{y}_i$
1	96	H	20	-2,5
2	92	M	20	-6,5
3	106	H	20	7,5
4	100	M	20	1,5
5	98	M	25	-5,0
6	104	H	25	1,0
7	110	H	25	7,0
8	101	M	25	-2,0
9	116	M	30	8,5
10	106	H	30	-1,5
11	109	H	30	1,5
12	100	M	30	-7,5
13	112	M	35	0,0
14	105	M	35	-7,0
15	118	H	35	6,0
16	108	H	35	-4,0
17	113	M	40	-4,5
18	112	M	40	-5,5
19	127	H	40	9,5
20	117	H	40	-0,5
$SQRes$				563
S_e^2				31,28
S_e				5,59
$2S_e$				11,18

No entanto, a comparação direta dessas somas de quadrados não nos parece justa, pois o modelo (16.18) tem mais parâmetros do que o modelo (16.19). Vejamos, então, como comparar as variâncias residuais. Para o modelo simples (16.19) o estimador não-viesado de σ_e^2 é

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{SQTot.}{n-1}. \quad (16.23)$$

Também vimos que para o modelo (16.2), com I níveis ou subpopulações, o estimado da variância residual era

$$S_e^2 = \frac{SQDen}{n-I} = \frac{SQRes}{n-I}, \quad (16.24)$$

e I também denota o número de parâmetros desconhecidos do modelo (as médias μ_i). Portanto, de modo geral, perde-se um grau de liberdade para cada parâmetro envolvido no modelo e é natural definir o estimador de σ_e^2 num modelo de regressão como sendo

$$S_e^2 = \frac{SQRes}{n-p}, \quad (16.25)$$

onde p é o número de parâmetros do modelo. No caso particular da regressão linear simples, $p = 2$ e

$$S_e^2 = \frac{SQRes}{n-2}, \quad (16.26)$$

será um estimador não-viesado de σ_e^2 , isto é, $E(S_e^2) = \sigma_e^2$. Veja o Problema 32.

Exemplo 16.2. Continuando o exemplo anterior, obteremos

$$S^2 = 1.373/19 = 72,26, \quad S = 8,50$$

e

$$S_e^2 = 563/18 = 31,28, \quad S_e = 5,59,$$

números que sugerem uma diminuição significativa nos resíduos. Observe que, passando de um modelo com um parâmetro para outro com dois, há uma redução de 813 unidades na soma de quadrados residuais. Ou seja, perdendo um grau de liberdade, reduziu-se a soma dos resíduos quadráticos em 810 unidades, o que é mais uma evidência da vantagem de adoção do segundo modelo.

16.3.2 Decomposição da Soma de Quadrados

Ao passarmos do modelo simples para o modelo de regressão linear, vimos que a redução da soma de quadrados é dada por $SQTot - SQRes$. Esse lucro é devido à adoção do segundo modelo e será indicado por $SQReg$, significando a *soma dos quadrados devida à regressão*. Segue-se que

$$SQReg = SQTot - SQRes, \quad (16.27)$$

ou seja,


$$SQ_{Tot} = SQ_{Reg} + SQ_{Res}. \quad (16.28)$$

Observando a Figura 16.3, notamos que vale a seguinte relação:

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}) = \hat{e}_i + (\hat{y}_i - \bar{y}). \quad (16.29)$$

Em palavras, o desvio de uma observação em relação à média pode ser decomposto como o desvio da observação em relação ao valor ajustado pela regressão, mais o desvio do valor ajustado em relação à média.

Figura 16.3: Representação gráfica dos diversos desvios.



Elevando-se ao quadrado ambos os membros da igualdade (16.29), tomando-se a soma e observando-se que a soma do duplo produto se anula (veja o Problema 31), obtemos

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{e}_i^2, \quad (16.30)$$

ou

$$SQ_{Tot} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + SQ_{Res}, \quad (16.31)$$

do que deduzimos que

$$SQ_{Reg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2. \quad (16.32)$$

De (16.17) obtemos que

$$\hat{y}_i - \bar{y} = \hat{\beta}(x_i - \bar{x}),$$

portanto, podemos escrever

$$SQ_{Reg} = \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2. \quad (16.33)$$

Daqui se pode observar que, quanto maior o valor de $\hat{\beta}$, maior será a redução da soma dos quadrados dos resíduos.

16.3.3 Tabela de Análise de Variância

Do mesmo modo como foi feito na seção 15.2, podemos resumir as informações anteriores numa única tabela ANOVA, ilustrada na Tabela 16.2.

Tabela 16.2: Tabela ANOVA para modelo de regressão.

F.V.	g.l.	SQ	QM	F
Regressão	1	SQReg	SQReg = QMReg	QMReg/ S_e^2
Resíduo	$n - 2$	SQRes	SQRes/ $(n - 2) = S_e^2$	
Total	$n - 1$	SQTot	SQTot/ $(n - 1) = S^2$	

Também podemos medir o lucro relativo que se ganha ao introduzir o modelo, usando a estatística

$$R^2 = \frac{SQReg}{SQTot}, \tag{16.34}$$

definida anteriormente. A estatística F será discutida na seção 16.4.

Exemplo 16.3. Dos cálculos que nos levaram ao modelo (16.18), podemos construir a Tabela 16.3. Temos que

$$R^2 = \frac{810}{1.373} = 59\%.$$

Tabela 16.3: Tabela ANOVA para o modelo (16.18).

F.V.	g.l.	SQ	QM	F
Regressão	1	810	810	25,90
Resíduo	18	563	31,28	
Total	19	1.373	72,26	

O modelo proposto diminui a variância residual em mais da metade e explica 59% da variabilidade total. Verificamos, então, que é vantajosa a adoção do modelo linear (16.18) para explicar o tempo médio de reação ao estímulo, em função da idade.


A estratégia adotada para verificar se compensa ou não utilizar o modelo $y = \alpha + \beta x + e$ é observar a redução no resíduo quando comparado com o modelo $y = \mu + e$. Se a redução for muito pequena, os dois modelos serão praticamente equivalentes, e isso ocorre quando a inclinação β for zero ou muito pequena, não compensando usar um modelo mais complexo. Estaremos, pois, interessados em testar a hipótese

$$H_0: \beta = 0, \tag{16.35}$$

o que irá exigir que se coloque uma estrutura de probabilidades sobre os erros. Esse assunto será objeto da próxima seção. A Figura 16.4 ilustra as duas situações que podem ocorrer.

Na Figura 16.4 (a) temos o caso em que claramente a variável auxiliar ajuda a prever a variável resposta. Na situação da Figura 16.4 (b) teremos dúvidas se vale a pena ou não introduzir um modelo mais complexo, ganhando muito pouco em termos de explicação.

Figura 16.4: Retas ajustadas a dois conjuntos de dados. (a) x explica y ; (b) x não explica y .



Para a avaliação final do modelo devemos investigar com mais cuidado o comportamento dos resíduos, o que será feito na seção 16.5.

Problemas

- Usando os resultados do Problema 1, construa a tabela ANOVA para o modelo $\hat{z} = \hat{\alpha} + \hat{\beta}x$, encontrado naquele problema.
 - Qual a estimativa S^2 ? E S_e^2 ?
 - Você acha que a redução nos resíduos foi grande?
 - Qual o valor de R^2 ? Interprete esse número.
- Um estudo sobre duração de certas operações está investigando o tempo requerido (em segundos) para acondicionar objetos e o volume (em dm^3) que eles ocupam. Uma amostra foi observada e obtiveram-se os seguintes resultados:

Tempo	10,8	14,4	19,6	18,0	8,4	15,2	11,0	13,3	23,1
Volume	20,39	24,92	34,84	31,72	13,59	30,87	17,84	23,22	39,65

- Faça o diagrama de dispersão dos dados.
 - Estime a reta de regressão do tempo de operação em função do volume.
 - Construa a tabela ANOVA para o modelo.
 - Qual o valor de S^2 ? É pequeno quando comparado com S_e^2 ?
 - Você acha que conhecer o volume do pacote ajuda a prever o tempo de empacotamento?
- Construa a tabela ANOVA para o Problema 2 e interprete os resultados.
 - Construa a tabela ANOVA com os dados do Problema 3.
 - Idem para o Problema 4.

16.4 Propriedades dos Estimadores

Iremos agora estudar as propriedades amostrais dos estimadores $\hat{\alpha}$ e $\hat{\beta}$, e para isso é conveniente voltar ao modelo e às suposições adotadas para a variável aleatória Y sob investigação. Lembremos que a variável X é suposta controlada, fixa, e para cada valor x de X teremos associada uma distribuição de probabilidades para Y , como ilustra a Figura 16.5 (a), onde supomos que a dispersão é a mesma para cada nível da variável X . A Figura 16.5 (b) ilustra o caso que será considerado aqui, em que estas distribuições condicionais são normais, com a mesma variância. Note que $E(Y|x)$ é linear, como estamos considerando neste capítulo.

Formalmente, o modelo

$$Y_i = E(Y|x_i) + e_i = \alpha + \beta x_i + e_i, \quad i = 1, \dots, n$$

deve satisfazer as seguintes suposições:


- (i) Para cada valor de x_i , o erro e_i tem média zero e variância constante σ_e^2 ;
- (ii) Se $i \neq j$, $\text{Cov}(e_i, e_j) = 0$, isto é, para duas observações distintas, os erros são não-correlacionados.

Segue-se que

$$E(Y_i|x_i) = \alpha + \beta x_i \quad \text{e} \quad \text{Var}(Y_i|x_i) = \sigma_e^2,$$

e ainda que Y_i e Y_j são não-correlacionados, para $i \neq j$.

Figura 16.5: (a) médias alinhadas, distribuições com a mesma variância;
(b) médias alinhadas, distribuições normais com a mesma variância.



16.4.1 Média e Variância dos Estimadores

Nesta seção vamos obter a média e a variância dos estimadores $\hat{\alpha}$ e $\hat{\beta}$, dados em (16.14).

Proposição 16.1. Para o estimador $\hat{\beta}$ temos

$$E(\hat{\beta}) = \beta, \quad (16.36)$$

$$\text{Var}(\hat{\beta}) = \frac{\sigma_e^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (16.37)$$

Prova. Inicialmente, vamos escrever β de um modo mais conveniente (veja o Problema 30):

$$\begin{aligned} \hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i - \bar{Y} \sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} Y_i = \sum_{i=1}^n w_i Y_i, \end{aligned}$$

onde estamos usando a notação Y (maiúscula) e x (minúscula) para diferenciar o fato de que a primeira está sendo considerada aleatória e a segunda, fixa; e

$$w_i = \frac{x_i - \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \sum_{i=1}^n w_i = 0.$$

Observe que estamos usando o fato de $\sum_{i=1}^n (x_i - \bar{x}) = 0$ e que

$$\begin{aligned} \sum_{i=1}^n w_i x_i &= \sum_{i=1}^n w_i x_i - \bar{x} \sum_{i=1}^n w_i = \sum_{i=1}^n w_i (x_i - \bar{x}) \\ &= \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} (x_i - \bar{x}) = 1. \end{aligned}$$

Usando propriedades da esperança e variância de somas de v.a. (veja o Capítulo 8), podemos escrever

$$\begin{aligned} E(\hat{\beta}) &= E\left(\sum_{i=1}^n w_i Y_i\right) = \sum_{i=1}^n w_i E(Y_i) \\ &= \sum_{i=1}^n w_i (\alpha + \beta x_i) = \alpha \sum_{i=1}^n w_i + \beta \sum_{i=1}^n w_i x_i = \beta, \end{aligned}$$

o que mostra que o estimador é não-viesado. Para a variância,

$$\text{Var}(\hat{\beta}) = \text{Var}\left(\sum_{i=1}^n w_i Y_i\right) = \sum_{i=1}^n w_i^2 \text{Var}(Y_i),$$

pois as observações são não-correlacionadas, e, portanto,

$$\text{Var}(\hat{\beta}) = \sum_{i=1}^n w_i^2 \sigma_e^2 = \sigma_e^2 \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^2 = \sigma_e^2 \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2},$$

e o resultado segue.

Proposição 16.2. Para o estimador $\hat{\alpha}$ temos:

$$E(\hat{\alpha}) = \alpha, \quad (16.38)$$

$$\text{Var}(\hat{\alpha}) = \sigma_e^2 \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}. \quad (16.39)$$

Prova. Precisaremos dos seguintes resultados (Problema 33):

$$\text{Cov}(\bar{y}, \hat{\beta}) = 0, \quad (16.40)$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2. \quad (16.41)$$

Como

$$\begin{aligned} \bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{n} \sum_{i=1}^n (\alpha + \beta x_i + e_i) \\ &= \alpha + \beta \bar{x} + \frac{1}{n} \sum_{i=1}^n e_i, \end{aligned}$$

temos que

$$E(\bar{y}) = \alpha + \beta \bar{x} + \frac{1}{n} \sum_{i=1}^n E(e_i) = \alpha + \beta \bar{x},$$

dado que x é supostamente fixa e não uma v.a. Também,

$$\text{Var}(\bar{y}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(e_i) = \frac{\sigma_e^2}{n}.$$

Temos, então, que

$$E(\hat{\alpha}) = E(\bar{y} - \hat{\beta} \bar{x}) = \alpha + \beta \bar{x} - \beta \bar{x} = \alpha,$$

e

$$\begin{aligned} \text{Var}(\hat{\alpha}) &= \text{Var}(\bar{y} - \hat{\beta} \bar{x}) = \text{Var}(\bar{y}) + \text{Var}(\hat{\beta} \bar{x}) - 2\text{Cov}(\bar{y}, \hat{\beta} \bar{x}) \\ &= \text{Var}(\bar{y}) + \bar{x}^2 \text{Var}(\hat{\beta}) - 2\bar{x} \text{Cov}(\bar{y}, \hat{\beta}) \end{aligned}$$

e usando os diversos resultados obtidos acima, obtemos (16.39).

16.4.2 Distribuições Amostrais dos Estimadores dos Parâmetros

Para completar o estudo das propriedades dos estimadores, vamos introduzir uma terceira suposição:

(iii) Os erros e_i são v.a. com distribuição normal, isto é,

$$e_i \sim N(0; \sigma_e^2), \quad (16.42)$$

o que implica

$$y_i \sim N(\alpha + \beta x_i; \sigma_e^2). \quad (16.43)$$

Como $\hat{\beta}$ e $\hat{\alpha}$ são combinações lineares de v.a. normais e independentes, temos o seguinte resultado:

Proposição 16.3. Os estimadores $\hat{\alpha}$ e $\hat{\beta}$ têm ambos distribuição normal, com médias e variâncias dadas pelas Proposições 16.1 e 16.2, isto é,

$$\hat{\alpha} \sim N\left(\alpha; \frac{\sigma_e^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}\right), \quad (16.44)$$

$$\hat{\beta} \sim N\left(\beta; \frac{\sigma_e^2}{\sum (x_i - \bar{x})^2}\right). \quad (16.45)$$

Os resultados acima permitem concluir que

$$\frac{\hat{\beta} - \beta}{\sigma_e} \sqrt{\sum (x_i - \bar{x})^2} \sim N(0, 1), \quad (16.46)$$

$$\frac{\hat{\alpha} - \alpha}{\sigma_e} \sqrt{\frac{n \sum (x_i - \bar{x})^2}{\sum x_i^2}} \sim N(0, 1). \quad (16.47)$$

16.4.3 Intervalos de Confiança para α e β

Substituindo σ_e por seu estimador S_e em (16.46) e (16.47), sabemos que as estatísticas resultantes terão distribuição t de Student, com $(n - 2)$ graus de liberdade, o que permitirá construir intervalos de confiança para os parâmetros.

Proposição 16.4. As estatísticas

$$t(\hat{\beta}) = \frac{\hat{\beta} - \beta}{S_e} \sqrt{\sum (x_i - \bar{x})^2} \quad (16.48)$$

e

$$t(\hat{\alpha}) = \frac{\hat{\alpha} - \alpha}{S_e} \sqrt{\frac{n \sum (x_i - \bar{x})^2}{\sum x_i^2}} \quad (16.49)$$

têm distribuição t de Student com $(n - 2)$ graus de liberdade.

Esse resultado, combinado com os procedimentos de construção de intervalos de confiança já estudados, nos leva aos seguintes intervalos para α e β , com γ denotando o coeficiente de confiança e $t_\gamma(n - 2)$ denotando o valor obtido da Tabela V, com $(n - 2)$ graus de liberdade:

$$IC(\alpha; \gamma) = \hat{\alpha} \pm t_\gamma(n - 2) S_e \sqrt{\frac{\sum x_i^2}{n \sum (x_i - \bar{x})^2}}, \quad (16.50)$$

$$IC(\beta; \gamma) = \hat{\beta} \pm t_\gamma(n - 2) S_e \sqrt{\frac{1}{\sum (x_i - \bar{x})^2}}. \quad (16.51)$$

Exemplo 16.4. Da tabela ANOVA do Exemplo 16.3 podemos retirar as informações necessárias para construir intervalos de confiança para α e β . Temos que $\sum x_i^2 = 19.000$, $\sum (x_i - \bar{x})^2 = 1.000$, e $\bar{x} = 30$.

Temos, também, $S_e^2 = 31,28$ e, portanto, $S_e = 5,59$. Se $\gamma = 0,95$, obtemos $t_{0,95}(18) = 2,101$. Os intervalos são dados por:

$$IC(\alpha; 0,95) = 80,50 \pm (2,101)(5,59) \sqrt{\frac{19.000}{(1.000)(20)}} = 80,50 \pm 11,45,$$

$$\begin{aligned} IC(\beta; 0,95) &= 0,90 \pm (2,101)(5,59) \sqrt{1/1.000} \\ &= 0,90 \pm 0,30. \end{aligned}$$

Ou seja,

$$IC(\alpha; 0,95) = [69,05; 91,95],$$

$$IC[\beta; 0,95] = [0,60; 1,20].$$

Este último resultado é mais uma evidência de que $\beta \neq 0$, o que reforça conclusões anteriores.

Os intervalos de confiança (16.50) e (16.51) podem ser utilizados para testar hipóteses do tipo

$$H_0: \alpha = \alpha_0,$$

$$H_0: \beta = \beta_0.$$

Em particular, temos o resultado:

Proposição 16.5. A estatística para testar $H_0: \alpha = 0$ é

$$t(\hat{\alpha}) = \frac{\hat{\alpha}}{S_e} \sqrt{\frac{n \sum (x_i - \bar{x})^2}{\sum x_i^2}}, \quad (16.52)$$

e a estatística para testar $H_0: \beta = 0$ é

$$t(\hat{\beta}) = \frac{\hat{\beta}}{S_e} \sqrt{\sum (x_i - \bar{x})^2}, \quad (16.53)$$

cada uma tendo distribuição t de Student com $(n - 2)$ graus de liberdade.

Observe que

$$[t(\hat{\beta})]^2 = \frac{\hat{\beta}^2 \sum (x_i - \bar{x})^2}{S_e^2},$$

e usando o resultado (16.33) podemos escrever

$$[t(\hat{\beta})]^2 = \frac{\text{SQReg}}{S_e^2}, \quad (16.54)$$

que é a estatística F que aparece na tabela ANOVA. Assim, para testar a hipótese $H_0: \beta = 0$, pode-se usar a estatística (16.54), que segue uma distribuição $F(1, n - 2)$.

Exemplo 16.5. Para testar separadamente as hipóteses acima, os valores das estatísticas correspondentes serão:

$$t(\hat{\alpha}) = (80,5/5,59) \sqrt{\frac{(20)(1.000)}{19.000}} = 14,77,$$

$$t(\hat{\beta}) = (0,90/5,59) \sqrt{1.000} = 5,09,$$

os quais devem ser comparados com 2,101, que é o valor crítico de $t(18)$, no nível de significância 5%. Vemos que em ambos os casos rejeitamos as hipóteses de que os parâmetros sejam iguais a zero. Comparando o resultado de $t(\hat{\beta})$ com o valor F da tabela ANOVA, constatamos que $t^2(\hat{\beta}) = 25,90 = F$, de acordo com o apresentado acima. Algumas vezes, para indicar a significância das estatísticas, a reta ajustada é escrita do seguinte modo:

$$\hat{y} = \begin{matrix} 80,50 \\ (14,77) \end{matrix} + \begin{matrix} 0,90x \\ (5,09) \end{matrix},$$

onde entre parênteses aparece o valor de t , para indicar com que intensidade o parâmetro pode ser considerado distinto de zero.

16.4.4 Intervalo de Confiança para $\mu(z)$ e Intervalo de Predição

O modelo linear (16.6), estudado até agora, será utilizado freqüentemente para fazer previsões da variável resposta (y) para algum nível da variável de controle (x). Usando o enunciado do Exemplo 16.1, poderíamos estar interessados em saber qual o tempo de reação aos 28 anos. É importante estabelecer se queremos estimar o tempo médio para o grupo etário de 28 anos ou o tempo de reação provável para uma pessoa de 28 anos. Veremos que a estimação pontual é a mesma nos dois casos, porém os intervalos de “confiança” serão distintos. Para entender bem as diferenças sugerimos recordar as soluções aos exercícios 23, 24 e 25 do Capítulo 15.

Do modelo (16.3) e do exposto até agora, temos o seguinte resultado.

Proposição 16.6. A distribuição amostral do estimador (16.15) é dada por

$$\widehat{\mu(x_i)} = \hat{y}_i = \hat{\alpha} + \hat{\beta}x_i \sim N(\alpha + \beta x_i, \text{Var}(\hat{y}_i)) \quad (16.55)$$

onde

$$\text{Var}(\widehat{\mu(x_i)}) = \text{Var}(\hat{y}_i) = \sigma_e^2 \left[\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right] \quad (16.56)$$

Prova. Das proposições 16.1 e 16.2 vem:

$$E(\widehat{\mu(x_i)}) = E(\hat{\alpha}) + E(\hat{\beta})x_i = \alpha + \beta x_i = \mu(x_i)$$

o que demonstra a primeira parte da proposição. De (16.17) temos

$$\hat{y}_i = \bar{y} + \hat{\beta}(x_i - \bar{x}),$$

portanto

$$\text{Var}(\hat{y}_i) = \text{Var}(\bar{y}) + (x_i - \bar{x})^2 \text{Var}(\hat{\beta}) + 2(x_i - \bar{x}) \text{Cov}(\bar{y}, \hat{\beta}),$$

mas de (16.40), $\text{Cov}(\bar{y}, \hat{\beta}) = 0$, e de (16.37) vem

$$\text{Var}(\hat{y}_i) = \frac{\sigma_e^2}{n} + (x_i - \bar{x})^2 \frac{\sigma_e^2}{\sum (x_i - \bar{x})^2} = \sigma_e^2 \left[\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right],$$

o que conclui a prova.

Com a proposição acima e substituindo σ_e^2 por seu estimador S_e^2 é fácil verificar que o Intervalo de Confiança para $\mu(x)$ será dado por:

$$\text{IC}(\mu(x); \gamma) = \hat{y}_i \pm t_\gamma(n-2) S_e \sqrt{\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum (x_i - \bar{x})^2}} \quad (16.57)$$

Vejamos agora como construir um intervalo de predição para uma futura observação. Imitando a proposta do Problema 15.24, uma futura observação para um dado nível x_f é dada por

$$Y_f(x) = \mu(x_f) + \varepsilon_f$$

e o estimador será

$$\hat{Y}_f = \hat{y}_f + \varepsilon_f = \hat{y}_f,$$

onde substituímos o valor desconhecido ε_f pelo seu valor esperado que é zero.

Da expressão anterior, calculamos:

$$\text{Var}(\hat{Y}_f) = \text{Var}(\hat{y}_f) + \text{Var}(\varepsilon_f) = \sigma_e^2 \left[\frac{1}{n} + \frac{(x_1 - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right] + \sigma_e^2,$$

ou seja,

$$\text{Var}(\hat{Y}_f) = \sigma_e^2 \left[1 + \frac{1}{n} + \frac{(x_1 - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right]. \quad (16.58)$$

Substituindo σ_e^2 pelo seu estimador S_e^2 , teremos um estimador da variância, e analogamente o intervalo de predição abaixo:

$$\text{IP}(Y_f; \gamma) = \hat{y}_f \pm t_\gamma S_e \sqrt{1 + \frac{1}{n} + \frac{(x_f - \bar{x})^2}{\sum (x_i - \bar{x})^2}} \quad (16.59)$$

Exemplo 16.6. Qual o tempo de reação aos 28 anos?

A estimativa pontual é dada por:

$$\hat{y}(28) = 80,5 + 0,9(28) = 105,7.$$

Considerando como resposta adequada o tempo de reação médio do grupo de 28 anos, podemos escrever o Intervalo de Confiança para a média, ou seja:

$$\begin{aligned} IC(\mu(28); 0,95) &= 105,7 \pm (2,101)(5,59) \sqrt{\frac{1}{20} + \frac{(28 - 30)^2}{1000}} = \\ &= 105,7 \pm 2,7 =]103,0; 108,4[. \end{aligned}$$

Se quiséssemos saber dentro de que intervalo 95% das futuras observações iriam estar, construiríamos o Intervalo de Predição:

$$\begin{aligned} IP(Y_p; 0,95) &= 105,7 \pm (2,101)(5,59) \sqrt{1 + \frac{1}{20} + \frac{(28 - 30)^2}{1000}} = \\ &= 105,7 \pm 12,1 =]93,6; 117,8[. \end{aligned}$$

Problemas

10. Usando a tabela ANOVA, construída no Problema 5:
 - (a) Construa o IC(β ; 95%).
 - (b) Construa o IC(α ; 90%).
 - (c) Use a estatística F para testar a hipótese $H_0: \beta = 0$.
 - (d) Construa o IC para a acuidade visual média do grupo etário de 28 anos.
 - (e) E qual seria o Intervalo de Predição da acuidade visual das pessoas de 28 anos?
11. Com as informações do Exemplo 15.1, e a ANOVA construída no Problema 9, você diria que a acuidade visual ajuda a prever o tempo de reação dos indivíduos? Que estatística você usou para justificar seu argumento e por quê?
12. Investigando a relação entre a quantidade de fertilizante usado (x) e a produção de soja (y) numa estação experimental com 20 canteiros, obteve-se a equação de MQ:

$$\hat{y} = 15,00 + 2,83x.$$

(3,22) (1,65)

Com esses resultados você diria que a quantidade de fertilizante influi na produção? Por quê?

16.5 Análise de Resíduos

Para verificar se um modelo é adequado, temos que investigar se as suposições feitas para o desenvolvimento do modelo estão satisfeitas. Para tanto, estudamos o comportamento do modelo usando o conjunto de dados observados, notadamente as discrepâncias entre os valores observados e os valores ajustados pelo modelo, ou seja, fazemos uma *análise dos resíduos*.

O i -ésimo resíduo é dado por

$$\hat{e}_i = y_i - \hat{y}_i, \quad i = 1, 2, \dots, n. \quad (16.60)$$

Lembremos que já utilizamos estes resíduos para obter medidas da qualidade e dos estimadores dos parâmetros do modelo. Agora iremos estudar o comportamento individual e conjunto destes resíduos, comparando com as suposições feitas sobre os verdadeiros erros e_i . Existem várias técnicas formais para conduzir essa análise, mas aqui iremos ressaltar basicamente métodos gráficos. Para mais detalhes, ver Draper e Smith (1998).

Uma representação gráfica bastante útil é obtida plotando-se pares $(x_i, \hat{e}_i)$, $i = 1, \dots, n$. Outras vezes, é de maior utilidade fazer a representação gráfica dos chamados resíduos padronizados,

$$\hat{z}_i = \frac{y_i - \hat{y}_i}{S_e} = \frac{\hat{e}_i}{S_e}, \tag{16.61}$$

plotando-se os pares $(x_i, \hat{z}_i)$. Observe que a forma dos dois gráficos será semelhante, havendo apenas uma mudança de escala das ordenadas nos dois casos. Por isso, iremos usar a primeira representação, indicando no gráfico a posição do valor S_e .

Outro resíduo usado é o chamado *resíduo estudentizado*, definido por

$$\hat{r}_i = \frac{\hat{e}_i}{S_e \sqrt{1 - v_{ii}}}, \tag{16.62}$$


onde $v_{ii} = 1/n + (x_i - \bar{x})^2 / \sum (x_i - \bar{x})^2$. O denominador de (16.62) é o desvio padrão de $\hat{e}_i$. Não iremos explorar aqui a análise feita com esse tipo de resíduo.

Exemplo 16.7. Voltemos ao Exemplo 15.1. Os resíduos do modelo (16.18) estão reproduzidos na Tabela 16.4, dos quais foram obtidos os demais. Os dois primeiros resíduos estão representados na Figura 16.6. Note que os dois gráficos são parecidos e levarão ao mesmo tipo de diagnóstico. Comentários adicionais sobre esse exemplo serão feitos abaixo.

Tabela 16.4: Resíduos para o modelo (16.18).


Idade	$\hat{e}_i$	$\hat{z}_i$	$\hat{r}_i$	Idade	$\hat{e}_i$	$\hat{z}_i$	$\hat{r}_i$
20	-2,5	-0,45	-0,49	30	1,5	0,27	0,28
20	-6,5	-1,16	-1,26	30	-7,5	-1,34	-1,37
20	7,5	1,34	1,45	35	0,0	0,0	0,0
20	1,5	0,27	0,29	35	-7,0	-1,25	-1,30
25	-5,0	-0,89	-0,92	35	6,0	1,07	1,11
25	1,0	0,18	0,19	35	-4,0	-0,72	-0,75
25	7,0	1,25	1,30	40	-4,5	-0,80	-0,86
25	-2,0	-0,36	0,37	40	-5,5	-0,98	-1,06
30	8,5	1,52	1,56	40	9,5	1,70	1,84
30	-1,5	-0,27	-0,28	40	-0,5	-0,09	-0,10

Figura 16.6: Resíduos para o Exemplo 16.1. (a) $\hat{e}_i = y_i - \hat{y}_i$; (b) resíduos padronizados.



Obtido o gráfico dos resíduos, precisamos saber como identificar possíveis inadequações. Apresentamos na Figura 16.7 alguns tipos usuais de gráficos de resíduos. A Figura 16.7 (a) é a situação ideal para os resíduos, distribuídos aleatoriamente em torno do zero, sem nenhuma observação muito discrepante.

Figura 16.7: Gráficos de resíduos. (a) situação ideal; (b), (c) modelo não-linear; (d) elemento atípico; (e), (f), (g) heterocedasticidade; (h) não-normalidade.



Nas situações (b) e (c) temos possíveis inadequações do modelo adotado, e as curvaturas sugerem que devemos procurar outras funções matemáticas que expliquem melhor o fenômeno.

A Figura 16.7 (d) mostra a existência de um elemento discrepante, e deve ser investigada a razão desse desvio tão marcante. Pode ser um erro de medida, ou a discrepância pode ser real. Em situações como essa, em que há observações muito diferentes das demais, métodos chamados robustos têm de ser utilizados.

Os casos (e), (f) e (g) indicam claramente que a suposição de homoscedasticidade (mesma variância) não está satisfeita. Em (h), parece haver maior incidência de observações nos extremos, mostrando que a suposição de normalidade não está satisfeita.

Analizados os resíduos e diagnosticada uma possível transgressão das suposições, devemos propor alterações que tornem o modelo mais adequado aos dados e às suposições feitas.

A verificação da hipótese de normalidade pode ser realizada fazendo-se um histograma dos resíduos ou um gráfico de $q \times q$, como explicado no Capítulo 3.

Exemplo 16.7. (continuação) A análise dos resíduos do modelo (16.18) mostra que esses não violam as suposições de média zero e variância comum. A Figura 16.8 mostra

o histograma dos resíduos, e a Figura 16.9 mostra um gráfico $q \times q$. Esse gráfico, feito com o SPlus, coloca nos eixos das ordenadas os valores crescentes dos $\hat{e}_i$ e no eixo das abscissas os quantis de uma normal padrão. Se os valores fossem de uma normal, eles deveriam se dispor ao longo de uma reta. Notamos que tanto o histograma quanto o gráfico de quantis mostram que os resíduos não são normalmente distribuídos.

Figura 16.8: Histograma dos resíduos do modelo (16.18).





Figura 16.9: Gráfico $q \times q$ (normalidade) para os resíduos do modelo (16.18).



Quando a suposição de variância comum não estiver satisfeita, usualmente faz-se uma transformação da variável resposta y , ou da preditora x , ou de ambas. Para detalhes, ver Bussab (1986) e a seção 16.6.

Exemplo 16.8. Num processo industrial, além de outras variáveis, foram medidas: X = temperatura média ($^{\circ}\text{F}$) e Y = quantidade de vapor. Os dados estão na Tabela 16.5 (Draper & Smith, 1998, Appendix A).

Tabela 16.5: Temperatura e quantidade de vapor de um processo industrial.

Nº	x_i	y_i	$\hat{e}_i$
1	35,3	10,98	0,174
2	29,7	11,13	-0,123
3	30,8	12,51	1,345
4	58,8	8,40	-0,531
5	61,4	9,27	0,547
6	71,3	8,73	0,797
7	74,4	6,36	-1,326
8	76,7	8,50	0,998
9	70,7	7,82	-0,161
10	57,5	9,14	0,106
11	46,4	8,24	-1,680
12	28,9	12,19	0,873
13	28,1	11,88	0,499
14	39,1	9,57	-0,933
15	46,8	10,94	1,052
16	48,5	9,58	-0,173
17	59,3	10,09	1,199
18	70,0	8,11	0,073
19	70,0	6,83	-1,207
20	74,5	8,88	1,202
21	72,1	7,68	-0,189
22	58,1	8,47	-0,517
23	44,6	8,86	-1,204
24	33,4	10,36	-0,598
25	28,6	11,08	-0,261

Fonte: Draper e Smith (1998).

O gráfico de dispersão e a reta de MQ estão na Figura 16.10 (a). A reta estimada de MQ é dada por


$$\hat{y}_i = 9,424 - 0,0798(x_i - 52,6), \quad (16.63)$$

ou ainda

$$\hat{y}_i = 13,623 - 0,0798x_i, \quad (16.64)$$

de modo que $\hat{\alpha} = 13,623$ e $\hat{\beta} = -0,0798$. Os resíduos $\hat{e}_i = y_i - \hat{y}_i$ estão na quarta coluna da Tabela 16.5 e seu gráfico contra x_i na Figura 16.10 (b). O gráfico $q \times q$ para verificar a suposição de normalidade está na Figura 16.10 (c). Observamos que há vários pontos afastados da reta.


Figura 16.10: (a) gráfico de dispersão com reta ajustada;
(b) resíduos vs temperatura;
(c) gráfico $q \times q$ (normalidade).



Problemas

13. Com o modelo linear já obtido para a acuidade visual como função da idade, construa os tipos de resíduos apresentados no Exemplo 16.6. Represente-os graficamente. Você observa alguma transgressão das suposições básicas?

14. Para cada gráfico de resíduo abaixo, indique qual a possível transgressão observada.



15. Abaixo estão os valores da variável preditora (x), os resíduos observados depois do ajuste do modelo e a ordem em que os dados foram obtidos.

Preditor	11	20	14	22	12	25	15
Resíduo	-1	-2	3	-3	-1	5	0
Ordem	9	6	13	1	7	14	8

Preditor	14	19	21	18	22	16	21
Resíduo	0	3	-2	2	-5	0	1
Ordem	3	12	4	11	2	10	5

- (a) Verifique se existe alguma possível transgressão das suposições, analisando o gráfico $(x_i, \hat{e}_i)$.
 (b) Faça o gráfico do resíduo contra a ordem do experimento. Você observa alguma inconveniência?

16.6 Alguns Modelos Especiais

Nesta seção introduziremos alguns modelos particulares simples e que são de interesse prático. Iniciamos com o modelo que teoricamente passa pela origem. Depois, consideramos modelos não-lineares, mas que podem ser linearizados por meio de alguma transformação.

16.6.1 Reta Passando pela Origem

Em algumas situações temos razões teóricas (ou ditadas pelas peculiaridades do problema a analisar) para supor que o modelo deva ser do tipo

$$y_i = \beta x_i + e_i, \quad i = 1, \dots, n. \quad (16.65)$$

Com as mesmas suposições anteriores e observada uma amostra (x_i, y_i) , $i = 1, \dots, n$, é fácil ver que o EMQ de β é

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}. \quad (16.66)$$

Deixamos a cargo do leitor verificar como ficam os resultados obtidos anteriormente para o modelo completo nesse caso particular. Por exemplo,

$$E(\hat{\beta}) = \beta, \\ \text{Var}(\hat{\beta}) = \frac{\sigma_e^2}{\sum_{i=1}^n x_i^2}.$$

Exemplo 16.9. A mensuração exata (Y) de uma substância do sangue, por meio de uma análise química, é muito cara. Um novo método mais barato resulta na medida X , que supostamente pode ser usada para prever o valor de Y . Nove amostras de sangue foram obtidas e avaliadas pelos dois métodos, obtendo-se as medidas abaixo.

X	119	155	174	190	196	233	272	253	276
Y	112	152	172	183	192	228	263	239	263

Algumas estatísticas obtidas são:

$$\begin{aligned} n &= 9, & \sum_i x_i &= 1.868, & \sum_i y_i &= 1.804, \\ \sum_i x_i y_i &= 396.933, & \sum_i x_i^2 &= 411.436, & \sum_i y_i^2 &= 383.028. \end{aligned}$$

Vamos ajustar o modelo (16.65) a esses dados. Obtemos

$$\hat{\beta} = 396.933/411.436 = 0,9648,$$

resultando no modelo ajustado

$$\hat{y}_i = 0,9648x_i, \quad i = 1, 2, \dots, 9.$$

É fácil ver que $S_e^2 = 5,9136$ e $S_e = 2,4318$. Para testar a hipótese $H_0: \beta = 0$, usamos a estatística

$$t(\hat{\beta}) = \frac{\hat{\beta} - \beta}{S_e} \sqrt{\sum x_i^2},$$


que resulta ser igual a $t(\hat{\beta}) = (0,9648/2,4318)\sqrt{411.436} = 254,48$, o que claramente leva à rejeição de H_0 . Um intervalo de confiança para β , com coeficiente de confiança 95% é

$$0,9648 \pm (2,306) \frac{2,4318}{\sqrt{411.436}} = 0,9648 \pm 0,0087,$$

ou seja,

$$\text{IC}(\beta; 0,95) = [0,9561; 0,9735].$$

Os dados e a reta ajustada estão na Figura 16.11.

Figura 16.11: Dados e reta ajustada para o Exemplo 16.8.

16.6.2 Modelos Não-Lineares

Quando usamos modelos de regressão, ou qualquer outro tipo de modelo, a situação ideal é aquela em que o pesquisador, por razões teóricas inerentes ao problema real sob estudo, pode sugerir a forma funcional da relação entre duas ou mais variáveis. Na prática, isso nem sempre acontece. Muitas vezes o pesquisador está interessado em usar técnicas de regressão para explorar modelos convenientes sugeridos pelos dados observados.

Como vimos, o primeiro passo para investigar o tipo de modelo a ser adotado é a representação gráfica dos dados, a qual pode sugerir a forma da curva relacionando as variáveis, além de fornecer outras informações (veja o final da seção 16.1). Por exemplo, com os dados da Tabela 16.6 obtemos o diagrama de dispersão da Figura 16.12. Notamos claramente a inadequação da reta como modelo, sendo que provavelmente uma relação exponencial do tipo

$$f(x) = \alpha e^{\beta x} \quad (16.67)$$


seja mais adequada. Um modelo que pode, então, ser sugerido, é

$$y_i = \alpha e^{\beta x_i} + \varepsilon_i, \quad i = 1, \dots, n. \quad (16.68)$$

Tabela 16.6: Taxa de Inflação no Brasil de 1961 a 1979.

Ano	t	Inflação (Y)	$Y^* = \log Y$
1961	-9	9	2,2
1963	-7	24	3,2
1965	-5	72	4,3
1967	-3	128	4,8
1969	-1	192	5,2
1971	1	277	5,6
1973	3	373	5,9
1975	5	613	6,4
1977	7	1.236	7,1
1979	9	2.639	7,9

Figura 16.12: Dados de inflação no Brasil (pontos) e modelo exponencial ajustado (+).



Suponha que queiramos estimar os parâmetros α e β pelo método de mínimos quadrados. Devemos minimizar

$$S(\alpha, \beta) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \alpha e^{\beta x_i})^2. \quad (16.69)$$

Derivando S em relação a α e β e igualando a zero, obtemos as duas equações

$$\begin{aligned} \hat{\alpha} \sum_{i=1}^n e^{2\hat{\beta} x_i} &= \sum_{i=1}^n y_i e^{\hat{\beta} x_i}, \\ \hat{\alpha}^2 \sum_{i=1}^n x_i e^{2\hat{\beta} x_i} &= \hat{\alpha} \sum_{i=1}^n x_i y_i e^{\hat{\beta} x_i}. \end{aligned} \quad (16.70)$$

A solução desse sistema de equações não-lineares exige o uso de procedimentos de otimização não-lineares, como Newton-Raphson, Gauss-Newton, “scoring” e outros. Ou seja, os pontos de máximo da função S são obtidos numericamente, dada a impossibilidade de termos soluções analíticas para as equações (16.70). Mas devemos dizer que essa é a regra, mais do que a exceção, em problemas encontrados na prática. Portanto, a utilização desses procedimentos de otimização é um requisito importante para estudantes de áreas como estatística, economia, engenharia etc.

Neste livro, vamos nos limitar a tratar de alguns casos onde transformações das variáveis sob estudo permitirão o uso de um modelo linear simples.

Suponha que a função (16.67) seja apropriada para os dados da Tabela 16.6. Considere o modelo

$$y_i = \alpha e^{\beta x_i} \varepsilon_i, \quad i = 1, \dots, n. \quad (16.71)$$

Observe que nesse modelo os erros ε_i entram de forma *multiplicativa* e não aditiva, como no caso do modelo (16.6). Considerando, agora, o logaritmo (na base e) de ambos os lados de (16.71) e chamando

$$y_i^* = \log y_i, \quad \alpha^* = \log \alpha, \quad \varepsilon_i^* = \log \varepsilon_i, \quad (16.72)$$

podemos escrever o modelo na forma

$$y_i^* = \alpha^* + \beta x_i + \varepsilon_i^*, \quad i = 1, \dots, n. \quad (16.73)$$

Note que esse modelo é *linear* em α^* e β , e temos que supor que os erros ε_i sejam *positivos*; do contrário, não podemos tomar logaritmos deles. Por outro lado, os erros

ε_i^* podem ser negativos, positivos ou nulos. Portanto, para o modelo linear (16.73) podemos fazer as suposições usuais das seções anteriores.

Exemplo 16.10. Utilizando os dados da Tabela 16.6, devemos, inicialmente, calcular os logaritmos naturais da variável Y . Note que nesse exemplo a variável explicativa é o tempo, convenientemente codificado. Na Figura 16.13 temos o diagrama de dispersão dos dados transformados e da reta ajustada, a saber

$$\hat{y}_i^* = 5,27 + 0,28t, \quad t = -9, \dots, 9. \quad (16.74)$$

A análise de tal modelo pode ser conduzida como antes. Veja o Problema 35.

Observe que o modelo original ajustado é

$$\hat{y}_i = 194,42 \cdot e^{0,28t}, \quad i = 1, \dots, 10, \quad (16.75)$$

pois $\alpha = e^{5,27}$. Essa curva está representada na Figura 16.12. Os resíduos do modelo (16.74), transformado, e do modelo (16.75), original, são dados na Tabela 16.7 e nas Figuras 16.14 e 16.15, respectivamente. Note que em ambos os casos os resíduos não parecem ser aleatórios, havendo curvaturas, sugerindo a possibilidade de um modelo com termos quadráticos ou cúbicos, por exemplo.

Figura 16.13: Diagrama de dispersão para o logaritmo da inflação com reta ajustada.




Tabela 16.7: Resíduos para os modelos linear e exponencial.

t	Resíduos Reta	Resíduos Exponencial
-9	-0,55	-6,643
-7	-0,11	-3,386
-5	0,43	24,057
-3	0,37	44,067
-1	0,21	45,061
1	0,05	19,757
3	-0,21	-77,348
5	-0,27	-175,412
7	-0,13	-145,251
9	0,11	222,632

Figura 16.14: Resíduos da reta ajustada ao logaritmo da inflação versus ano.





Figura 16.15: Resíduos do modelo exponencial ajustado aos dados originais versus ano.



Os histogramas e gráficos $q \times q$ para normalidade dos resíduos estão nas Figuras 16.16 e 16.17. Notamos que o histograma é assimétrico, mostrando claramente o valor correspondente a $t = 9$. Como há poucos pontos, a análise de resíduos fica prejudicada; o gráfico $q \times q$ mostra os pontos não muito próximos de retas.

Figura 16.16: Histogramas: (a) resíduos reta ajustada ao log (inflação); (b) resíduos modelo exponencial.





Figura 16.17: Gráficos $q \times q$ dos resíduos: (a) reta; (b) exponencial.

16.7 Regressão Resistente

Nesta seção vamos considerar apenas o caso de regressão linear simples. Ou seja, temos os valores observados (x_i, y_i) , $i = 1, \dots, n$ e queremos ajustar o modelo (16.6).


Notamos que os estimadores $\hat{\alpha}$ e $\hat{\beta}$ em (16.14) são baseados em $\bar{x}$, $\bar{y}$ e desvios em relação a essas médias.

A regressão resistente baseia-se em medianas, em vez de médias. Inicialmente, dividimos o conjunto dos n pontos em três grupos, de tamanhos aproximadamente iguais, baseados principalmente na ordenação da variável x e no gráfico de dispersão. Chamemos esses grupos de E (de esquerda), C (de centro) e D (de direita). Se $n = 3k$, cada grupo terá k pontos. Se $n = 3k + 1$, colocamos k pontos nos grupos E e D e $k + 1$ pontos no grupo C. Finalmente, se $n = 3k + 2$, colocamos $k + 1$ pontos nos grupos E e D e k pontos no grupo C.

Para cada grupo obtemos um *ponto resumo*, formado pela mediana dos x_i e a mediana dos y_i naquele grupo. Denominemos esses pontos por

$$(x_E, y_E), (x_C, y_C), (x_D, y_D).$$

Na Figura 16.18 temos um exemplo com três grupos com $k = 3$ em cada grupo.

Figura 16.18: Reta resistente com três grupos.

Os estimadores de β e α são dados, respectivamente, por

$$b_0 = \frac{y_D - y_E}{x_D - x_E}, \tag{16.76}$$

$$a_0 = \frac{1}{3} [(y_E - b_0 x_E) + (y_C - b_0 x_C) + (y_D - b_0 x_D)]. \tag{16.77}$$

A reta resistente ajustada é

$$\tilde{y}_i = a_0 + b_0 x_i, \quad i = 1, \dots, n. \tag{16.78}$$

Os modelos robustos necessitam, muitas vezes, recorrer a processos iterativos para obter estimadores mais eficientes. Isso deve ser feito quando os resíduos não forem bem comportados. Não abordaremos esse tópico neste livro. Veja Hoaglin et al. (1983) para mais informação.

Exemplo 16.11. Voltemos aos dados do exemplo 16.1. Como $n = 20 = 3 \times 6 + 2$, os grupos E, C e D serão formados com 7, 6 e 7 pontos, respectivamente. Observando a Figura 16.1, consideramos os grupos como segue:

Grupo E							
i	2	1	4	3	5	8	6
Idade	20	20	20	20	25	25	25
Y	92	96	100	106	98	101	104

Grupo C						
i	7	12	10	11	9	14
Idade	25	30	30	30	30	35
Y	110	100	106	109	116	105

Grupo D							
i	16	13	15	18	17	20	19
Idade	35	35	35	40	40	40	40
Y	108	112	118	112	113	117	127

Os pontos resumidores são:

$$\begin{aligned} (x_E, y_E) &= (20, 100), \\ (x_C, y_C) &= (30, 107, 5), \\ (x_D, y_D) &= (40, 112), \end{aligned}$$

logo, as estimativas dos coeficientes serão

$$b_0 = \frac{112 - 100}{20} = 0,6,$$


$$a_0 = \frac{1}{3} [(100 - 0,6(20)) + (107,5 - 0,6(30)) + (112 - 0,6(40))] = 88,3$$

de modo que a reta resistente ajustada será

$$\tilde{y}_i = 88,3 + 0,6x_i,$$

que está representada na Figura 16.19, justamente com a reta de MQ, dada em (16.18).

Figura 16.19: Reta de MQ (—) e reta resistente (---) para o Exemplo 16.11.



Na próxima seção daremos um exemplo em que as duas retas, a de MQ e a resistente, são bastante diferentes.

16.8 Exemplos Computacionais

Nesta seção vamos considerar dois exemplos: um sobre a aplicação a dados reais do mercado de ações e outro aplicando regressão resistente a um conjunto de dados com um *outlier*.

Exemplo 16.12. Retomemos o Exemplo 4.13, no qual consideramos as variáveis Y = preço de ação da Telebrás e X = índice da Bolsa de Valores de São Paulo, cada uma com $n = 39$ observações. O gráfico de dispersão das duas variáveis está na Figura 16.20, juntamente com a reta de mínimos quadrados. O modelo ajustado é


$$\hat{y}_i = -5,57 + 0,93x_i,$$

e no Quadro 16.1 temos a saída do programa Minitab. Nesta, encontramos:

- Estimativas dos coeficientes α e β , juntamente com as estimativas dos desvios padrões respectivos (1,085 e 0,0297).
- Valores da estatística t , para testar as hipóteses nulas de que os coeficientes são nulos (denotadas por T), juntamente com o valor- p ($P = 0,000$), mostrando que devemos rejeitar essas hipóteses nulas.

- (c) Uma tabela de análise de variância, com o valor $F = 969,44$, com 1 e 37 g.l., e o valor- p $P = 0,000$.
- (d) O valor de $R^2 = 96,3\%$, que nos diz que o modelo ajustado explica a maior parte da variabilidade dos dados.

Figura 16.20: Gráfico de dispersão das variáveis X e Y, para o Exemplo 16.12 e reta ajustada.



Quadro 16.1: Análise do Exemplo 16.12. Minitab.

Regression Analysis					
The regression equation is					
Tel = − 5.57 + 0.925 Ibv					
Predictor	Coef	StDev	T	P	
Constant	−5.570	1.085	−5.13	0.000	
Ibv	0.92491	0.02971	31.14	0.000	
S = 0.7614	R − Sq = 96.3%		R − Sq (adj) = 96.2%		
Analysis of Variance					
Source	DF	SS	MS	F	P
Regression	1	561.99	561.99	969.44	0.000
Residual Error	37	21.45	0.58		
Total	38	583.44			

Na Figura 16.21 temos gráficos que nos auxiliam a fazer um diagnóstico do modelo ajustado. Na Figura 16.21(a) temos o gráfico $q \times q$ dos quantis dos resíduos contra os quantis da normal padrão, para avaliar a normalidade dos resíduos. Na Figura 16.21(b) temos o gráfico dos resíduos contra a ordem das observações e, na Figura 16.21(d), o gráfico dos resíduos contra os valores ajustados. Finalmente, na Figura 16.21(c) temos o histograma dos resíduos. O que você pode dizer desses gráficos?